

Base de données intelligente et BigData

Contenu

Intitulé de l'UE : Représentation de connaissance de masse

Intitulé de la matière : Base de données intelligente et Bigdata

Crédits : 4

Coefficients : 2

Contenu

Contenu de la matière.

- 1, Business intelligence ou entrepôts de données
- 2- Principe d'un Entrepôt de Données (Datawarehousing)
 - Conception d'un Entrepôt de Données
 - Alimentation d'un entrepôt de données
- 3- Fouille intelligente de données
- 4- Fouille sémantique de données (Ontologie,..)
- 5- Applications Internet
- 6- Bigdata
 - 6.1 Histoire
 - 6.2 Dimensions
 - 6.3-Représentation
 - 6.4-Applications
 - 6.5-Perspectives et évolutions

Introduction


au-delà du concept relationnel

- Base de données : un entrepôt de données
- Ce n'est pas seulement des tables et des relations.
- Peut contenir des documents, images, vidéo...

Introduction

au-delà du concept relationnel

- Base de Données



Les BD sont partout

- Recherches Google
- Réseaux sociaux : Twitter, Facebook
- Musique / vidéo : Spotify,, YouTube, IMDb
- photo : Flickr, Picasa
- commerce : Amazon, eBay
- voyage : Expedia, TripAdvisor, AirBnB
- encyclopédies : Wikipedia, Dbpedia
- bases de données médicales et scientifiques
- exploration de données (data mining)

Les BD sont partout



BD peut être

BD relationnelle

Documents XML

Documents Multimédia : images, video,...

Documents textuel plat : DOC, PDF, ...

Page web HTML (comme wikipédia)

BD intelligente ?

- C'est quoi l'intelligence ?
- **Intelligence** est l'ensemble des processus de pensée d'un être vivant qui lui permettent de s'adapter à des situations nouvelles, d'apprendre ou de comprendre

BD intelligente ?

- Une base de données intelligente est une base de données qui utilise les techniques de l'intelligence artificielle (AI).
- C'est quoi l'intelligence artificielle (AI) ?

BD intelligente

- BDI utilise des techniques intelligentes pour améliorer les interactions avec les utilisateurs



The screenshot shows a web browser window with the URL <https://www.ouedkniss.com/annonces/?c=telephones&keywords=ritina>. The page features a search bar with the text 'Recherche dans téléphones'. Below the search bar, there are several filter options: 'Téléphones' (selected), 'Filtrer par catégorie', 'ritina' (in the search bar), 'Wilaya', 'Marque', 'Copie', 'OS', 'Mémoire', 'Etat', 'Prix', 'Echange', 'Livraison', 'Photos', and a yellow 'Filtrer' button. At the bottom of the filter section, there are four tabs: 'Particuliers' (selected), 'Stores', 'Connectés', and 'BestOf'.

Ritina téléphones Algerie

Aucun résultat de recherche trouvé sur ouedkniss.com

Vérifiez l'orthographe des mots de recherche utilisés ???

N'utilisez pas des mots qui contiennent moins de trois lettres

Spécifiez un moins grand nombre de mots

BD intelligente

- Retourner les meilleurs réponses dans un temps réduit

- A screenshot of a Google search interface. The address bar shows a URL with 'google.dz' highlighted by a red box. The search bar contains the text 'Big data' with a blue search button to its right. Below the search bar, navigation tabs include 'Tous', 'Images', 'Vidéos', 'Actualités', 'Livres', 'Plus', and 'Outils de recherche'. A red box highlights the text 'Environ 298 000 000 résultats (0,59 secondes)'. Below this, a text box defines 'Le big data' as 'littéralement « grosses données », ou mégadonnées (recommandé), parfois appelées données massives, désignent des ensembles de données qui deviennent tellement volumineux qu'ils en deviennent'. To the right of the text is a small image of a data visualization heatmap.

BD intelligente

- Trouver l'information la plus pertinente pour une requête

ipad ritina

Tous Images Vidéos Actualités Maps Plus ▾ Outils de recherche

Environ 19 800 000 résultats (0,47 secondes)

Résultats pour **ipad retina**
Essayez avec l'orthographe **ipad ritina**

iPad avec écran Retina Wi-Fi + Cellular 32 Go reconditionné - Blanc ...
[www.apple.com/.../ipad-avec-ecran-retina-wi-fi-%2B-cellular-32 go-reconditionné-bl...](http://www.apple.com/.../ipad-avec-ecran-retina-wi-fi-%2B-cellular-32-go-reconditionné-bl...)
Initialement commercialisé en octobre 2012 Wi-Fi (802.11a/b/g/n) Technologie Bluetooth 4.0 Écran **Retina** de 9,7 pouces Appareil photo iSight 5 mégapixels ...

iPad - Comparer les modèles - Apple (FR)
www.apple.com/fr/ipad/compare/ ▾
Écran **Retina** 12,9 pouces (diagonale). 9,7 pouces (diagonale). 9,7 pouces (diagonale). 7,9 pouces (diagonale). 7,9 pouces (diagonale). Écran Multi-Touch ...

iPad avec écran Retina - Achat Informatique | fnac
www.fnac.com/iPad-avec-ecran-Retina/iPad/nsh352291/w-4 ▾
Plus de 21 références: **iPad avec écran Retina** avec la livraison en 1 jour avec Fnac+. Retrouvez aussi tous nos produits de notre univers iPad.

BD intelligente

- Analyser le contenu pour extraire des connaissances

Publication suggérée

Mobilealgerie.com
Sponsorisé ·

J'aime la Page

Condor Electronics présente le premier téléviseur 8K



: Condor Electronics présente le premier téléviseur 8K
Le leader Algérien des produits électroniques, électroménagers et Multimédias...

MOBILEALGERIE.COM

En savoir plus


Définition

- Le terme base de données intelligente a été introduit en 1989 par le livre « Intelligent Databases »
- Les auteurs définissent trois niveaux d'intelligence:
 - Système de stockage
 - Outils de haut niveau
 - interface utilisateur

Définition

1. Système de stockage:

- La partie qui permet d'enregistrer, trier, supprimer, lire et mettre à jour les données dans une base de donnée




Définition

2. Outils de haut niveau

- Utiliser des techniques d'intelligence artificielle, pour découvrir automatiquement des **patterns** (parties significatives)
- A l'aide d'un processus appelé **data mining**

Définition

- data mining et patterns



Définition

3. interface utilisateur

- Pour exprimer le besoin de l'utilisateur (requête)
- Présenter les résultat en utilisant l'hypermédia (texte, image, lien...)

Roger Federer

Joueur de tennis



Roger Federer est un joueur de tennis suisse né le 8 août 1981 à Bâle. Joueur professionnel depuis 1998, il détient le record de 302 semaines passées à la première place du classement mondial de tennis ATP World Tour, ainsi que le record de 17 ... [Wikipédia](#)

Naissance : 8 août 1981 (35 ans), Bâle, Suisse

Tournois du Grand Chelem remportés (simple) : 17

Taille : 6 pi 1 po

Épouse : Miroslava Vavrinec (m. 2009)

Enfants : Lennart Federer, Myla Rose Federer, Charlene Riva Federer, Leo Federer

Distinctions et récompenses : ESPY Award du meilleur joueur de tennis, plus...

Recherches associées

[Voir d'autres éléments \(plus de 15\)](#)



Rafael Nadal



Novak Djokovic



Andy Murray




Miroslava Vavrinec
Épouse



Stanislas Wawrinka

Architecture



Caractéristiques d'une BDI

1. Feedback (réaction)

- Ce que l'utilisateur recherche et ce qu'il ne veut pas.

Exploration de données — Wikipédia

https://fr.wikipedia.org/wiki/Exploration_de_données ▼

L'exploration de données, connue aussi sous l'expression de fouille de données, forage de données, prospection de données, **data mining**, ou encore ...

[Histoire](#) - [Applications industrielles](#) - [Recherche et groupes de réflexion](#)

Data mining - Wikipedia

https://en.wikipedia.org/wiki/Data_mining ▼ [Traduire cette page](#)

Data mining is the computational process of discovering patterns in large data sets involving methods at the intersection of artificial intelligence, machine ...

Qu'est-ce que le data Mining ? Exploration des données - Piloter.org

www.piloter.org/business-intelligence/datamining.htm ▼

Qu'est-ce que Le **Data mining**, définition, et comment l'utiliser pour explorer et exploiter les données du Data Warehouse, Quel en est le principe, les outils du ...

DATA MINING - DATA SCIENCE - BIG DATA ANALYTICS

chirouble.univ-lyon2.fr/~ricco/data-mining/ ▼

Le **DATA MINING**, ("Knowledge Discovery in Databases"- KDD serait plus approprié en réalité), est un domaine reconnu. A la lecture des différents documents ...

What is data mining? - Definition from WhatIs.com - SearchSQLServer

searchsqlserver.techtarget.com › ... › [Software applications](#) ▼ [Traduire cette page](#)

Data mining is the analysis of data for relationships that have not previously been discovered. For example, the sales records for a particular brand of tennis

Caractéristiques d'une BDI

2. Interface

- Montrer des recherches précédentes.

Recherches associées à data mining

[data mining cours](#)

[data mining big data](#)

[data mining pdf](#)

[data mining et statistique décisionnelle](#)

[logiciel data mining](#)

[datamining smite](#)


[data mining marketing](#)

[data mining def](#)

Caractéristiques d'une BDI

3. Assistance

Guider l'utilisateur pour formuler ces requêtes



Caractéristiques d'une BDI

4. Correction automatique

- Proposer une correction
- Trouver des termes proches


A screenshot of a Google search interface. The search bar contains the text "data infrmatique". Below the search bar, there are tabs for "Tous", "Images", "Actualités", "Vidéos", and "Plus". The "Tous" tab is selected. Below the tabs, it says "Environ 11 800 000 résultats (0,37 secondes)". The search results are for "data *informatique*". Below this, it says "Essayez avec l'orthographe data informatique". The first result is "Donnée (informatique) — Wikipédia" with the URL "https://fr.wikipedia.org/wiki/Donnée_(informatique)". Below the URL, it says "Cet article ne cite pas suffisamment ses sources (juin 2012). Si vous disposez de technologies de l'information, une donnée (**data** en anglais) est la représentation d'un programme : soit dans le ...". The second result is "Big data — Wikipédia" with the URL "https://fr.wikipedia.org/wiki/Big_data". Below the URL, it says "Aller à Différence avec l'**informatique** décisionnelle - ... de différence avec l'inf Data : utilisation de statistique inférentielle, ...".

Caractéristiques d'une BDI

5. Affichage des résultats d'une recherche

Lien direct vers le résultat

Mots de requêtes coloré



The screenshot shows a search engine interface with a search bar containing the text 'text mining search'. Below the search bar are navigation tabs: 'Tous' (selected), 'Actualités', 'Vidéos', 'Images', 'Plus', and 'Paramètres'. The search results indicate 'Environ 7 820 000 résultats (0,38 secondes)'. The first result is 'Deep Rich Text Analytics - Insights from Big Data - theysay.io', with a green 'Annonce' label and a link to 'www.theysay.io/'. The second result is 'Articles universitaires correspondant aux termes text mining search', listing three academic articles with their authors and citation counts. The third result is '[PDF] Introduction to Text Mining and Web Search' from 'people.cs.aau.dk/~simas/dat5_08/.../textminingandsearch1.pdf', with a green 'Traduire cette page' label. The bottom of the page shows 'Results 1 - 10' and a footer note about borrowed content from Prof. Marti Hearst.

text mining search

Tous Actualités Vidéos Images Plus Paramètres

Environ 7 820 000 résultats (0,38 secondes)

Deep Rich Text Analytics - Insights from Big Data - theysay.io
Annonce www.theysay.io/ ▼
Trial TheySay's Leading Technology and Extract Value from all Textual Data
[Online Demo](#) - [Contact Us](#)


Articles universitaires correspondant aux termes text mining search
Survey of text mining - [Berry](#) - Cité 660 fois
Text mining: The state of the art and the challenges - [Tan](#) - Cité 575 fois
The text mining handbook: advanced approaches in ... - [Feldman](#) - Cité 1640 fois

[PDF] Introduction to Text Mining and Web Search
people.cs.aau.dk/~simas/dat5_08/.../textminingandsearch1.pdf ▼ Traduire cette page
Results 1 - 10 - Introduction to Text Mining and Web. Search. Gao Cong gaocong@cs.aau.dk. Sc
are borrowed from Prof. Marti Hearst, Christopher.

Caractéristiques d'une BDI

6. Termes similaires

Autres termes de recherche à partir d'un dictionnaire.



The screenshot shows a Google search interface. The search bar contains the text "calculate words", with "calculate" highlighted by a red box. Below the search bar, the navigation tabs "Tous", "Images", "Vidéos", "Actualités", "Plus", and "Paramètres" are visible. The search results indicate "Environ 143 000 000 résultats (0,46 secondes)".

The first search result is titled "Word Counter: The Word Count Calculator" with the URL <https://wordcounter.net/>. The description states: "Wordcounter is a word **count** and a character **count** tool. Simply place your cursor into the box at typing. Word counter will automatically **count** the ...". The word "count" is highlighted by a red box.

Below this result are two more links: "Website Page Word Counter" and "Word Counter Blog".

The second search result is titled "Word Counter Tool - Get The Word Count Of A Given Text" with the URL <https://wordcounttools.com/>. The description states: "Word counter tool provides an extensive report about the word **count**, character **count**, keyword readability and many other statistics." The word "count" is highlighted by a red box.

The third search result is titled "Accurate Word counter, word count, character counter, character c" with the URL www.wordcountertool.com/. The description states: "The free word counter tool lets you easily **count words**, characters and typing speed, find your wo".

Caractéristiques d'une BDI

7. Exploitation du profil

- Utilisateur : (femme ou homme)



- Adresse IP



Interface intelligente d'une BD

Interface utilisateur intelligente

- Objectif

Transformer la demande de l'utilisateur
formuler en langue naturelle vers une requête
comprise par la BD

Ex dans le BD relationnel :

« Trouver un magasin de pièces Samsung à
Biskra » → SQL

Interface utilisateur intelligente

Trouver un magasin de pièces Sumsung à Biskra

Correction

Trouver un magasin de pièces **Samsung** à Biskra

Analyse
Lexicale

Trouver magasin pièce **Samsung** Biskra

(Marquage)
Tagging

Trouver (verbe) magasin pièce **Samsung** Biskra (place)

Génération du
SQL

Interface utilisateur intelligente

- Correction des erreurs

Rechercher


Biksra

Voulez vous dire : Biskra ?



Interface utilisateur intelligente

- Correction des erreurs (Spell Check)



Interface utilisateur intelligente

- Correction des erreurs

- ➔ **Distance de Levenshtein**

donne par un calcul assez simple des indications sur le degré de ressemblance entre les chaînes

Distance(Biskra, Biskra)= 0 identique

Distance(Biksra, Batna)=4 loin

Distance(Biksra, Biskra)= 2 plus proche

Interface utilisateur intelligente

Distance de Levenshtein

		B	I	S	K	R	A
	0	1	2	3	4	5	6
B	1	0	1	2	3	4	5
I	2	1	0	1	2	3	4
S	3	2	1	0	1	2	3
K	4	3	2	1	0	1	2
R	5	4	3	2	1	0	1
A	6	5	4	3	2	1	0

		B	I	S	K	R	A
	0	1	2	3	4	5	6
B	1	0	1	2	3	4	5
I	2	1	0	1	2	3	4
K	3	2	1	1	1	2	3
S	4	3	2	1	2	2	3
R	5	4	3	2	2	2	3
A	6	5	4	3	3	3	2

Interface utilisateur intelligente

Distance de Levenshtein

Le minimum entre :

- le nombre à sa gauche +1
- le nombre au-dessus de lui +1
- le nombre en haut à gauche (en diagonale) +
 - 0 si les lettres à gauche et en haut sont identiques
 - 1 si ces lettres sont différentes

B	I	S	K	R	A
---	---	---	---	---	---

	0	1	2	3	4	5	6
B	1						
I	2						
S	3						
K	4						
R	5						
A	6						?

$$0 = \text{Min}((1+1), (1+1), (0+0(B=B)))$$

Interface utilisateur intelligente

Optimisation de la requête

- `SELECT * FROM Personne WHERE Prénom = 'Ali';`
- Big Table ? > 1 000 000 Enregistrements !??
- Recherche séquentielle → full table scan

Interface utilisateur intelligente

Optimisation de la requête

- La table contient 1 000 000 Enregistrements
- Taille 1 enregistrement = 1200 octets
- Taille de bloc de disque dur est 4 KO
- ➔ 3 enregistrement par bloc
- ➔ 333 334 blocs (>1,4 G)
- Temps de Recherche !!!!! (parcourir >300000 blocs) ➔ 5ms /bloc =60 s

Interface utilisateur intelligente

Optimisation de la requête

- Optimiser une requête

Si une requête a un temps de calcul trop long, on peut voir si il ne serait pas utile **d'ajouter un index** sur un des champs de la requête

Interface utilisateur intelligente

Optimisation de la requête

- Solution : Création d'index
- Un index est une structure de données utilisée par le SGBD pour lui permettre de retrouver rapidement les données

Interface utilisateur intelligente

Optimisation de la requête

- Index dans les livres
- Un index est construit sur une clé
 - ballon, page 56
 - ballon, page 80
 - ballon, page 95
 - bille, page 57, page 77, page 83
 - bulle, page 65, page 66, page 88,
 - câble, page 72

Interface utilisateur intelligente

Optimisation de la requête

- Un index est construit sur une clé
- Avantages

utiliser l'index pour des recherches :

1. par valeur de clé : ballon , bille
2. par *intervalle* des valeurs de clé : entre bille et câble
3. par *préfixe* de la valeur de la clé: les clés commençant par b

Interface utilisateur intelligente

Optimisation de la requête

- **Index Dans les BD**
- Un index est une table à deux champs.
- Le premier est le champ sur lequel porte l'index (clé).
- Le second est le numéro d'enregistrement correspondant dans la table(adresse).
- La table d'index est triée sur les valeurs du premier champ

Interface utilisateur intelligente

Optimisation de la requête

- Exemple
- Soit une table CLIENTS(numclient, nom, prénom, ...). Un index sur le champ CLIENTS.nom est une table :
-

.....	
Ahmed	55 330
Ahmed	133 487
Ali	194 451
.....	

Interface utilisateur intelligente


Optimisation de la requête

- Quelques définitions sur l'index
 1. Une **clé** (d'indexation)
 2. Une **adresse** est un emplacement physique dans la base de données
 3. une **entrée** (d'index) est un enregistrement constitué d'une paire de valeurs

Interface utilisateur intelligente

Optimisation de la requête

- Utilisation de arbre-B



Interface utilisateur intelligente

Optimisation de la requête

- **Intérêts des index**
 - Un index sur un champ permet un accès rapide sur les valeurs de ce champ
 - le temps moyen d'accès à un élément est de N sans index
 - Recherche par dichotomie avec $(\log_2 N)$ avec un index $\rightarrow \log_2 (1000000)=20$
 - 20 enregistrement $\rightarrow 7$ bloc
 - $\rightarrow 5\text{ms} * 7 = 35 \text{ ms}$

Interface utilisateur intelligente

Optimisation de la requête

- **Syntaxe**

```
CREATE INDEX 'index_nom' ON 'table';
```

```
CREATE INDEX `index_nom` ON `table` (`colonne1`);
```

- On peut créer un index sur un ou plusieurs attributs

Interface utilisateur intelligente

Optimisation de la requête

- Définir un index → sur quels champs ?
1. La table doit avoir un grand nombre de lignes
 2. L'attribut doit avoir beaucoup de valeurs différentes
 3. Pas tous les champs à cause du compromis temps-espace

Hyundai Accent 2014 - Automobiles



Catégorie : Berline
Energie : GPL
Moteur : 1.5 ess 91ch
Boite : Manuelle
Couleur : Gris Argent
Carte Grise (safia)

112000 km

accent gls 2014 , 00 peinture, sauf retouche sur capot voir photos
, avec glp 60 l mémoire, offert 135 m

138 Millions Fixe

Interface utilisateur intelligente

Optimisation de la requête

- Définir un index → sur quels champs ?
-
4. Indexer les attributs servant aux jointures
 5. Indexer les attributs qui interviennent dans les clauses WHERE

Interface utilisateur intelligente

Optimisation de la requête

- Problème

```
SELECT * FROM PRODUCTS  
WHERE LOWER(title) like LOWER('%$phrase%')  
OR LOWER(description) like LOWER('%$phrase%');
```

Title			
Apple iPhone 4G black 16GB			
.....			

Requête : “iPhone 16GB” → résultat ?

Interface utilisateur intelligente

Optimisation de la requête

Title
Apple iPhone 4G black 16GB


- → Solution “%”
 - « %iPhone %16GB% »
- Requête:
“iPhone 16GB 4G”? → résultat ?
- Pb de recherche de texte
- Moteur de recherche

Optimisation de la requête

- Intégration de Moteur de recherche dans les BDs
 - Exemple Apache Solr
- Solr Basé sur Apache lucene
- Lucene permet d'**indexer** et de **recherche** dans les documents Textuels

Optimisation de la requête


- Indexation de collection de Documents



La	Doc1, Doc2, Doc3, Doc4, Doc5,.....
De	Doc1, Doc2, Doc3, Doc4, Doc5,.....
Recherche	Doc2, Doc5
Information	Doc2, Doc5
Base	Doc3, Doc5

Optimisation de la requête

- Indexation et représentation



Optimisation de la requête

- Indexation et représentation

1. Analyse lexicale

2. L'élimination des mots vides (La, le, de,)

- Une liste de Mots vides
- Seuil d'occurrence dans la collection

3. Lemmatisation

- «informé», «informer», «informe», « information » → informe
- Algorithme de lemmatisation de Porter [POR 80].

Optimisation de la requête

- Indexation et représentation

- 4. Pondération des termes

- Associer à chaque terme un poids qui représente son importance dans la collection de documents
- Deux type de pondération: locale et globale
- pondération locale : l'importance d'un terme dans un seul document → la fréquence TF
- pondération globale: l'importance d'un terme dans toute la collection de documents
 - Elle permet de réduire l'importance des termes qui se trouvent souvent dans un document
 - IDF (Inverse of Document Frequency)

Optimisation de la requête

- Indexation et représentation
- Pondération des termes (Exemple)
- comment est calculé le TF*IDF de trois termes dans chaque document de la collection (10 documents dans la collection).
- IDF est calculé par la formule : $(\log(N/n))$ où
 - N représente le nombre total de documents (10 documents)
 - n est le nombre de documents qui contient le terme.

N° Document	Beaucoup	xml	recherche	tf*idf Beaucoup	tf*idf xml	tf*idf recherche	SOMME	classement
1	20	1	1	0,91515	0,2218487	0,301029996	1,438029	10
2	5	4	15	0,228787	0,887395	4,515449935	5,631632	2
3	26	12	2	1,189695	2,662185	0,602059991	4,45394	5
4	5	10	10	0,228787	2,2184875	3,010299957	5,457575	3
5	32	0	0	1,46424	0	0	1,46424	9
6	35	0	0	1,601512	0	0	1,601512	8
7	80	0	0	3,660599	0	0	3,660599	6
8	15	22	0	0,686362	4,2151262	0	4,901489	4
9	20	20	2	0,91515	4,436975	0,602059991	5,954185	1
10	0	9	0	0	1,9966387	0	1,996639	7
idf (Log (N/n))	0,045757	0,2	0,30103					

Optimisation de la requête

- On remarque que le terme "Beaucoup", malgré son TF élevé dans le document 3, mais son $TF*IDF$ sera réduit par rapport au $TF*IDF$ du terme "XML" dans le document 8.
-
- Les documents qui contiennent fréquemment les termes "XML" et "recherche" seront mieux classé que les documents qui contient seulement le terme "Beaucoup"

Optimisation de la requête

- Outils d'indexation
- Lucene
- Terrier
-

Indexation des Documents avec Lucene



- Lucene est une bibliothèque Java qui permet aux applications d'indexer et de rechercher un texte dans les documents.
- Lucene n'est pas une application, c.-à-d. elle ne peut pas fonctionner toute seule. Mais c'est un ensemble de classes et de méthodes qui sont utilisé dans des applications java.
- Plusieurs projets ont utilisés Lucene comme un outil puissant de recherche d'information. Parmi ces projets : LinkedIn, ifinder, blogdigger,

Indexation des Documents avec Lucene

- **Les classes de Lucene**
- **IndexWriter** est utilisé pour créer et maintenir des index
- **IndexSearcher** est utilisée pour rechercher dans un index
- La classe **Analyzer** est une classe abstraite qui est utilisé pour prendre un document et le transformer en termes qui peuvent être indexés.
- La classe **Document** représente un document dans Lucene. Les documents sont l'unité de l'indexation et de la recherche. Un document est un ensemble de champs (**Field**)




Indexation des Documents avec Lucene

- **Les classes de Lucene**
- La classe **Field** est un champ qui représente une section d'un document. chaque champ a un nom et contient un texte comme données
- La classe **QueryParser** est utilisée pour construire un parseur qui peut analyser la requête pour chercher ensuite dans un index

Analyse et traitement du Contenu

Indexation des Documents avec Lucene

- Indexation – construction de l'index – classe IndexWriter



Indexation des Documents avec Lucene

- `Analyzer luceneAnalyzer = new StandardAnalyzer();`
- `IndexWriter indexWriter = new IndexWriter( indexDir, luceneAnalyzer);`
- cette classe peut créer un nouvel index ou ouvrir un index existant et lui ajouter des documents.
- le premier paramètre : ou on stocke les fichiers d'index ;
- le deuxième paramètre : l'analyseur qui sera employé ;
- le dernier paramètre : si vraie, la classe crée un nouvel index ; si faux, il ouvre un index existant

Analyse des Documents avec Lucene

- Analyzer luceneAnalyzer = new **StandardAnalyzer**();

Variantes :

- **WhitespaceAnalyzer** Un analyseur très simple qui sépare juste la marque en
- utilisant l'espace blanc.
- **StopAnalyzer** Enlève les mots anglais communs et de liaison, inutiles pour l'indexation.
- **SnowballAnalyzer** Un analyseur expérimental intéressant qui travaille sur le racines (recherche sur la raining renvoie aussi rained, rain)
- **FrenchAnalyzer** Un analyseur pour le Français

Analyse des Documents avec Lucene

Apache Lucene, ou tout simplement Lucene est un logiciel de recherche et l'indexation des documents API, écrite dans le langage de programmation JAVA. Ce est un logiciel open source de l'Apache Software Foundation sous la Licence Apache.



apache lucene ou tout simplement lucene est un logiciel de recherche et l'indexation des documents api écrite dans le langage de programmation java ce est un logiciel open source de l apache software foundation sous la licence apache



apache lucene ou tout simplement lucene est un logiciel de recherche et l'indexation des documents api écrite dans le langage de programmation java ce est un logiciel open source de l apache software foundation sous a licence apache

Analyse des Documents avec Lucene

apache lucene ou tout simplement lucene est un logiciel de recherche et l'indexation des documents api écrite dans le langage de programmation java ce est un logiciel open source de l'apache software foundation sous la licence apache

Filtration

apache lucene simplement lucene logiciel recherche indexation documents
api écrite langage programmation java logiciel open source apache software
foundation licence apache

Analyse des Documents avec Lucene

Lemmatisation

Sample text: Such an analysis can reveal features that are not easily visible from the variations in the individual genes and can lead to a picture of expression that is more biologically transparent and accessible to interpretation

Lovins stemmer: such an analys can reve featur that ar not eas vis from th vari in th individu gen and can lead to a pictur of expres that is mor biolog transpar and acces to interpres

Porter stemmer: such an analysi can reveal featur that ar not easili visibl from the variat in the individu gene and can lead to a pictur of express that is more biolog transpar and access to interpret

Paice stemmer: such an analys can rev feat that are not easy vis from the vary in the individ gen and can lead to a pict of express that is mor biolog transp and access to interpret

Analyse des Documents

- **Extraction des phrases**
- l'analyse grammaticale
 - ➔ «syntagme nominal»
 - » ➔ «chien noir » ou « petit enfant ».
 - ➔ «syntagme verbal».
 - » ➔ : "Ilyès aime l'informatique".

Analyse des Documents

- **Extraction des Mots composé**
- Un mot composé est constitué de deux ou plusieurs mots attachés pour former un nouveau mot
- Par exemple
 - ➔ « base de donnée », « *pommes de terre* » « *computer science* »

Analyse des Documents

- **Extraction des entités nommées**

- Jim bought 300 shares of Acme Corp. in 2006.

➔ [Jim]**Person** bought 300 shares of [Acme Corp.]**Organization** in
[2006]**Time**.

Analyse des Documents

- Unstructured Information Management Architecture (**UIMA**)
- General Architecture for Text Engineering (**GATE**)
- **Apache OpenNLP library**



The screenshot shows the top section of the Apache OpenNLP website. At the top left is the 'openNLP' logo in a stylized blue font. To its right is the Apache Software Foundation logo, which includes a colorful feather and the text 'The Apache Software Foundati' and 'http://www.apache.org/'. Below the logo area is a horizontal line. Underneath the line, on the left, is the word 'General' in blue. To its right is the heading 'Welcome to Apache OpenNLP' in a larger blue font. Below the heading is a paragraph of text: 'The Apache OpenNLP library is a machine learning based toolkit for the processing'. On the far left, under the 'General' heading, is a list of links: 'Home', 'Download', and 'Maven Dependency', all in blue and underlined.

openNLP™

The Apache Software Foundati
<http://www.apache.org/>

General


- [Home](#)
- [Download](#)
- [Maven Dependency](#)

Welcome to Apache OpenNLP

The Apache OpenNLP library is a machine learning based toolkit for the processing

Analyse des Documents

- Apache OpenNLP library



```
195     out2.println(txt2);
196     out.close();
197     out2.close();
198     return txtlist;
199 }
200 public static void main(String[] args) throws IOException {
201
202     NLP nlp=new NLP();
203     String input=" ";
204     //String content="Pierre Vinken, 61 years old, will join the board as a nonexecut
205     nlp.tag(input);
206     //nlp.sent(content);
207     nlp.parse("los angeles is a state in USA");
208     //nlp.parse("Can anyone help me dig through OpenNLP's horrible documentation? ");
209     //nlp.parse("abdominal external oblique muscle");
210     //nlp.parse("external oblique muscle");
211
212 }
```

Analyse des Documents

- **Apache OpenNLP library**
- **Exemple** : Los Angeles is a state in USA



- (TOP (S (NP (NNS los) (NNS angeles)) (VP (VBZ is) (NP (DT a) (NN state)) (PP (IN in) (NP (NNP USA))))))



- NP los angeles
- NP a state
- NP USA

Analyse des Documents

Part of speech tags¹

CC - Coordinating conjunction	PRP - Personal pronoun
CD - Cardinal number	RB - Adverb
DT - Determiner	RBR - Adverb, comparative
EX - Existential there	RBS - Adverb, superlative
FW - Foreign word	RP - Particle
IN - Preposition or subordinating conjunction	SYM - Symbol
JJ - Adjective	TO - to
JJR - Adjective, comparative	UH - Interjection
JJS - Adjective, superlative	VB - Verb, base form
NN - Noun, singular or mass	VBD - Verb, past tense
NNS - Noun, plural	VBG - Verb, gerund or present participle
NNP - Proper noun, singular	VCN - Verb, past participle
NNPS - Proper noun, plural	VBP - Verb, non-3rd person singular present
PDT - Predeterminer	VBZ - Verb, 3rd person singular present
NP - Noun Phrase.	WDT - Wh-determiner
PP - Prepositional Phrase	WP - Wh-pronoun
VP - Verb Phrase.	WRB - Wh-adverb

¹ <http://bulba.edsu.edu/jeanette/thesis/PennTags.html>

Analyse des Documents

- **Extraction des concepts**
- Concept se concentre plus sur la sémantique du texte.
- C'est une unité abstraite de connaissances qui explique le sens des mots.
- Il faut utiliser les ressources sémantiques externes pour extraire le concept à partir du texte.

The noun **computer science** has 1 sense

1. computer science, computing -- (the branch of engineering science that studies (with the aid of computers) computable processes and structures)

Analyse des Documents

- **Extraction des concepts**

The noun **computer** has 2 senses (first 1 from tagged texts)

1. (6) computer, computing machine, computing device, data processor, electronic computer, information processing system -- (a machine for performing calculations automatically)
2. calculator, reckoner, figurer, estimator, computer -- (an expert at calculation (or at operating calculating machines))

Analyse des Documents

- Extraction des concepts



Indexation des Documents avec Lucene

- `Document doc = new Document();`
-
- `Field contentField1=new Field("contenu", contenu, Field.Store.YES, Field.Index.ANALYZED);`
- `doc.add(contentField1);`
-
- `doc.add(new Field("Titre", Titre_principale, Field.Store.YES, Field.Index.ANALYZED));`
-
- `indexWriter.addDocument(doc);`
-
- `indexWriter.optimize();`
- `indexWriter.close();`

Indexation des BDs avec Lucene

- `Void indexDocs(IndexWriter writer, Connection conn) throws Exception {`
- `String sql = "select id, name from employe";`
- `Statement stmt = conn.createStatement();`
- `ResultSet rs = stmt.executeQuery(sql);`
- `while (rs.next()) {`
- `Document d = new Document();`
- `d.add(new Field("id", rs.getString("id"), Field.Store.YES,Field.Index.NO));`
- `d.add(new Field("name", rs.getString("name"),`
`Field.Store.NO,Field.Index.TOKENIZED));`
- `writer.addDocument(d);`
- `}`
- `}`

Indexation des Documents avec Lucene

```
11  import java.io.IOException;
12  import org.apache.lucene.analysis.standard.StandardAnalyzer;
13  import org.apache.lucene.document.Document;
14  import org.apache.lucene.document.Field;
15  import org.apache.lucene.index.IndexWriter;
16  import org.apache.lucene.store.FSDirectory;
17  import org.apache.lucene.util.Version;
18
19
20  public class Index {
21
22      public void indexFile(String contenu, String Titre_principale) throws IOException {
23
24          File indexDir=new File("C:/Users/pc/Documents/NetBeansProjects/Lucene/Index");
25
26          IndexWriter indexWriter = new IndexWriter(FSDirectory.open(indexDir),new StandardAnalyzer(Version.LUCENE_30),false
27
28          Document doc = new Document();
29
30
31          Field contentField1=new Field("contenu", contenu, Field.Store.YES, Field.Index.ANALYZED);
32          doc.add(contentField1);
33
34          doc.add(new Field("Titre", Titre_principale, Field.Store.YES, Field.Index.ANALYZED));
35          indexWriter.addDocument(doc);
36          indexWriter.optimize();
37          indexWriter.close();
38
39      }
40
41  }
```

Indexation des Documents avec Lucene

```
public static void main(String[] args) {  
    // TODO Auto-generated method stub  
    String contenu="nous allons 'etudier l'utilisation d'un index de recherche textuel OpenSource : Lucene";  
    String titre="Lucene in Action";  
  
    String contenu2="Pour aller plus loin, nous vous proposons de cr'eer un index pour un site web. Pour cela, v  
    "un objet qui va r'ecup'eer la page principale d'un site web d'etermin'e par son domaine. Ensuite pour chaque\n" +  
    "ancree (lien href) pr'esent sur la page, vous parcourrez le lien s'il est sur le m'eme site web et le parcourir\n" +  
    "r'ecursivement";  
    String titre2="Recherche d'information";  
  
    Index ndx =new Index();  
    try {  
        ndx.indexFile(contenu, titre);  
    }  
}
```

Indexation des Documents avec Lucene

```
17
public class Recherche {

    public void search(File indexDir, String queryStr) throws IOException, ParseException {
        int i;
        Directory directory = FSDirectory.open(indexDir);
        IndexReader reader = IndexReader.open(directory);
        IndexSearcher searcher = new IndexSearcher(reader);
        QueryParser parser = new QueryParser(Version.LUCENE_31, "contenu", new StandardAnalyzer(Version.LUCENE_31));
        Query query = parser.parse(queryStr);

        TopDocs topDocs = searcher.search(query, 10);
        ScoreDoc[] hits = topDocs.scoreDocs;
        for (i = 0; i < hits.length; i++) {

            int docId = hits[i].doc;
            Document d = searcher.doc(docId);

            System.out.println("-----");
            System.out.println(i+1+" ~ " + d.get("Titre"));

        }

    }

    public static void main(String[] args) throws IOException, ParseException {

        File indexDir = new File("C:/Users/pc/Documents/NetBeansProjects/Lucene/Index");
        Recherche R = new Recherche();
        R.search(indexDir, "site web");

    }
}
```

Indexation des Documents avec Lucene

Index name: C:\eclipse\workspace\PDF\indexe

Number of fields: 5

Number of documents: 2250

Number of terms: 60715

Has deletions? / Optimized? No / Yes

Last modified: Thu Feb 04 19:51:48 GMT+01:00 2016

Index version: 15299995901

Index format: -11 (Lucene 1.3 or prior)

Index functionality: unknown

TermInfo index data: N/A

Directory implementation: org.apache.lucene.store.MMapDirectory

Currently opened commit point: segments_3rq (Thu Feb 04 19:51:40 GMT+01:00 2016)

Current commit user data: --

Select fields from the list below, and press button to view top terms in these fields. No selection means all fields.

Available fields and term counts per field:

Name	Term count	%	Decoder
Titre	188	0,27 %	string utf8
contents	65 041	93,3 %	string utf8
page	0	0,00 %	string utf8
sous_titre	2 401	3,44 %	string utf8
sous_titre_di	2 085	2,99 %	string utf8

Select a field and set its value decoder: string utf8 Set


Index name: C:\eclipse\workspace\PDF\indexe

Top ranking terms. (Right-click for more options)


No.	Rank	Field	Text
1	1919	contents	de
2	1702	contents	et
3	1696	contents	a
4	1682	contents	le
5	1613	contents	la
6	1566	contents	il
7	1539	contents	un
8	1523	contents	est
9	1515	contents	une
10	1506	contents	i

Indexation des Documents avec Lucene

- Requête / Document
- La similarité entre deux vecteurs de documents (d_1 : requête) et (d_2)



- $\text{Cos}(\theta) = \frac{\vec{d}_1 \cdot \vec{d}_2}{|\vec{d}_1| |\vec{d}_2|}$
- Documents et requêtes sont représentés
- comme des vecteurs
- $D1 = \{w_{11}, w_{21}, \dots, w_{N, 1}\},$
- $q = \{w_{1,q}, w_{2,q}, \dots, w_{N, q}\}$
- $\vec{d}_1 \cdot \vec{q} = \sum w_{d1} * w_{q}$
- Norme $|\vec{d}_1| = \sqrt{w_1^2 + w_2^2 + w_3^2 + \dots}$



Big Data

Introduction

Big Data : Faits

- Chaque jour, nous générons 2,5 trillions d'octets de données
- 90% des données dans le monde ont été créées au cours des deux dernières années
- Source:
 - Capteurs utilisés pour collecter les informations climatiques
 - Messages sur les médias sociaux
 - Images numériques et vidéos publiées en ligne
 - Enregistrements transactionnels d'achat en ligne
 - Signaux GPS de téléphones mobiles
 - ...
- Données appelées **Big Data** ou **Données Massives**

3 / 1

- Chefs d'entreprise prennent fréquemment des décisions basées sur des informations en lesquelles ils n'ont pas confiance, ou qu'ils n'ont pas

1 / 2

- Chefs d'entreprise disent qu'ils n'ont pas accès aux informations dont ils ont besoin pour faire leur travail

% 83

- Des DSI (Directeurs des SI) citent : « L'informatique décisionnelle et analytique » comme faisant partie de leurs plans pour améliorer leur compétitivité

% 60

- Des PDG ont besoin d'améliorer la capture et la compréhension des informations pour prendre des décisions plus rapidement

Big Data : Sources

- Sources multiples: sites, bases de données, téléphones, serveurs:
 - Détecter les sentiments et réactions des clients
 - Détecter les conditions critiques ou potentiellement mortelles dans les hôpitaux , et à temps pour intervenir
 - Prédire des modèles météorologiques pour planifier l'usage optimal des éoliennes
 - Prendre des décisions risquées basées sur des données transactionnelles en temps réel
 - Identifier les criminels et les menaces à partir de vidéos, sons et flux de données
 - Étudier les réactions des étudiants pendant un cour, prédire ceux qui vont réussir, d'après les statistiques et modèles réunis au long des années (domaine *Big Data in Education*)

Big Data : Challenges

- Réunir un grand volume de données variées pour trouver de nouvelles idées
- Difficulté pour sauvegarder toutes ces données
- Difficulté pour traiter ces données et les utiliser
- Les données sont créées rapidement

Big Data : Termes Clefs

- Extraction d'informations et décisions à partir de données caractérisées par les 3 V:
 - **Volume (Volume)**
 - ✓✓ L'entreprise est submergée de volumes de données croissants de tous types, qui se comptent en téraoctets, ou même en pétaoctet
 - **Variété (Variety)**
 - ✓✓ Gérer la complexité de plusieurs types de données et de schémas structurés ou non structurés)texte, données de capteurs, son, vidéo, logs(...
 - **Vitesse (Velocity)**
 - ✓✓ Parfois, les données doivent être saisies et traitées au fil de l'eau, au fur et à mesure de leur collection par l'entreprise, pour la détection des fraudes par exemple
- *Objectif* : relever ce qui est important et ce qui l'est moins

Big Data : Volume

- Le prix de stockage des données a beaucoup diminué ces 30 dernières années:
 - De \$100,000 / Go ((1980
 - À \$0.10 / Go ((2013
- Les lieux de stockage fiables (comme des SAN: Storage Area Network) ou réseaux de stockage peuvent être très coûteux
 - Choisir de ne stocker que certaines données, jugées sensibles
 - Perte de données, pouvant être très utiles, comme les logs
- Comment déterminer les données qui méritent d'être stockées?
 - Transactions? Logs? Métier? Utilisateur? Capteurs? Médicales? Sociales?
- ➔➔ **Aucune donnée n'est inutile.** Certaines n'ont juste pas encore servi.
- Problèmes:
 - Comment stocker les données dans un endroit fiable, qui soit moins cher
 - Comment parcourir ces données et en extraire des informations facilement et rapidement?

Big Data : Variété

- Pour un stockage dans des bases de données ou dans des entrepôts de données ,les données doivent respecter un format prédéfini.
- La plupart des données existantes sont non-structurées ou semi-structurées
- Données sous plusieurs formats et types
- On veut tout stocker:
 - *Exemple:* pour une discussion dans un centre d'appel, on peut la stocker sous forme textuelle pour son contenu, comme on peut stocker l'enregistrement en entier, pour interpréter le ton de voix du client
- Certaines données peuvent paraître obsolètes, mais sont utiles pour certaines décisions:
 - *Exemple:* Pour le transport de marchandise, on a tendance à choisir le camion le plus proche. Mais parfois, ce n'est pas la meilleure solution. D'autres pb peuvent intervenir.
 - Besoin de : Données GPS, Plan de livraison du camion, Circulation, Chargement du camion, Niveau d'essence...

Big Data : **Vitesse**

- Rapidité d'arrivée des données
- Vitesse de traitement
- Les données doivent être stockées à l'arrivée, parfois même des Teraoctets par jour
 - Sinon, risque de perte d'informations
- Exemple
 - Il ne suffit pas de savoir quel article un client a acheté ou réservé
 - Si on sait que vous avez passé plus de 5mn à consulter un article dans une boutique d'achat en ligne, il est possible de vous envoyer un email dès que cet article est soldé.

Approche Traditionnelle

10

Les besoins métier guident la conception de la solution



Approche Traditionnelle


11

- Appropriée pour:
 - Des données structurées
 - Opérations et processus répétitifs
 - Sources relativement stables
 - Besoins bien compris et bien cadrés

Approche Big Data

12

Les sources d'information guident la découverte créative



Approche Big Data

- La question **n'est pas**:
 - Dois-je choisir entre l'approche classique et l'approche big data?
- Mais plutôt:
 - Comment les faire fonctionner Ensemble ?

Data Warehouse

Big Data Platform



Traditional Sources

New Sources

Fusionner l'approche Big Data avec l'approche Traditionnelle

14

Approche Traditionnelle

Analyse Structurée et Répétée

Responsables Métier

Déterminent quelles questions poser



Responsables IT

Structurent les données pour répondre à ces questions



Approche Big Data

Analyse Itérative et Exploratoire

Responsables IT

Fournissent une plateforme pour permettre la découverte créative



Responsables Métier

Explorent la plateforme pour déterminer quelles questions poser



➤➤ **Cours**

- *Big Data Analytics – Lesson 1: What is Big Data*, IBM, Big Data University
- *Intro to Hadoop and MapReduce*, Coursera, Udacity

Big Data

Bases de Données NOSQL

Bases de Données NOSQL

- Bases de données NOSQL (Not Only SQL) :
 - Ce n'est pas (comme son nom le laisse supposer) No SQL (pas de SQL)
 - Privilégier donc N**O**SQL plutôt que N**o**SQL
- Bases de données non-relationnelles et largement distribuées
- Permet une analyse et une organisation rapides et ad-hoc des données de très grands volumes et de types de données disparates
- Appelées également
 - *Cloud Databases*
 - *Non-Relational Databases*
 - *Big Data Databases*
 - ...
- Développées en réponse à l'augmentation exponentielle des données générées, enregistrées et analysées par les utilisateurs modernes et leurs applications

Atouts

➤➤ Principaux atouts

- Évolutivité
- Disponibilité
- Tolérance aux fautes

➤➤ Caractéristiques

- Modèle de données sans schéma
- Architecture distribuée
- Utilisation de langages et interfaces qui ne sont pas uniquement du SQL

NOSQL et Big Data

- De point de vue métier, utiliser un environnement BigData et NOSQL fournit un avantage compétitif certain
- Importance des données:
 - « **Si vos données ne croissent pas, alors votre entreprise ne le fait pas non plus** »

Types de Bases de Données NOSQL


➤➤ Types des bases de données NOSQL

- Clef/valeur
- Orientées colonnes
- Orientées documents
- Orientées graphes

➤➤ Propriétés des BDR

- ACID : Atomicity, Consistency, Isolation
- Utilisation de SQL

and Durability



Id	Nom	Humeur	Date_naissance	Couleur
12	Stella	Heureuse	2007-04-01	NULL
13	Wimma	Faim	NULL	Noire
9	Ninja	NULL	NULL	NULL

Types de Bases de Données NOSQL


.1 Clef/Valeur)Key/Value Store(

- L'un des types les plus simples, sorte de Hashmap distribuée
Conçues pour sauvegarder les données sans définir de schéma
- Toutes les données sont sous forme de clef/valeur
 - La valeur peut être une chaîne de caractères, un objet sérialisé, blob...
 - La donnée est opaque au système: il n'est pas possible d'y accéder sans passer par la clef
- Absence de typage a un impact sur le requêtage: toute l'intelligence portée avant par les requêtes devra être portée par l'applicatif qui interroge la BD
- Communications se résumant surtout aux opérations PUT, GET et DELETE
- Objectif: fournir un accès rapide aux informations, conserver la session d'un site web...
- Exemple : DynamoDB (Amazon), Azure Table Storage (ATS), Redis, BerkeleyDB, Voldemort (LinkedIn)


Types de Bases de Données NOSQL

1. Clef/Valeur (Key/Value Store)

7



Id	Nom	Humeur	Date_naissance	Couleur
12	Stella	Heureuse	2007-04-01	NULL
13	Wimma	Faim	NULL	Noire
9	Ninja	NULL	NULL	NULL



Clef

Chien_12

Valeur

Nom_\$\$_Stella~~Humeur_
_#\$Heureuse~~Date_naissance_
...01-04-2007_#\$

Types de Bases de Données NOSQL


.2 Orientée Documents (*Document Database*)

- Étendent le paradigme clef/valeur, avec des « documents » plus complexes à la place des données simples, et une clef unique pour chacun d'eux
- Documents de type JSON ou XML
- Chaque document est un objet, contient un ou plusieurs champs, et chaque champs contient une valeur typée (string, date, binary ou array)
- Permettent de stocker, extraire et gérer les informations orientées documents)données semi-structurées(
- Avantage : pouvoir récupérer, via une seule clef, un ensemble d'informations structurées de manière hiérarchique
 - Dans les bases relationnelles, cela impliquerait plusieurs jointures
- Exemples : Mongo DB (SourceForge), Couch DB (Apache), RavenDB (destiné aux plateformes .Net/Windows, interrogation via LINQ)

Types de Bases de Données NOSQL

.2Orientée Documents (*Document Database*)

9



Id	Nom	Humeur	Date_naissance	Couleur
12	Stella	Heureuse	2007-04-01	NULL
13	Wimma	Faim	NULL	Noire
9	Ninja	NULL	NULL	NULL



Document (V2)

```
{
  type : « Chien »,
  nom : « Stella »,
  humeur : « Heureuse »,
  date_naissance : 2007-04-01
  aboiement : [
    {
      texte : « j'ai mangé de la pâtée »
      commentaires : [
        {
          id_chien : « chien_4 »,
          texte : « on s'en fout! »
        }
      ]
    }
  ]
}
```

Document (V1)

```
{
  type : « Chien »,
  nom : « Stella »,
  humeur : « Heureuse »,
  date_naissance : 2007-04-01
}
```

Clef

Chien_12

Types de Bases de Données NOSQL

.3 Orientées Colonnes (*Column Store*)

- Évolution de la BD clef/valeur
- Ressemble aux SGBDR, mais avec un nombre de colonnes dynamique, différent d'un enregistrement à un autre (pas de colonnes portant les valeurs NULL)
- Offrent de très hautes performances et une architecture hautement évolutive
- Exemples: Hbase (Hadoop), Cassandra (Facebook, Twitter), BigTable (Google)



	A	B	C	D	E
1	Foo	Bar	Hello		
2		Tom			
3			Java	Scala	Cobol

1	A Foo	B Bar	C Hello
2	B Tom		
3	C Java	D Scala	E Cobol

Types de Bases de Données NOSQL

.3Orientées Colonnes (Column Store)

11



Types de Bases de Données NOSQL

.3Orientées Colonnes (*Column Store*)

12

ColumnFamily		
Key	Value	
AddressBook	SuperColumns	
	Key	Value
	person1	Column
		Name
		Value
		firstName
		John
		lastName
		Calagan
	person2	Column
		Name
		Value
		firstName
		George
		lastName
		Truffe

Exemple Cassandra : Colonne / Super Colonne / Famille de Colonnes

Types de Bases de Données NOSQL

13


4. Orienté Graphes (*Graph Database*)

- Basées sur les théories des graphes
- S'appuie sur les notions de nœuds, de relations et des propriétés qui leur sont rattachées
- Conçues pour les données dont les relations sont représentées comme graphes, et ayant des éléments interconnectés, avec un nombre indéterminé de relations entre elles
- Adapté aux traitements des données des réseaux sociaux
- Exemples : Neo4J et InfiniteGraph, OrientDB

Types de Bases de Données NOSQL

.4Orienté Graphes (Graph Database)

14



Comparaison entre Types de BD NOSQL

15

Modèle	Performance	Évolutivité	Flexibilité	Complexité	Fonctionnalités
Clef/Valeur					Variable
Orienté Colonnes					Minimale
Orienté Document					Variable
Orienté Graphes					Théorie des Graphes

NOSQL vs. BDR

BIG DATA

CHP3 – BASES DE DONNÉES NOSQL

NOSQL et BDR (1/3)

- Choix de NOSQL en opposition aux bases de données relationnelles conduits par les contraintes du marché et les besoins techniques

- **BigData**

- Adaptation des BD NOSQL au BigData
 - ✓✓ Vitesse (*Velocity*) : beaucoup de données qui arrivent rapidement, à partir de plusieurs sources
 - ✓✓ Variété (*Variety*) : données structurées, semi-structurées ou non-structurées
 - ✓✓ Volume (*Volume*) : données très nombreuses (To et Po)
 - ✓✓ Complexité (*Complexity*) : données stockées et gérées à plusieurs endroits et data centers.

- **Disponibilité continue des données**

- Le manque de disponibilité peut être fatal pour une entreprise
- BD NOSQL utilisent une architecture hautement distribuée : pas de SPOF
- Redondance des données et traitements : tolérance aux fautes
- D'où : disponibilité continue à travers les data centers, et le cloud
- Toute mise à jour ou modification est faite sans déconnecter la base

NOSQLet BDR (2/3)

➤➤ **Indépendance de l'emplacement**

- Possibilité de consulter et modifier une BD sans savoir où est-ce que ces opérations ont réellement lieu
- Toute fonctionnalité d'écriture propagée à partir d'un emplacement, pour être disponible aux utilisateurs à partir d'autres sites
- Difficile à appliquer aux BDR, surtout pour l'écriture

➤➤ **Modèles de données flexibles**

- Une des raisons majeures
- Dans le modèle relationnel, les relations entre les tables sont prédéfinies, fixes et organisées dans un schéma strict et uniforme
 - ✓✓ Problèmes d'évolutivité et de performance en gérant de grands volumes de données
- Les BD NOSQL peuvent accepter tout type de données (structurées, semi-structurées ou non-structurées) plus facilement
- Dans les BDR, les performances posent problème, surtout quand des lignes « larges » sont utilisées et les actions de modification sont nombreuses

NOSQL et BDR (3/3)

➤➤ **Business Intelligence et Analyse**

- Capacité des bases NOSQL à exploiter les données collectées pour dériver des idées
- Extraction d'informations décisionnelles à partir d'un grand volume de données, difficile à obtenir avec des bases relationnelles
- Bases NoSQL permettent le stockage et la gestion des données des applications métier, et fournissent une possibilité de comprendre les données complexes, et de prendre des décisions

➤➤ **Capacités transactionnelles modernes**

- Nouvelles définition du principe de transaction
- Utilisation des propriétés BASE au lieu des propriétés ACID

NOSQL et BDR : Propriétés ACID

➤➤ **Propriétés ACID** : Atomicité, Cohérence, Isolation et Durabilité

- Propriétés des transactions des BDR
- *Atomicité* : Soit toutes les instructions sont exécutées, soit aucune
- *Consistance* : toute transaction amène la BD d'un état valide à un autre ➡➡ renforcée par les contraintes d'intégrité et les clefs étrangères
- *Isolation* : Même si plusieurs transactions peuvent être exécutées par un ou plusieurs utilisateurs simultanément, une transaction ne devrait pas voir les effets des autres transactions concurrentes
- *Durabilité* : Une fois la transaction enregistrée dans la base (*commit*), ces changements sont persistants.

➤➤ Toutes les BDR supportent les transactions ACID

➤➤ Mais :

- Données de plus en plus volumineuses + Besoin de systèmes évolutifs
- Besoin de BD distribuées sur le réseau, pour une évolutivité horizontale


NOSQL et BDR : Théorème CAP

- Destiné à évaluer les systèmes de stockage distribués
- Théorème CAP : « Il est impossible de satisfaire les trois propriétés CAP en même temps »
- **Propriétés CAP** : *Consistency, Availability, Partition tolerance*
 - Consistance : Si j'écris une donnée dans un nœud et que je la lis à partir d'un autre nœud dans un système distribué, je retrouve ce que j'ai écrit sur le premier.
 - Haute disponibilité : à tout moment, pour chaque requête, la réponse est garantie. Même en cas de panne, les données restent accessibles
 - Tolérance au partitionnement : les données peuvent être partitionnées sur différents supports sans souci de localisation. Les activités continuent sans interruption lors de la modification du système (en cas d'ajout ou suppression de nœuds) et en cas de chute du réseau

Consistency:
ACIO
Transactions

Oracle
RAC

Availability
(Total
Redundancy)



NOSQL et BDR : Théorème CAP

- **Pourquoi est-il impossible de satisfaire les 3 propriétés CAP en même temps?**
- Soit un système distribué. On est entrain de modifier une donnée sur le nœud N1 et d'essayer de la lire à partir du nœud N2
 - N2 peut retourner la dernière bonne valeur dont il dispose, ce qui viole la Consistance
 - N2 attend que la nouvelle valeur lui parvienne. Comme c'est un système distribué, les chances d'un échec de transmission sont assez importantes, ce qui provoquera une attente infinie de N2. D'où une violation de la Disponibilité
 - Si on veut satisfaire à la fois la consistance et la disponibilité, le système de stockage ne doit pas être partitionné. D'où violation de la Tolérance au partitionnement.
- Pour les BD NOSQL, il n'y a plus de jointures
 - ➡➡ La propriété de consistance n'est plus assurée de la même manière
- Consistance dans NOSQL: consistance immédiate et éventuelle des données à travers les nœuds de la base distribuée

NOSQL et BDR : Propriétés BASE

- **BASE** : Basically Available, Soft-state, Eventual consistency
- Basically Available
 - Le système garantit la disponibilité, comme définie dans le théorème CAP
- Soft-State
 - L'état du système peut changer dans le temps, même sans nouvelles entrées, et ce à cause du principe de consistance éventuelle
- Eventual Consistency
 - Les modification arriveront éventuellement à tous les serveurs, si on leur donne suffisamment de temps
- BASE est plus flexible que ACID, accepte certaines erreurs, dont l'occurrence est assez rare

NOSQL et BDR : Recapitulatif

BRD		NOSQL
Consistance forte	vs	Consistance éventuelle
Grandes quantités de données	vs	Enorme quantité de données
Évolutivité possible	vs	Evolutivité facile
SQL	vs	Map-Reduce
Bonne disponibilité	vs	Très haute disponibilité

Synthèse

➤➤ Bases de données NOSQL

- Performances sur de gros volumes de données
- Performances sur des données non structurées
- Evolutivité très importante, même pour de faibles volumes

➤➤ Cependant:

- Technologie assez jeune ➡➡➡ Manque d'outils la supportant
- Encore en évolution, pas de standards
- Pas de langage de requêtage commun comme SQL, mais divers:
 - ✓✓ Requêtes spécifiques au langage (Java, Python...)
 - ✓✓ Requêtes spéciale pour la base (Cassandra Query Language)
 - ✓✓ API basée sur Map Reduce, ou sur graphes d'objets
- On doit faire plus de travail au niveau du code, ce qui peut influencer sur la performance

Quand utiliser NOSQL?

- Si l'**évolutivité** est une préoccupation
 - Mais attention, ce n'est pas toujours un MUST : Flickr et Wikipedia utilisent des RDBMS

- Si l'**absence de schéma** est une préoccupation

- Si être **IN et FASHION** est une préoccupation
 - Pour un nombre important de personnes, l'utilisation d'un nouveau paradigme ou technologie est un MUST!

Cassandra

BIG DATA
BASES DE DONNÉES NOSQL

Cassandra

- Base de données :
 - Distribuée
 - À haute performance
 - Extrêmement évolutive
 - Tolérante aux fautes (pas de SPOF)
 - Non-relationnelle
- Peut être utilisée à la fois comme :
 - Base de données temps réel
 - Base de données pour une lecture intensive pour les systèmes décisionnels
- À la base, c'est une combinaison de BigTable de Google et DynamoDB de Amazon, incubée dans Facebook, et hébergée comme solution open source dans Apache.

Architecture de Cassandra (1/2)

- Système distribué, P2P
 - Composés de plusieurs nœuds identiques
 - Pas de notion de NameNode ou nœud maître...
- Les données sont partitionnées par défaut à travers les différents nœuds du cluster
- Les données sont répliquées pour assurer une tolérance aux fautes maximale
 - L'utilisateur contrôle le nombre de répliques qu'il désire avoir pour ses données
- Lecture et écriture à partir de n'importe quel nœud, indépendamment de l'emplacement des données
- Utilisation du protocole **Gossip** pour la communication entre les différents nœuds du cluster
 - Échange de données entre les nœuds chaque seconde



Architecture de Cassandra (2/2)

- Structure orientée colonnes, à l'image de BigTable
- Vocabulaire:
 - **Keyspace** (équivalent de *database*)
 - **Column Family** (équivalent de *table*)
 - ✓✓ Dans la nouvelle version du langage CQL, appelée Table
 - ✓✓ Schéma plus flexible et dynamique qu'une table
 - **Colonne** (équivalent à *enregistrement*)
 - ✓✓ Indexée par une clef
 - ✓✓ D'autres champs peuvent être également indexés, mais à la demande

Keyspace : Portfolio


Column Family : Client

ID	Nom	Adresse	Tel

Partitionnement dans Cassandra (1/2)

31

- Partitionnement facile des données à travers les différents nœuds participants du cluster
- Chaque nœud est responsable d'une partie de la base de données
- Les données sont insérées par l'utilisateur dans une famille de colonnes
- Elles sont ensuite placées sur un nœud, selon sa clef de colonne



Partitionnement dans Cassandra (2/2)

32

➤➤ Stratégies de partitionnement

○ Partitionnement aléatoire


- ✓✓ Par défaut, recommandé
- ✓✓ Données partitionnée le plus équitablement possible à travers les différents nœuds
- ✓✓ Utilisation de MD5 (ou Murmur3) pour le hachage de chaque clef de famille de colonnes

○ Partitionnement ordonné

- ✓✓ Sauvegarde les clefs de familles de colonnes par ordre à travers les nœuds d'un cluster
- ✓✓ Peut provoquer des problèmes, surtout pour la répartition des charges (des nœuds avec des données plus volumineuses que d'autres)


➤➤ Stratégie spécifiée dans un fichier de configuration `cassandra.yaml`

➤➤ Si la stratégie d'une base est modifiée, il faut recharger toutes les données



Réplication dans Cassandra (1/3)

- Pour assurer la tolérance aux fautes et pas de SPOF, il est possible de créer une ou plusieurs copie(s) de chaque colonne à travers les nœuds participants
- L'utilisateur spécifie le **facteur de réplication** désiré à la création du keyspace
- Les données sont insérées par l'utilisateur dans une famille de colonnes
- La colonne est répliquée dans les nœuds du cluster selon le facteur de réplication



Réplication dans Cassandra (2/3)

34



➤➤ Stratégies de réplication

○ **Stratégie Simple :**

- ✓✓ La colonne originelle est placée sur un nœud déterminé par le partitionneur
- ✓✓ La réplique est placée sur le nœud suivant de l'anneau (clockwise)
- ✓✓ Pas de considération pour l'emplacement dans un data-center ou dans une baie (approprié pour les déploiement sur un seul datacenter)

○ **Stratégie par topologie du réseau**

- ✓✓ Plus sophistiquée
- ✓✓ Plus de contrôle sur l'emplacement des répliques de colonnes
- ✓✓ Parcourt le cluster (clockwise) à la recherche d'un nœud dans une baie différente. Si introuvable, stocker la colonne dans un nœud de la même baie
- ✓✓ Un *groupe de réplication* est spécifié, pour distinguer entre plusieurs datacenters



Réplication dans Cassandra (3/3)

➤➤ Mécanisme de réplication

○ Utilisation de **SNITCH**:

- ✓✓ Définition de la manière dont les nœuds sont groupés dans un réseau
- ✓✓ Répartition des nœuds entre baies et datacenters

○ Plusieurs types de SNITCH

- ✓✓ **Simple SNITCH** : utilise la stratégie simple
- ✓✓ **Rack-Inferring SNITCH** : détermine la topologie du réseau en analysant les adresses IP:
 - Second octet de l'adresse IP: Data Center
 - Troisième octet de l'adresse IP: Baie
- ✓✓ **Property File SNITCH** : se base sur une description de l'utilisateur pour déterminer l'emplacement des nœuds (*cassandra-topology.properties*)
- ✓✓ **EC2 SNITCH** : pour déploiement dans Amazon EC2. Utilise l'API AWS pour déterminer la topologie

○ Défini dans le fichier de configuration *cassandra.yaml*

Consistance dans Cassandra


- Architecture *Read and Write Anywhere*
- L'utilisateur peut se connecter à n'importe quel nœud, dans n'importe quel datacenter, et lire/écrire les données qu'il veut
- Les données sont automatiquement partitionnées et répliquées à travers le cluster

Consistance dans Cassandra

➤➤ Écriture:

- Données écrites d'abord dans un *commit log* pour la durabilité
- Ensuite, écriture en mémoire dans une *MemTable*
- Une fois la MemTable pleine, les données sont sauvegardées dans le disque, dans une *SSTable* (*Sorted Strings Table*)
- Même si les transactions relationnelles (commits et rollbacks) ne sont pas supportées, les écritures sont atomiques au niveau des colonnes
 - ✓✓ Soit toutes les colonnes sont modifiées, soit aucune ne l'est

➤➤ Cassandra est la base de données NOSQL la plus rapide en écriture



Consistance dans Cassandra

- Consistance : à quel point est-ce qu'une donnée est à jour et synchronisée sur toutes ses répliques.
- Extension du concept de consistance éventuelle à une **consistance ajustable**
- Choix possible entre une consistance forte ou éventuelle selon les besoins
- Ce choix est fait par opération, ce n'est pas une stratégie globale pour la base de données (ex, pour changer la stratégie de lecture en *quorum*)
 - `SELECT * FROM users USING CONSISTENCY QUORUM WHERE state='TX';`
- Consistance gérée à travers plusieurs data centers.

Stratégies d'Écriture

- **Niveau de consistance** : combien de répliques doivent être écrites avec succès avant de retourner acquittement au client
- **Any** : une écriture doit réussir sur n'importe quel nœud, au moins un.
✓✓ Offre la plus haute disponibilité, mais la plus basse consistance
 - **One (défaut dans CQL)** : une écriture doit réussir sur le commit log et la memtable d'au moins une réplique
 - **Quorum** : une écriture doit réussir sur un certain pourcentage de répliques (pourcentage = $(\text{facteur de réplication}/2)+1$)
✓✓ Meilleure alternative en terme de consistance et de disponibilité
 - **Local-Quorum** : une écriture doit réussir sur un certain pourcentage de nœuds répliques sur le même datacenter que le nœud coordinateur
 - **Each-Quorum** : une écriture doit réussir sur un certain pourcentage de nœuds répliques sur tous les datacenters.
 - **All** : une écriture doit réussir sur tous les nœuds répliques d'une colonne
✓✓ Offre la plus haute consistance, mais la plus basse disponibilité

- Cassandra utilise les **Hinted Handoffs**
- Elle tente de modifier une colonne sur toutes les répliques
- Si certains des nœuds répliques ne sont pas disponibles, un indice (*hint*) est sauvegardé sur l'un des nœuds répliques en marche, pour mettre à jour tous les nœuds répliques en panne une fois disponibles
- Si aucun nœud réplique n'est disponible, l'utilisation de la stratégie **ANY** permettra au nœud coordinateur de stocker cet indice. Mais la donnée ne sera lisible que quand l'un des nœuds est disponible de nouveau.


Stratégies de Lecture

- **Niveau de consistance** : combien de répliques doivent répondre avant de retourner le résultat à l'application cliente
- Cassandra vérifie le nombre de répliques pour la donnée la plus récente pour satisfaire une demande de lecture (basée sur le temps)
 - **One (défaut dans CQL)** : obtention d'une réponse à partir de la réplique la plus proche selon le SNITCH
 - ✓✓ Offre la plus faible consistance, mais la plus haute disponibilité
 - **Quorum** : obtention du résultat le plus récent à partir d'un certain pourcentage de nœuds répliques (pourcentage = $(\text{facteur de réplication}/2)+1$)
 - ✓✓ Meilleure alternative en terme de consistance et de disponibilité
 - **Local-Quorum** : obtention du résultat le plus récent à partir d'un certain pourcentage de nœuds répliques sur le même datacenter que le nœud coordinateur
 - ✓✓ Évite la latence due à la communication inter-datacenters
 - **Each-Quorum** : : obtention du résultat le plus récent à partir d'un certain pourcentage de nœuds répliques sur tous les datacenters.
 - **All** : obtention du résultat le plus récent à partir de tous les nœuds répliques
 - ✓✓ Offre la plus haute consistance, mais la plus basse disponibilité

Stratégies de Lecture

➤➤ **Read Repair**

- Cassandra assure que les données fréquemment lues soient consistantes
- À la lecture d'une donnée, le nœud coordinateur compare toutes ses répliques en arrière plan.
- Si ces données ne sont pas consistantes, envoie une demande d'écriture aux nœuds répliques pour mettre à jour leur donnée et afficher la donnée la plus récente
- *Read Repair* peut être configuré par famille de colonnes et est activé par défaut.



Gérer les Données et Objets dans Cassandra

43

- Deux interfaces pour gérer les objets/données
 - Cassandra CLI (Command Line Interface)
 - CQL (Cassandra Query Language)

- CLI
 - Interface originelle conçue pour créer des objets, entrées et manipuler les données

- CQL
 - Utilisée pour créer/manipuler des données en utilisant un langage proche de SQL

Gérer les Données et Objets dans Cassandra

44

➤➤ CQL

- Objets tels que les keyspaces, familles de colonnes et index sont créés, modifiés et supprimés avec les requêtes usuelles: CREATE, ALTER et DROP
- Données insérées, modifiées et supprimées avec INSERT, UPDATE et DELETE
- Données lues avec SELECT
- **Mais**
 - ✓✓ Ne supporte pas des opérations telles que GROUP BY, ORDER BY (sauf pour les clefs composées, et ordonnées seulement selon la deuxième clef primaire)...
- Utiliser la clause USING CONSISTENCY pour déterminer le type de consistance forte pour chaque opération de lecture et l'écriture (Any, One, Quorum...)

Récapitulatif : Cassandra (1/2)

- Grande Scalabilité (Gigaoctet/Petaoctet) ➡➡ Appropriée aux Big Data
 - Gain de performances linéaire grâce à l'ajout des nœuds
- Pas de SPOF (Single Point of Failure)
- Réplication et distribution des données facile à travers les data-centers
- Pas besoin de couche de cache séparée
 - Utilisation des mémoires vives de l'ensemble des nœuds
- Consistance des données ajustable
 - Possibilité de choisir pour chaque opération si une donnée est fortement consistante (tous les nœuds sont similaires à tout moment) ou éventuellement consistante
- Schéma de données flexible

Récapitulatif : Cassandra (2/2)

- Compression des données
 - Utilisation de l'algorithme de compression Snappy de Google
 - Compression des données pour chaque famille de colonnes
 - Pas de pénalité pour la performance, et même une amélioration notable, grâce à la diminution du nombre de I/O physique
- Langage CQL très proche de SQL
- Support des langages et plateformes clef
- Pas besoin de matériel ou de logiciel particulier

Sources

➤➤ Sites (consultés en février 2014)

- Planet Cassandra : www.planetcassandra.org
- NOSQL : 5 minutes pour comprendre : <http://blog.neoxia.com/nosql-5-minutes-pour-comprendre/> NEOXIA
- NOSQL Europe : Bases de données orientées colonnes et Cassandra
<http://blog.xebia.fr/2010/05/04/nosql-europe-bases-de-donnees-orientees-colonnes-et-cassandra/> XEBIA
- Une base NOSQL, Cassandra : <http://www-igm.univ-mlv.fr/~dr/XPOSE2010/Cassandra> IGM
- Why NOSQL – Part 1 – CAP Theorem :
<http://bigdatanerd.wordpress.com/2011/12/08/why-nosql-part-1-cap-theorem/> DATANERD
- DataStax Cassandra Tutorials : <http://www.datastax.com/resources/tutorials/cassandra-overview> DataStax

➤➤ Présentations

- Harri Kauhanen, « NOSQL Databases », *Futurice, Septembre 2010*

➤➤ Rapports

- Mouna Laroussi, « Etude et mise en place de la technologie Big Data pour la télécommunication », *Projet de fin d'études, INSAT, 2013*

➤➤ Livres Blancs

- Top 5 Considerations when evaluating NOSQL Databases, *MongoDB White Paper, Juin 2013*