

TD n°1

Matière : Introduction au Big Data

Classe : 1ère année MPSD

Enseignant TD : Mohamed Anouar DAHDEH



Objectif: Découvrir le concept du **Big Data** et ses différents outils

Partie 1 : Questions réponses

- 1- Quelles sont les unités de mesure pour le **Big Data** ?
- 2- Citer des exemples d'entreprises qui possèdent des données massives.
- 3- Quelles sont les frontières de **Big Data** ?
- 4- Les 4 V de **Big Data** ?
- 5- Quelles sont les types de données dans le cadre de **Big Data** ? Citer des exemples pour chaque type.
- 6- Déterminer les exemples qui relèvent et ceux qui ne relèvent pas de **Big Data** :
 - a- Un volume de données que l'on peut traiter au moyen d'une fiche Excel.
 - b- Le trafic d'un gros site web.
 - c- Les données qui sont « chères » à produire telles que celles qui sont collectées par des sondages ou par recensement et produite par un organisme de sondage.
 - d- Les données publiques librement disponibles au téléchargement.
 - e- Les volumes de données qu'il n'est possible de stocker ou de traiter avec les technologies traditionnelles que le SGBDR ou par lesquelles le coût d'un tel traitement serait prohibitif.
 - f- Des données que l'on peut héberger dans un seul nœud de base de données relationnelle.
 - g- Les données de logs transactionnelles d'un site web d'une grande enseigne de distribution.
 - h- Les données de localisation GSM d'un opérateur téléphonique sur une journée.
 - i- Les données boursières échangées quotidiennement sur une grande place financière.

Exemples de Big Data	Exemples de non Big Data
b - d - e - g - h - i	a - c - f

7- Cloudera, Hortonworks et MapR représente les trois principales distributions de Hadoop. Compléter ce tableau comparatif entre les distributions Hadoop:

Distribution	Cloudera	Hortonworks	MapR
Année de création			
Fondateurs			
Noyau			
Licences			
Points forts			
Points faibles			
Partenaires			

HOMEWORK: Déterminer l'écosystème de chaque distribution, en définissant chaque composant. N'oublier pas de citer vos références.

8- Comparer entre Hadoop et Spark

Distribution	Hadoop	Spark
Rapidité de traitement	Spark est généralement plus rapide que Hadoop en raison de son traitement en mémoire.	
Langage	Hadoop utilise principalement Java, tandis que Spark prend en charge plusieurs langages, dont Scala, Python et Java.	
Type de traitement des données	Hadoop est optimisé pour le traitement par lots, tandis que Spark prend en charge le traitement en temps réel et le traitement par lots.	
Simplicité de la mise en œuvre	Spark est souvent considéré comme plus convivial que Hadoop.	
Stockage de données de traitement	Hadoop stocke les données sur le disque, tandis que Spark favorise le stockage en mémoire.	

9- Dans un cadre de Big data que représente PIG ?
 PIG est un langage de script conçu pour effectuer des transformations de données massives dans le cadre du Big Data.

10- Déterminer les exemples qui relèvent et ceux qui ne relèvent pas de NoSQL :

- a- Bases données cloud NoSQL
- b- Base de données relationnelles Base de données traditionnelle
- c- Bases de données non relationnelles NoSQL
- d- Bases de données Big Data NoSQL
- e- MySQL Base de données traditionnelle
- f- Cassandra NoSQL
- g- MongoDB NoSQL
- h- SQLServer Base de données traditionnelle
- i- Modèle de données sans schéma NoSQL
- j- Bases de données distribuées NoSQL

k- Modèle de données avec schéma

Exemples de NoSQL	Exemples de base traditionnelle

Partie 2 : QCM du certificat IBM (Big Data Developer - 2016)

Déterminer la ou les bonnes réponses :

1- Qu'est-ce que le Big Data?

- A.** Une fonctionnalité Hadoop capable de traiter de grandes quantités de données en parallèle sur de grands groupes de matériel de base dans un environnement fiable et tolérant aux pannes.
- B.** Des grandes quantités de données brutes non structurées, semi-structurées et structurées qui ne peuvent pas être stockées, traitées ou analysées à l'aide de techniques traditionnelles d'entrepôts de données relationnels. oui
- C.** Une fonction de base de données capable de convertir des données structurées préexistantes en données brutes non structurées.
- D.** Seules les données stockées dans la table BIGDATA dans une base de données relationnelle.

2- Dans une pile Hadoop traditionnelle, lequel des composants suivants fournit une infrastructure d'entrepôt de données et permet aux développeurs SQL et aux analystes d'exploiter leurs compétences SQL existantes?

- A.** Avro.
- B.** Hive. oui
- C.** Zookeeper.
- D.** Text analytics.

3- Laquelle des options suivantes n'est pas correcte?

- A.** Les solutions Big Data sont idéales pour analyser non seulement des données structurées brutes, mais également des données semi-structurées et données non structurées provenant d'une grande variété de sources.
- B.** Les solutions Big Data sont idéales pour les environnements OLTP (Online Transaction Analytical Process). non

C. Les solutions Big Data sont idéales pour l'analyse itérative et exploratoire lorsque les mesures commerciales relatives aux données ne sont pas prédéterminées.

4- Laquelle des options suivantes décrivent le mieux les différences entre un entrepôt de base de données traditionnelle et un environnement Hadoop?

A. Les environnements d'entreposage de données traditionnels sont généralement idéaux pour analyser des données structurées à partir de différents systèmes, alors qu'un environnement Hadoop est bien adapté pour traiter des données semi-structurées et non structurées, ainsi que lorsqu'un processus de découverte de données est nécessaire.

B. Les environnements Hadoop sont principalement adaptés à l'analyse de données structurées et semi-structurées système unique, tandis que l'environnement d'entreposage de données traditionnel est bien adapté pour traiter des données non structurées, ainsi que lorsqu'un processus de découverte de données est nécessaire.

C. En règle générale, les données stockées dans les environnements Hadoop sont nettoyées avant d'être stockées dans l'environnement de système de fichiers distribué.

D. En règle générale, les données stockées dans des environnements d'entreposage de données sont rarement filtrées et pré-traitées. D'autre part, les données injectées dans les environnements Hadoop sont toujours pré-traitées et filtrées.

Partie 1 : Questions réponses

Les unités de mesure courantes pour le Big Data sont l'octet, le kilo-octet (Ko), le méga-octet (Mo), le giga-octet (Go), le téra-octet (To), le péta-octet (Po), et l'exaoctet (Eo).

Exemples d'entreprises possédant des données massives sont Google, Facebook, Amazon, Netflix, Twitter, et bien d'autres.

Les frontières du Big Data ne sont pas strictement définies, mais il est généralement associé à la gestion et à l'analyse de données à une échelle massive, généralement au-delà des capacités des systèmes traditionnels.

Les 4 V de Big Data sont le Volume (la quantité de données), la Vitesse (la vitesse à laquelle les données sont générées et traitées), la Variété (les différents types de données, structurées et non structurées) et la Valeur (l'importance des informations tirées des données).

Les types de données dans le cadre du Big Data comprennent les données structurées (par exemple, des bases de données relationnelles), les données semi-structurées (par exemple, XML, JSON) et les données non structurées (par exemple, texte, images, vidéos). Exemples : données structurées (informations dans une base de données SQL), données semi-structurées (JSON de Twitter), données non structurées (texte de blogs).