

TP n°1 : Configuration et installation de Hadoop Cloudera

Matière : Introduction au Big Data

Classe : 1ère année MPSD

Enseignant : Mohamed Anouar DAHDEH



Objectifs:

Cet atelier a pour objectifs :

- Installation et configuration de l'environnement de virtualisation **VirtualBox**
- Installation et configuration de l'environnement **Hadoop** via la plateforme **Cloudera**
- Lancement et test de l'environnement **Hadoop**

1- Présentation

Cet atelier s'intéresse à **l'installation et la configuration d'un cluster Hadoop simple nœud (MonoNode)**. En effet, utiliser Hadoop dans un environnement simple nœud, comme nous allons le faire, n'a de sens que pour tester la configuration de l'installation ou fournir un environnement de développement MapReduce.

Pour utiliser **Hadoop** deux solutions sont disponibles. La première est d'utiliser la version proposée par la fondation Apache. Cette version est celle de référence et contient le noyau et quelques interfaces d'administration très simplifiée. La seconde solution est d'utiliser les distributions fournies par des entreprises qui font du service autour de **Hadoop**. Comme il y a une valeur ajoutée non négligeable, ces distributions fournissent des services payants. Sans être exhaustif, voici trois sociétés qui font de Hadoop leur spécialité :

- Cloudera : <http://www.cloudera.com/>
- Hortonworks : <http://hortonworks.com/>
- MapR Technologies : <http://www.mapr.com/>

Dans le cadre de cet atelier, nous utilisons la version gratuite de la distribution **Cloudera**. Elle fournit également des outils d'administration supplémentaires qui facilitent son usage.

2- Configuration requise pour exécuter un cluster simple nœud de Cloudera :


Cloudera fournit des machines virtuelles prêtes à l'emploi pour **VMware**, **VirtualBox** et **KVM flavors**. Ces machines virtuelles s'exécutent sur **Centos 6.x**. Les machines virtuelles « **Cloudera QuickStart (VMs)** » comprennent tout ce que vous devez essayer avec **CDH¹**, **Cloudera Manager²**, **Cloudera Impala³** et **Cloudera Search⁴**. Les machines virtuelles utilisent des packages préinstallés de CDH. Pour utiliser ces machines virtuelles, vous avez besoin de ces configurations suivantes :

- Un ordinateur (**votre laptop**) doté d'un système d'exploitation 64-bit (Ubuntu LTS 64 bits ou Windows 7 ou 10- 64bits) avec un outil de virtualisation qui supporte un système d'exploitation 64-bit.
- Outils de virtualisation : Virtual Box : <https://www.virtualbox.org/>
- RAM Requisite : Au minimum 8 Go de RAM.

3- Téléchargement de machine virtuelle

Lien : https://www.cloudera.com/downloads/quickstart_vms/5-13.html

Inscrivez-vous sur le site de **Cloudera** et téléchargez comme indique la figure suivante :



¹CDH contient les principaux éléments, de base du framework Hadoop (MapReduce et HDFS), ainsi que d'autres composants orientés vers les entreprises qui assurent la sécurité, la haute disponibilité, et l'intégration avec le matériel et les autres logiciels (HDFS & MapReduce, Impala, Apache Spark, HBase, Accumulo, Apache Kafka)


² **Cloudera Manager** est l'outil de confiance pour gérer Hadoop en production.

³ **Cloudera Impala** est intégrée à CDH et supportée par Cloudera Enterprise, Impala est une base de données analytique de traitement massivement parallèle (MPP) en open source.

⁴ **Cloudera Search** est un moteur de requête

4- Configuration de l'environnement de virtualisation :

a- Installation de VirtualBox




b- Importer la machine virtuelle téléchargée de Cloudera sous VirtualBox

L'archive contient deux fichiers comme suit en fonction de la version téléchargée par exemple la version 5.13.0.0

	cloudera-quickstart-vm-5.13.0-0-virtualbox.ovf	23/10/2017 16:29	Open Virtualizatio...	15 Ko
	cloudera-quickstart-vm-5.13.0-0-virtualbox-disk1.vmdk	23/10/2017 16:34	Virtual Machine Di...	5 810 349 Ko

Il y a plusieurs étapes dans le processus d'importation que l'on initie en cliquant sur le menu adéquat dans **VirtualBox** :



← Importer un appareil virtuel

Paramètres de l'appareil virtuel

Voici les machines virtuelles décrites dans l'appareil virtuel et les paramètres suggérés pour les machines importées. Vous pouvez en changer certains en double-cliquant dessus et désactiver les autres avec les cases à cocher.

Système virtuel 1	
Nom	cloudera-quickstart-vm-5.13.0-0-virtualbox
Système d'exploitation invité	Red Hat (64-bit)
Processeur	1
Mémoire vive	4096 Mio
DVD	☒
Carte réseau	☒ Intel PRO/1000 MT Desktop (82540EM)
Contrôleur de stockage (IDE)	PIIX4
Contrôleur de stockage (IDE)	PIIX4
Disque virtuel	cloudera-quickstart-vm-5.13.0-0-virtualbox-disk1.vmdk
Dossier de base	E:\Machine Virtuelle\MS
Groupe primaire	/

Vous pouvez modifier le dossier de base qui hébergera toutes les machines virtuelles. Les dossiers d'accueil peuvent aussi être modifiés individuellement (par machine virtuelle).

E:\Machine Virtuelle\MS 4

Politique d'adresse MAC : Induire uniquement les adresses MAC de l'interface réseau NAT

Options supplémentaires : ☒ Importer les disques durs comme VDI


L'appareil n'est pas signé

Valeurs par défaut 5 Importer Annuler



Etape 4 : Choix du dossier de destination du fichier contenant la machine virtuelle.

Attention, il faut prévoir de la place parce que sa taille va enfler considérablement au fil des opérations.

Etape 5 : Le processus d'importation est démarré lorsque l'on clique sur IMPORTER




La machine virtuelle est maintenant installée dans VirtualBox





Le fichier qui lui est associé fait plus de 9 Go ! Et ce n'est que le début.

c- Démarrage de la machine virtuelle




Attention : Le démarrage de la machine virtuelle peut prendre un certain temps


Remarque : Le message "vt-x is disabled in the bios" peut apparaître sur certains ordinateurs. La machine virtuelle n'est pas démarrée. Il faut alors activer la technologie de virtualisation d'Intel dans le BIOS du PC c.-à-d. le mettre à ENABLED.



Au démarrage de la machine, Hadoop est fonctionnel. Il n'y a pas de manipulations particulières à faire de ce côté-là.



Installation du clavier français pour les différentes manipulations ultérieures. Nous aurons à saisir des commandes dans un terminal notamment



Il faut cliquer sur ADD, puis sélectionner FRENCH et le choisir comme clavier par défaut.