

## TP n°5 : MapReduce

**Matière :** Introduction au Big Data

**Classe :** 1ère année MPSD

**Enseignant TP :** Mohamed Anouar DAHDEH



### Introduction

Vous travaillez chez Yahoo, et vous souhaitez développer les fonctionnalités d'indexation du moteur de recherche autour des livres.

L'objectif de cet atelier est de créer un job Java MapReduce capable d'analyser des textes de livres.

Tout d'abord commencez par télécharger, à partir de la plateforme le fichier zip contenant 3 livres (provenant du projet Gutenberg : <https://www.gutenberg.org/>)

### Travail à faire :

- 1- On souhaite réaliser un programme capable de collecter des informations sur les sentiments cités dans un livre à partir d'un vocabulaire donné. Le job MapReduce doit compter le nombre d'apparitions des mots "love" et "hate" dans un lot de donnée. On nommera la classe principale "BookMatcher".

Vous devriez trouver :

```
hate 11  
love 106
```

- 2- Afin d'établir des statistiques sur les livres, donnez les mots qui apparaissent le plus souvent en début de lignes dans les livres. On cherchera le mot qui apparaît le plus souvent. Vous modifierez le programme précédent, et renommerez la classe en "BookMatcherLine". Pensez à nettoyer les mots en enlevant tout caractère spéciaux (guillemet, virgules)

**Indice :** Pour ne garder que les caractères alpha-numériques, il suffit d'écrire en Java : `token = token.replaceAll("[^A-Za-z0-9]", "");`