

Fondements mathématiques des données scientifiques

MP1 DS

Chapitre I

Introduction à la statistique descriptive

Dorsaf OMRI

Année Universitaire 2023/2024

Introduction

Statistique descriptive:

Analyse et synthèse, **Numérique** et **Graphique** d'un
ensemble de **données**



But: Synthétiser l'information contenue dans les données

Origine: Etude démographique

→ Une science et un ensemble de techniques.

Introduction

La statistique consiste à :

- ▶ Recueillir des données.
- ▶ Présenter et résumer des données collectées.
- ▶ Tirer des conclusions sur la population étudiée → Aider à la prise de décision.
- ▶ Faire de la prévision, en présence de données dépendant du temps.

Outils utilisés:

- ▶ Tableaux (table des fréquences, ...)
- ▶ Graphiques (histogrammes,...)
- ▶ Indicateurs (moyenne, corrélation,...).



▶ 3

But de la statistique

→ Ensembles de méthode dont le but est de présenter les données pour que l'on puisse en prendre connaissance facilement.

▶ Cela peut concerner :

- ▶ une variable à la fois : **statistique à une dimension**,
- ▶ deux variables à la fois : **statistique à deux dimensions**,
- ▶ plus de deux variables à la fois : **statistique multidimensionnelle**.

▶ 4

Statistiques descriptives et inférentielles


Statistiques descriptives

Méthodes statistiques utilisées pour construire des tables, des graphiques et des résumés numériques des données.

Statistiques inférentielles

Tirer une conclusion (inférence) **objective** à propos d'une population.

► 5



► 6

Mesure et variable

► Des unités statistiques ou unités d'observation

Exemple: des individus, des entreprises, des ménages.

► Sur ces unités, on mesure un caractère ou une variable,

Exemple: le chiffre d'affaires de l'entreprise, le revenu du ménage, l'âge de la personne, ...

Les variables sont désignées par simplicité par une lettre (X,Y,Z).

- ❑ Les valeurs possibles de la variable, sont appelées modalités.
- ❑ L'ensemble des valeurs possibles ou des modalités est appelé le domaine de la variable.

► 7

Mesure et variable: Terminologie

► Population

Ensemble que l'on observe et qui sera soumis à une analyse statistique. Chaque élément de cet ensemble est un **individu** ou **unité statistique**.

► Echantillon

C'est un sous ensemble de la population considérée. Le nombre d'individus dans l'échantillon est la **taille** de l'échantillon.

► Caractère


C'est la propriété ou l'aspect singulier que l'on se propose d'observer dans la population ou l'échantillon. Un caractère qui fait le sujet d'une étude porte aussi le nom de **variable statistique**.

► Modalité

Les modalités d'une variable statistique sont les différentes valeurs que peut prendre celle-ci.

► 8


Mesure et variable: Terminologie



L'épreuve statistique est une expérience que l'on provoque

► 9

Différent types de variables statistiques



► 10

Typologie des variable

Variable qualitative

La variable est dite qualitative quand les modalités sont des catégories.

- ▶ Variable qualitative nominale : les modalités ne peuvent pas être ordonnées.
- ▶ Variable qualitative ordinale : les modalités peuvent être ordonnées.

Le fait de pouvoir ou non ordonner les modalités est parfois discutable.

Exemple :

'ouvriers', 'employés', 'cadres'.

Si on ajoute les modalités 'sans profession', 'enseignant', 'artisan', l'ordre devient beaucoup plus discutable.

▶ 11

Typologie des variable

Variable quantitative

Une variable est dite quantitative si toute ses valeurs possibles sont numériques.

- ▶ *Variable quantitative discrète* : Une variable est dite discrète, si l'ensemble des valeurs possibles est dénombrable.
- ▶ *Variable quantitative continue* : Une variable est dite continue, si l'ensemble des valeurs possibles est continu.

▶ 12

Typologie des variable

Exemple

Les modalités de la variable sexe sont *masculin* (codé M) et *féminin* (codé F). Le domaine de la variable est $\{M, F\}$.

Les modalités de la variable nombre d'enfants par famille sont 0, 1, 2, 3, 4, 5, ... C'est une variable quantitative discrète.

Remarques:

- ▶ Les variables statistiques sont analysées différemment selon leur nature (quantitative, qualitative).
- ▶ Pour faire des traitements statistiques, il arrive qu'on transforme une variable quantitative en variable qualitative.
- ▶ Les variables quantitatives peuvent être transformées en variable qualitative.

Variable quantitative	Modalités envisageables
Hauteur	Petit, Moyen, Grand
Poids	Très léger, Léger, Moyen, Lourd, Très lourd
Rendement	Faible, Moyen, Elevé

▶ 13

Série statistique

- ▶ Une suite des valeurs prises par une variable X sur les unités d'observation.
- ▶ Le nombre d'unités d'observation est noté n .
- ▶ Les valeurs de la variable X sont notées

$$x_1, x_2, \dots, x_i, \dots, x_n$$

- ▶ **Séries statistiques** (tout type de données) :

- ▶ Enumération des résultats :

- ▶ Exemples :

- Couleurs des cheveux : blond, brun, blond, noir
- Nombre d'enfants dans les familles : 1, 2, 1, 4, 0

- ▶ **Séries statistiques ordonnées** :

- ▶ Ne concernent que les données quantitatives et ordinales
- ▶ Enumération du plus petit au plus grand
 - Exemple : Nombre d'enfants : 0, 1, 1, 2, 4

▶ 14

Organisation des données

L'**effectif** : Nombre d'individus qui ont le même caractère

Caractère (x_i)	Effectif (n_i)
A (x_1)	n_1
B (x_2)	n_2
C (x_3)	n_3
D (x_4)	n_4

4 modalités

L'**effectif cumulé** N d'une valeur est la somme de l'effectif de cette valeur et de tous les effectifs des valeurs qui précèdent

$$\sum_{i=1}^K n_i = N$$

► 15

Organisation des données

- La **fréquence** : La proportion d'individus de la population ou de l'échantillon ayant même effectif: on la note f_i .
- La fréquence d'une valeur est le rapport de l'effectif de cette valeur par l'effectif total.

f_i et n_i sont liés par $f_i = \frac{n_i}{N}$

où N est le nombre total d'individus dans la population.

- **Remarque** : On peut remplacer f_i par $f_i \cdot 100$ qui représente alors un pourcentage

$$0 \leq f_i \leq 1 \quad \sum_{i=1}^K f_i = 1$$

► 16

Organisation des données

- ▶ La fréquence **cumulée** : Pour chaque valeur x_p on pose par définition

$$F_i = f_1 + f_2 + \dots + f_i$$

- ▶ La quantité F_i s'appelle la fréquence cumulée de x_i

▶ 17

Variable qualitative nominale

Effectifs, fréquences et tableau statistique


- ▶ Une variable qualitative nominale a des valeurs distinctes qui ne peuvent pas être ordonnées.
- ▶ On note N le nombre de valeurs distinctes ou modalités.
- ▶ Les valeurs distinctes : $x_1, x_2, \dots, x_N$
- ▶ L'effectif d'une modalité ou d'une valeur distincte: le nombre de fois que cette modalité (ou valeur distincte) apparaît.

▶ 18

Variable qualitative nominale

Diagramme en secteurs et diagramme en barres

- ▶ Les effectifs sont représentés par un diagramme en barres.
- ▶ Les fréquences par un diagramme en secteurs ou camembert.



▶ 19

Variable qualitative ordinale

- ▶ Les valeurs distinctes d'une variable ordinale peuvent être ordonnées:

$$x_1 < x_2 < \dots, x_{N-1} < x_N$$

x_1 précède x_2

- ▶ Effectifs cumulés:

$$N_j = \sum_{k=1}^j n_k, j = 1, \dots, N$$

- ▶ Fréquences cumulées

$$F_j = \frac{N_j}{N} = \sum_{k=1}^j f_k, j = 1, \dots, N$$

▶ 20

Variable qualitative ordinaire

Exemple

On interroge 50 personnes sur leur dernier diplôme obtenu (variable X). On obtient:

Série statistique de la variable X

SD SD SD SD P P P P P P P P SE SE
SE SE SE SE SE SE SE SE SE SE SE SU
SU SU SU SU SU SU SU SU U U U U U
U U U U U

Codification de la variable X

Dernier Diplôme	x_j
Sans Diplôme	SD
Primaire	P
Secondaire	SE
Supérieur non-universitaire	SU
Universitaire	U

Tableau statistique

x_j	n_j	N_j	f_j	F_j
SD	4	4	0.08	0.08
P	11	15	0.22	0.30
SE	14	29	0.28	0.58
SU	9	38	0.18	0.76
U	12	50	0.24	1
	50		1	

► 21

Variable qualitative ordinaire

Diagramme en secteurs en fréquence






Diagramme en barres des effectifs



► 22

Variable qualitative ordinale

Diagramme en barres des effectifs cumulés



► 23

Variable quantitative discrète

Le tableau statistique

Une variable discrète à un domaine dénombrable

Exemple:

- Un quartier est composé de 50 familles, et la variable X représente le nombre de personnes par famille.


1	1	1	1	1	2	2	2	2	2
2	2	2	2	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	4
4	4	4	4	4	4	4	4	4	5
5	5	5	5	5	6	6	6	8	8

- Donner le tableau statistique.

► 24

Variable quantitative discrète

► Diagramme en batônnets des effectifs




► 25

Variable quantitative discrète

Fonction de répartition

Les fréquences cumulées sont représentées au moyen de la fonction de répartition.

$$F(x) = \begin{cases} 0 & , x < x_1 \\ F_j & , x_j \leq x < x_{j+1} \\ 1 & , x_j \leq x \end{cases}$$



► 26

Variable quantitative continue

- ▶ Dans le cas des variables quantitatives continues les données sont groupées en **classes**.
- ▶ A la différence des variables quantitatives discrètes, une classe donnée ne contient pas une seule valeur mais une infinité de valeurs possibles sur un intervalle défini: **Intervalle de classe**.
- ▶ Cet intervalle permet de définir
 - ❑ **Une amplitude de classe**
 - ❑ Une valeur centrale de la classe: **Centre de classe**.
- La répartition des données brutes en classes nécessite de faire un choix sur le nombre de classes et donc sur l'amplitude.
- Ce choix doit être suffisamment judicieux pour permettre la représentation graphique des données sans perdre trop d'information initialement contenue dans la série statistique.

▶ 27

Variable quantitative continue

Les classes

- ▶ La répartition en classes des données nécessite de définir le nombre de classes N et l'amplitude de chaque classe.
- ▶ En règle générale, on choisit au moins cinq classes de même amplitude.
- ▶ Il existent des formules qui permettent d'établir le nombre de classes et l'intervalle de classe (l'amplitude) pour une série statistique de n observations.
 - La règle de Sturge : $N = 1 + (3.3 \log_{10}(n))$
 - La règle de Yule : $N = 2.5 \sqrt[4]{n}$

Dans les deux cas, on arrondit à l'entier le plus proche, car un nombre de classes doit être un entier

▶ 28

Variable quantitative continue

Les classes

- ▶ L'intervalle de classe est obtenue ensuite de la manière suivante :

$$\text{Longueur de l'intervalle} = (x_{\max} - x_{\min})/N$$

ou $x_{\max}$ (resp. $x_{\min}$) désigne la plus grande (resp. la plus petite) valeur observée.

- ▶ Par commodité, on peut arrondir la valeur obtenue de l'intervalle de classe.
- ▶ A partir de la plus petite valeur observée, on obtient les bornes de classes en additionnant successivement l'intervalle de classe (l'amplitude).

▶ 29

Variable quantitative continue

Tableau statistique

- ▶ Si $[c^{-j}; c^{+j}[$ désigne la classe j , on note,
 - c^{-j} la borne inférieure de la classe j ,
 - c^{+j} la borne supérieure de la classe j ,
 - $c_j = (c^{+j} + c^{-j})/2$ le centre de la classe j ,
 - $a_j = c^{+j} - c^{-j}$ l'amplitude de la classe j ,
 - n_j l'effectif de la classe j ,
 - N_j l'effectif cumulé de la classe j ,
 - f_j la fréquence de la classe j ,
 - F_j la fréquence cumulée de la classe j .

▶ 30

Variable quantitative continue

► Exemple

On mesure la taille en centimètres de 50 élèves d'une classe

152	152	152	153	153
154	154	154	155	155
156	156	156	156	156
157	157	157	158	158
159	159	160	160	160
161	160	160	161	162
162	162	163	164	164
164	164	165	166	167
168	168	168	169	169
170	171	171	171	171

$[c_j^-, c_j^+]$	n_j	N_j	f_j	F_j
$[151, 5; 155, 5[$	10	10	0.20	0.20
$[155, 5; 159, 5[$	12	22	0.24	0.44
$[159, 5; 163, 5[$	11	33	0.22	0.66
$[163, 5; 167, 5[$	7	40	0.14	0.80
$[167, 5; 171, 5[$	10	50	0.20	1.00
	50		1.00	

► 31

Variable quantitative continue

Histogramme

- L'histogramme consiste à représenter les effectifs (resp. les fréquences) des classes par des rectangles contigus dont la surface (et non la hauteur) représente l'effectif (resp. la fréquence).
- Pour un histogramme des effectifs, la hauteur du rectangle correspondant à la classe j est donnée par

$$h_j = \frac{n_j}{a_j} \quad d_j = \frac{f_j}{a_j}$$


h_j : Densité d'effectif
 d_j : Densité de fréquence

- L'aire de l'histogramme est égale à l'effectif total n , puisque l'aire de chaque rectangle est égale à l'effectif de la classe j : $a_j \times h_j = n_j$ ($a_j \times d_j = f_j$)

► 32

Variable quantitative continue

► Histogramme des fréquences




► 33

Variable quantitative continue

► Polygone des fréquences

Le polygone des fréquences est représenté en joignant les milieux des cotés supérieurs des rectangles dans un histogramme.

C'est une ligne brisée dont les extrémités rejoignent l'axe des abscisses.




► 34

Variable quantitative continue

La courbe cumulative (ou polygone des fréquences cumulées) est obtenue:

- ▶ En portant les points:
 - Les abscisses représentent la borne supérieure de chaque classe
 - Les ordonnées les fréquences cumulées correspondantes,
- ▶ En reliant ces points par des segments de droite.



▶ 35

Variable quantitative continue

- ▶ La fonction de répartition

$F(b_0)$	=	0	=	$f] - \infty; b_0]$
$F(b_1)$	=	f_1	=	$f] - \infty; b_1]$
$F(b_2)$	=	$f_1 + f_2$	=	$f] - \infty; b_2]$
...	.	...	.	...
$F(b_{k-1})$	=	$f_1 + f_2 + \dots + f_{k-1}$	=	$f] - \infty; b_{k-1}]$
$F(b_k)$	=	1	=	$f] - \infty; \infty[$

Pour $x \leq b_0$,	$F(x)$	=	$f] - \infty; b_0]$	=	0
Pour $b_0 \leq x \leq b_1$,	$F(x)$	=	$f] - \infty; b_0] + f] b_0; x]$	=	$F(b_0) + \frac{x-b_0}{b_1-b_0} f_1$
Pour $b_1 \leq x \leq b_2$,	$F(x)$	=	$f] - \infty; b_1] + f] b_1; x]$	=	$F(b_1) + \frac{x-b_1}{b_2-b_1} f_2$
...	..	.	...	.	...
Pour $b_{k-1} \leq x \leq b_k$,	$F(x)$	=	$f] - \infty; b_{k-1}] + f] b_{k-1}; x]$	=	$F(b_{k-1}) + \frac{x-b_{k-1}}{b_k-b_{k-1}} f_k$
Pour $b_k \leq x$	$F(x)$	=	$f] - \infty; \infty[$	=	1

▶ 36

Variable quantitative continue

► La fonction de répartition

$$F(x) = \begin{cases} 0 & , x < c_1^- \\ F_{j-1} + \frac{(x - c_j^-)}{c_j^+ - c_j^-} f_j & , c_j^- \leq x < c_j^+ \\ 1 & , c_j^+ \leq x \end{cases}$$

