



Fondements mathématiques des données scientifiques

MP1 DS

Chapitre III

Statistique descriptive à deux caractères

Dorsaf OMRI

Année Universitaire 2023/2024

Introduction

Série statistique simple = ensemble de données relatives à une variable mesurée sur un échantillon ou une population d'éléments

Série statistique double = ensemble de couples de données relatives à deux variables mesurées sur un échantillon ou une population d'éléments

Série statistique multiple = ensemble de multiples de données relatives à plusieurs variables mesurées sur un échantillon ou une population d'éléments

Définition

- ▶ Soit une population d'effectif n , si on étudie deux caractères X et Y de cette population, on dit que l'on étudie une série statistique double.

- ▶ A chaque individu i correspond un couple $(x_i ; y_i)$
 - x_i est la modalité du caractère X
 - y_i est la modalité du caractère Y

L'ensemble des couples $(x_i ; y_i)$ définit une **série statistique à deux variables**

- ▶ Lorsque l'un des deux caractères est une année, une date, on dit que la série statistique double est une **série chronologique**

▶ 3

Série statistique bivariée

Deux variables X et Y .

- ▶ Les deux variables sont mesurées sur les N unités d'observation.
- ▶ $x_1, x_2, \dots, x_k$: les valeurs distincts observées pour X
- ▶ $y_1, y_2, \dots, y_l$: les valeurs distincts observées pour Y
- ▶ Les valeurs distinctes observées pour X et Y sont ordonnées dans l'ordre croissant.
- ▶ Pour chaque unité, on obtient donc deux mesures.
- ➔ La série statistique est une suite de n couples des valeurs prises par les deux variables sur chaque individu.

$$(x_1, y_1), \dots, (x_k, y_l)$$

▶ 4

Exemple

Objectif: Suivre l'évolution de l'espérance de vie à la naissance (en année) en Tunisie de 2000 à 2008 pour les femmes

Année	2000	2001	2002	2003	2004	2005	2006	2007	2008
Espérance de vie	80	81	79	81	80	80	78	81	80

Population : les femmes en Tunisie

Caractère n°1 : l'année

Caractère n°2 : l'espérance de vie

► 5

Effectifs

N_{ij} représente l'effectif des individus de la population qui possèdent à la fois la valeur x_i de la variable X et la valeur y_j de la variable Y.

Total des effectifs de la ligne i → Effectif total des individus qui possèdent la valeur x_i de la variable X (indépendamment de la valeur y_j de la variable Y)

$$N_{i\bullet} = N_{i1} + N_{i2} + \dots + N_{il} = \sum_{j=1}^l N_{ij}$$

Total des effectifs de la colonne j → Effectif total des individus qui possèdent la valeur y_j de la variable Y (indépendamment de la valeur x_i de la variable X)

$$N_{\bullet j} = N_{1j} + N_{2j} + \dots + N_{kj} = \sum_{i=1}^k N_{ij}$$

$$N = \sum_{i=1}^k \sum_{j=1}^l N_{ij} = \sum_{i=1}^k N_{i\bullet} = \sum_{j=1}^l N_{\bullet j}$$

► 6

Tableau de contingence

X \ Y	y	y ₂	...	y _j	...	y _l	Total
x ₁	N ₁₁	N ₁₂		N _{1j}		N _{1l}	N _{1.}
x ₂	N ₂₁	N ₂₂		N _{2j}		N _{2l}	N _{2.}
.			...		...	.	.
.						.	.
x _i	N _{i1}	N _{i2}		N _{ij}		N _{il}	N _{i.}
.	.	.		.		.	.
.	.	.		.		.	.
.	.	.		.		.	.
x _k	N _{k1}	N _{k2}		N _{kj}		N _{kl}	N _{k.}
Total	N _{.1}	N _{.2}	...	N _{.j}	...	N _{.l}	N

► 7

Fréquence ou pourcentage

La fréquence du couple (x_i, y_j) observée sur l'ensemble de la population est:

$$f_{ij} = \frac{N_{ij}}{N}$$

- Fréquence conjointe

$$f_{ij} = \frac{N_{ij}}{N}$$

- Total des fréquences conjointes de la ligne i

$$f_{i\bullet} = \frac{N_{i\bullet}}{N} = \sum_{j=1}^l f_{ij}$$

- Total des fréquences conjointes de la ligne j

$$f_{\bullet j} = \frac{N_{\bullet j}}{N} = \sum_{i=1}^k f_{ij}$$

► 8

Distribution marginale des variables X et Y

Les sommes des effectifs ou des fréquences **en lignes** (respectivement **en colonnes**) définissent la distribution marginale (d'effectifs ou de fréquences) de la variable X (respectivement de la variable Y)

Distribution marginale de X	Valeurs de X (x_i)	Effectifs marginaux	Fréquences marginales
	x_1	$N_{1.}$	$f_{1.}$
	x_2	$N_{2.}$	$f_{2.}$
	.	.	.
	.	.	.
	.	.	.
	x_i	$N_{i.}$	$f_{i.}$
	.	.	.
	.	.	.
	x_k	$N_{k.}$	$f_{k.}$
	Total	N	1

Distribution marginale de Y	Valeurs de Y (y_i)	Effectifs marginaux	Fréquences marginales
	y_1	$N_{.1}$	$f_{.1}$
	y_2	$N_{.2}$	$f_{.2}$
	.	.	.
	.	.	.
	.	.	.
	y_j	$N_{.j}$	$f_{.j}$
	.	.	.
	.	.	.
	y_l	$N_{.l}$	$f_{.l}$
	Total	N	1

► 9

Distribution des effectifs et des fréquences

Deux variables X et Y.

- Les deux variables sont mesurées sur les **N** unités d'observation.
- $x_1, x_2, \dots, x_k$: les valeurs distinctes observées pour X
- $y_1, y_2, \dots, y_l$: les valeurs distinctes observées pour Y

$$\left((x_i, y_j), N_{ij} \right)_{\substack{i=1, \dots, k \\ j=1, \dots, l}} \quad \text{Distribution des effectifs du couple (X,Y)}$$

$$\left((x_i, y_j), f_{ij} \right)_{\substack{i=1, \dots, k \\ j=1, \dots, l}} \quad \text{Distribution des fréquences du couple (X,Y)}$$

► 10

Distribution conditionnelle

- ▶ Lorsqu'on ne considère qu'une colonne (colonne j) du tableau de distribution conjointe de X et Y, on obtient une distribution à une dimension appelée distribution conditionnelle ou liée à X sous la condition $Y=y_j$ ou encore distribution X sachant $Y=y_j$

- ▶ La fréquence Conditionnelle de x_i sachant y_j est:

$$f_{i/j} = f(x_i / y_j) = \frac{N_{ij}}{N_{\bullet j}} = \frac{f_{ij}}{f_{\bullet j}}$$

Distribution conditionnelle
de x sachant y_j

Valeurs de X (x_i)	Effectifs conditionnels	Fréquences conditionnelles
x_1	N_{1j}	$f_{1/j}$
x_2	N_{2j}	$f_{2/j}$
.	.	.
.	.	.
.	.	.
x_i	N_{ij}	$f_{i/j}$
.	.	.
.	.	.
.	.	.
x_k	N_{kj}	$f_{k/j}$
Total	N	1

▶ 11

Représentations graphiques bivariées

- ▶ Le mode de représentation graphique d'une série à deux dimensions dépend de la nature de chacun des caractères: qualitatifs, quantitatifs discrets ou continus.
- ▶ Il existe une grande diversité de représentations graphiques des distributions statistiques à deux caractères:
 - Cas de deux caractères qualitatifs;
 - Cas d'un caractère quantitatif et d'un caractère qualitatif;
 - Cas de deux caractères quantitatifs.

▶ 12

Représentations graphiques bivariées

Cas de deux caractères qualitatifs

- a) **Distributions marginales:** Lorsque nous croisons deux caractères qualitatifs, la représentation graphique d'une distribution marginale est réalisée à l'aide d'un diagramme à barres ou à points vertical (ou horizontal) d'un diagramme circulaire.
- b) **Distributions conditionnelles:** La distribution graphique des distributions conditionnelles est réalisée à l'aide d'un diagramme à barres juxtaposées ou d'un diagramme à barres empilées. Ce type de représentation a pour avantage de pouvoir comparer rapidement les différentes distributions en particulier savoir si elles sont homogènes ou non.

► 13



Représentations graphiques bivariées

Cas d'un caractère quantitatif et d'un caractère qualitatif

- a) **Distributions marginales:** Pour le caractère quantitatif, discret ou continu, la représentation graphique de la distribution marginale est réalisée à l'aide d'un diagramme en bâtons ou d'un histogramme selon que la distribution est groupée ou non groupée. Pour le caractère qualitatif, la représentation graphique de la distribution marginale est réalisée à l'aide d'un diagramme à barres ou à points vertical (ou horizontal) ou d'un diagramme circulaire.
- b) **Distributions conditionnelles:** Selon la modalité du caractère qualitatif, la représentation graphique des distributions conditionnelles est réalisée à l'aide des diagrammes en bâtons et d'histogrammes selon que la distribution quantitative, discrète ou continue, est groupée. Sachant les classes du caractère quantitatif, la représentation graphique des distributions conditionnelles est réalisée à l'aide d'un diagramme à barres juxtaposées ou d'un diagramme à barres empilées.

► 14

Représentations graphiques bivariées


Cas de deux caractères quantitatifs

- a) **Distributions marginales:** La représentation graphique est réalisée à l'aide de diagrammes en bâtons ou d'histogrammes selon que les caractères sont quantitatifs discrets ou continus.
- b) **Distributions conditionnelles:** La représentation graphique est réalisée à l'aide de diagrammes en bâtons ou d'histogrammes selon que les caractères sont quantitatifs discrets ou continus.
- c) **Distribution conjointe:** Lorsque nous disposons d'une distribution groupée et du tableau de contingence associé, la représentation graphique de la loi jointe est réalisée à l'aide d'un stéréogramme. Dans le cas des données brutes, nous représentons le diagramme de dispersion.

► 15

Représentations graphiques bivariées

Le tableau croisé est traduit dans une figure appelée "le nuage de points" ou "diagramme de dispersion". Cette représentation est obtenue en mettant dans un repère cartésien chaque couple d'observation (x_i, y_i) par un point.




► 16

Représentations graphiques bivariées

Exemple

nombre d'écrans \ nombre de voitures	0	1	2	3	4	5	6	7	8
0	2	2	1	2	0	0	1	0	0
1	1	4	3	2	2	3	3	1	1
2	0	0	1	0	0	2	2	2	1
3	0	0	0	1	0	0	1	1	0
4	0	0	0	0	1	0	0	0	0



► 17

Paramètres: Centre de gravité

Centre de gravité

=


centroïde (d'une série statistique $\{x_i, y_i\}$)

=

point dont les coordonnées sont les moyennes de chacun des coordonnées

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_N}{N} = \frac{\sum_{i=1}^N X_i}{N}$$

$$\bar{Y} = \frac{Y_1 + Y_2 + \dots + Y_N}{N} = \frac{\sum_{i=1}^N Y_i}{N}$$



► 18

Paramètres: Médiane, Mode et Quartiles

Médiane: n'a pas de sens pour une série statistique double car elle demande de classer préalablement tous les éléments de la série. Or, il n'y a pas de relation d'ordre naturelle en 2D

Mode: la zone du plan correspondant au maximum de densité d'éléments. Ce paramètre a les mêmes défauts que le mode d'une série statistique unidimensionnelle.

Quartile: Pour les mêmes raisons que dans le cas de la médiane, on ne peut pas définir de quartiles

► 19

Mesure de la liaison entre deux variables

- L'un des intérêts de l'étude simultanée de deux caractères est l'analyse des variations communes afin de détecter l'**existence** ou non d'**une dépendance**.
- Les cas suivants peuvent se présenter :
 - Les variations des deux caractères n'ont **aucun lien** entre elles
 - Les deux variables sont rigoureusement liées. On parle de **liaison fonctionnelle**.
 - Les deux variables **évoluent globalement** dans le même sens (ou en sens contraire) sans être **liées rigoureusement**

► 20

Mesure de la liaison entre deux variables

Il existe des indicateurs permettant de mesurer le niveau de la relation entre deux variables. Parmi ces indicateurs, on a :

- ❖ La covariance
- ❖ Le coefficient de corrélation
- ❖ Le khi-deux (distance du khi-deux)

► 21

Mesure de la liaison entre deux variables

- On dit que deux variables statistiques X et Y sont indépendantes si la réalisation de n'importe quel résultat de X n'influence d'aucune façon celle d'un résultat quelconque pour Y .
- En considérant le tableau de contingence de X et Y et les distributions conditionnelles de X et Y , l'indépendance de X et Y se traduit par le résultat suivant:

Pour i et j , la fréquence conditionnelle f_{ij} est égale à la fréquence marginale f_{ij}

$$f_{i|j} = f_{i\bullet} \Rightarrow f_{ij} = f_{i\bullet} \cdot f_{\bullet j}$$

► 22

Paramètres: Variance


Comme pour les séries simples, il est possible de calculer la variance pour chacune des coordonnées de la série.

$$\sigma_X^2 = \frac{\sum_{i=1}^N (X_i - \bar{X})^2}{N} \quad \sigma_Y^2 = \frac{\sum_{i=1}^N (Y_i - \bar{Y})^2}{N}$$

► 23

Paramètres: Variance

Mais est-ce satisfaisant ?



► 24

Paramètres: Covariance

On introduit un nouveau paramètre pour traduire cette tendance d'une variation conjointe des deux données : la covariance




$$\sigma_{XY} = \frac{\sum_{i=1}^N (x_i - \bar{X})(y_i - \bar{Y})}{N}$$

Après transformation cette formule s'écrit:

$$\sigma_{XY} = \frac{1}{N} \sum_{i=1}^N x_i y_i - \bar{X}\bar{Y}$$

► 25

Paramètres: Covariance



► 26

Paramètres: Covariance

Remarque : La nullité de la covariance n'implique pas forcément l'indépendance entre X et Y.

Exemple:

X	-2	-1	0	1	2
Y	2	1	0	1	2

Dans cet exemple on a $\text{Cov}(X, Y) = 0$ alors qu'il existe une relation fonctionnelle entre X et Y du type $Y = |X|$

► 27


Paramètres: Coefficient de corrélation

Coefficient de corrélation linéaire =

Rapport de la covariance sur les écarts-types de chacune des variables

$$r = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

r est entre -1 et 1



► 28

Matrice de covariance

- (1) La variance est un cas particulier de covariance avec $X=Y$
- (2) $\sigma_{XY} = \sigma_{YX}$

→ Combiner ces informations dans une seule structure : la matrice de covariance

$$\begin{bmatrix} \sigma_X^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_Y^2 \end{bmatrix}$$

► 29

Matrice de covariance

Si les deux variables ont tendance à varier indépendamment et non plus conjointement.

Quantitativement : $\sigma_{XY} = 0$

Nous avons donc diagonalisé la matrice de covariance

$$\begin{bmatrix} \sigma_X^2 & 0 \\ 0 & \sigma_Y^2 \end{bmatrix}$$

► 30

Distance de khi-deux et indépendance entre 2 variables

La distance du khi-deux est définie par:

$$D = \sum_{i=1}^k \sum_{j=1}^l \frac{(f_{ij} - f_{i\bullet} f_{\bullet j})^2}{f_{i\bullet} f_{\bullet j}}$$

Ou encore

$$D = \sum_{i=1}^k \sum_{j=1}^l \frac{\left(\frac{N_{ij}}{N} - \frac{N_{i\bullet} N_{\bullet j}}{N^2} \right)^2}{\frac{N_{i\bullet} N_{\bullet j}}{N^2}}$$

Effectif observé ← (N_{ij})

Effectif attendu (pas de dépendance) (N_{i•} N_{•j} / N)

→ Mesure le degré de liaison entre deux caractères qualitatifs X et Y:
Coefficient d'association

► 31

Distance de khi-deux et indépendance entre 2 variables: Exemple

Un sondage est réalisé sur 400 individus pour savoir si les individus sont pour ou contre les normes de sécurité dans l'aéroport en fonction de l'âges.

	Age				Total
	18-29	30-49	50-54	+65	
Favorable	57	66	77	87	287
Défavorable	43	34	23	13	113
Total	100	100	100	100	400

► 32

Distance de khi-deux et indépendance entre 2 variables: Exemple

	Age				
	18-29	30-49	50-54	+65	
Favorable	71,75	71,75	71,75	71,75	$\frac{100 \times 287}{400} = 71,75$
Défavorable	28,25	28,25	28,25	28,25	

	Age				
	18-29	30-49	50-54	+65	
Favorable	3,03	0,46	0,38	3,24	$\frac{(57 - 71,75)^2}{71,75} = 3,03$
Défavorable	7,70	1,17	0,98	8,23	

Distance de Khi-deux $3,03 + 0,46 + 0,38 + 3,24 + 7,7 + 1,17 + 0,98 + 8,23 = 25,20$

► 33

Distance de khi-deux et indépendance entre 2 variables

La distance du khi-deux vaut 0 si les variables X et Y sont indépendantes. En effet, si X et Y sont indépendantes:

$$f_{ij} = f_{i.} \cdot f_{.j}$$

Et donc pour tous i et j

$$f_{ij} - f_{i.} \cdot f_{.j} = 0$$

► 34

Régression

- ▶ Une population d'individus (êtres humains, animaux, pays, biens de consommation...) qui peuvent être décrits selon plusieurs critères appelés *variables*.
- ▶ Certaines variables peuvent être plus difficiles à mesurer que d'autres, pour des raisons techniques, des raisons d'accès (données publiques contre données privées), ou encore du fait d'un délai important entre la mise en place d'une expérience et son aboutissement.

→ On souhaite estimer ces variables (dites *expliquées*) à partir des données plus faciles à obtenir (dites *explicatives*).

La régression consiste à formuler un indicateur sur les valeurs de la variable ***expliquée*** dépendant uniquement des valeurs des variables ***explicatives***.

Cet indicateur pourra ensuite être utilisé sur une population pour laquelle on ne connaît que les valeurs des variables explicatives, afin d'estimer les valeurs de la variable expliquée.

▶ 35

Régression linéaire

- ▶ Un modèle de **régression linéaire** est un modèle de régression qui cherche à établir une relation linéaire entre une variable, dite expliquée, et une ou plusieurs variables, dites explicatives.
- ▶ On parle aussi de **modèle linéaire** ou de **modèle de régression linéaire**.
- ▶ Parmi les modèles de régression linéaire, le plus simple est l'ajustement affine.
- ▶ L'ajustement affine consiste à rechercher la droite permettant d'expliquer le comportement d'une variable statistique y comme étant une fonction affine d'une autre variable statistique x .

▶ 36

Ajustements affines

- ▶ On peut avoir besoin d'effectuer une approximation du nuage par une courbe, dépendant de sa distribution (sa « forme »).
- ▶ Cette approximation est appelée **ajustement**.
- ▶ Un **ajustement affine** est la détermination d'une droite approchant au mieux un nuage de points dans le plan.
- ▶ Des ajustements par des fonctions affines: n'a un sens que lorsque le nuage de points semble distribué le long d'une droite.
 - ❖ Ajustement affine par la droite de Mayer
 - ❖ Ajustement affine par la méthode des moindres carrés

▶ 37

Ajustement affine par la droite de Mayer

Principe:

- ▶ Partager le nuage de points en deux groupes (choisis en fonction de la forme du nuage, très souvent, on partage le nuage en deux groupes de points de même effectif).
- ▶ Chacun de ces nouveaux nuages admet un point moyen (G_1 pour le premier nuage, G_2 pour le second).
- ▶ La droite (G_1G_2), appelée **droite de Mayer**, constitue alors une approximation du nuage.

Remarque:

- La droite de Mayer d'un nuage dépend de la façon dont on forme les deux groupes de points
- Le point moyen du nuage (G) se trouve sur la droite de Mayer, quel que soit le regroupement effectué.

▶ 38

Ajustement affine par la droite de Mayer

Exemple I

	Premier groupe					Deuxième groupe				
Frais de publicité x_i	6	6,5	6,5	7	8	9	10	11	11	11,5
Chiffre d'affaires y_i	220	228	222	240	244	246	250	259	268	262

Calcul de G_1

$$G_1 \begin{cases} x = \frac{6+6,5+6,5+7+8}{5} \approx 6,8 \\ y = \frac{220+228+222+240+244}{5} \approx 230,8 \end{cases}$$

Calcul de G_2

$$G_2 \begin{cases} x = \frac{9+10+11+11+11,5}{5} \approx 10,5 \\ y = \frac{246+250+259+268+262}{5} = 257 \end{cases}$$

► 39

Ajustement affine par la droite de Mayer

L'équation de la droite $(G_1 G_2)$ est de la forme: $y = a x + b$

$$\text{Avec } \begin{cases} a = \frac{y_{G_2} - y_{G_1}}{x_{G_2} - x_{G_1}} = \frac{257 - 230,8}{10,5 - 6,8} \approx 7,08 \\ b = y_{G_1} - a x_{G_1} = 230,8 - 7,08 \times 6,8 = 182,7 \end{cases}$$

On peut également utiliser les coordonnées du point G_2 pour le calcul de b .

L'équation de la droite $(G_1 G_2)$ est: $y = 7,08 x + 182,7$

Vérification du point moyen $G(8,65; 243,9)$


Pour $x = 8,65$, on a : $y = 7,08 \times 8,65 + 182,7 = 243,9$

Les coordonnées du point G vérifient l'équation de la droite $(G_1 G_2)$.

Le point G est donc un point de la droite $(G_1 G_2)$.

► 40


Ajustement affine par la droite de Mayer



Ajustement affine par la droite de Mayer

Exemple 2: Recensement de la population d'une ville

année	1993	1995	1999	2002	2004	2006	2009
nombre d'années x_i depuis 1992	1	3	7	10	12	14	17
population y_i (en milliers d'habitants)	4,4	4,7	4,8	4,9	5,5	5,5	5,7




- 1) Calculer les coordonnées des point G1 et G2
- 2) Donner l'équation de la droite de Mayer
- 3) Donner une estimation de la population en 2012

Ajustement affine par la méthode des moindres carrés

Principe:


La méthode des moindres carrés consiste à projeter l'ensemble des points M_i de coordonnées (x_i, y_i) sur une courbe, parallèlement à l'axe des ordonnées, de telle sorte que l'ensemble des écarts entre les points observés M_i et les points projetés P_i soient les plus faibles possibles.



► 43

Ajustement affine par la méthode des moindres carrés

- L'objectif est de choisir la droite « $ax+b$ » de telle sorte que la somme des carrés des « distances » entre les points du nuage et la droite soit la plus petite possible.



► 44

Ajustement affine par la méthode des moindres carrés

Minimisation de l'erreur

Le nuage $(X_i, Y_i)_{i=1, \dots, n}$:

$$\begin{aligned} \{Droites\} &\rightarrow \mathcal{R} \\ D &\rightarrow \sum_i e_i^2 = \sum_i (y_i - ax_i - b)^2 \end{aligned}$$

Une droite D non parallèle à l'axe OY étant déterminée par son coefficient directeur a et son ordonnée à l'origine b , on peut plutôt considérer l'application suivante

$$\begin{aligned} \phi : \mathcal{R}^2 &\rightarrow \mathcal{R} \\ (a, b) &\rightarrow \sum_i (y_i - ax_i - b)^2 \end{aligned}$$

► 45

Ajustement affine par la méthode des moindres carrés

Minimisation de l'erreur

Minimiser l'erreur $\rightarrow$ Déterminer le (ou les) point(s) critique(s) de ϕ

$$\begin{aligned} \rightarrow \text{Résoudre} \quad &\begin{cases} \frac{\partial \phi}{\partial a}(a, b) = 0 \\ \frac{\partial \phi}{\partial b}(a, b) = 0 \end{cases} \Rightarrow \begin{cases} -2 \sum_i x_i (y_i - ax_i - b) = 0 \\ -2 \sum_i (y_i - ax_i - b) = 0 \end{cases} \\ &\Rightarrow \begin{cases} \sum_i x_i y_i - a \sum_i x_i^2 - b \sum_i x_i = 0 \\ \sum_i y_i - a \sum_i x_i - bn = 0 \end{cases} \end{aligned}$$

► 46

Ajustement affine par la méthode des moindres carrés

Minimisation de l'erreur

$$\begin{aligned} \begin{cases} \bar{x} = \frac{1}{n} \sum_i x_i \\ \bar{y} = \frac{1}{n} \sum_i y_i \end{cases} &\Rightarrow \begin{cases} \sum_i x_i y_i - a \sum_i x_i^2 - nb\bar{x} = 0 \\ \bar{y} - a\bar{x} - b = 0 \end{cases} \\ &\Rightarrow \begin{cases} \sum_i x_i y_i - a \sum_i x_i^2 - (\bar{y} - a\bar{x})n\bar{x} = 0 \\ b = \bar{y} - a\bar{x} \end{cases} \end{aligned}$$

► 47

Ajustement affine par la méthode des moindres carrés

Minimisation de l'erreur

$$a = \frac{\sum_i x_i y_i - n\bar{x}\bar{y}}{\sum_i x_i^2 - n\bar{x}^2} = \frac{\frac{1}{n} \sum_i x_i y_i - \bar{x}\bar{y}}{\frac{1}{n} \sum_i x_i^2 - \bar{x}^2} = \frac{\text{cov}(x, y)}{\text{var}(x)}$$

→ Un point critique (a; b)

→ un extremum?

Le point critique obtenu est-il un minimum?

La matrice hessienne

► 48

Ajustement affine par la méthode des moindres carrés

Minimisation de l'erreur

- ▶ La matrice hessienne (ou la hessienne) d'une fonction numérique f est la matrice carrée, notée $H(f)$, de ses dérivées partielles secondes.

$$H_{(a,b)} = \begin{pmatrix} \frac{\partial^2 \varphi}{\partial a^2}(a,b) & \frac{\partial^2 \varphi}{\partial a \partial b}(a,b) \\ \frac{\partial^2 \varphi}{\partial a \partial b}(a,b) & \frac{\partial^2 \varphi}{\partial b^2}(a,b) \end{pmatrix} = \begin{pmatrix} 2 \sum_i x_i^2 & 2 \sum_i x_i \\ 2 \sum_i x_i & 2n \end{pmatrix}$$
$$\Rightarrow \begin{cases} \text{Tr}(H_{(a,b)}) = \sum_i h_{ii} = 2 \sum_i x_i^2 + 2n > 0 \\ \det(H_{(a,b)}) = 4n \sum_i x_i^2 - 4 \left(\sum_i x_i \right)^2 = 4n \sigma_x^2 > 0 \end{cases}$$

▶ 49

Ajustement affine par la méthode des moindres carrés

Minimisation de l'erreur

- ▶ $(a,b) \rightarrow$ un minium
- ▶ La droite $y=ax+b$ minimise l'erreur
- ▶ La droite passe au milieu du nuage

▶ 50

Ajustement affine par la méthode des moindres carrés


La solution:

- la pente de la droite

$$\hat{a} = \frac{\sigma_{XY}}{\sigma_X^2}$$

- l'ordonnée à l'origine

$$\hat{b} = \bar{Y} - \hat{a} \cdot \bar{X}$$




► 51

Ajustement affine par la méthode des moindres carrés

► Exemple:

numéro	X	Y
1	3	6
2	10	12
3	6	8
4	7	8
5	4	7
6	8	10
7	9	11
8	2	4
9	5	7
10	1	3

Existe-t-il une liaison linéaire entre les deux variables quantitatives X et Y ?



► 52

Ajustement affine par la méthode des moindres carrés

- ▶ Calculs des moyennes des variables

$$\bar{X} = \frac{1}{N} \sum_{i=1}^{i=N} x_i$$

$$\bar{Y} = \frac{1}{N} \sum_{i=1}^{i=N} y_i$$

- ▶ Calculs des variances des variables

$$\sigma_x^2 = \frac{1}{N} \sum_{i=1}^{i=N} x_i^2 - \bar{X}^2$$

$$\sigma_y^2 = \frac{1}{N} \sum_{i=1}^{i=N} y_i^2 - \bar{Y}^2$$

▶ 53

Ajustement affine par la méthode des moindres carrés

- ▶ Calcul de la covariance entre X et Y

$$\sigma_{xy} = \frac{1}{N} \sum_{i=1}^{i=N} x_i \cdot y_i - \bar{X} \cdot \bar{Y}$$

- ▶ Calcul de la pente de la liaison

$$\hat{a} = \frac{\frac{1}{N} \sum_{i=1}^N x_i y_i - \bar{X} \cdot \bar{Y}}{\frac{1}{N} \sum_{i=1}^N x_i^2 - \bar{X}^2} = \frac{\sigma_{xy}}{\sigma_x^2}$$

- ▶ Calcul de l'ordonnée de la liaison $Y = a X + b$

$$\hat{b} = \bar{Y} - \hat{a} \cdot \bar{X}$$

▶ 54

Ajustement affine par la méthode des moindres carrés

Etapes Suivantes:

- ▶ Calcul des valeurs de $\hat{Y}$ en fonction de la liaison $\hat{Y} = \hat{a} X + \hat{b}$
- ▶ Calcul du coefficient de corrélation linéaire entre les deux variables X et Y

$$r = \frac{\sigma_{xy}}{\sigma_x \cdot \sigma_y} \quad -1 \leq r \leq 1$$

- ▶ Calcul des écarts e_i en écrivant $e_i = y_i - \hat{y}_i$ avec $i \in \{1 \dots N\}$
- ▶ Calcul des caractéristiques des écarts e_i

$$\bar{e} = \frac{1}{N} \sum_{i=1}^{i=N} e_i$$

$$\sigma_e^2 = \frac{1}{N} \sum_{i=1}^{i=N} e_i^2 - \bar{e}^2$$

▶ 55

Ajustement affine par la méthode des moindres carrés

- ▶ Calcul des caractéristiques des points projetés $\hat{y}_i$

$$\bar{\hat{Y}} = \frac{1}{N} \sum_{i=1}^{i=N} \hat{y}_i$$

La moyenne des points projetés est égale à la moyenne des points observés

$$\sigma_{\hat{Y}}^2 = \frac{1}{N} \sum_{i=1}^{i=N} \hat{y}_i^2 - \bar{\hat{Y}}^2$$

- ▶ **Relation entre les trois variances:** *La variance totale (variance de Y) est égale à la variance des points projetés (variance de $\hat{Y}$) augmentée de la variance des écarts (variance e_i)*

$$\sigma_Y^2 = \sigma_{\hat{Y}}^2 + \sigma_e^2$$

▶ 56

Ajustement affine par la méthode des moindres carrés

► Vérification de la décomposition de la variance

$$\begin{array}{rcl}
 & \sigma_{\hat{Y}}^2 & \text{Variance expliquée par la régression} \\
 + & & \\
 & \sigma_e^2 & \text{Variance non expliquée par la régression} \\
 \hline
 \text{Total} & \text{Variance totale} & \sigma_Y^2 \\
 & & \text{Vérification}
 \end{array}$$

► Le rapport de corrélation de Y en X

$$\sigma_Y^2 = \sigma_{\hat{Y}}^2 + \sigma_e^2 \quad \eta_{Y/X}^2 = \frac{\sigma_{\hat{Y}}^2}{\sigma_Y^2} \quad 0 \leq \eta_{Y/X}^2 \leq 1$$

► 57

Mesurer la qualité de l'ajustement

$$\sigma_Y^2 = \sigma_{\hat{Y}}^2 + \sigma_e^2$$

information totale (pointing to σ_Y^2)
 information modélisée (pointing to $\sigma_{\hat{Y}}^2$)
 information résiduelle (pointing to σ_e^2)


$$\text{Qualité d'ajustement} = \frac{\sigma_{\hat{Y}}^2}{\sigma_Y^2} = r(X, Y)^2 \quad \text{coeff. de détermination}$$

Cette qualité d'ajustement varie entre 0% (X n'apporte aucun élément de prévision sur Y) et 100% (la connaissance des valeurs de X permet de prévoir intégralement les valeurs de Y) et dépend de l'intensité de la corrélation entre X et Y

► 58

Ajustement affine par la méthode des moindres carrés

► Représentation graphiques des trois écarts



► 59

Ajustement affine par la méthode des moindres carrés

- La droite de régression linéaire de X en Y obtenue par la méthode des moindres carrée est la droite d'équation: $X = a'Y + b'$ avec

$$a' = \frac{\text{cov}(X, Y)}{\sigma_Y^2} \text{ et } b' = \bar{X} - a'\bar{Y}$$

La droite D' de régression de X par rapport à Y a donc pour équation **D'**: $\mathbf{X} = \mathbf{a' Y + b'}$

$$Y = \frac{1}{a'} X - \frac{b'}{a'}$$

► 60

Ajustement affine par la méthode des moindres carrés

Deux droites de régression :

- ▶ La droite de régression linéaire de Y en X

$$D: Y = aX + b$$

- ▶ La droite de régression linéaire de X en Y

$$D': Y = \frac{1}{a'} X - \frac{b'}{a'}$$

**D minimise la somme des écarts au carrés verticaux
alors que D' minimise la somme des écarts au carrés
horizontaux**

▶ 61

Ajustement affine par la méthode des moindres carrés

- ▶ D et D' sont d'autant plus distinctes que le nuage de points est dispersé.
- ▶ Plus le nuage de points est "aligné", plus les deux droites de régression sont « proches ».

**Cas particulier : Si le nuage est parfaitement aligné,
on a D=D' → Les 2 droites ont les mêmes équations.**

$$a = \frac{1}{a'} \quad \text{et} \quad b = -\frac{b'}{a'}$$

$$\rightarrow aa' = 1$$

▶ 62

Ajustement affine par la méthode des moindres carrés

$$\begin{cases} a = \frac{\text{cov}(X, Y)}{\sigma_X^2} \\ a' = \frac{\text{cov}(X, Y)}{\sigma_Y^2} \end{cases} \Rightarrow aa' = r^2(X, Y)$$

Coeff de correlation	Droites de régression (D) et (D')	Liaison entre X et Y	Nuage de points
$ r = 1$	confondues	dépendance linéaire parfaite	aligné
$ r \approx 1$	voisine	dépendance linéaire d'autant plus prononcée que r est proche de 1	d'autant plus aligné que r est proche de 1
$ r \approx 0$	(D) et (D') sont quasi orthogonales	indépendant	dispersé

► 63