



Fondements mathématiques des données scientifiques

MP1- DS

Chapitre VI


Statistique inférentielle

Dorsaf OMRI

Année Universitaire 2023/2024

1

Introduction



La *statistique inférentielle* établit des relations entre populations et échantillons.


- ▶ La démarche d'échantillonnage (de la population vers l'échantillon).
- ▶ La démarche d'estimation (de l'échantillon vers la population).
- ▶ Tests statistiques

▶ 2

2

Population & Echantillon

- ▶ La **population**: L'ensemble des éléments auxquels on s'intéresse. Chaque élément est appelé « unité statistique » (u.s.) ou « individu » ou « observation ».
 - La population peut être parfaitement définie (ensemble dénombrable fini).
Exemple: Ensemble de clients d'une banque.
 - La population peut être non définie: infinie ou imparfaitement connue.
Exemple: Ensemble des clients d'une grande surface d'une enseigne donnée.
- ▶ Dans la plupart des cas, on ne peut pas mesurer tous les individus de la population, pour des raisons pratiques.
- ▶ L'**échantillon**: Un sous ensemble de la population étudiée pour lequel on effectue une série de mesures sur la ou les variables étudiées: L'échantillon est une fraction d'individus de la population.
 - Sondage
 - Echantillonnage aléatoire



▶ 3

3


Statistiques descriptive et inférentielle

- ▶ La **statistique descriptive** ne s'intéresse qu'à la sous-population formée par l'**échantillon** avec comme objectif de décrire et résumer la variabilité de l'**échantillon**.
 - ▶ La **statistique inférentielle** s'intéresse à la **population** dont est issu l'**échantillon** avec comme objectif d'inférer, à partir des seules caractéristiques de l'**échantillon**, des propriétés plus générales concernant la **population**.
 - ▶ La **statistique inférentielle** s'appuie sur la théorie des probabilités.
- ✓ Connaissant la distribution d'une variable dans une population, la théorie des probabilités permet de tirer aléatoirement un échantillon.
 - ✓ Connaissant les valeurs prises par une variable sur un échantillon, la statistique inférentielle essaie de préciser la distribution de la variable dans la population.

▶ 4

4

Statistiques descriptive et inférentielle




La statistique inférentielle donne une information sur un ensemble plus vaste: la population
L'opération de "remontée" de l'échantillon à la population est appelée inférence statistique

► 5

5

Statistiques: descriptive et inférentielle



► 6

6

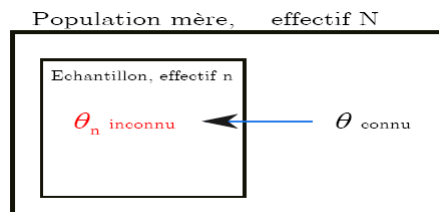
Echantillonnage

7

Le principe de base

Chaque individu constitutif de la population doit avoir la même chance de figurer dans l'échantillon.

L'échantillonnage permet de passer (de la loi connue d'un paramètre θ dans une population de taille N) à une estimée d'une quantité θ_n fabriquée à partir seulement d'une population de taille n plus petite (échantillon).



► 8

8

Méthode d'échantillonnage

Echantillonnage doit être représentatif

- ▶ Comment on doit extraire les éléments de l'échantillon?
→ Représentation qualitative
- ▶ Combien on doit extraire d'éléments pour l'échantillon?
→ Représentation quantitative
- ▶ Distribution d'échantillonnage

▶ 9

9

Méthode d'échantillonnage

Méthode d'échantillonnage

Empirique ou pratique Quotas

Variable de contrôle
Taux de sondage: n/N
(N taille de la population)
(n taille de l'échantillon)

Base de sondage ou Probabiliste

Méthode d'échantillonnage aléatoire
Méthode d'échantillonnage stratifiée
Méthode d'échantillonnage systématique

▶ 10

10

Méthode d'échantillonnage

Base de sondage ou Probabiliste

▶ Méthode d'échantillonnage aléatoire

1. Construire une base de sondage en utilisant la table de nombre aléatoire
2. Choisir les éléments aléatoirement

▶ Méthode d'échantillonnage stratifiée

C'est une méthode qui consiste à subdiviser, partager une population hétérogène en strates homogènes

Pour chaque strate: La taille de l'échantillon $n_i = (n/N) * N_i$; N_i taille du strate; (n/N) taux de sondage

▶ Méthode d'échantillonnage systématique

On utilise la table de nombre aléatoire pour déterminer i

$$\begin{cases} i : \text{Point entrée (Choisi de façon aléatoire dans la table)} \\ k = \frac{N}{n} : \text{Pas} \\ n' = \{i, i+k, i+2k, i+3k, \dots\} : \text{élément de l'échantillon} \\ i \in [1, k] \end{cases}$$

▶ 11

11

Echantillon aléatoire

Soit X une variable aléatoire réelle. **Un échantillon aléatoire** d'effectif $n \geq 1$ est un vecteur aléatoire $\mathbf{X}_n = (X_1, X_2, \dots, X_n)$ à n composantes qui sont n variables aléatoires indépendantes suivant la même loi que X , appelée **variable aléatoire parente**.

▶ 12

12

Statistique de l'échantillon

Toute variable aléatoire T , fonction de l'échantillon aléatoire $\mathbf{X}_n=(X_1, X_2, \dots, X_n)$ est appelée statistique de l'échantillon.

Remarques

1. Une statistique peut être à valeur dans $\mathcal{R}$ ou $\mathcal{R}^p$. Dans le dernier cas nous parlerons de la statistique vectorielle.
2. La difficulté de cette notion est: Nous avons une double conception, qui à la base de la statistique mathématique. Les valeurs observées $(x_1, x_2, \dots, x_n)$ (notées en minuscules) constituent n réalisations indépendantes d'une variable aléatoire X ou encore une réalisation unique du vecteur aléatoire $\mathbf{X}_n=(X_1, X_2, \dots, X_n)$ à n composantes où les x_i sont n variables aléatoires indépendantes et de même loi.

► 13

13

Modèle statistique

Définition

Un phénomène aléatoire repéré par une caractéristique vectorielle X , est parfaitement défini par la donnée d'un couple (D_X, P_θ)

D_X est l'ensemble des résultats possibles pour la caractéristique X

P_θ est la loi de probabilité de X

P est une famille de lois à laquelle appartient la vraie loi P_θ régissant le phénomène.

Le couple (D_X, P_θ) est appelé modèle statistique .

Modèle statistique

- Discret
- Continue

► 14

14

Modèle statistique

Modèle statistique

Soit $X = (X_1, \dots, X_n)$, un vecteur de n variables aléatoires X_i .

$$X_i : (\Omega, \mathcal{B}) \rightarrow (\mathcal{R}, \mathcal{B}_{\mathcal{R}})$$

$$X : (\Omega, \mathcal{B}, P) \rightarrow (\mathcal{R}^n, \mathcal{B}_{\mathcal{R}^n}, Q_X)$$

Q_X est la loi de probabilité image du vecteur aléatoire X .

► Hypothèse fondamentale

On va supposer que la loi de probabilité Q_X appartient à une famille de lois de probabilité $\mathcal{Q}$.

Un modèle statistique (ou structure statistique) est le triplet $(\mathcal{R}^n, \mathcal{B}_{\mathcal{R}^n}, \mathcal{Q})$, c'est à dire la donnée d'une famille de lois de probabilité $\mathcal{Q}$ à laquelle on astreint Q_X à appartenir.

► 15

15

Modèle statistique paramétrique

On appelle modèle statistique paramétrique un modèle statistique (D_X, P_θ) tel que

$$\exists p \in \mathbb{N} : P = \{P_\theta; \theta \in \Theta \subset \mathcal{R}^p\}$$

Θ est appelé l'espace des paramètres.

→ Si la famille de lois P est indexées par un paramètre

$$\theta \in \Theta \subset \mathcal{R}^p$$

Le modèle est dit paramétrique

► 16

16

Le modèle d'échantillonnage indépendant

- ▶ Un cas particulier du modèle statistique général.
- ▶ Il consiste à supposer que les variables aléatoires $X_1, \dots, X_n$ sont indépendantes et identiquement distribuées (i.i.d.).

Propriétés

- ▶ Les variables aléatoires X_i étant identiquement distribuées, elles ont même loi Q_X .
- ▶ Les variables aléatoires X_i étant indépendantes, la loi Q_X du vecteur aléatoire X est la loi produit.

▶ 17

17

Le modèle d'échantillonnage paramétrique

Il consiste, dans le cadre de l'échantillonnage, à supposer que la famille P de lois de probabilité est indicée par un paramètre θ .

$$P = (P_\theta, \theta \in \Theta \subset \mathbb{R}^k)$$

- ▶ P_θ est la loi de probabilité correspondant à la valeur du paramètre.
- ▶ Θ est l'espace paramétrique (dans lequel θ peut prendre sa valeur).
- ▶ k est la dimension du paramètre (pour $k = 1$, on parle de paramètre unidimensionnel, pour $k > 1$, on parle de paramètre multidimensionnel ou vectoriel).

$$(\mathcal{R}, B_{\mathcal{R}}, (P_\theta, \theta \in \Theta \subset \mathbb{R}^k))^n$$

Le modèle d'échantillonnage paramétrique

Exemple: P est une loi Normale $\Theta = \{(\mu, \sigma^2), \mu \in \mathbb{R}, \sigma > 0\}$ Cadre paramétrique bidimensionnel

▶ 18

18

Définition d'une statistique

- ▶ On appelle statistique toute variable aléatoire définie sur $(\mathfrak{R}^n, \mathcal{B}_{\mathfrak{R}^n})$ à valeurs dans $(\mathfrak{R}^k, \mathcal{B}_{\mathfrak{R}^k})$.
- ▶ Une Statistique est notée par T_n .
- ▶ Une statistique ne dépend pas de la famille de lois de probabilités $\mathcal{Q}$.
- ▶ En particulier, dans un modèle paramétrique, une statistique T_n ne dépend pas de θ . C'est la loi de probabilité de T_n qui dépend de θ .

Exemple

- ▶ $P = N(\mu, 1) \Rightarrow \theta = \mu$
- ▶ Une statistique T_n permet de « préciser » le paramètre θ (moyenne d'une loi normale réduite)

$$T_n : (\mathfrak{R}, \mathcal{B}_{\mathfrak{R}}, (P_\theta \in \Theta \subset \mathfrak{R}^k))^n \rightarrow (\mathfrak{R}^k, \mathcal{B}_{\mathfrak{R}^k})$$

$$(x_1, x_2, \dots, x_n) \rightarrow \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

▶ 19

19

Définition d'une statistique

- ▶ La statistique T_n est une variable aléatoire sur $(\mathfrak{R}^n, \mathcal{B}, \mathcal{Q})$.
- ▶ La variable aléatoire $T_n(X_1, \dots, X_n)$ est une variable aléatoire sur $(\Omega, \mathcal{B}) \rightarrow$ **La statistique inférentielle.**
- ▶ La valeur observée de cette variable aléatoire est

$$T_n(x_1, \dots, x_n) \in \mathfrak{R}^k \rightarrow \text{La statistique descriptive.}$$

Le modèle d'échantillonnage indépendant paramétrique réel

$$(\mathfrak{R}, \mathcal{B}_{\mathfrak{R}}, (P_\theta, \theta \in \Theta \subset \mathfrak{R}^k))^n$$

Si le paramètre θ est connu $\rightarrow$ La loi de probabilité P est connue.

Les méthodes standards de la statistique inférentielle (**estimation et test d'hypothèse**) ont pour objectif de préciser au maximum le paramètre θ quand ce dernier est inconnu.

▶ 20

20

Distribution d'échantillonnage

Echantillon

Soit X une variable aléatoire réelle. Un échantillon de **taille n** (ou n -échantillon) est une suite $(X_1, X_2, \dots, X_n)$ de **n variables aléatoires** indépendantes suivant la même loi que X , appelée variable aléatoire parente.

Toute variable aléatoire T , fonction mesurable de l'échantillon, est appelée statistique de l'échantillon.

➡ $(x_1, x_2, \dots, x_n)$: Série statistique

➤ Moyenne $\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$

▶ 21

21

Distribution d'échantillonnage

Exemple

- ▶ Population: Les étudiants
- ▶ Taille de la population 6
- ▶ Le caractère = Age
- ▶ Série statistique suivante: 20; 22; 19; 19; 19; 21
- ▶ Moyenne=20

On va extraire trois échantillons de taille 3

Echantillon 1: 20; 21; 22 ➔ Moyenne 1 = 21

Echantillon 2: 19; 19; 19 ➔ Moyenne 2 = 19

Echantillon 3: 19; 22; 19 ➔ Moyenne 3 = 20

Moyenne (moyenne
des échantillons)
=
(21+19+20)/3=20

▶ 22

22

Distribution d'échantillonnage

► La représentativité quantitative de l'échantillon

Si n augmente → les caractéristiques de l'échantillon tend vers les caractéristiques de la population

Loi des grands nombres



Inégalité de Bienaymé-Tchebychev

- Cas d'une moyenne
- Cas d'une proportion

Théorème central limite



Théorème de De Moivre-Laplace: Loi normale

- Cas d'une moyenne
- Cas d'une proportion

► 23

23

Théorème de De Moivre-Laplace

► Théorème de De Moivre-Laplace

Soit X une variable aléatoire qui suit la loi binomiale $B(n;p)$ et Y une variable aléatoire qui suit une loi normale centrée réduite alors

$$\lim_{n \rightarrow +\infty} P\left(a \leq \frac{X - E(X)}{\sigma} \leq b\right) = P(a \leq Y \leq b)$$

► Approximation d'une loi binomiale par une loi normale

Soit X une variable aléatoire qui suit la loi binomiale $B(n;p)$ et Y suit une loi Normale $N(E(X); \sigma^2)$

Si $n \geq 30$ et $np \geq 5$ et $n(1-p) \geq 5$ alors $P(a \leq X \leq b)$ pourra être approximée par $P(a \leq Y \leq b)$.

► Approximation d'une loi binomiale par une loi normale centrée réduite

Soit X une variable aléatoire qui suit la loi binomiale $B(n;p)$ et Y suit une loi Normale centrée réduite. Si $n \geq 30$ et $np \geq 5$ et $n(1-p) \geq 5$ alors

$$P\left(a \leq \frac{X - E(X)}{\sigma} \leq b\right) \text{ pourra être approximée par } P(a \leq Y \leq b)$$


► 24

24

Estimation

25

Introduction

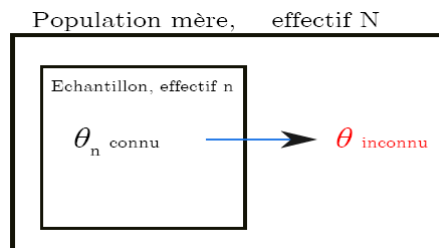


► 26

26

Introduction

L'estimation permet d'induire, à partir des résultats observés sur un échantillon, des informations sur la population totale.



L'estimation est un ensemble de méthodes permettant de

- ▶ Fixer une valeur: **Estimation ponctuelle**
 - ▶ Fixer un ensemble de valeurs: **Estimation par intervalle de confiance**
- pour le paramètre θ .

▶ 27

27

Estimation ponctuelle

28

Définition d'un estimateur

- ▶ Lorsqu'on utilise fréquemment des estimateurs ponctuels, on souhaite qu'ils possèdent certaines propriétés.
- ▶ Ces propriétés sont importantes pour choisir le meilleur estimateur du paramètre correspondant → s'approche le plus possible du paramètre à estimer.
- ▶ Un paramètre inconnu peut avoir plusieurs estimateurs.

Par exemple, pour estimer le paramètre m , moyenne d'une population, on pourrait se servir de la moyenne arithmétique, de la médiane ou du mode.

▶ 29

29

Estimateur et Estimation

▶ Estimateur

Si $(X_1, X_2, \dots, X_n)$ est un échantillon aléatoire d'effectif n de loi parente la loi de X , prélevé dans une population U alors nous appelons estimateur de θ toute fonction T_n de l'échantillon aléatoire $(X_1, X_2, \dots, X_n)$, noté $\hat{\theta}_n$:

$$\hat{\theta}_n = T_n(X_1, X_2, \dots, X_n)$$

Remarque

- ▶ $\hat{\theta}_n$ est une variable aléatoire de loi de probabilité qui dépend de θ
- ▶ $\hat{\theta}_n$ peut-être univarié ou multivarié.

▶ 30

30

Estimateur et Estimation

Estimation

Une fois l'échantillon prélevé, nous disposons de n valeurs observées $(x_1, x_2, \dots, x_n)$, ce qui fournit une valeur $T_n(x_1, x_2, \dots, x_n)$ qui est une réalisation de $\hat{\theta}_n$ et que nous appelons estimation

Remarques:

1. Nous distinguons la variable aléatoire $\hat{\theta}_n$ de sa valeur observée, notée $\hat{\theta}_n(x_1, x_2, \dots, x_n)$.
2. Nous utiliserons les notations suivantes:
 - $(X_1, X_2, \dots, X_n)$ désigne l'échantillon aléatoire de taille n et les n observations ne sont pas encore à disposition
 - $(x_1, x_2, \dots, x_n)$ désigne une réalisation de l'échantillon aléatoire et les n observations sont à disposition.
3. Il faut systématiquement se demander: « suis-je en train de manipuler une variable aléatoire ou l'une de ses réalisations? »

► 31

31

Estimateur et Estimation

$$\left(\mathfrak{R}, B_{\mathfrak{R}}, \left(P_{\theta}, \theta \in \Theta \subset R^k \right) \right)^n$$

- On appelle **estimateur** d'un paramètre θ toute statistique a valeur dans $(\mathfrak{R}^k, B_{\mathfrak{R}^k})$, notée $\hat{\theta} = T_n$.
- On appelle **estimation** la valeur observée de T_n sur l'échantillon, notée $T_n(x_1, \dots, x_n) \in \mathfrak{R}^k$.

Propriétés d'un estimateur

- Biais d'un estimateur
- Efficacité d'un estimateur
- Convergence d'un estimateur

► 32

32

Biais d'un estimateur

Dans ce qui suit $\hat{\theta}$ sera une notation pour un estimateur du paramètre θ

Définition

On appelle biais de l'estimateur $\hat{\theta}$ pour le paramètre θ la quantité

$$B_{\theta}(\hat{\theta}) = E(\hat{\theta}) - \theta$$

C'est une fonction de θ .

On appelle **estimateur sans biais** de (θ) un estimateur $\hat{\theta}$

$$B_{\theta}(\hat{\theta}) = 0 \Leftrightarrow E(\hat{\theta}) = \theta, \forall \theta$$

Sinon, on parle d'**estimateur biaisé**.

Si l'estimateur est biaisé, mais que $B_{\theta}(\hat{\theta}) \xrightarrow{n \rightarrow +\infty} 0$

on dit que $\hat{\theta} = T_n$ est asymptotiquement sans biais pour θ

► 33

33

Biais d'un estimateur

Soit un échantillon $(X_1, \dots, X_n)$ associé à X , tel que

$$E(X) = \mu \text{ et } \text{var}(X) = \sigma^2$$

Alors $\bar{X}$ est un estimateur sans biais pour μ .

$$E(\bar{X}) = \frac{1}{n} E\left(\sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} n \mu = \mu$$

Si μ connu, $S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ est sans biais pour σ^2

Si μ est inconnu, $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ est sans biais pour σ^2

► 34

34

Biais d'un estimateur

- ▶ L'absence de biais ne garantit pas que nous avons un bon estimateur.
- ▶ Certains paramètres peuvent avoir plusieurs estimateurs sans biais.
- ▶ Le choix parmi les estimateurs sans biais s'effectue en comparant les variances des estimateurs.
- ▶ Un estimateur sans biais mais à variance élevée peut fournir des estimations très éloignées de la vraie valeur du paramètre.

▶ 35

35

Convergence d'un estimateur

On dit que $\hat{\theta} = T_n$ est convergent pour θ , s'il converge en probabilité vers θ :

$$\forall \varepsilon > 0, P[T_n - \theta] < \varepsilon \xrightarrow{n \rightarrow +\infty} 1$$

Critères de convergence d'un estimateur

- ▶ Si T_n est un estimateur sans biais de θ et si $Var(T_n) \xrightarrow{n \rightarrow +\infty} 0$ alors T_n est un estimateur convergent pour θ .
- ▶ Si T_n est un estimateur asymptotiquement sans biais de θ et si $Var(T_n) \xrightarrow{n \rightarrow +\infty} 0$, alors T_n est un estimateur convergent pour θ .

▶ 36

36

Efficacité d'un estimateur

On utilise le risque quadratique pour comparer deux estimateurs du même paramètre θ . Pour l'estimateur T_n de θ , il est défini par :

$$R(T_n, \theta) = E[(T_n - \theta)^2]$$

Propriété

$$R(T_n, \theta) = (B_\theta(T_n))^2 + V(T_n)$$

Remarques

- ▶ L'idée est de minimiser le risque quadratique $R(T_n, \theta)$, c'est à dire minimiser le biais (si possible l'annuler) ainsi que la variance de l'estimateur.
- ▶ La variance de T_n ne pourra pas descendre en dessous d'une certaine borne.
- ▶ La quantité $R(T_n, \theta)$ est aussi appelée **erreur quadratique moyenne**.
- ▶ Le risque quadratique est le critère de choix généralement utilisé entre deux estimateurs.

▶ 37

37

Efficacité et convergence d'un estimateur

- ▶ Biais d'un estimateur $E(\hat{\theta}) = \theta$

$$\hat{\theta} = \begin{cases} \bar{X} \\ S^2 : \text{Echantillon} \\ f \end{cases} \quad \theta = \begin{cases} \mu \\ \sigma^2 : \text{Paramètres population} \\ p \end{cases}$$

- ▶ Efficacité d'un estimateur

$$\text{var}(\hat{\theta}_1) < \text{var}(\hat{\theta}_2) \implies \hat{\theta}_1 \text{ est plus efficace que } \hat{\theta}_2$$

- ▶ Convergence d'un estimateur

$$\lim_{n \rightarrow +\infty} \text{var}(\hat{\theta}) = 0 \implies \hat{\theta} \text{ est un estimateur convergent de } \theta$$

▶ 38

38

Estimation de la moyenne

Soit $(X_1, X_2, \dots, X_n)$ un échantillon aléatoire de loi parente la loi de X .

L'estimateur $\hat{\mu}_n$ de la moyenne μ est égal à:

$$\hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Propriétés

1. Pour un échantillon aléatoire dont la loi parente admet une espérance notée μ , $\hat{\mu}_n$ est un estimateur sans biais de la moyenne μ

$$E(\hat{\mu}_n) = \mu$$

2. Lorsque la loi parente admet une variance, notée σ^2 , la variance de l'estimateur $\hat{\mu}_n$ est égale à

$$\text{var}(\hat{\mu}_n) = \frac{\sigma^2}{n}$$

$\hat{\mu}_n$ est un **estimateur convergent** de la moyenne μ .

► 39

39

Convergence d'un estimateur

Théorème

Soit un échantillon $(X_1, \dots, X_n)$ associé à X , tel que

$$E(X) = \mu \text{ et } \text{var}(X) = \sigma^2$$

- i. $\bar{X}$ est un estimateur convergent pour μ
- ii. Si μ est connu, $\hat{\sigma}^2$ est un estimateur convergent pour σ^2
- iii. Si μ est inconnu, alors S^2 est un estimateur convergent pour σ^2

En effet, on a déjà vu que $\bar{X}$ est sans biais pour μ , or

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n} \xrightarrow{n \rightarrow \infty} 0$$

► 40

40

Estimation de la variance

Soit $(X_1, X_2, \dots, X_n)$ un échantillon aléatoire de loi parente la loi de X.

Estimateur non corrigé de la variance

L'estimateur S_n^2 de la variance σ^2 , souvent noté simplement par S^2 , est égale à

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\mu}_n)^2$$

Propriété

Pour un échantillon aléatoire dont la loi parente admet une espérance notée μ et une variance notée σ^2 , S_n^2 est un estimateur biaisé de la variance σ^2 et le biais $B(S_n^2)$ est égal à $-\frac{\sigma^2}{n}$

S_n^2 est donc un estimateur asymptotiquement sans biais de la variance σ^2 .

► 41

41

Estimation de la variance

Soit $(X_1, X_2, \dots, X_n)$ un échantillon aléatoire de loi parente la loi de X.

Estimateur corrigé de la variance

L'estimateur $S_{n,c}^2$ de la variance σ^2 , souvent noté simplement par S_c^2 , est égale à

$$S_{n,c}^2 = \frac{n S_n^2}{n-1} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \hat{\mu}_n)^2$$

Propriété

Pour un échantillon aléatoire dont la loi parente admet une espérance notée μ et une variance notée σ^2 , $S_{n,c}^2$ est un estimateur sans biais de la variance σ^2

► 42

42

Estimation de la variance

Estimation de la variance: Estimateur **corrigé** de la variance

- ▶ La **variance observée sans biais** s^{2*} sur l'échantillon comme **estimation ponctuelle** de σ

$$S^{2*} = \frac{n}{n-1} S^2$$

- ▶ L'**écart-type observé sans biais** s^* sur l'échantillon comme **estimation ponctuelle** de σ

▶ 43

43

Estimation de la proportion

- ▶ Dans le cas de l'estimateur d'une proportion, les variables X_i prennent les valeurs 0 ou 1.
- ▶ L'estimateur noté f_n de la proportion A de la population est égal à:

Propriété: $\hat{f}_n$ est un estimateur sans biais de la proportion f_n .

$f_n = \frac{N_A}{N}$, où N_A est le nombre d'individus de la population ayant la caractéristique A. N est la taille de la population

L'estimation d'une proportion P est un cas particulier du de l'estimation de la moyenne, au sens où les v.a. X_i considérées sont de Bernoulli de paramètre p.

Exemple: Dans une population de taille $N=100000$, pour estimer la proportion p de foyers disposant d'un abonnement internet, on prélève de manière exhaustive un échantillon de 100 foyers dont 80 disposent d'un abonnement internet. L'estimation ponctuelle de p est:

$$f_n = \frac{X}{n} = \frac{80}{100} = 0,8; X = \text{nombre de foyers disposant d'un abonnement internet dans l'échantillon}$$

▶ 44

44

Méthode du maximum de vraisemblance

► Vraisemblance d'un échantillon

La vraisemblance des observation $X=(x_1, x_2, \dots, x_n)$ d'un échantillon aléatoire de loi parente la loi de X est définie de la façon suivante:

Si X est une variable aléatoire continue

$$\theta \in \Theta \mapsto L(x_1, x_2, \dots, x_n | \theta) = \prod_{i=1}^n f_X(x_i, \theta)$$

Θ est l'ensemble des valeurs possibles du paramètre θ

f_X est la densité de probabilité de X

Si X est une variable aléatoire discrète

$$\theta \in \Theta \mapsto L(x_1, x_2, \dots, x_n | \theta) = \prod_{i=1}^n P_\theta(X_i = x_i)$$

Θ est l'ensemble des valeurs possibles du paramètre θ

P_θ est la fonction de probabilité de X

Les expressions des vraisemblances ci-dessus ne sont valables que parce que les variables aléatoires $X_1, X_2, \dots, X_n$ sont indépendantes par définition d'un échantillon aléatoire.

► 45

45

Méthode du maximum de vraisemblance

► Estimateur du maximum de vraisemblance

Un estimateur du maximum de vraisemblance (EMV) de paramètre θ est une statistique de l'échantillon:

$$\hat{\theta}_n : D_X^n \rightarrow \Theta$$

$$X = (x_1, x_2, \dots, x_n) \mapsto \hat{\theta}_n(x_1, x_2, \dots, x_n)$$

$$\text{telle que } \forall \theta \in \Theta, L(x_1, x_2, \dots, x_n | \hat{\theta}_n) \geq L(x_1, x_2, \dots, x_n | \theta)$$

Remarque

Le principe de vraisemblance, à la base de la procédure d'estimation du maximum de vraisemblance revient à rechercher la valeur de θ , fonction de l'observation $(x_1, x_2, \dots, x_n)$ qui assure la plus grande probabilité d'obtenir ces observations.

► 46

46

Méthode du maximum de vraisemblance

► Estimateur du maximum de vraisemblance

1. D_X ne dépend pas de θ

2. $\forall X = (x_1, \dots, x_n) \in D_X^n, \forall \theta \in \Theta, L$ est deux fois continument dérivable par rapport à θ .

Alors $\hat{\theta}_n, EMV$, est solution du système mixte d'équation et d'inéquation en θ suivante :

$$(1) \Leftrightarrow \begin{cases} \frac{dL}{d\theta}(X|\theta) = 0 \\ \frac{d^2L}{d\theta^2}(X|\theta) < 0 \end{cases}$$

Vu la forme des densités des lois usuelles de probabilité, il est aisé d'utiliser le logarithme de la vraisemblance,

$$\ln(L(x_1, x_2, \dots, x_n | \theta)), L(x_1, x_2, \dots, x_n | \theta) > 0, \forall x = (x_1, x_2, \dots, x_n) \in D_X^n \text{ pour tout } \theta \in \Theta$$



$$(1) \Leftrightarrow (1') : \begin{cases} \frac{d \ln L}{d\theta}(X|\theta) = 0 \\ \frac{d^2 \ln L}{d\theta^2}(X|\theta) < 0 \end{cases} \text{ Equation de vraisemblance}$$

► 47

47

Conclusion

- Les estimations ponctuelles ne fournissent aucune information concernant la précision des estimations
- Les estimations ponctuelles ne tiennent pas compte de l'erreur possible dans l'estimation, erreur attribuable aux fluctuations d'échantillonnage.
- Quelle confiance avons-nous dans une valeur unique ?

→ Il faut associer à l'estimation ponctuelle un intervalle qui permet d'englober avec une certaine fiabilité, la vraie valeur du paramètre correspondant.

► 48

48

Estimation par intervalle de confiance

49

Introduction

Pour estimer une des caractéristiques, θ , de la population il est plus pertinent de fournir un intervalle $\theta_1 \leq \theta \leq \theta_2$ plutôt que de donner simplement une estimation ponctuelle.

Un tel intervalle $[\theta_1 ; \theta_2]$ s'appelle une estimation par intervalle de confiance du paramètre θ ou estimation ensembliste de la caractéristique θ .

Estimer un paramètre θ inconnu par intervalle de confiance consiste à associer à un échantillon de taille n , un intervalle aléatoire tel que la probabilité que cet intervalle contient θ soit égale à une valeur convenue d'avance, notée $1-\alpha$

$1-\alpha$ s'appelle le niveau de confiance ou seuil de confiance

► 50

50

Intervalle de confiance

► Définition

Nous appelons intervalle de confiance de niveau de confiance $(1-\alpha)$ du paramètre θ tout intervalle $[\theta_1; \theta_2]$ tel que

$$P(\theta \in [\theta_1; \theta_2]) = 1 - \alpha \text{ pour } \alpha \in [0; 1] \text{ fixé}$$

► 51

51

Intervalle de confiance

► Propriétés

1. La probabilité α pour que l'intervalle de confiance ne contienne pas la vraie valeur θ peut être répartie différemment de part et d'autre des bornes de l'intervalle de confiance. Posons $\alpha = \alpha_1 + \alpha_2$, où α_1 mesure le risque que la vraie valeur inconnue de θ soit plus petite que la borne inférieure θ_1 de la intervalle de confiance et où α_2 mesure le risque que la vraie valeur inconnue de θ soit plus grande que la borne supérieure θ_2 de la intervalle de confiance.
2. L'intervalle de confiance est dit bilatéral lorsque $\alpha_1 \neq 0$ et $\alpha_2 \neq 0$. Si $\alpha_1 = \alpha_2 = \frac{1}{2}$, l'intervalle est dit symétrique sinon il est dit dissymétrique.

► 52

52

Intervalle de confiance

3. L'intervalle de confiance est dit unilatéral lorsque $\alpha_1 = 0$ et $\alpha_2 = 0$. Il est toujours dissymétrique.
 - Si nous sommes uniquement intéressés par le calcul d'une valeur minimale pour la quantité estimée, nous fixons $\alpha_1 = 0$ et $\alpha_2 = 0$. L'intervalle de confiance est alors de la forme
$$]\theta_1; \theta_2[=]a; +\infty[$$
 - Si nous sommes uniquement intéressés par le calcul d'une valeur maximale pour la quantité estimée, nous fixons $\alpha_1 = 0$ et $\alpha_2 = \alpha$. L'intervalle de confiance est alors de la forme
$$]\theta_1; \theta_2[=]-\infty; b[$$
4. $]\theta_1; \theta_2[$ est un intervalle aléatoire car il dépend de l'estimateur $\widehat{\theta}_n$.

► 53

53

Intervalle de confiance

5. Si nous augmentons le niveau $1-\alpha$ ou le coefficient de confiance, nous augmentons la longueur de l'intervalle de probabilité.
6. Nous associons souvent aux intervalles de confiance, un test, basé sur la règle de décision suivante: Soit $\hat{\theta}(obs)$ la valeur observée de l'estimateur $\hat{\theta}_n$
 - Si la valeur observée $\hat{\theta}(obs) \in]\theta_1^n; \theta_2^n[$ nous conservons la valeur comme valeur possible du paramètre θ .
 - Si la valeur observée $\hat{\theta}(obs) \notin]\theta_1^n; \theta_2^n[$, nous éliminons cette valeur.

► 54

54

Intervalle de confiance

- ▶ Estimation par intervalle de confiance: **Moyenne ou espérance**
 - Variance est connue
 - Variance est inconnue
 - Estimation de la taille minimale d'un échantillon
 - Distribution d'échantillonnage de la différence de moyennes
- ▶ Estimation par intervalle de confiance: **Variance**
- ▶ Estimation par intervalle de confiance: **Proportion**

▶ 55

55

Estimation par intervalle de confiance: **Moyenne**

Objectif : Encadrement de la moyenne $\dots \leq \mu \leq \dots$
 $\dots \leq \bar{X}_n \leq \dots$

→ Etudier la distribution de l'échantillonnage de la moyenne:
 $\bar{X}_n$ suit quelle loi? et sous quelle condition?


▶ **Si variance de la population:**

- 1. ■ **Connue** → $\bar{X}_n \propto N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$ $\begin{cases} E(\bar{X}_n) = \mu \\ \sigma(\bar{X}_n) = \sqrt{\text{Var}(\bar{X}_n)} = \sqrt{\frac{\sigma^2}{n}} = \frac{\sigma}{\sqrt{n}} \end{cases}$
- **Inconnue**

- ▶ **Variance est estimée par l'estimateur sans biais S^2**
- ▶ **On vérifie la taille de l'échantillon n**

□ **$n \geq 30$** → $\bar{X}_n \propto N\left(\mu, \frac{S}{\sqrt{n}}\right)$ 2

□ **$n < 30$** → $\bar{X}_n \propto T(n-1)ddl$ 3



▶ 56

56

Estimation par intervalle de confiance: Moyenne & Variance est connue

1^{er} cas: Variance est connue $\bar{X}_n \propto N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$

► La formule d'encadrement:


$$P\left[|Z| \leq z_{\alpha/2}\right] = 1 - \alpha$$

1-α s'appelle le niveau de confiance ou seuil de confiance
α s'appelle le risque ou le niveau de signification

$$Z \propto N(0,1) \Rightarrow Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$$

$$P\left[|Z| \leq z_{\alpha/2}\right] = P\left[-z_{\alpha/2} \leq Z \leq z_{\alpha/2}\right]$$

$$= P\left[-z_{\alpha/2} \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right] = P\left[\mu - \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \leq \bar{X}_n \leq \mu + \frac{\sigma}{\sqrt{n}} z_{\alpha/2}\right] = 1 - \alpha$$



► 57

57

Estimation par intervalle de confiance: Moyenne & Variance est connue

► Déterminer la valeur critique $z_{\alpha/2}$:

$$2 \Pi(z_{\alpha/2}) - 1 = 1 - \alpha = P\left[|Z| \leq z_{\alpha/2}\right]$$

Déterminer la valeur critique $z_{\alpha/2}$

Encadrement → Intervalle de confiance

$$\Pi(z_{\alpha/2}) = \frac{2 - \alpha}{2}$$

Exemple

$$1 - \alpha = 95\% = 0,95 \Rightarrow \Pi(z_{\alpha/2}) = 0,975 \xrightarrow{\text{Table}} z_{\alpha/2} = 1,96$$

► 58

58

Estimation par intervalle de confiance: Moyenne & Variance est connue

- ▶ Une population normale et de variance connue
- ▶ Meilleure estimation de la moyenne μ de la population est la moyenne $\bar{X}$ de l'échantillon.
- ▶ L'estimateur suit une loi normale $N\left(\mu, \sigma/\sqrt{n}\right)$

Intervalle de confiance pour la moyenne

$$P\left[-z_{\alpha/2} \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right] = 1 - \alpha \Rightarrow P\left[\bar{X}_n - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}_n + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right] = 1 - \alpha$$

Il y a $1-\alpha$ chances que la moyenne inconnue μ appartienne à l'intervalle aléatoire $\left[\bar{X}_n - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X}_n + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right]$


↗ **Fiabilité**
↘ **Précision**

▶ 59

59

Estimation par intervalle de confiance: Moyenne & Variance est connue

Prendre une décision à partir d'un échantillon, est-ce vraiment fiable ?




▶ 60

60

Estimation par intervalle de confiance: Moyenne & Variance est connue

Plus la taille de l'échantillon grandit plus la variance diminue. Pour n infini, l'observation tombe forcément sur μ

$\bar{X}$ est un estimateur convergent



► 61

61

Estimation par intervalle de confiance: Moyenne & Variance est inconnue & $n \geq 30$

2^{ème} cas: Variance est inconnue et $n \geq 30$

$$\bar{X}_n \propto N\left(\mu, \frac{S}{\sqrt{n}}\right); S^2 = \frac{n \sigma_{obs}^2}{n-1} \text{ (S = variance corrigée)}$$


► La formule d'encadrement:

$$P[|Z| \leq z_{\alpha/2}] = 1 - \alpha$$

$$Z \propto N(0,1) \Rightarrow Z = \frac{\bar{X}_n - \mu}{S/\sqrt{n}}$$

$$P[|Z| \leq z_{\alpha/2}] = P[-z_{\alpha/2} \leq Z \leq z_{\alpha/2}]$$

$$= P\left[-z_{\alpha/2} \leq \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \leq z_{\alpha/2}\right] = P\left[\mu - \frac{S}{\sqrt{n}} z_{\alpha/2} \leq \bar{X}_n \leq \mu + \frac{S}{\sqrt{n}} z_{\alpha/2}\right] = 1 - \alpha$$



Encadré
estimateur

$$P\left[\bar{X}_n - \frac{S}{\sqrt{n}} z_{\alpha/2} \leq \mu \leq \bar{X}_n + \frac{S}{\sqrt{n}} z_{\alpha/2}\right] = 1 - \alpha \Rightarrow \mu \in \left[\bar{X}_n - \frac{S}{\sqrt{n}} z_{\alpha/2}, \bar{X}_n + \frac{S}{\sqrt{n}} z_{\alpha/2}\right]$$

► 62

62


Estimation par intervalle de confiance: Moyenne & Variance est inconnue & n<30

3^{ème} cas: Variance est inconnue et n<30

$$\bar{X}_n \propto \text{loi de student } T(n-1) \text{ ddl avec } T = \frac{\bar{X}_n - \mu}{S/\sqrt{n}}$$

► La formule d'encadrement:

$$P[|T| \leq t_{\alpha/2}] = 1 - \alpha$$



$$\begin{aligned} P[|T| < t_{\alpha/2}] &= P[-t_{\alpha/2} \leq T \leq t_{\alpha/2}] \\ &= P\left[-t_{\alpha/2} \leq \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \leq t_{\alpha/2}\right] = P\left[\bar{X}_n - \frac{S}{\sqrt{n}} t_{\alpha/2} \leq \mu \leq \bar{X}_n + \frac{S}{\sqrt{n}} t_{\alpha/2}\right] = 1 - \alpha \end{aligned}$$

► 63

63

Estimation par intervalle de confiance: Moyenne & Variance est inconnue & n<30

► Déterminer la valeur critique $t_{\alpha/2}$:

$$2\Pi(t_{\alpha/2}) - 1 = 1 - \alpha = P[|T| \leq t_{\alpha/2}]$$

Déterminer la valeur critique $t_{\alpha/2}$

Encadrement → Intervalle de confiance

$$\Pi(t_{\alpha/2}) = \frac{2 - \alpha}{2}$$

► 64

64

Estimation de la taille minimale d'un échantillon : **La moyenne**

- ▶ **L'erreur absolue** (ou **incertitude absolue**) mesure l'imprécision sur une mesure effectuée.

$$e_{absolue} = |V_{approchée} - V_{réelle}|$$

- ▶ Elle est appelée absolue, car elle est le résultat de la valeur absolue de la différence entre
 - d'une part la valeur réelle de la grandeur que l'on mesure
 - et d'autre part une valeur de référence que nous avons choisie comme une bonne approximation de celle-ci.

▶ **L'erreur relative:**
$$e_{relative} = \frac{|V_{approchée} - V_{réelle}|}{|V_{réelle}|} = \frac{e_{absolue}}{|V_{réelle}|}$$

(%)

il n'y a pas de valeur absolue au numérateur → Une erreur relative algébrique :

- Si elle est *positive* → La valeur approchée est supérieure à la valeur exacte (erreur par excès),
- Si elle est *négative* → La valeur approchée est inférieure à la valeur exacte (erreur par défaut).

▶ 65

65

Estimation de la taille minimale d'un échantillon : **La moyenne**

- ▶ **Cas de variance connue**

$$P\left[|Z| \leq z_{\alpha/2}\right] = 1 - \alpha \quad |Z| = \frac{|\bar{X}_n - \mu|}{\sigma/\sqrt{n}} \leq z_{\alpha/2} \Rightarrow |\bar{X}_n - \mu| \leq z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq e$$

La taille minimale d'un échantillon →

$$\left\{ \begin{array}{l} n \geq \left(\frac{z_{\alpha/2} \times \sigma}{|\bar{X}_n - \mu|} \right)^2 = \left(\frac{z_{\alpha/2} \times \sigma}{e_{absolue}} \right)^2 \\ n \geq \left(\frac{z_{\alpha/2} \times \sigma}{e_{relative}} \right)^2, \text{ avec } e_{relative} = e_{absolue} \times \mu \end{array} \right.$$

- ▶ **Cas de variance inconnue et $n \geq 30$**

La taille minimale d'un échantillon →

$$\left\{ \begin{array}{l} n \geq \left(\frac{z_{\alpha/2} \times S}{|\bar{X}_n - \mu|} \right)^2 = \left(\frac{z_{\alpha/2} \times S}{e_{absolue}} \right)^2 \\ n \geq \left(\frac{z_{\alpha/2} \times S}{e_{relative}} \right)^2, \text{ avec } e_{relative} = e_{absolue} \times \mu \end{array} \right.$$

▶ 66

66

Estimation de la taille minimale d'un échantillon : **La moyenne**

► Cas de variance inconnue et $n < 30$

$$P\left[\left|T\right| \leq t_{\alpha/2}\right] = 1 - \alpha \quad \rightarrow \quad T = \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \leq t_{\alpha/2} \Rightarrow \left|\bar{X}_n - \mu\right| \leq t_{\alpha/2} \frac{S}{\sqrt{n}} \leq e$$

La taille minimale d'un échantillon $\rightarrow$

$$\begin{cases} n \geq \left(\frac{t_{\alpha/2} \times S}{\left|\bar{X}_n - \mu\right|}\right)^2 = \left(\frac{t_{\alpha/2} \times S}{e_{\text{absolue}}}\right)^2 \\ n \geq \left(\frac{t_{\alpha/2} \times S}{e_{\text{relative}}}\right)^2, \text{ avec } e_{\text{relative}} = e_{\text{absolue}} \times \mu \end{cases}$$

► 67

67

Distribution d'échantillonnage de la différence de moyennes

Considérons deux distributions de moyennes indépendantes $\bar{X}_{n_1}$ et $\bar{X}_{n_2}$

► Les variances des populations sont connues σ_{n_1} et σ_{n_2}

$$(\bar{X}_{n_1} - \bar{X}_{n_2}) \propto N\left(E(\bar{X}_{n_1} - \bar{X}_{n_2}), \sigma(\bar{X}_{n_1} - \bar{X}_{n_2})\right)$$

$$\begin{cases} E(\bar{X}_{n_1} - \bar{X}_{n_2}) = E(\bar{X}_{n_1}) - E(\bar{X}_{n_2}) = \mu_1 - \mu_2 \\ \sigma(\bar{X}_{n_1} - \bar{X}_{n_2}) = \sqrt{\text{var}(\bar{X}_{n_1} - \bar{X}_{n_2})} = \sqrt{\text{var}(\bar{X}_{n_1}) + \text{var}(\bar{X}_{n_2})} = \sqrt{\frac{\sigma_{n_1}^2}{n_1} + \frac{\sigma_{n_2}^2}{n_2}} \end{cases}$$

$$\rightarrow (\bar{X}_{n_1} - \bar{X}_{n_2}) \propto N\left(\mu_1 - \mu_2, \sqrt{\frac{\sigma_{n_1}^2}{n_1} + \frac{\sigma_{n_2}^2}{n_2}}\right)$$

► 68

68

Distribution d'échantillonnage de la différence de moyennes

- **Les variances des populations sont connues** σ_{n_1} et σ_{n_2}

$$(\bar{X}_{n_1} - \bar{X}_{n_2}) \propto N\left(\mu_1 - \mu_2, \sqrt{\frac{\sigma_{n_1}^2}{n_1} + \frac{\sigma_{n_2}^2}{n_2}}\right) \Rightarrow Z = \frac{(\bar{X}_{n_1} - \bar{X}_{n_2}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_{n_1}^2}{n_1} + \frac{\sigma_{n_2}^2}{n_2}}} \propto N(0,1)$$

$$P[|Z| \leq z_{\alpha/2}] = 1 - \alpha$$

- **On détermine l'intervalle de confiance: encadrement des deux moyennes** $(\mu_1 - \mu_2)$

$$\mu_1 - \mu_2 \in \left[(\bar{X}_{n_1} - \bar{X}_{n_2}) - z_{\alpha/2} \sqrt{\frac{\sigma_{n_1}^2}{n_1} + \frac{\sigma_{n_2}^2}{n_2}}, (\bar{X}_{n_1} - \bar{X}_{n_2}) + z_{\alpha/2} \sqrt{\frac{\sigma_{n_1}^2}{n_1} + \frac{\sigma_{n_2}^2}{n_2}} \right]$$

► 69

69

Distribution d'échantillonnage de la différence de moyennes

Considérons deux distributions de moyennes indépendantes $\bar{X}_{n_1}$ et $\bar{X}_{n_2}$
Les variances des populations sont inconnues, on calcule S_{n_1} et S_{n_2}

- **Si n_1 et $n_2 \geq 30$**

$$(\bar{X}_{n_1} - \bar{X}_{n_2}) \propto N\left(\mu_1 - \mu_2, \sqrt{\frac{S_{n_1}^2}{n_1} + \frac{S_{n_2}^2}{n_2}}\right)$$

On détermine l'intervalle de confiance: encadrement des deux moyennes $(\mu_1 - \mu_2)$

$$P[|Z| \leq z_{\alpha/2}] = 1 - \alpha$$

$$\mu_1 - \mu_2 \in \left[(\bar{X}_{n_1} - \bar{X}_{n_2}) - z_{\alpha/2} \sqrt{\frac{S_{n_1}^2}{n_1} + \frac{S_{n_2}^2}{n_2}}, (\bar{X}_{n_1} - \bar{X}_{n_2}) + z_{\alpha/2} \sqrt{\frac{S_{n_1}^2}{n_1} + \frac{S_{n_2}^2}{n_2}} \right]$$

► 70

70

Distribution d'échantillonnage de la différence de moyennes

Considérons deux distributions de moyennes indépendantes $\bar{X}_{n_1}$ et $\bar{X}_{n_2}$
Les variances des populations sont inconnues, on calcule S_{n_1} et S_{n_2}

- ▶ Si $\{n_1 \text{ et } n_2 < 30\}$ et $\{n_1 + n_2 - 2 < 30\}$

$$(\bar{X}_{n_1} - \bar{X}_{n_2}) \propto \text{Loi de Student } T(n_1 + n_2 - 2) \text{ ddl}$$

$$P[|T| \leq t_{\alpha/2}] = 1 - \alpha$$

$$\mu_1 - \mu_2 \in \left[(\bar{X}_{n_1} - \bar{X}_{n_2}) - t_{\alpha/2} \sqrt{\frac{S_{n_1}^2}{n_1} + \frac{S_{n_2}^2}{n_2}}, (\bar{X}_{n_1} - \bar{X}_{n_2}) + t_{\alpha/2} \sqrt{\frac{S_{n_1}^2}{n_1} + \frac{S_{n_2}^2}{n_2}} \right]$$

- ▶ Si $\{n_1 \text{ et } n_2 < 30\}$ et $\{n_1 + n_2 - 2 > 30\}$

$$(\bar{X}_{n_1} - \bar{X}_{n_2}) \propto N\left(\mu_1 - \mu_2, \sqrt{\frac{S_{n_1}^2}{n_1} + \frac{S_{n_2}^2}{n_2}}\right)$$

▶ 71

71

Estimation par intervalle de confiance: **Variance**

La loi de khi-deux:

$$\chi^2 = \frac{(n-1)S^2}{\sigma^2}$$

Estimation de la variance:

- ▶ $n < 30 \rightarrow \chi^2 \propto \text{khi-deux à } \nu \text{ ddl avec } \begin{cases} \nu = n & \text{si } \mu \text{ est connue} \\ \nu = n-1 & \text{si } \mu \text{ est inconnue} \end{cases}$

- ▶ $n \geq 30 \rightarrow \chi^2 \propto N(\nu, \sqrt{2\nu}) \text{ avec } \begin{cases} \nu = n & \text{si } \mu \text{ est connue} \\ \nu = n-1 & \text{si } \mu \text{ est inconnue} \end{cases}$

▶ 72

72

Estimation par intervalle de confiance:
Variance & moyenne inconnue & n≥30

Encadrement:

$$\chi^2 \propto N\left(n-1, \sqrt{2(n-1)}\right) \Rightarrow Z = \frac{\chi^2 - (n-1)}{\sqrt{2(n-1)}} \propto N(0,1)$$

$$P\left[|Z| \leq z_{\alpha/2}\right] = 1 - \alpha$$

$$P\left[-z_{\alpha/2} \leq \frac{\chi^2 - (n-1)}{\sqrt{2(n-1)}} \leq z_{\alpha/2}\right] = 1 - \alpha$$

$$\Rightarrow P\left[(n-1) - z_{\alpha/2}\sqrt{2(n-1)} \leq \chi^2 \leq (n-1) + z_{\alpha/2}\sqrt{2(n-1)}\right] = 1 - \alpha$$

$$\chi^2 = \frac{(n-1)S^2}{\sigma^2}$$

► 73

73

Estimation par intervalle de confiance:
Variance & moyenne inconnue & n≥30

Cas Echantillonnage:

$$P\left[\frac{[(n-1) - z_{\alpha/2}\sqrt{2(n-1)}] \times \sigma^2}{n-1} \leq S^2 \leq \frac{[(n-1) + z_{\alpha/2}\sqrt{2(n-1)}] \times \sigma^2}{n-1}\right] = 1 - \alpha$$

Cas Estimation

$$P\left[\frac{(n-1) \times S^2}{(n-1) + z_{\alpha/2}\sqrt{2(n-1)}} \leq \sigma^2 \leq \frac{(n-1) \times S^2}{(n-1) - z_{\alpha/2}\sqrt{2(n-1)}}\right] = 1 - \alpha$$

► 74

74

Estimation par intervalle de confiance: Variance & moyenne inconnue & n<30

Encadrement:

$$\chi^2 \propto \chi^2(n-1) \text{ à } n-1 \text{ ddl}$$

$$P\left[\chi^2_{1-\alpha/2} \leq \chi^2 \leq \chi^2_{\alpha/2}\right] = 1 - \alpha$$

$$\Rightarrow P\left[\chi^2_{1-\alpha/2} \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi^2_{\alpha/2}\right] = 1 - \alpha$$

► 75

75

Estimation par intervalle de confiance: Variance & moyenne inconnue & n≥30

Cas Echantillonnage

$$P\left[\frac{\chi^2_{1-\alpha/2} \times \sigma^2}{n-1} \leq S^2 \leq \frac{\chi^2_{\alpha/2} \times \sigma^2}{n-1}\right] = 1 - \alpha$$

Cas Estimation

$$P\left[\frac{(n-1) \times S^2}{\chi^2_{\alpha/2}} \leq \sigma^2 \leq \frac{(n-1) \times S^2}{\chi^2_{1-\alpha/2}}\right] = 1 - \alpha$$

Lire des valeurs de la table de Khi-deux

Exemple

$$1 - \alpha = 0,95 \text{ et } n = 10$$

$$\alpha = 0,05 \Rightarrow \frac{\alpha}{2} = 0,025$$

$$1 - \frac{\alpha}{2} = 0,975$$

► 76

$$n-1=9$$

k	1 - $\frac{\alpha}{2}$						$\frac{\alpha}{2}$	
	$\alpha = 0,990$	$\alpha = 0,975$	$\alpha = 0,950$	$\alpha = 0,900$	$\alpha = 0,100$	$\alpha = 0,050$	$\alpha = 0,025$	$\alpha = 0,010$
1	0,0002	0,0010	0,0039	0,0158	2,71	3,84	5,02	6,63
2	0,02	0,05	0,10	0,21	4,61	5,99	7,38	9,00
3	0,12	0,22	0,35	0,58	6,25	7,81	9,35	11,14
4	0,30	0,48	0,71	1,06	7,78	9,49	11,14	14,86
5	0,55	0,83	1,15	1,61	9,24	11,07	12,83	16,75
6	0,87	1,24	1,64	2,20	10,64	12,59	14,45	18,55
7	1,24	1,69	2,17	2,83	12,02	14,07	16,01	20,48
8	1,65	2,18	2,73	3,49	13,36	15,51	17,53	22,37
9	2,09	2,70	3,33	4,17	14,68	16,92	19,02	24,47
10	2,56	3,25	3,94	4,87	15,99	18,31	20,48	26,75

76

Intervalle de confiance pour des paramètres de lois normales: **Proportion**

Dans la population il y a une proportion p d'individus possédant un certain caractère. Considérons une population dont l'effectif est important

Il est naturel d'estimer la proportion P d'une population par la proportion f_n de l'échantillon de taille n .

Pour n suffisamment grand, la convergence en loi de la loi $B(n,p)$, nous permet de considérer que

V.A. Bernoulli ↓

f_n , proportion d'échantillon, est une v.a. qui tend vers une loi $N\left(p, \sqrt{\frac{p(1-p)}{n}}\right)$

$$E(f_n) = P$$

f_n est un estimateur sans biais de P

$$Var(f_n) = \frac{p(1-p)}{n} \xrightarrow{n \rightarrow +\infty} 0$$

f_n est un estimateur convergent de P

► 77

77

Intervalle de confiance pour des paramètres de lois normales: **Proportion**

Encadrement de proportion: Intervalle de confiance

$$f_n \sim N\left(P, \frac{P(1-P)}{n}\right) \Rightarrow Z = \frac{f_n - P}{\sqrt{\frac{P(1-P)}{n}}} \sim N(0,1) \quad \begin{array}{l} \text{dès que } n > 100 \\ \text{et} \\ 0,1 < P < 0,9 \end{array}$$

$$P[|Z| \leq z_{\alpha/2}] = 1 - \alpha$$

$$\Rightarrow P \in \left[f_n - z_{\alpha/2} \times \sqrt{\frac{P(1-P)}{n}}, f_n + z_{\alpha/2} \times \sqrt{\frac{P(1-P)}{n}} \right]$$

Solutions:

- $P(1-P)$ est maximum pour $p=1/2 \rightarrow$ Si $P=1/2$, on obtient l'intervalle maximum à α fixe
- p (dans les bornes de l'intervalle aléatoire) étant inconnu, il est approché par l'estimation f_n , d'où un intervalle de confiance

$$P \in \left[f_n - z_{\alpha/2} \times \sqrt{\frac{f_n(1-f_n)}{n}}, f_n + z_{\alpha/2} \times \sqrt{\frac{f_n(1-f_n)}{n}} \right]$$

► 78

78

Estimation de la taille minimale d'un échantillon : **La proportion**

$$f_n \propto N\left(P, \sqrt{\frac{P(1-P)}{n}}\right) \Rightarrow Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2} \Rightarrow |\bar{X}_n - \mu| \leq z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq e$$

$$P\left[|Z| \leq z_{\alpha/2}\right] = 1 - \alpha$$

La taille minimale d'un échantillon

$$\begin{cases} n \geq \frac{(z_{\alpha/2})^2 \times P(1-P)}{|f_n - P|^2} = \frac{(z_{\alpha/2})^2 \times P(1-P)}{(e_{\text{absolue}})^2} \\ n \geq \frac{(z_{\alpha/2})^2 \times P(1-P)}{(e_{\text{relative}})^2} = \frac{(z_{\alpha/2})^2 \times (1-P)}{(e_{\text{absolue}})^2 P}, \text{ avec } e_{\text{relative}} = e_{\text{absolue}} \times P \end{cases}$$

► 79

79

Intervalle de confiance pour une **proportion**

► Méthodes de construction de l'estimateur

- ❑ La méthode exacte ou encore appelée la méthode de Clopper-Pearson qui est réalisable avec la plupart des logiciels de statistique.
- ❑ La méthode du score ou encore appelés la méthode de Wilson ou encore la méthode d'ellipse.
- ❑ La méthode asymptotique ou encore appelé la méthode de Wald

► 80

80