


Logistic Regression Model



Régression logistique

Introduction

Régression linéaire pour un problème de classification

2

Age	Subscribe
25	Yes
55	No
..	..



Y = 1 si Yes
Y = 0 si No

Model 1: OLS, using observations 1-1000
Dependent variable: subscribe

	coefficient	std. error	t-ratio	p-value
const	-1.70073	0.0638035	-26.66	1.20e-118 ***
age	0.0645433	0.00178736	36.11	2.52e-183 ***

$subscribe = -1.700 + 0.064 \text{ age}$

M
S
R
F(1, 998) 1304.002 P-value(F) 2.5e-183


$P(subscribe = 1) = p = -1.700 + 0.064 \text{ age}$

Introduction

Problèmes avec l'approche linéaire

3

- Une probabilité : $0 \leq p \leq 1$
- La variable âge $\in [20, 55]$
- La probabilité qu'une personne âgée de 35 ans s'inscrit est :
 - ▣ $p = -1700 + 0.064 \times 35 = 0.54$
- Qu'en est-il des personnes entre 25 et 45 ans ?
 - ▣ $p = -1700 + 0.064 \times 25 = -0.09$
 - ▣ $p = -1700 + 0.064 \times 45 = 1.2$



Introduction

Problèmes avec l'approche linéaire

4

- Si p est une probabilité, cette probabilité sera toujours comprise entre 0 et 1, et donc toute tentative pour ajuster un nuage de probabilité par une droite sera invalidée par le fait que la droite n'est pas bornée.

Introduction

Problèmes avec l'approche linéaire

5

- Si on utilise la régression linéaire pour un problème de classification, même si les données d'apprentissage auront des étiquettes 0 ou 1, $h_{\theta}(x)$ peut être >1 ou <0

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n \rightarrow \text{Varie entre } -\infty \text{ et } +\infty$$

- La régression logistique par contre possède la propriété : $h_{\theta}(x) \in]0, 1[$

Régression logistique

Fonction sigmoïde

6

Si on se limite à cette modélisation, on ne peut pas prendre Y comme variable expliquée car c'est une variable binaire et l'hyper-droite transforme chaque input en un nombre non borné qui ne permet pas de classifier l'input associé.

$$Y = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

$\in]-\infty, +\infty[$ alors que Y varie entre 0 et 1

Pour transformer le nombre que l'hyper droite fournie en une classification, on utilise une fonction que l'on nomme fonction sigmoïde et qui a la propriété intéressante de transformer les nombres passés à l'intérieur en nombres entre 0 et 1.

Régression logistique


Fonction sigmoïde

7

$$h_{\theta}(x) = \text{sig}(\theta^T x)$$

$$\text{sig}(t) = \frac{1}{1 + e^{-t}}$$

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$




Régression logistique

Fonction sigmoïde

8

Exemple :

Courbe du modèle logistique



Régression logistique

Fonction sigmoïde

9

Exercice :

Supposons que nous ayons un modèle de régression logistique avec trois caractéristiques qui a appris les biais et pondérations suivantes :

$$\theta_0 = 1, \theta_1 = 2, \theta_2 = -1, \theta_3 = 5$$

Supposons ensuite les valeurs de caractéristiques suivantes pour un exemple X donné : $x_1 = 0, x_2 = 10, x_3 = 2$

Calculer $h_\theta(X)$

Régression logistique


Fonction sigmoïde

10

Exercice - Correction :

$$z = (1) + (2).(0) + (-1).(10) + (5).(2) = 1$$

$$h_{\theta}(X) = \sigma(z) = 1 / (1 + e^{-1}) = 0.731$$



Régression logistique

La fonction sigmoïde comme estimateur d'une probabilité

11

□ Interprétation de l'hypothèse

$h_{\theta}(x)$ = probabilité estimée que $y = 1$ sur l'entrée x

▣ Exemple

$$x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ \text{tumorSize} \end{bmatrix}$$
$$h_{\theta}(x) = 0.7$$

Ça veut dire qu'il y a 70% de chance que la tumeur de ce patient soit maligne

$h_{\theta}(x) = P(y = 1 \mid x; \theta)$ probabilité que $y = 1$ sachant x , paramétrée par θ

Régression logistique

La fonction sigmoïde comme estimateur d'une probabilité

12

Il s'agit bien d'une « régression » car on veut montrer une relation de dépendance entre une variable à expliquer et une série de variables explicatives.

Il s'agit d'une régression « logistique » car la loi de probabilité est modélisée à partir d'une loi logistique.

$$\ln \left(\frac{P(y = 1 | x)}{1 - P(y = 1 | x)} \right) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

logit(P(y = 1 | x))

En effet, après transformation de l'équation ci-dessus, nous obtenons :


$$P(y = 1 | x) = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n)}} = \frac{1}{1 + e^{-\theta^T x}}$$

Régression logistique

Exemple

13

Par exemple, en choisissant un seuil de 0.5, on estime qu'une patiente ayant plus de 50% de chance d'être diabétique alors on la classifie comme diabétique




Régression logistique


Interprétation

14

Prenons l'exemple du jeu de données Mnist :



Les images sont encodées comme nombres




Interprétation

15

$$X =$$
[illegible]


Output binaire



Régression logistique

Interprétation


16



Régression logistique

Interprétation

17




Régression logistique

Interprétation

18

Sections négatives




Régression logistique

Interprétation

19


Sections positives



Régression logistique

Interprétation

20



- Une forte correspondance entre le filtre et les données indique que $P(y^{(i)}=1 \mid x^{(i)})$ est élevée
- Une faible correspondance entre le filtre et les données indique que $P(y^{(i)}=1 \mid x^{(i)})$ est faible

Maximum de vraisemblance

21

□ On peut écrire:

$$P(Y | X) = h_{\theta}(x)^y (1 - h_{\theta}(x))^{1-y}$$

$$y = \{0, 1\}$$

$$\text{Avec : } h_{\theta}(x) = \frac{1}{1 + e^{-(\theta^T x)}}$$

Maximum de vraisemblance

22

- Le but est de déterminer les valeurs optimales de θ
- ▣ À l'aide de la méthode du maximum de vraisemblance:

$$L(\theta) = P(Y | X; \theta) = \prod_{i=1}^m P(y^{(i)} | x^{(i)}, \theta) = \prod_{i=1}^m (h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}})$$

Estimateur du maximum de vraisemblance (maximum likelihood estimator)

Maximum de vraisemblance

23

- ▣ Pour faciliter les manipulations, on préfère souvent travailler sur la log-vraisemblance (log-likelihood)
- le vecteur a qui maximise la vraisemblance est le même que celui qui maximise la log-vraisemblance. Cette dernière en revanche varie entre $-\infty$ et 0

$$l(\theta) = \sum_{i=1}^m [y^{(i)} \log (h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))]$$

Fonction coût et descente de gradient

24

$$\max_{\theta}(l(\theta)) \Leftrightarrow \min_{\theta}(-l(\theta)) \Leftrightarrow \min_{\theta}(J(\theta))$$

Gradient Descent

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right]$$

Want $\min_{\theta} J(\theta)$:

Repeat {

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \quad \text{for } j = 0, 1, \dots, n$$


(simultaneously update all θ_j)
}

n : nb of features; m : training set dimension

Frontière de décision


25

- On suppose qu'on prédit $y=1$ si $h_{\theta}(x) \geq 0.5$
 - Lorsque : $t \geq 0 \Rightarrow \theta^T x \geq 0$
- On suppose qu'on prédit $y=0$ si $h_{\theta}(x) < 0.5$
 - Lorsque : $t < 0 \Rightarrow \theta^T x < 0$



Frontière de décision

26



$$h_{\theta}(x) = \text{sig}(\underbrace{\theta_0}_{-3} + \underbrace{\theta_1}_{1}x_1 + \underbrace{\theta_2}_{1}x_2)$$

Prédire $y = 1$ si : $\theta^T x \geq 0$


C'est à dire : $-3 + x_1 + x_2 \geq 0$

$$\rightarrow x_1 + x_2 \geq 3$$

Choix de la valeur seuil

Exemple

27




Choix de la valeur seuil

Exemple

28

Matrice de confusion

		Actual	
		Is Obese	Is Not Obese
Predicted	Is Obese	3	0
	Is Not Obese	1	4




Choix de la valeur seuil

Exemple

29

Matrice de confusion

		Actual	
		Is Obese	Is Not Obese
Predicted	Is Obese	4	2
	Is Not Obese	0	2



Choix de la valeur seuil

Exemple

30

		Actual	
		Is Obese	Is Not Obese
Predicted	Is Obese	True Positives	False Positives
	Is Not Obese	False Negatives	True Negatives

Calculer à partir de la matrice de confusion le taux de vrai positifs

$$\text{True Positive Rate} = \text{Sensitivity} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

Matrice de confusion

		Actual	
		Is Obese	Is Not Obese
Predicted	Is Obese	4	2
	Is Not Obese	0	2



$$\text{True Positive Rate} = \text{Sensitivity} = \frac{4}{4 + 0} = 1$$

Choix de la valeur seuil

Exemple

31

		Actual	
		Is Obese	Is Not Obese
Predicted	Is Obese	True Positives	False Positives
	Is Not Obese	False Negatives	True Negatives

Calculer à partir de la matrice de confusion le taux de faux positifs

$$\text{False Positive Rate} = (1 - \text{Specificity}) = \frac{\text{False Positives}}{\text{False Positives} + \text{True Negatives}}$$

Matrice de confusion

		Actual	
		Is Obese	Is Not Obese
Predicted	Is Obese	4	2
	Is Not Obese	0	2




$$\text{False Positive Rate} = 1 - \text{Specificity} = \frac{2}{2 + 2} = 0.5$$

Choix de la valeur seuil

Exemple

32

Tracer la courbe ROC, en variant les seuils, et choisir la valeur seuil qui convient : dans cet exemple, le choix se porte entre 0.9 et 0.1




Classification multi-classes

One-vs-all

33

One-vs-all (one-vs-rest):




Class 1: $\triangle$ $\leftarrow y = 1$

Class 2: $\square$ $\leftarrow y = 2$

Class 3: $\times$ $\leftarrow y = 3$

$$h_{\theta}^{(i)}(x) = P(y = i|x; \theta) \quad (i = 1, 2, 3)$$



Classification multi-classes

One-vs-all

34

□ Algorithme One-vs-all


■ Entrainer un classifieur de régression logistique $h_{\theta}^{(i)}(x)$ pour chaque classe i afin de prédire la probabilité que $y = i$

■ Pour chaque nouveau individu x à prédire, choisir la classe i qui maximise :

$$\max_i h_{\theta}^{(i)}(x)$$

Evaluation d'un modèle de classification

35



Matrice de confusion

Evaluation d'un modèle de classification

36

		Observations		
		+	-	Total
Prédictions	+	Vrais positifs (VP)	Faux positifs (FP)	Positifs prédits (VP+FP)
	-	Faux négatifs (FN)	Vrais négatifs (VN)	Négatifs prédits (FN+VN)
Total		Total des vrais positifs observés (VP+FN)	Total des vrais négatifs observés (FP+VN)	Total des échantillons (N)

VP : correctement identifié
FP : incorrectement identifié
erreur de type I

VN : correctement rejeté
FN : incorrectement rejeté
erreur de type II

- **Toutes les erreurs ne se valent pas.**
- On peut représenter les performances d'un modèle de classification dans une **matrice de confusion**.
- On peut extraire de cette matrice différentes mesures de performance, comme le **rappel**, la **précision**, la **spécificité** et le **F-score**, qui reflètent différents aspects du modèle.

Evaluation d'un modèle de classification

37

$$\text{Accuracy} = \frac{VP + VN}{N} \quad (\% \text{ du nombre total de prédictions correctes})$$

$$\text{Précision} = \frac{VP}{VP + FP} \quad (\text{De ceux que l'algorithme a pu classer, combien sont corrects})$$

$$\text{Rappel} = \frac{VP}{VP + FN} \quad (\text{Taux de vrai positifs / de ceux qui existent, combien l'algorithme a pu trouver})$$

(Recall)

$$\text{F - mesure} = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

(F1)