






Apprentissage non supervisé : le clustering

Enseignante : Rim Mahouachi

Rappel : apprentissage non supervisé

2



Introduction


3

- Processus qui partitionne un ensemble de données en sous-classes (clusters) ayant du sens
- Classification non-supervisée : classes non prédéfinies
 - ▣ Les regroupements d'objets (clusters) forment les classes
- Deux méthodologies générales
 - ▣ Algorithmes de partitionnement
 - Diviser un ensemble de N items en K clusters
 - Exemple : KMeans
 - ▣ Algorithmes hiérarchiques :
 - Par agglomérations : les paires d'items ou de clusters sont successivement liés pour produire des clusters plus grands (bottom-up). Exemple : CAH
 - Par divisions : commencer par l'ensemble entier comme cluster et successivement diviser en de plus petites partitions (top-down).

Introduction

4


- ❑ Principales applications
 - ▣ Observer la distribution des données en identifiant les groupes et leurs caractéristiques (découvrir des corrélations)
 - ▣ Préparation des données pour un autre algorithme ou application
 - ▣ Affecter de nouveaux individus à des catégories
 - ▣ Résumer des comportements
 - ▣ Identifier les cas totalement atypiques



Exemples d'application

5

- ❑ Identifier des communautés dans des réseaux sociaux
- ❑ Identifier des clients avec un profil similaire
- ❑ Analyser des logs d'applications
- ❑ Analyser des textes, des emails
- ❑ Segmenter des images



Exemple d'application

6

Segmentation des clients


Objectif : Etablir 3 stratégies

Données : clients (Age ; Engagement avec la page en combien de fois / jours)




Exemple d'application

7




Exemple d'application

8



Objectifs

9



- Détecter au sein d'un ensemble de données non étiquetées des groupes d'objets similaires
- Organiser des données en groupes (clusters) de façon à ce que les données similaires soient dans le même groupe
- 2 optimisations :
 - ▣ Similarités entre les données dans un groupe aussi élevées que possible (intra-groupe)
 - grande homogénéité de chaque classe(critère de compacité)
 - ▣ Similarités entre les données de différents groupes aussi distinctes que possible (inter-groupes)
 - bonne séparation des classes (critère de séparabilité)

Hypothèse

10

- On suppose qu'une structure de classes existe au sein de la population étudiée
 - ▣ Le but de la classification est de la mettre à jour ou de l'identifier
- On suppose que la population étudiée est séparable
- Une classification automatique obtenue sur un ensemble n n'est jamais la classification de cet ensemble
 - ▣ C'est une classification parmi beaucoup d'autres

Etapes de la classification automatique

11

- Choix des données
 - ▣ la classification s'intéresse à des tableaux de données (individus $\times$ variables quantitatives)

- Choix d'un algorithme de classification à exécuter
 - ▣ Calcul des similarités entre les n individus

- Interprétation des résultats :
 - ▣ Évaluation de la qualité de la classification
 - ▣ Description des classes obtenues

12

Algorithme K-means (k-moyennes)

Généralités

13

- Le plus connu des algorithmes non hiérarchiques.
- K-means
 - K : fait référence au nombre de groupes (clusters)
 - Means : fait référence au centroïde du cluster, c'est-à-dire un point de données choisi arbitrairement puis affiné de manière itérative jusqu'à ce qu'il représente la moyenne vraie de tous les points de données dans le cluster

Fonctionnement



14

- **Etape 1** : Choisir K éléments initiaux "centres" des K groupes
- **Etape 2** : Placer les objets dans le groupe de centre le plus proche
- **Etape 3** : Recalculer le centre de chaque groupe

Pour un cluster K de N points $\{p_1, \dots, p_N\}$, son centre :
$$C = \frac{\sum_{i=1}^N p_i}{N}$$

- **Etape 4** : Itérer l'algorithme jusqu'à ce que les objets ne changent plus de groupe


Exercice



15

- 4 types de médicaments ayant chacun deux modalités :
 - ▣ La concentration
 - ▣ L'efficacité,
- on veut créer deux classes $\Rightarrow K=2$
- On choisit A et B comme centroids

Médicaments	Concentration	Efficacité
A	1	1
B	2	1
C	4	3
D	5	4



Exercice – correction (1/3)



16

- Etape 1 : On désigne aléatoirement A et B comme centres des classes.


- ▣ $C1 = A$

- ▣ $C2 = B$

- Etape 2 :

- ▣ On assigne chaque point à une des classes.

- ▣ On commence par D



$$d(D, c_1) = \sqrt{(5-1)^2 + (4-1)^2} = 5$$

$$d(D, c_2) = \sqrt{(5-2)^2 + (4-1)^2} = 4.24$$


Exercice – correction (2/3)



17

- Etape 3 : Calculer les nouveaux centres des classes compte tenu de la nouvelle classification

$$\begin{aligned}c_1 &= (1, 1) \\c_2 &= \left(\frac{2+4+5}{3}, \frac{1+3+4}{3} \right) \\&= (11/3, 8/3) \\&= (3.67, 2.67)\end{aligned}$$



Exercice – correction (3/3)




18

□ Le résultat final est donc:

▣ **Classe1** = {A , B}
avec centre de classe
 $c1 = (1.5 , 1)$

▣ **Classe2** = {C , D}
avec centre de classe
 $c2 = (4.5 , 3.5)$



Points faibles



19

- Points d'attention
 - ▣ Le nombre de clusters K doit être fixé au départ
 - ▣ Reste bloqué dans un optimum local

- Sensibilité aux bruits et anomalies
 - ▣ il calcule les centroïdes des clusters par la moyenne de leurs points
 - et la moyenne est sensible aux outliers

Points faibles




20

□ Sensibilité à l'initialisation

▣ si les centres initiaux sont tirés aléatoirement, des exécutions successives de l'algorithme peuvent donner des résultats différents.

■ K-means++ : Choix des centres avec une probabilité liée à la distance au carré aux autres centres




Points faibles



21

- Sensibilité à la densité des points, à la taille ou forme des clusters
 - ▣ fonctionne bien si les clusters à identifier sont hypersphériques et de tailles similaires
 - ▣ Problèmes dans les autres cas :
 - Ex. si les clusters sont hypersphériques mais de tailles différentes




Points faibles



22

- Sensibilité à la densité des points, à la taille ou forme des clusters
 - ▣ fonctionne bien si les clusters à identifier sont hypersphériques et de tailles similaires
 - ▣ Problèmes dans les autres cas :
 - Ex. si les clusters ne sont pas hypersphériques



Comment choisir K ?


Méthode Elbow (du coude)

23

- ▣ Choisir une plage de valeurs candidates de k
- ▣ Appliquer K-Means en utilisant chacune des valeurs de k
- ▣ Calculer la somme des carrées des distances entre chaque point d'un cluster et son centre de gravité (dispersion intra-classes) et la représenter dans un tracé :

$$\sum_{k=1}^K \sum_{i=1}^{n_k} d^2(i, G_k)$$

- ▣ Choisir la valeur de k, où **la somme des distances tombe soudainement**



Comment choisir K ?

Méthode de la Silhouette

24

■ Coefficient de la silhouette

- Pour chaque point, son coefficient de silhouette est la différence entre la distance moyenne avec les points du même groupe que lui (cohésion) et la distance moyenne avec les points du plus proche groupe voisin (séparation).
 - Si cette différence est négative, le point est en moyenne plus proche du groupe voisin que du sien : il est donc mal classé.
 - A l'inverse, si cette différence est positive, le point est en moyenne plus proche de son groupe que du groupe voisin : il est donc bien classé.
- Le coefficient de silhouette proprement dit est la moyenne du coefficient de silhouette pour tous les points.

Comment choisir K ?

Méthode de la Silhouette


25

■ Calcul du coefficient de la silhouette

- Calculer $a(i)$: la distance moyenne de ce point avec tous les autres points dans le même cluster.
- Calculer $b(i)$: la distance moyenne de ce point avec tous les points du cluster le plus proche de son cluster.
- Calculer $s(i)$ - coefficient de silhouette du point i en utilisant la formule:

$$s_{sil}(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

La valeur de la silhouette est comprise entre $[-1, 1]$. Si la plupart des objets ont une valeur élevée, la configuration de clustering est appropriée. Si de nombreux points ont une valeur faible ou négative, la configuration de clustering peut avoir trop ou trop peu de clusters.



Comment choisir K ?

Méthode de la Silhouette

26

- Choisir une plage de valeurs candidates de k
- Appliquer K-Means pour chacune des valeurs de k .
- Pour chaque modèle obtenu, représenter les coefficients de silhouette dans un graphique

