


Classe : MPDS1 / MRSI1
Matière : MACHINE LEARNING 1

Durée : 2 séances
Enseignant : R. Mahouachi

TP3 : Analyse de données avec Pandas

1. Importer les données avec Pandas

Le dataset¹ qu'on va utiliser porte sur les différents types de Pokémons et leurs pouvoirs. Vous pouvez examiner la description des données avant de les télécharger :



Travail à faire :

1. Importez le dataset en utilisant le code suivant :

```
df = pd.read_csv('pokemon_data.csv')
```

2. Visualisez les 5 premières lignes du dataframe.

3. Répétez le même travail avec les autres formats des fichiers de données :

```
df = pd.read_excel('pokemon_data.xlsx')
```

¹ <https://www.kaggle.com/haiannguyen/learnpanda1>

```
df = pd.read_csv('pokemon_data.txt', delimiter='\t') #remarquez l'utilisation du
délimiteur
```

4. Affichez les noms des colonnes

5. Utilisez : `df.describe()` et examinez le résultat obtenu

3. Analyse de données avec Pandas

Pour le reste du TP, travaillez avec le fichier « pokemon.csv ».

(a) Accès aux données et filtrage

Travail à faire :

1. Affichez la colonne « Name »

2. Afficher les 5 premières lignes de la colonne « Type 1 »

3. Affichez seulement les colonnes suivantes : Name, Type 1 et Type 2

4. Affichez la deuxième ligne

5. Filtrez les lignes qui vérifient la condition suivante:

(a) Type 1 = 'Fire'

(b) Type 1 = 'Grass' et Type 2 = 'Poison'

(c) Type 1 = 'Grass' ou Type 2 = 'Poison'

(d) Type 1 = 'Grass' et Type 2 = 'Poison' et HP > 70

6. Filtrez les lignes dont les noms comportent le terme 'Mega'.

(b) Statistiques simples et tri des données

Travail à faire :

1. Affichez la moyenne, la somme et la médiane de la colonne 'speed'

2. Triez les données dans un ordre alphabétique selon le nom

3. Changez le tri par ordre décroissant (à partir de Z)

4. Triez les données selon les colonnes Type 1 et HP (le premier dans un ordre croissant et le deuxième dans un ordre décroissant)

(c) Ajout et suppression de colonnes

Travail à faire :

1. Ajoutez au dataframe une colonne Total dont la valeur sera calculée en faisant la somme de toutes les colonnes numériques sauf Generation (c'est-à dire les colonnes : HP, Attack, Defense, Sp. Atk, Sp. Def, Speed)

2. Supprimez la colonne Total