



TP4 : Prétraitement et visualisation des données

1. Visualisation des données

Pandas utilise Matplotlib.pyplot ce qui permet de réaliser des graphiques facilement. Il faut importer matplotlib pour que l'ensemble fonctionne correctement :

```
import matplotlib.pyplot as plt
```

Travail à faire :

1. Importez le dataset iris de l'url suivant :

<https://gist.githubusercontent.com/netj/8836201/raw/6f9306ad21398ea43cba4f7d537619d0e07d5ae3/iris.csv>

2. Visualisez les données :

```
#on crée la figure et les axes :  
  
figure, axe = plt.subplots()  
  
#on peut ensuite dessiner par exemple la dispersion des sepal_length  
#en fonction des sepal_width :  
  
axe.scatter(iris['sepal_length'], iris['sepal_width'])  
  
#mettre un titre et des étiquettes :  
  
axe.set_title('Iris Dataset')  
axe.set_xlabel('sepal_length')  
axe.set_ylabel('sepal_width')
```

3. Changez les couleurs pour une meilleure visibilité :

```

#On peut également changer les couleurs :

colors = {'Setosa':'r', 'Versicolor':'g', 'Virginica':'b'}

#créer notre figures et les axes

figure, axe = plt.subplots()

#dessiner le nuage de points :

for i in range(len(iris['sepal_length'])):

    axe.scatter(iris['sepal_length'][i],
iris['sepal_width'][i],color=colors[iris['class'][i]])

#mettre le titre et les étiquettes :

axe.set_title('Iris Dataset')

axe.set_xlabel('sepal_length')

axe.set_ylabel('sepal_width')

```

4. Refaire la même chose pour visualiser par exemple la dispersion des petal_length en fonction des petal_width

2. Prétraitement des données

Travail à faire :

1. Traitement des doublons et des valeurs manquantes

(a) Chargez et examinez le jeu de données « titanic.csv »

(b) Vérifiez s'il y a des doublons. Si oui, supprimez-les.

(c) En utilisant le code suivant, vérifiez s'il y a des données manquantes ?

```
df.info()
```

(d) Vérifiez s'il y a des valeurs manquantes avec le code suivant : `df.isnull().sum()`. Calculez le pourcentage de données manquantes par variable.

(e) Supprimez toutes les lignes contenant des données manquantes

Vérifiez le résultat avec `df2.info()`. Qu'est ce que vous remarquez en termes de nombre de lignes supprimées ?

(f) Au lieu de supprimer toutes les valeurs manquantes, supprimez seulement les valeurs manquantes de la colonne Age. Le résultat est à mettre dans un dataframe `df3`.

(g) Au lieu de supprimer les valeurs manquantes, on va plutôt les remplacer.

- Pour l'âge, on va remplacer les données manquantes par la moyenne des âges.

- Pour Embarked, il s'agit d'une donnée catégorielle (non numérique), donc on ne peut pas utiliser la même stratégie. On remplace les données manquantes par la valeur la plus courante (ce n'est pas grave ici car on n'a que deux valeurs manquantes).

2. Normalisation

(a) Copiez le code suivant :

```
import numpy as np

import matplotlib.pyplot as plt

url = 'https://archive.ics.uci.edu/ml/machine-learning-
databases/cpu-performance/machine.data'

names=
['constructor', 'Model', 'MYCT', 'MMIN', 'MMAX', 'CACH', 'CHMIN', 'CHMAX', 'PRP', 'ERP']

dataset = pa.read_csv(url, names=names)
```

Nous allons nous intéresser aux deux attributs :

- MYCT : Machine Cycle time in nanoseconds
- MMAX : Maximum Main Memory in Kilobytes

Vous pouvez déjà observer que les unités de mesure sont très différentes

(b) Visualisez les données avant transformation

(c) Normalisez les colonnes MYCT et MMAX en utilisant la méthode min_max (créez deux nouvelles colonnes pour contenir les valeurs normalisées)