



Chapitre 1 : Introduction au NoSQL

Kaouther Gasmi, PhD
kaouther.gasmi@fsb.ucar.tn



Plan de Cours

- Introduction
- Stockage et manipulation de données avec NosQL
- Théorème de CAP
- Caractéristiques générales des BD NosQL
- SQL vs NoSQL



Introduction


- En 1970, Edgar F. Codd (IBM) publie un article considéré comme à l'origine du modèle relationnel
- Ce modèle Repose sur des relations entre les valeurs des données.
- Manipulation à travers une algèbre et un langage de haut niveau
- Toutes les lignes d'une Relation ont les mêmes colonnes
- Modifications par séquences atomiques pour que la BdD soit toujours totalement cohérente
- Conception d'un schéma de base qui s'impose à toute la BdD.



Introduction


- SGBD relationnels offrent :

- Un système de jointure entre les tables permettant de construire des requêtes complexes impliquant plusieurs entités
- Un système d'intégrité référentielle permettant de s'assurer la cohérence de la BD
 - dans un contexte fortement distribué ➡ ces mécanismes ont un cout considerable:*
- Avec la plupart des SGBD relationnels, les données d'une BD liées entre elles sont places sur le même noeud du serveur
-
- Si le nombre de liens importants, il est de plus en plus difficile de placer ces données sur des noeuds différents




Introduction

- SGBD relationnels sont généralement transactionnels
Gestion de transaction respectant les contraintes ACID:
 - **Atomique** Chaque transaction est exécutée correctement ou le processus s'arrête et la base de données revient à l'état précédant le début de la transaction. Cela garantit que toutes les données de la base sont valides.
 - **Cohérente** Une transaction traitée ne mettra jamais en péril l'intégrité structurelle de la base de données.
 - **Isolées** Les transactions ne peuvent pas compromettre l'intégrité d'autres transactions en interagissant avec elles alors qu'elles sont encore en cours.
 - **Durable** Les données relatives à la transaction achevée persistent même en cas de panne de réseau ou d'électricité. L'échec d'une transaction n'a pas d'incidence sur les données manipulées



Introduction

- Les SGBDs sont bien adaptées au stockage et à la manipulation d'informations bien structurées, décomposables en unités simples et représentables sous forme de tableaux.
- Les SGBDs font la preuve de leur efficacité depuis longtemps, et encore aujourd'hui !
- Mais...depuis quelques années, ce modèle est remis en cause ... pour des raisons que nous allons (tenter) d'expliquer à partir de deux constats.




Introduction-Constats

- **Constat 1 : le modèle relationnel présente certaines limites présentées en première partie du cours.**

- ▶ On ne peut pas imbriquer les informations: On multiplie le nombre de tables pour représenter conceptuellement le même objet.

- ▶ La structure du schéma est très rigide : une base a un nombre fixé de tables, une table a un nombre fixe d'attributs, ...

- ➡ Le modèle doit être défini tôt dans le processus de développement, il est souvent difficile et coûteux de le faire évoluer.




Introduction-Constats

- **Constat 2 : Croissance exponentielle des données générées par le web.**

- Essor des plateformes et applications web (Twitter, Amazon, Youtube, Netflix..)
- Ces masses de données apportent des opportunités d'analyses plus larges et plus fines ainsi que de nouveaux usages de l'information.
- Les données sont devenues le principal actif de certaines entreprises ! Le phénomène « Big data » !




Les systèmes de gestion des BD relationnelles n'ont pas été conçus pour gérer de tels volumes de données



Introduction- Constats


- Les premiers acteurs à avoir été confrontés à ces deux constats et avoir buté sur les limites des modèles relationnels furent les fournisseurs de services en ligne les plus populaires, tels que **Yahoo**, **Google**, ou plus récemment les acteurs du web social comme **Facebook**, **Twitter** ou **LinkedIn**.
- Ces grands acteurs du web ont alors conçu de nouveaux systèmes leur permettant de s'affranchir de ces limites
- C'est la naissance du phénomène **NoSQL** !
- NoSQL : No SQL ? Faut il jeter le modèle relationnel ?



Introduction- Réponse NoSQL

- **Réponse au constat n°1 : des modèles de données non-structurés ou semi-structurés, plus adaptés à de nombreux cas de collecte et de manipulation des données.**
- Les bases **NoSQL** manipulent les données à l'aide de modèles **non ou semi-structurés** : par exemple JSON, mais ça n'est pas le seul format de modèles semi-structurés qui existe...


Exemple : La base de données NoSQL MongoDB manipule les données à l'aide de modèle semi-structurés : Json



Introduction- Réponse NoSQL


Réponse au constat n°2 : Gérer de grands volumes de données nécessite de mettre en place des systèmes distribués

- Les capacités de stockage sont démultipliées par la possibilité de répartir les données sur plusieurs nœuds de serveurs
- Nécessaire de distribuer les traitements de données entre différents nœuds de serveurs
- La plupart des SGBD NoSQL relâchent les contraintes ACID.
- Difficile de maintenir les propriétés **ACID** à l'échelle du système distribué tout en maintenant des performances correctes.
- Les solutions NoSQL implémentent naturellement des mécanismes qui permettent une distribution des données



Stockage et manipulation de données avec NoSQL

- En introduction de ce cours, nous avons vu que les bases NoSQL manipulent des données non-structurées ou semi-structurées, plus adaptées à de nombreux cas de collecte et de manipulation des données:
- Quels sont les formats de manipulation de données « semi-structurées » ?
- En fait, il en existe une multitude, comme il existe une multitude de bases NoSQL !
 - ▶ XML, Xquery, XML-Schema : très répandu !
 - ▶ JSON : la valeur qui monte !
 - ▶ Autres : YAML, ... : moins répandus



Stockage et manipulation de données avec NoSQL- JSON

- JSON : Javascript Object Notation
- format de données textuelles dérivé de la notation des objets du langage de JavaScript. Permet de représenter de l'information structurée comme le permet XML.
- Dérivée de la représentation latérale de l'objet JavaScript.
- JSON est plus simple que XML . Il est facile à associer avec un langage de programmation.
- JSON est massivement utilisé dans les applications web (AJAX), les web-services (REST), et ... les bases de données NoSQL !




Stockage et manipulation de données avec NoSQL-JSON

■ JSON se base sur deux structures:

- ▶ Une collection de couples nom/valeur, appelée **objet**
- ▶ Une liste de valeurs ordonnées, appelée **tableau**.
- ▶ Une valeur de tableau peut être une chaîne de caractères, un nombre, true ou false ou null, un objet, un tableau.

Exemples :


```
"director": {  
  "first_name": "David",  
  "last_name": "Fincher",  
  "birth_date": 1962 }  
"actors": ["Eisenberg", "Mara", "Garfield", "Timberlake"]
```



Object

Couples Cle/Valeur

Tableau




Stockage et manipulation de données avec NoSQL- JSON

- Les structures peuvent être imbriquées.


```
MonFilmCulte" {  
  "Title": "The Social network",  
  "summary": "On a fall night in 2003, Harvard undergrad and \n  
programming genius Mark Zuckerberg sits down at his \n computer  
and heatedly begins working on a new idea. (...)",  
  "year": 2010,  
  "director": { "last_name": "Fincher",  
                "first_name": "David"  
              },  
  
  "actors": [ {"first_name": "Jesse", "last_name": "Eisenberg"},  
              {"first_name": "Rooney", "last_name": "Mara"} ] }
```

Stockage et manipulation des données- JSON

XML et JSON sont les deux formats documentaires les plus répandus dans les solutions NoSQL du marché.





- Solutions du marché :
 - **Solutions NoSQL basees sur XML** : baseX, Berkely BB XML, eXist
 - **Solutions NoSQL basees sur Json** : MongoDB, CouchDB, ..



Stockage et manipulation des données


Et dans cet exemple ?






Stockage et manipulation des données


- En NoSQL:
 - privilégier le rapprochement des informations
 - Pre-joining Data
 - Accès aux informations en un seul appel et une seule lecture
 - L'information regroupée ainsi simplifie la **répartition des données** et la **scalabilité** dans le cadre d'un système distribué





Stockage et manipulation des données

- La conception d'une base NoSQL peut paraître à première vue plus complexe qu'une base relationnelle.
- Les éléments fondamentaux à prendre en compte pour concevoir une base NoSQL :
 - Le ratio des accès en lecture et écriture sur la base,
 - Le type de requêtes et mises à jour sur la base,
 - Le cycle de vie des données et le taux de croissance du volume des données.
- Pour une base relationnelle soumise à de fortes sollicitations, on devrait se poser les mêmes questions.




Stockage et manipulation des données


- Contrairement aux bases relationnelles, il n'existe pas (encore) de langage standard pour l'interrogation des bases NoSQL.
- Exemples :
 - ▶ Cassandra : CQL Cassandra Query Language, basé sur SQL
 - ▶ Couchdb : JSON
 - ▶ eXist, BaseX : Xquery
 - ▶ MongoDB : langage spécifique
 - ▶ Neo4j : cypher
 - ▶ ...

Stockage et manipulation des données

- Il existe un très grand nombre de solutions Nosql

Document Database	Graph Databases
 Couchbase  MarkLogic  mongoDB	 Neo4j  InfiniteGraph The Distributed Graph Database
Wide Column Stores	Key-Value Databases
 redis  amazon DynamoDB  AEROSPIKE  riak	 ACCUMULO™ HYPERTABLE ^{INC}  Cassandra APACHE HBASE Amazon SimpleDB

@cloudtxt <http://www.aryannava.com>




Théorème de CAP :

Coherence, Disponibilité et Partitionnement

- L'émergence de Nosql est lié au théorème CAP:
 - **Coherence ou consistance** : tous les noeuds du système voient exactement les même données au même temps
 - **Disponibilite ou Availability** : l'échec d'un noeud n'empêche pas les survivants de continuer à fonctionner
 - **Résistance au partitionnement ou partition-tolerance**: Le système fonctionne malgré la partition physique de données
- Dans un système distribué, il est impossible d'obtenir ces trois propriétés en même temps

Théorème de CAP :


Coherence, Disponibilité et Partitionnement




- Les SGBD assurent les propriétés de **Cohérence** et **Disponibilité**.
- Les SGBD NoSQL sont des systèmes **CP** ou **AP**

Théorème de CAP :

Coherence, Disponibilité et Partitionnement





Caractéristiques générales des BD NosQL

- Adoptent une représentation non relationnelle de données
- Ne remplacent pas les BDR mais sont une alternative, un complément apportant des solutions plus intéressante dans certains contexte
- Apportent une plus grande performance dans le contexte des applications web avec des volumétries de donnees exponentielle.
- Utilise une très forte distribution de ces données et des traitements associés sur de nombreux serveurs
- Pas de schéma ou schéma dynamique
- données de structures complexe ou imbriqués
- Donnees distributes : Partition horizontale des données sur plusieurs noeuds (serveurs)
- Réplication des données sur plusieurs noeuds
- privilégient la disponibilité à la cohérence (theoreme de CAP) : AP (Disponibilité + Résistant au partitionnement) plutôt que CP
- Mode d utilisation : Peu d écritures, beaucoup de lectures



SQL VS NoSQL

SQL

- Généraliste
- Logique : schémas, contraintes
- Cohérence forte
- Ressources limitées
- Langage standard: SQL
- Traitements centralisés




Cohérence

NoSQL

- Systèmes sur mesure
- Pas de schéma ni contrainte
- Cohérence « à terme »
- Ressources « illimitées »
- Langages spécialisés, API
- Traitements distribués (MapRedu




Disponibilité



SQL Vs NoSQL


■ Les bases NoSQL ne remplacent pas les BD relationnelles mais en sont une **alternative**, un complément apportant des solutions plus intéressantes dans certains contextes.

	NoSQL	Relationnel
Capacite de stockage	tres eleve > To	Moderee < To
Architecture	distribué	centralise
Modele de donnees	Destructuree	Tabulaire
Scalability	Horizontale	Verticale
Langage de requetes	propore au systeme	SQL
Caracteristiques	CAP	ACID



Solutions NoSQL

- Les solutions NoSQL sont généralement classées en 4 catégories selon le schéma ou la structure de données qu'ils manipulent :
 1. Bases clé/valeur,
 2. Bases orientées colonnes,
 3. Bases orientées documents,
 4. Bases orientées graphes.




Solutions NoSQL

Le choix d'une catégorie ou d'une autre, d'une solution ou d'une autre, doit se faire en analysant :

- ▶ La structure des données à conserver,
- ▶ L'usage des données (modes de lectures, mises à jour, ...),
- ▶ Le besoin de performance,
- ▶ Le volume de données à traiter,
- ▶ ...

■




Solutions NoSQL-Les BD NoSQL orientées documents


■ Principe:

- Basées sur le modèle « clé-valeur » mais la valeur est un document en format semi-structuré hiérarchique de type JSON ou XML.
- Les documents n'ont pas de schéma, mais une structure arborescente : ils contiennent une liste de champs, un champ a une valeur qui peut être une liste de champs, ...
- Possibilité de requêter et manipuler ces documents, et notamment récupérer, via une seule clé, un ensemble d'informations structurées de manière hiérarchique (en relationnel, cette opération nécessite plusieurs jointures qui sont très coûteuse en ressources)

Solutions NoSQL-Les BD NoSQL orientées documents

Exemple






Solutions NoSQL-Les BD NoSQL orientées documents

- Principe (suite)

- Pas adapté pour les données interconnectées ni pour les données non-structurées
- Exemple d'applications : données clients (stockage de toutes les transactions et information du client (liées à une même clé) au sein d'un même document), gestion de catalogue de produits ...




Solutions NoSQL-Les BD NoSQL orientées documents

- Interets :

- Capacité à effectuer des requêtes sur le contenu des objets
- Modèle de données simple mais puissant
- Scalability
- Pas de maintenance de la BD requise pour ajouter/supprimer des colonnes

- Limites :

- Non adapter pour les données interconnectés et les données non-structurées
- Lent pour les grandes requetes



Solutions NoSQL-Les BD NoSQL orientées documents

- Usages:

- Enregistrements des evenements
- Catalogue de produits
- Données clients (stockage de toutes les transactions et information du client (liées à une même clé) au sein d'un même documents