

TP n°4: Synthèse PIG & Hive

Matière : Traitement du Big data avancé

Ghada Hamoudi

MPDS1

Partie 1 : Pig

3) Ecrivez un code qui permet de lire correctement les deux fichiers en spécifiant un schéma de lecture détaillé pour chaque fichier. (Afficher le résultat)

```
grunt> USERS = LOAD '/user/cloudera/data/users.txt' USING PigStorage(',') as(nom:chararray, age:int);
grunt> DUMP USERS;
2024-03-18 06:21:40,267 [main] INFO org.apache.pig.tools.pigstats.ScriptState -
-----
(Salem salem,25)
(Ichrak May,30)
(Mohamed Mensi,31)
(Islem Saada,28)
(Abrar Hammami,22)
(Houcem Ben Mansour,27)
(Mohamed Khalil,29)
(Khouloud Mernsi,25)
(Mohamed Bouke,24)
(Jihene Hasnaoui,27)
```

```
grunt> SITES = LOAD '/user/cloudera/data/sites.txt' USING PigStorage(',') as(nom:chararray, site:chararray);
grunt> DUMP SITES;
2024-03-18 06:25:51,461 [main] INFO org.apache.pig.tools.pigstats.ScriptState -
Pin features used in the script: UNKNOWN
-----
(Salem salem,http://www.fsb.rnu.tn/)
(Ichrak May,https://www.uvt.rnu.tn/)
(Mohamed Mensi,http://www.fsb.rnu.tn/)
(Islem Saada,https://www.facebook.com/)
(Abrar Hammami,http://www.fsb.rnu.tn/)
(Houcem Ben Mansour,http://www.fsb.rnu.tn/)
(Mohamed Khalil,https://www.uvt.rnu.tn/)
(Khouloud Mernsi,https://www.facebook.com/)
(Mohamed Bouke,http://www.fsb.rnu.tn/)
(Jihene Hasnaoui,https://pig.apache.org/)
```

4) Ecrivez un code qui permet de joindre les deux fichiers afin d'en avoir un seul qui sera l'objet de traitement suivant : comptage des sites les plus visités. (Afficher le résultat)

```
grunt> USERS_SITES= 'join 'USERS' by nom, 'SITES' by nom;
grunt>
grunt> DUMP USERS_SITES;

ne.util.MapReduceUtil - total input paths to process : 1
(Ichrak May,30,Ichrak May,https://www.uvt.rnu.tn/)
(Islem Saada,28,Islem Saada,https://www.facebook.com/)
(Salem salem,25,Salem salem,http://www.fsb.rnu.tn/)
(Abrar Hammami,22,Abrar Hammami,http://www.fsb.rnu.tn/)
(Mohamed Bouke,24,Mohamed Bouke,http://www.fsb.rnu.tn/)
(Mohamed Mensi,31,Mohamed Mensi,http://www.fsb.rnu.tn/)
(Mohamed Khalil,29,Mohamed Khalil,https://www.uvt.rnu.tn/)
(Jihene Hasnaoui,27,Jihene Hasnaoui,https://pig.apache.org/)
(Khouloud Mernsi,25,Khouloud Mernsi,https://www.facebook.com/)
(Houcem Ben Mansour,27,Houcem Ben Mansour,http://www.fsb.rnu.tn/)
```

5) Ecrivez un code qui permet de compter et trier les sites le plus fréquentés par ordre décroissant. (Afficher le résultat) Indice : utiliser l'argument « desc » de l'instruction « order »

```
grunt> site_group = GROUP USERS_SITES BY site;
grunt> site_count = FOREACH site_group GENERATE group, COUNT(USERS_SITES);
grunt>
grunt> site_order= order site_count by $1 DESC;
grunt> DUMP site_order;
2024-03-18 06:29:50,520 [main] INFO org.apache.pig.tools.pigstats.ScriptState
Pig features used in the script: HASH JOIN, GROUP BY, ORDER BY
ne.util.MapReduceUtil - total input paths to process : 1
(http://www.fsb.rnu.tn/,5)
(https://www.facebook.com/,2)
(https://www.uvt.rnu.tn/,2)
(https://pig.apache.org/,1)
```

6) Ecrivez un code qui permet d'afficher les 2 sites les plus fréquentés ainsi le nombre de fois où ils ont été visités. Donnez le résultat de cet affichage.

```
grunt> site_order2 = LIMIT site_order 2;
grunt>
grunt> DUMP site_order2;
2024-03-18 06:33:48,229 [main] INFO org.apache.pig.
Pig features used in the script: HASH JOIN, GROUP BY, ORDER BY, LIMIT
ne.util.MapReduceUtil - total input paths to process : 1
(http://www.fsb.rnu.tn/,5)
(https://www.facebook.com/,2)
grunt>
```

7) Ecrivez un code qui permet de stocker le résultat dans le dossier « res1 » dans le cluster Hadoop à l'emplacement « /user/cloudera/data-pig/result/ »

```
(https://www.facebook.com/,2)
grunt> store site_order2 into '/user/cloudera/data/result/res';
2024-03-18 06:38:08 778 [main] INFO org.apache.pig.tools.nistat
```

🏠 Home / user / cloudera / data / result / res

☐	Name	Size	User	Group	Permissions	Date
☐	📁 ↑		cloudera	cloudera	drwxr-xr-x	March 18, 2024 06:42 AM
☐	📁 .		cloudera	cloudera	drwxr-xr-x	March 18, 2024 06:42 AM
☐	📄 _SUCCESS	0 bytes	cloudera	cloudera	-rw-r--r--	March 18, 2024 06:42 AM
☐	📄 part-r-00000	53 bytes	cloudera	cloudera	-rw-r--r--	March 18, 2024 06:42 AM

Show 45 of 2 items Page 1 of 1

8) Vous vous êtes intéressé à une analyse plus fine en fonction de l'âge des employés. Ecrivez un code qui permet d'afficher les sites les plus visités pour la section d'âge allant de 23 à 29 ans inclus. Donnez le résultat de cet affichage.

```
grunt> age_23_29 = FILTER USERS_SITES by age>=23 and age<=29;
grunt> site_group_23_29 = GROUP age_23_29 BY site;
grunt> site_count_23_29 = FOREACH site_group_23_29 GENERATE group, COUNT(age_23_29);
grunt> site_order_23_29= order site_count_23_29 by $1 DESC;
grunt> DUMP site_order_23_29;

ne.util.mapreduce - total input paths to process : 1
(http://www.fsb.rnu.tn/,3)
(https://www.facebook.com/,2)
(https://www.uvt.rnu.tn/,1)
(https://pig.apache.org/,1)
```

9) Créez un dossier nommé « ageWeb » dans le cluster Hadoop au-dessous de « /user/cloudera/data-pig/result/» (A l'aide d'un terminal)

```
[cloudera@quickstart ~]$ hadoop fs -mkdir /user/cloudera/data/result/ageWeb
[cloudera@quickstart ~]$
```

10) Ecrire un code qui permet de répartir l'ensemble des employés en fonction de leurs âges sur 03 fichiers comme suit : - E1 : $age \in [18, 22]$ - E2 : $age \in [23, 28]$ - E3 : $age \geq 29$
Chaque fichier contient le nom, l'âge et le site visité. Enregistrez les trois fichiers dans « ageWeb ».

```
grunt> age_18_22 = FILTER USERS_SITES by age>=18 and age<=22;
grunt> age_18_22_project = foreach age_18_22 generate USERS::nom, age , site;
grunt> store age_18_22_project into '/user/cloudera/data/result/ageWeb/E1';
2024-03-18 06:53:49,626 [main] INFO org.apache.pig.tools.pigstats.ScriptState
```

[Home](#) / [user](#) / [cloudera](#) / [data](#) / [result](#) / [ageWeb](#) / **E1**

☐	Name	Size	User	Group	Permissions	Date
☐	 ↑		cloudera	cloudera	drwxr-xr-x	March 18, 2024 06:54 AM
☐	 .		cloudera	cloudera	drwxr-xr-x	March 18, 2024 06:54 AM
☐	 _SUCCESS	0 bytes	cloudera	cloudera	-rw-r--r--	March 18, 2024 06:54 AM
☐	 part-r-00000	40 bytes	cloudera	cloudera	-rw-r--r--	March 18, 2024 06:54 AM

Show of 2 items Page of 1    

```
ess
grunt> age_23_28 = FILTER USERS_SITES by age>=23 and age<=28;
grunt> age_23_28_project = foreach age_23_28 generate USERS::nom, age , site;
grunt>
grunt> store age_23_28_project into '/user/cloudera/data-pig/result/ageWeb/E2'
2024-03-18 06:56:06,829 [main] INFO org.apache.pig.tools.pigstats.ScriptState
Pig features used in the script: HASH JOIN,FILTER
```

[Home](#)

/ [user](#) / [cloudera](#) / [data-pig](#) / [result](#) / [ageWeb](#) / **E2**

☐	Name	Size	User	Group	Permissions	Date
☐	 ↑		cloudera	cloudera	drwxr-xr-x	March 18, 2024 06:56 A
☐	 .		cloudera	cloudera	drwxr-xr-x	March 18, 2024 06:56 A
☐	 _SUCCESS	0 bytes	cloudera	cloudera	-rw-r--r--	March 18, 2024 06:56 A
☐	 part-r-00000	252 bytes	cloudera	cloudera	-rw-r--r--	March 18, 2024 06:56 A

Show of 2 items Page of 1    

```
age_29_plus = FILTER USERS_SITES by age>=29;
```

```
age_29_plus_project = foreach age_29_plus generate USERS::nom, age , site;
```

```
store age_29_plus_project into '/user/cloudera/data-pig/result/ageWeb/E3';
```

11) Maintenant que les bugs sont corrigés et le fonctionnement de l'algorithme est testé, vous pensez l'exécuter en mode batch. Que devez-vous faire ? Rappelez l'instruction nécessaire.

La commande :

pig -x mapreduce /home/cloudera/tpsynthese.pig

Partie 2 : Hive

2) Vous commencez par organiser votre travail en créant une base de données nommée « WebBase » au-dessous de répertoire « /user/hive/warehouse ». Ecrivez un code qui crée la base en spécifiant son emplacement.

```
hive> CREATE DATABASE IF NOT EXISTS WebBase
> COMMENT 'Base de données sites web les plus fréquentés'
> LOCATION '/user/hive/warehouse/WebBase.db';
OK
Time taken: 5.944 seconds
```

3) Pour des raisons de commodité, vous pensez ajouter un commentaire pour décrire la base créée « Base de donnée sites web les plus fréquentés ». Ecrivez un code qui permet d'ajouter et d'afficher le commentaire.

```
> ALTER DATABASE WebBase SET DBPROPERTIES ('comment' = 'Base de donnée site
web les plus fréquentés');
OK
Time taken: 0.32 seconds
hive> DESC DATABASE EXTENDED WebBase;
OK
webbase Base de données sites web les plus fréquentés    hdfs://quickstart.cloud
ra:8020/user/hive/warehouse/WebBase.db cloudera        USER    {comment=Base d
donnée sites web les plus fréquentés}
Time taken: 0.982 seconds, Fetched: 1 row(s)
hive> █
```

4) Créez deux tables nommées « usersTab » et « sitesTab » dont vous spécifiez les schémas adéquats pour recevoir les données issues respectivement de fichiers « users » et « sites ». Spécifiez les types de données et ajoutez des commentaires pour chaque champ de données.

```
Time taken: 0.002 seconds, Fetched: 1 row(s)
hive> CREATE TABLE IF NOT EXISTS WebBase.usersTab (username STRING COMMENT 'Nom
d\'utilisateur',age INT COMMENT 'Âge de l\'utilisateur')
> ROW FORMAT DELIMITED
> FIELDS TERMINATED BY ','
> STORED AS TEXTFILE;
OK
Time taken: 1.103 seconds
hive> CREATE TABLE IF NOT EXISTS WebBase.sitesTab (name STRING COMMENT 'Nom de
sites sur le site web',
> site url STRING COMMENT 'URL du site web')
> ROW FORMAT DELIMITED
> FIELDS TERMINATED BY ','
> STORED AS TEXTFILE;
OK
Time taken: 0.138 seconds
hive> █
```

5) Joignez les deux tables pour en créer une seule table nommée « WebTable ».

```
hive> CREATE TABLE IF NOT EXISTS WebBase.WebTable AS
> SELECT
>     u.*,
>     s.*
> FROM
>     WebBase.usersTab u
> JOIN
>     WebBase.sitesTab s
> ON
>     (u.username = s.name);
Query ID = cloudera_20240318115959_6dad9f95-8b53-4f29-9c85-ad636947072b
Total jobs = 1
Execution log at: /tmp/cloudera/cloudera_20240318115959_6dad9f95-8b53-4f29-9c85-ad636947072b.log
2024-03-18 11:59:17      Starting to launch local task to process map input
```

6) Ecrire un code qui permet de déterminer et de trier les sites les plus visités.

```
SELECT
    name,
    traffic_count
FROM
    WebBase.sitesTab
ORDER BY
    traffic_count DESC;
```

7) Certains de vos employés ont l'habitude de visiter des sites de divertissement pendant les heures de travail tel que « <https://www.facebook.com/> ». Ecrire un code qui permet d'afficher les identités (nom et prénom) de ces employés

```
SELECT
    u.first_name,
    u.last_name
FROM
    WebBase.usersTab u
JOIN
    employee_visits ev
ON
    (u.user_id = ev.user_id)
JOIN
    WebBase.sitesTab s
ON
    (ev.site_id = s.site_id)
WHERE
    s.site_url = 'https://www.facebook.com/'
    AND ev.visit_time BETWEEN 'heure_de_début' AND 'heure_de_fin';
```