

TP n°4 : Synthèse PIG & Hive

Matière : Traitement du Big data avancé

Classe : 1ère année MPSD

Enseignant TP : Mohamed Anouar DAHDEH



Objectifs :

Ce TP de synthèse permet aux étudiants de :

- Créer des jointures, trier et filtrer des données avec PIG
- Créer des jointures et trier les données avec Hive
- Enregistrer le résultat dans HDFS

Les consignes :

Télécharger et décompresser le fichier **data.zip**, sous le dossier **/home/cloudera**

Livable : Un compte rendu (**seulement un fichier pdf**) soigneusement rédigé, contenant les requêtes exécutées et les résultats sous forme des captures d'écran.

Tout partage de travail du compte rendu avec vos collègues sera sanctionné par un **zero**

PROBLEME :

(Extrait de l'examen de la session principale juin 2020) – Avec adaptation au TP

Remarque : le problème est constitué de deux parties qui peuvent être traitées indépendamment.

Partie 1 : Pig

En tant qu'administrateur de réseau d'une grande entreprise, on vous charge de mettre en place un serveur proxy accélérant l'accès aux sites web les plus fréquentés. Pour cela, vous pensez commencer à identifier les sites les plus visités par vos employés. Vous disposez d'une plateforme Hadoop pour gérer l'entrepôt de données de votre entreprise. On met à votre disposition deux fichiers stockés en HDFS dans votre cluster Hadoop. Le premier fichier nommé « users » et les deuxièmes « sites ». Un extrait de ces deux fichiers est donné en dessous (les deux fichiers sont beaucoup plus volumineux).

Salem salem:25
Ichrak May:30
Mohamed Mensi:31
Islem Saada:28
Abrar Hammami:22
Houcem Ben Mansour:27
Mohamed Khalil:29
Khouloud Mernsi:25
Mohamed Bouke:24
Jihene Hasnaoui:27
...

Salem salem,<http://www.fsb.rnu.tn/>
Ichrak May,<https://www.uvt.rnu.tn/>
Mohamed Mensi,<http://www.fsb.rnu.tn/>
Islem Saada,<https://www.facebook.com/>
Abrar Hammami,<http://www.fsb.rnu.tn/>
Houcem Ben Mansour,<http://www.fsb.rnu.tn/>
Mohamed Khalil,<https://www.uvt.rnu.tn/>
Khouloud Mernsi,<https://www.facebook.com/>
Mohamed Bouke,<http://www.fsb.rnu.tn/>
Jihene Hasnaoui,<https://pig.apache.org/>
...

- 1) Quels sont les modes d'exécution de Pig ? Durant la phase de développement quel mode adoptez-vous ? Expliquez. Rappelez l'instruction en Pig Latin qui permet d'exécuter le code selon le mode choisi. (A ne répondre)
- 2) Quels sont les différents modes d'interaction avec Pig ? Détaillez votre réponse en précisant dans quels cas utilise-t-on chaque mode. A votre avis quel est le mode le plus adéquat durant une phase de développement et de test. (A ne répondre)

Pour la suite de l'exercice, déplacez les deux fichiers sous HDFS dans « /user/cloudera/data-pig/ » et utilisez le mode interactif.

- 3) Ecrivez un code qui permet de lire **correctement** les deux fichiers en spécifiant un schéma de lecture détaillé pour chaque fichier. (Afficher le résultat)
- 4) Ecrivez un code qui permet de joindre les deux fichiers afin d'en avoir un seul qui sera l'objet de traitement suivant : comptage des sites les plus visités. (Afficher le résultat)
- 5) Ecrivez un code qui permet de compter et trier les sites le plus fréquentés par ordre décroissant. (Afficher le résultat)
Indice : utiliser l'argument « desc » de l'instruction « order »
- 6) Ecrivez un code qui permet d'afficher les 2 sites les plus fréquentés ainsi le nombre de fois où ils ont été visités. Donnez le résultat de cet affichage.
- 7) Ecrivez un code qui permet de stocker le résultat dans le dossier « res1 » dans le cluster Hadoop à l'emplacement « /user/cloudera/data-pig/result/ »
- 8) Vous vous êtes intéressé à une analyse plus fine en fonction de l'âge des employés. Ecrivez un code qui permet d'afficher les sites les plus visité pour la section d'âge allant de 23 à 29 ans inclus. Donnez le résultat de cet affichage.
- 9) Créez un dossier nommé « ageWeb » dans le cluster Hadoop au-dessous de « /user/cloudera/data-pig/result/ » (A l'aide d'un terminal)
- 10) Ecrire un code qui permet de répartir l'ensemble des employés en fonction de leurs âges sur 03 fichiers comme suit :
 - E1 : $age \in [18, 22]$
 - E2 : $age \in [23, 28]$
 - E3 : $age \geq 29$

Chaque fichier contient le nom, l'âge et le site visité.

Enregistrez les trois fichiers dans « ageWeb ».

- 11) Maintenant que les bugs sont corrigés et le fonctionnement de l'algorithme est testé, vous pensez l'exécuter en mode batch. Que devez-vous faire ? Rappelez l'instruction nécessaire.

Partie 2 : Hive

Vous pensez tester une deuxième solution en utilisant le langage de requête Hive.

- 1) Comparer Pig et Hive en termes d'abstraction et de flexibilité. (A ne répondre)
- 2) Vous commencez par organiser votre travail en créant une base de données nommée « WebBase » au-dessous de répertoire « /user/hive/warehouse ». Ecrivez un code qui crée la base en spécifiant son emplacement.
- 3) Pour des raisons de commodité, vous pensez ajouter un commentaire pour décrire la base créée « Base de donnée sites web les plus fréquentés ». Ecrivez un code qui permet d'ajouter et d'afficher le commentaire.
- 4) Créez deux tables nommées « usersTab » et « sitesTab » dont vous spécifiez les schémas adéquats pour recevoir les données issues respectivement de fichiers « users » et « sites ». Spécifiez les types de données et ajoutez des commentaires pour chaque champ de données.
- 5) Joignez les deux tables pour en créer une seule table nommée « WebTable ».
- 6) Ecrire un code qui permet de déterminer et de trier les sites les plus visités.
- 7) Certains de vos employés ont l'habitude de visiter des sites de divertissement pendant les heures de travail tel que « <https://www.facebook.com/> ». Ecrire un code qui permet d'afficher les identités (nom et prénom) de ces employés.

Bon travail