

TP n°2 : PIG

Matière : Traitement du Big data avancé

Classe : 1ère année MPSD

Enseignant TP : Mohamed Anouar DAHDEH



Objectifs :

Ce TP permet aux étudiants d'apprendre comment :

- Charger des données avec Pig
- Créer un schéma, lire, écrire et afficher des données
- Accéder aux champs d'un schéma avec Pig

Consignes :

Télécharger et décompresser le fichier **data-pig.zip**, sous le dossier **/home/cloudera**

Livrable : Un compte rendu (**seulement un fichier pdf**) soigneusement rédigé, contenant les requêtes exécutées et les résultats sous forme des captures d'écran.

Tout partage de travail du compte rendu avec vos collègues sera sanctionné par un zero

Exercice 1: Exemple Word Count - Pig Script

Comment trouver le nombre d'occurrences des mots dans un fichier ? Certainement, vous connaissez la réponse en utilisant un programme MapReduce écrit en Java.

Dans cet exercice, nous allons écrire un script de Pig simple pour le problème de comptage des mots. Le script Pig suivant permet de calculer le nombre de fois qu'un mot répété dans un fichier :

```
lines = LOAD '/user/cloudera/data-pig/poemes.txt' AS (line:chararray);
words = FOREACH lines GENERATE FLATTEN(TOKENIZE(line)) as word;
grouped = GROUP words BY word;
wordcount = FOREACH grouped GENERATE group, COUNT(words);
DUMP wordcount;
```

Explication :

Ce script Pig divise d'abord chaque ligne en mots en utilisant l'opérateur **tokenize**. La fonction **tokenize** crée un sac de mots. L'utilisation de la fonction **FLATTEN** permet de convertir le sac de mots en un tuple. Dans la troisième déclaration, les mots sont regroupés de telle sorte que le nombre peut être calculé qui se fait à la quatrième déclaration. Vous pouvez voir juste avec 5 lignes de programme de Pig, nous avons résolu le problème de comptage des mots très facilement.

Questions :

Exécuter en mode MapReduce le script précédent :

- 1- En mode interactif (Grunt shell)
- 2- En mode Batch (script)

Exercice 2 : Création de schéma, lecture et écriture de données avec Pig

La première étape dans le traitement d'un ensemble de données à l'aide de Pig Script est de définir un schéma pour l'ensemble de données. Un schéma est une représentation de l'ensemble en termes de champs de données. Voyons comment définir un schéma avec un exemple.

Prenons l'ensemble de données des produits (produits.txt) suivants dans Hadoop comme exemple :

```
10, iphone, 1000  
20, samsung, 2000  
30, nokia, 3000
```

Ici le premier champ est l'identifiant du produit, le deuxième champ est le nom du produit et le troisième champ est le prix du produit.

Question : Copier le dossier **data-pig** sous HDFS (Utiliser HUE par exemple)

2.1. Définition de schéma :

L'opérateur LOAD est utilisé pour définir un schéma pour un ensemble de données. Voyons les différents usages de l'opérateur LOAD pour définir le schéma de l'ensemble de données ci-dessus.

- Création de schéma sans spécifier tous les champs :

```
grunt> A = LOAD '/user/cloudera/data-pig/produits.txt';
```

Pig est un langage de flux de données. Chaque instruction dans Pig se compose d'une relation et une opération. Le côté gauche de la déclaration est appelée relation et le côté droit est appelé l'opération. Chaque instruction pig doit se terminer par un point - virgule. Dans cet exemple **A** est une relation. **/user/cloudera/data-pig/produits.txt** est le fichier dans HDFS. Pour voir le schéma d'une relation, saisir l'instruction suivante :

```
grunt> describe A;  
Schema for A unknown.
```

Comme les champs ne sont pas définis, Le script a indiqué que le schéma de A est inconnu.

Question : Afficher le contenu de la relation A sur la console

```
grunt> -----
```

Pour charger les données sous HDFS, on utilise la commande STORE

```
grunt> STORE A INTO 'hdfs directory name'
```

Question : Charger la relation **A** dans un dossier « produits » du HDFS

- Définition de schéma avec les noms de champs et les types de données.

Le script Pig suivant montre comment pouvons définir les noms et les types des champs (int, chararray)

```
grunt> A = LOAD '/user/cloudera/data-pig/produits.txt' USING  
PigStorage(',') AS (id:int, product_name:chararray, price:int);  
grunt> describe A;  
A: {id: int,product_name: chararray,price: int}  
grunt> DUMP A;
```

Question : Charger la relation **A** dans un dossier « produits-copy » du HDFS en remplaçant le délimiteur « , » par « | ».

2.2 Accès aux champs :

Jusqu'à présent, nous avons vu comment définir un schéma, comment imprimer le contenu des données sur la console et comment écrire des données dans HDFS. Maintenant, nous allons voir comment accéder aux champs.

Les champs peuvent être accessibles de deux façons :

- **Noms de champs** : Nous pouvons spécifier le nom du champ pour accéder aux valeurs de ce champ particulier.
- **Paramètres positionnels** : Les positions des champs commencent à partir de 0 à n. \$ 0 indique **premier** champ, 1 \$ indique deuxième champ

Questions :

Soit la ligne grunt shell suivante :

```
grunt> A = LOAD '/user/cloudera/data-pig/produits.txt' USING  
PigStorage(',') AS(id:int, product_name:chararray, price:int);
```

- 1- Stocker dans une relation B tous les champs id des produits
- 2- Stocker dans une relation C tous les champs « nom et prix » des produits

Notes :

FOREACH est comme une boucle utilisée pour itérer sur les enregistrements d'une relation.

Le mot - clé **GENERATE** spécifie quelle opération à faire sur une relation.

Exercice 3 : Comment filtrer les enregistrements – Script Pig

Pig vous permet de supprimer les enregistrements non nécessaires en se basant sur des conditions. L'opérateur FILTER est similaire à la clause WHERE dans SQL.

Supposons que nous avons l'ensemble des données de vente « ventes.txt » ci – dessous :

```
année, produit, quantité  
-----  
2000, iphone, 1000  
2001, iphone, 1500  
2002, iphone, 2000  
2000, nokia, 1200  
2001, nokia, 1500  
2002, nokia, 900
```

Questions

- 1- Afficher les produits dont la quantité est supérieure ou égale à 1000
- 2- Afficher les produits dont la quantité est supérieure à 1000 dans l'année 2001
- 3- Afficher tous les produits vendus sauf ceux de l'année 2000

Note :

Vous pouvez utiliser tous les opérateurs logiques (NON, ET, OU) et les opérateurs relationnels (<, >, ==, =, >=, <= !) dans les conditions de filtre.

Bon travail