

TP n°3 : HIVE

Matière : Traitement du Big data avancé

Classe : 1ère année MPSD

Enseignant TP : Mohamed Anouar DAHDEH



Objectifs :

Ce TP permet aux étudiants d'apprendre comment :

- Assurer la persistance des données avec Hive
- Lancer des requêtes avec HiveQL
- Faire des agrégations, jointures, trie avec HiveQL

Présentation Hive :

Apache Hive est un entrepôt données (Data Warehouse) open source pour Hadoop. C'est une abstraction sur Apache Hadoop, pour les familiariser avec SQL, Hive fournit un langage de haut niveau semblable à SQL, appelé HQL, pour interagir avec un cluster Hadoop, dans le but de réaliser des analyses sur une masse importante de données.

L'accès aux données se fait via des tables structurées. Il se matérialise par la création d'un plan d'exécution de la requête HQL qui se traduit par la création et l'exécution d'un job MapReduce.

Présentation de l'atelier :

Les manipulations suivantes, utilisent une base de données météo du NCDC (National Climatic Data Center). Cette base est constituée d'une ligne par enregistrement, dont on veut extraire quelques informations utiles.

Télécharger et décompresser le fichier `data-hive.zip`, sous le dossier `/home/cloudera`

Livrable : Un compte rendu (**seulement un fichier pdf**) soigneusement rédigé, contenant les requêtes exécutées et les résultats sous forme des captures d'écran.

Tout partage de travail du compte rendu avec vos collègues sera sanctionné par un **zero**

1. Création de table :

Q1- Rentrer dans le shell de Hive :

\$ -----

Q2- Créer la table **records** :

```
CREATE TABLE records (year STRING, temperature INT, quality INT)
ROW FORMAT DELIMITED FIELDS TERMINATED BY '\t';
```

Q3- Où sont stockées les données de cette table ?

Le fichier **sample-with-tab.txt** contient un court extrait de données météorologique, dont les champs sont délimités par une tabulation.

Q4- Remplir la table "**records**" avec le contenu de ce fichier.

hive> -----

Q5- Vérifier que tout a été créé comme attendu :

- Afficher la liste des tables

hive> -----

- Afficher la structure de la table **records**

hive> -----

- Afficher tous les enregistrements de la table **records**

hive> -----

Q6- Vérifier que les champs de la table sont correctement mappés en faisant exécuter à Hive un job MapReduce simple :

- Afficher toutes les années de la table **records** en éliminant les doublons

hive> -----

Q7- D'autres formats de fichier peuvent être utilisés par Hive grâce aux serialiseurs/désérialiseurs (SERDE). Utiliser le SERDE basé sur les expressions régulières pour importer dans Hive le fichier '**stations-fixed-width.txt**' contenant des champs de taille fixe :

```
CREATE TABLE stations (usaf STRING, wban STRING, name STRING)

ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.RegexSerDe'

WITH SERDEPROPERTIES ( "input.regex" = "(\d{6}) (\d{5}) (.{29}) .*" );

LOAD DATA LOCAL INPATH '/home/cloudera/data-hive/stations-fixed-width.txt'

OVERWRITE INTO TABLE stations;
```

Q8- Vérifier que les champs de la table **stations** sont correctement mappés en faisant exécuter à Hive un job MapReduce simple :

- Afficher tous les enregistrements des stations situées à PARIS

hive> -----

Comme vous pouvez le constater en exécutant la commande `hadoop fs -cat /user/hive/warehouse/records/sample-with-tab.txt` (à l'extérieur du shell de Hive), hive copie les fichiers contenant les enregistrements de la table sous un répertoire situé dans son espace HDFS (/user/hive/warehouse). Ce répertoire porte le nom de la table. Ce mode de fonctionnement permet à Hive de gérer la table indépendamment du fichier de données d'origine mais il nécessite de dupliquer ce fichier d'origine.

- Supprimer la table **records**

hive> -----

2. Création de table externe

2.1. Table externe avec tabulations

Q1- Si les données sont également utilisées en dehors de Hive et qu'on souhaite éviter de les dupliquer, il faut alors utiliser le mode "externe" :

```
CREATE EXTERNAL TABLE records (year STRING, temperature INT, quality INT)

ROW FORMAT DELIMITED FIELDS TERMINATED BY '\t'

LOCATION '/user/cloudera/records/'
```

Q2- Charger les données tabulées à partir du fichier **sample-with-tab.txt**:

hive> -----

Q3- Vérifier le type et l'emplacement de la nouvelle table 'records' :

hive> -----

Notez que dans ce mode d'utilisation, la commande DROP TABLE supprimera la table dans Hive, mais pas le fichier de données. Vous pouvez le vérifier en supprimant puis recréant la table 'records'.

2.2. Table externe avec champs de taille fixe

Q1- Importer (sans les copier !) le fichier météo **sample.txt** dans une table **records2(station STRING, year STRING, temperature INT, quality INT)** :

- La décompression gzip est supportée de façon implicite.
- Dans vos règles de mapping, pensez à supprimer le signe '+' (non reconnu) tout en conservant le signe '-'.

```
CREATE EXTERNAL TABLE records2 (station STRING, year STRING, temperature INT, quality INT)
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.RegexSerDe'
WITH SERDEPROPERTIES ("input.regex"=".{4}(.{6}).{5}(.{4}).{68}\\+?(-?\\d{4})(\\d).*")
LOCATION '/user/cloudera/records2'
```

Q2- Charger les données à partir du fichier **sample.txt**:

hive> -----

Q3- Vérifier que les champs de la table sont correctement mappés en faisant exécuter à Hive un job MapReduce simple.

- Sélectionner seulement 10 lignes (enregistrements) de la table **records2**

hive> -----

- Sélectionner de la table **records2**, les enregistrements ayant la qualité 9

hive> -----

3. Agrégats

Ecrire des jobs MapReduce en utilisant les fonctions d'agrégation de HiveQL :

Q1- calcul de la température maximale par année.

```
SELECT year, MAX(temperature)
FROM records2
WHERE temperature != 9999
AND (quality=0 OR quality=1 OR quality=4 OR quality=5 OR quality=9)
GROUP BY year;
```

Q2- calcul de la température moyenne par année.

hive> -----

4. Requêtes imbriquées

HiveQL supporte les requêtes imbriquées. Tirez profit de cette possibilité pour écrire les requêtes suivantes :

Q1- calculer la moyenne de l'ensemble des températures maximum de chaque couple année/station météo : Compléter la requête suivante au niveau de la clause **GROUP BY**

```
SELECT AVG(max_temperature)
FROM (
  SELECT station, year, MAX(temperature) AS max_temperature
  FROM records2
  WHERE temperature != 9999
  AND (quality=0 OR quality=1 OR quality=4 OR quality=5 OR quality=9)
  GROUP BY -----
) mt;
```

Q2- Pour chaque tranche de 5°C, calcul du nombre de stations ayant une température moyenne comprise dans cette tranche : Compléter la requête suivante au niveau des clauses **GROUP BY**

```
SELECT FLOOR(avg_temperature/50), COUNT(station)
FROM (
  SELECT station, AVG(temperature) AS avg_temperature
  FROM records2
  WHERE temperature != 9999
  AND (quality=0 OR quality=1 OR quality=4 OR quality=5 OR quality=9)
  GROUP BY -----
) mt
GROUP BY -----;
```

5. Jointures

HiveQL supporte les jointures, mais à condition de les expliciter (la clause FROM n'accepte qu'un seul nom de table).

Q1- L'exemple suivant donne la liste des stations météo enregistrées dans la base en 1901 et 1902 :

```
SELECT DISTINCT name
FROM stations
JOIN records2 ON (records2.station = stations.usaf)
WHERE year = '1901' OR year = '1902';
```

Q2- Ecrire en HiveQL les requêtes suivantes :

- Calcul de la température moyenne de l'ensemble des stations météo UTO et TURKU.

hive> -----

- Calcul de la température moyenne de la station météo UTO, et de celle de TURKU.

hive> -----

6. Tri

HiveQL supporte le tri du résultat de la requête avec la clause standard ORDER BY, mais celle-ci réduit considérablement la performance du traitement puisqu'elle nécessite de regrouper tous les résultats intermédiaires en une seule tâche "reduce" afin de les trier entre eux.

Lorsque le tri n'a pas besoin d'être global sur l'ensemble du résultat de la requête, vous pouvez utiliser l'extension non-standard de Hive SORT BY à la place de ORDER BY, afin de trier chacune des parties de résultat produites par les différentes tâches "reduce". La clause DISTRIBUTE BY de Hive permet de contrôler la façon dont les données intermédiaires produites par les tâches "map" sont réparties dans les tâches "reduce".

Q1- Trier les données météo de la table **record2** par température décroissante au sein de chaque année, et les années croissantes :

```
hive> -----
```

Bon travail