



Data Mining

Hela Mahersia
helamahersia@yahoo.fr

Master M Pro DS - Université de Carthage
Faculté des Sciences de Bizerte
Fouille de données

Partie 1 :




Introduction au Data Mining

Data Mining ?

- Traduction :
 - Fouille de données,
 - Exploration de données
 - Forage de données
 - Extraction de connaissances à base de données
- Terme récent (1995) représentant un mélange d'idées et d'outils provenant de la Statistique, de l'Intelligence Artificielle et de l'Informatique.



Motivation




Exemples d'applications

- Entreprise et Relation Clients : ciblage de clients potentiels et nouveaux marchés
- Finances : minimisation de risques financiers
- Bio informatique : analyse du génome, mise au point de médicaments
- Banque, opérateurs de téléphonie, assurance : recherche à minimiser l'attrition de leurs clients
- Internet : spam, e-commerce, détection d'intrusion, recherche d'informations
- Sécurité,
- Services de police, ...

Y

	1	1			
	1			1	1
		?	1	1	
	1	1			
				1	
			1	1	



Exemples d'applications : E-commerce

● Targeting

- Stocker les séquences de clicks des visiteurs, analyser les caractéristiques des acheteurs
- Faire du "targeting" lors de la visite d'un client potentiel

● Systèmes de recommandation (amazon!)

- Opportunité : les clients notent les produits ! Comment tirer profit de ces données pour proposer des produits à un autre client ?
- Solutions : technique de filtrage collaboratif pour regrouper les clients ayant les mêmes "goûts".

Exemples d'applications : Analyse des risques

- Détection de fraudes pour les assurances

- Analyse des déclarations des assurés par un expert afin d'identifier les cas de fraudes.
- Applications de méthodes statistiques pour identifier les déclarations fortement corrélées à la fraude.

- Prêt Bancaire

- Objectif des banques : réduire le risque des prêts bancaires.
- Créer un modèle à partir de caractéristiques des clients pour:
 - ◆ discriminer les clients à risque des autres..
 - ◆ proposer des produits attractifs pour les bons clients sans risque de non remboursement

Exemples d'applications : Commerce

Organisation de rayonnage

- Objectifs : Identifier les produits que les gens sont susceptibles d'acheter conjointement afin d'organiser les rayonnages
- Données : Code-Barre des produits.
- Méthodes : Extractions de règles (**Règles d'association**)
- Exemples :
 - résultats logiques : les boissons alcoolisées et les biscuits apéritifs sont souvent proches.
 - résultats étranges : dans une étude américaine, la vente de bière est plus importante si le rayon sanitaire n'est pas trop loin, et si sur le chemin il y a des chips, cela permet d'augmenter la vente des 3 produits.

Définitions de la Data-Mining

● Définition 1

Extraction of interesting **patterns** ou knowledge from huge amount of data

● Définition 2

The non trivial process of identifying valid, novel, potentially useful and ultimately understandable **patterns** in data

***Wikipédia** : L'extractions d'un savoir ou d'une connaissance à partir des données par des méthodes automatiques ou semi-automatiques*

● Autre point de vue :

Le data-mining est un processus de découverte de règle, relations, corrélations et/ou dépendances à travers une grande quantité de données, grâce à des méthodes statistiques, mathématiques et de reconnaissances de formes.

Patterns ?


- Patterns = arrangement (disposition) de parties qui se répètent → formes = relations

- Valides
- Nouveaux
- Actionnables
- compréhensibles

Row #	Shape	Color	Weight
1	Box	Red	100
2	Box	Red	200
3	Box	Red	300
4	Box	Blue	400
5	Cone	Blue	400

Transport


Credit Risk



Défis de la Data Mining (1/2)

- Bien qu'il s'agisse d'un processus puissant, la DM est entravé par la quantité et la complexité croissantes des Big Data :

- Big Data : 4 défis majeurs : volume, variété, véracité et vitesse → la DM a pour objectif de résoudre ces défis et de dégager la valeur des données.



- Modèles sur-ajustés : le risque est accru par l'augmentation du volume et de la variété des données.


Défis de la Data Mining (2/2)

- Confidentialité et sécurité :

- L'augmentation des besoins en stockage de données a obligé de nombreuses entreprises à se tourner vers le cloud computing et le stockage cloud
- Mais : importantes menaces pour la sécurité et la confidentialité.

- Coût d'échelle

- Pour tirer pleinement parti de la DM, un investissement important en infrastructure informatique et en puissance de traitement est nécessaire → les entreprises doivent acheter et entretenir des ordinateurs, des serveurs et des logiciels puissants conçus pour gérer la grande quantité et l'importante variété de ses données .



Principales tâches de la DM

classification

Clustering

Régression

Réduction de données

Modélisation de la dépendance

Comment décrire un problème data mining

- Pour chaque question posée, il faut :


- Comprendre le processus associé
- Quelles sont les variables associées
- Quel est le résultat attendu

- Les variables d'entrée


- Ou variables explicatives
- Ou inputs
- Doivent être disponibles

- La cible

- Ou variable expliquée
- Ou output
- Doit être mesurable
- Et “actionnable”




Processus de la Data Mining (1/2)



Principales étapes

- 1 Collecte de données
- 2 Pré-traitement
- 3 Analyse statistique
- 4 Identifier le problème de DM
- 5 Apprendre le modèle mathématique
- 6 Évaluer ses capacités



Y


		1	1			
		1			1	1
			?	1	1	
	1		1			
					1	
			1	1		

Processus de la Data Mining (2/2)

1. Comprendre et analyser les objectifs de l'application
2. Créer\collecter une base de données pour la mise au point de l'application.
3. Prétraitement et nettoyage des données
4. Analyse statistique des données (réduction de la dimension, etc...)
5. Identifier le type de problèmes (discrimination, clustering, etc...) et choisir un algorithme adéquat.
6. Evaluer les performances de l'algorithme.
7. Réitérer les étapes précédentes si nécessaire.
8. Déployer l'application.


Objectifs du cours : Etude des méthodes pour les étapes 3 à 6

Types d'apprentissage en DM




Apprentissage supervisé (1/2)

- On dispose d'un ensemble d'objets (données d'apprentissage) et pour chaque objet, on a une valeur cible associée (labels ou étiquettes)
- Il faut apprendre un modèle capable de prédire la bonne valeur cible d'un objet nouveau.




Apprentissage supervisé (2/2)



Apprentissage non supervisé

- on dispose d'un ensemble d'objets **sans aucune valeur** cible associée;
- il faut apprendre un modèle capable d'extraire les caractéristiques présentes dans les objets pour mieux représenter la structure de l'ensemble des données.




Apprentissage semi-supervisé


- Parfois, on dispose de :
 - un petit ensemble d'objets ayant chacun une valeur cible associée
 - un ensemble plus grand d'objets sans valeur cible;
- il faut tirer profit à la fois des données avec et sans valeurs cibles pour résoudre des tâches d'apprentissage supervisé ou non supervisé.
- On peut parfois utiliser des données sans labels (approche non supervisée) en s'aidant de paires de contraintes (valeur de K dans Kmeans par exemple)

Apprentissage par renforcement

- on dispose d'un ensemble de séquences de décisions dans un environnement dynamique, et pour chaque action de chaque séquence on a une valeur de récompense
- il faut apprendre un modèle capable de prédire la meilleure décision à prendre étant donné un état de l'environnement.



Nature des données en apprentissage




Nature des données en apprentissage

- Une donnée est une collection d'information, appelée aussi :
 - enregistrement (au sens des bases de données),
 - individu (terminologie issue des statistiques)
 - instance (terminologie orientée objet en informatique)
- Une donnée est considérée comme un point ou vecteur : une donnée est un **point** dans un espace euclidien ou un vecteur dans un espace vectoriel.
- Une données est caractérisée par un ensemble de caractéristiques appelés **attributs**



Nature des données en apprentissage



Données et Métriques


- Les algorithmes nécessitent une notion de similarité dans l'espace X des données. La similarité est traduite par la notion de distance.

- distance euclidienne : $x, z \in \mathbb{R}^d$, on a
$$d(x, z) = \|x - z\|_2 = \sqrt{\sum_{j=1}^d (x_j - z_j)^2} = \sqrt{(x - z)^\top (x - z)}$$

- distance de manhattan
$$d(x, z) = \|x - z\|_1 = \sum_{j=1}^d |x_j - z_j|$$

- distance de mahalanobis
$$d(x, z) = \sqrt{(x - z)^\top \Sigma^{-1} (x - z)}$$

$\Sigma \in \mathbb{R}^{d \times d}$: matrice carrée définie positive





**Merci pour
votre attention**

des questions ?

Partie 2 :




Préparation des données

Plan

- Motivation
- Nettoyage des données
- Intégration et transformation
- Réduction des données
- Discretisation

Motivation

- Cleaning data = remove noise = nettoyage de données




Motivation



- Les données réelles sont souvent : incomplètes, bruitées et incohérentes → rarement prêtes telles quelles
- Les algorithmes sont sensibles aux valeurs entrées:
 - Echelles des variables doivent être comparables (Variables d'échelles plus grandes dominantes dans les mesures de similarité et les distance , valeurs d'entrées élevées provoquent la saturation de neurones)
 - Variables peuvent parfois être manquantes (Capteur défectueux, oublis/manques dans collecte, mesures ajoutées en cours de route
 - Dimensionnalité élevée (Sensibilité des algorithmes à la dimensionnalité, Redondance dans les mesures)
- La préparation des données est une tâche essentielle car les résultats de la fouille dépendent de la qualité des données

Objectifs de la préparation

- Constituer un jeu de données apte à être analysé :
 - de qualité homogène
 - avec des structures et des formats bien définis
 - exploitable par des algorithmes d'analyse automatique
- Corriger les défauts (révélés par l'exploration) :
 - Traiter les valeurs manquantes et aberrantes
 - Redéfinir certaines échelles pour homogénéiser des variabilités
 - Utiliser des données externes pour enrichir le jeu initial
- 5 étapes principales :



Principales étapes dans le prétraitement des données



Comprendre avant de prétraiter !



- La question la plus importante : **Est-ce que l'ensemble de donnée est bien adapté au problème (relevant or not?)**
 - How big is the dataset?
 - Est-il assez représentatif ?
 - Doit-on ajouter des sources additionnelles
 - Y-a-t-il des valeurs aberrantes (outliers)

Les 5 étapes de la préparation

Nettoyage des données

- Identifier toutes les données indésirables:
 - Erronées / aberrantes
 - Trop inexactes (manque de précision)
 - ◆ Ex : valeurs trop éloignées de la normale ou des autres, enregistrement d'utilisateurs sans leurs emails...
 - Inutiles pour l'analyse voulue ... faut-il les supprimer ?
- Actions possibles :
 - Supprimer la valeur non conforme et garder le reste de l'enregistrement
 - Supprimer tout l'enregistrement (toute la ligne)
 - Ajouter un flag indiquant si l'enregistrement est conforme ou non (exploitable ou non)
 - Remplacer la valeur non conforme par : la médiane, la moyenne, la valeur précédente (cas des données ordonnées)

Les 5 étapes de la préparation

Nettoyage des données

- Remarques : Que faire si des valeurs de variables sont **manquantes**?
 - Retirer les données avec valeurs manquantes → Perte de données pour l'apprentissage
 - Marquer les variables manquantes pour l'algorithme d'apprentissage → Certains algorithmes d'apprentissage peuvent gérer les variables manquantes d'autres non
 - Assigner une valeur par défaut aux variables manquantes → laquelle ? (typiquement zéro)
 - Sélectionner la plus probable valeur dans les autres données et assigner sa valeur à la variable manquante (val majoritaire)
 - Assigner **valeur moyenne** de la variable (**ou médiane**),
 - ◆ Réduit la variance mesurée de la variable dans le jeu de données
 - ◆ Ou bien calculer la moyenne seulement sur la même classe

- Remarques : Que faire si des valeurs de variables sont **erronées** ?

- Binning :

- ◆ Ordonner les données
- ◆ Les subdiviser en **bins** et lisser (moyenne, ...) chaque bin
- ◆ Remplacer les valeurs d'origine par les valeurs lissées

- Régression :

- ◆ Trouver un modèle qui représente les données puis appliquer le modèle pour corriger la valeur erronées

- Clustering :

- ◆ Chaque donnée hors cluster doit être ramenée au cluster le plus proche

Les 5 étapes de la préparation

Nettoyage des données

- Remarques : Que faire si des valeurs de variables sont **incohérentes** ?
 - Généralement ce type d'erreurs n'est pas fréquent
 - On peut les corriger manuellement
 - Exemples :
 - ◆ 5% des clients d'une banque sont nés le 2-2-2020
 - ◆ Des erreurs de noms par exemple Dennis et Denis
 - ◆ ...

Les 5 étapes de la préparation

Intégration des données

Intégration des données = combinaison de différentes sources en une seule

- Pourquoi : **small dataset** or **more attributes**
- Détecter et résoudre les conflits de valeurs
 - pour les mêmes entités réelles, les valeurs des attributs provenant de sources différentes sont différentes
 - ◆ causes : représentation différentes, échelles différentes, ex : cm et pouces
 - Gestion de la redondance : fréquente lors de l'intégration de plusieurs sources de données
 - ◆ le même attribut peut avoir des noms différents
 - ◆ un attribut peut être déduit d'un autre
 - ◆ peut être détectée par des analyses de corrélation

Les 5 étapes de la préparation

Transformation des données

- Objectifs :

Manipuler, modifier, créer de nouvelles informations à partir de celles contenues dans les données initiales

- Exemples :

- Identifier et Lister les mots les plus fréquents dans des articles à analyser
- Identifier et Taguer les événements dont les dates correspondent à des vacances scolaires ou à des jours fériés

- Opérations possibles :

- Opérations de Séparation et Extraction
- Opérations de Lissage
- Opérations d'Agrégation de valeurs
- Opérations de Modification de valeurs

Les 5 étapes de la préparation

Transformation des données

- Opérations de **Lissage** : réduire le bruit dans les données
- Opérations **d'Agrégation de valeurs** : summarization
Remplacement d'un ensemble de données par :
 - Le nombre des occurrences d'un terme
 - Les termes les plus fréquents
 - Une valeur moyenne, médiane, maximale, minimale...
- Opérations de **Généralisation** : remplacer une donnée par une représentation plus générale (hiérarchique)
- Opérations de **Extraction d'attribut**
 - Extraction de nouveau élément à partir des attributs existants...

Les 5 étapes de la préparation

Transformation des données

- Opérations de **Normalisation** = mise à l'échelle pour avoir un petit intervalle spécifié
 - Min-Max
 - Z-score (standard scaler)
 - Mise à l'échelle décimale
- Exemple :
 - A1 : 0...1 et A2 : 100...1000
 - Schématiser les attributs?

Normalisation = Ajustement d'échelle des variables

- **Min-Max**

- Approche plus facile : ramener l'échelle des variables dans $[0,1]$
- S'effectue sur chaque attribut indépendamment des autres

$$v' = \frac{v - \min_A}{\max_A - \min_A} (\text{new_max}_A - \text{new_min}_A) + \text{new_min}_A$$

- **Z-score :**



Moins sensible aux valeurs aberrantes que Min-Max

- $z = \frac{x - \mu}{\sigma}$
 - Where x is the value of the feature instance,
 - μ is the mean of the feature's values and $= \frac{\sum x_i}{N}$
 - σ is the variance $= \sqrt{\frac{\sum (x_i - \mu)^2}{N}}$



- **Mise à l'échelle décimale**

$$v' = \frac{v}{10^j} \quad \text{avec } j \text{ le plus petit entier tq } \max(|v'|) < 1$$

Normalisation



Z-score



Min-Max

Les 5 étapes de la préparation

Réduction des données

- La fouille de données peut être très longue sur les données complètes

Réduction des données = obtenir une représentation réduite du jeu de données, plus petite en volume, mais qui produit les mêmes (ou presque) résultats analytiques

- Stratégies
 - Agrégation par cubes de données
 - Réduction de dimension
 - Réduction de numérosité
 - Discrétisation et génération de hiérarchies de concepts

Les 5 étapes de la préparation

Réduction des données


Réduction de numérosité

● Méthodes paramétriques

- suppose que les données suivent un modèle $Y = \alpha + \beta X$
 - ◆ Estimer et stocker seulement les paramètres du modèle (α, β)
- modèle log linéaire : approximation de la distribution des valeurs dans un espace multidimensionnel → probabilité

● Méthodes non paramétriques

- les données ne suivent pas un modèle
- principales : histogrammes, échantillonnage
 - ◆ Histogramme : la plus utilisée
 - ◆ diviser en intervalles et stocker la somme (ou la moyenne)



Les 5 étapes de la préparation

Réduction des données

Réduction de dimension

- Réduction de la dimensionnalité

- ▶ Passer d'un espace à D dimensions vers un espace à K dimensions, où $K < D$

$$X_1, \dots, X_D \mapsto X'_1, \dots, X'_K$$

- Approches possibles

- ▶ Sélection de caractéristiques : choisir K variables parmi les D variables possibles


$$X_1, \dots, X_D \mapsto X_{v_1}, \dots, X_{v_K}$$
$$v_i \in \{1, \dots, D\} \mid v_j \neq v_i \ \forall j \neq i$$

- ▶ Extraction de caractéristiques : générer K variables comme des transformations des D variables d'origine

$$X_1, \dots, X_D \mapsto f_1(X_1, \dots, X_D), \dots, f_K(X_1, \dots, X_D)$$

L'analyse en composantes principales (ACP)

- L'ACP est une technique d'analyse de données multivariées qui permet de réduire la dimensionnalité d'un jeu de données tout en préservant autant que possible la variation d'origine.
- elle permet de passer d'un grand nombre de variables à un nombre plus réduit, appelées composantes principales, tout en conservant le maximum d'information possible.



Les 4 étapes de l'ACP (1/2)

- Normalisation des données : Avant d'appliquer l'ACP, il est nécessaire de leur donner une moyenne de 0 et un écart-type de 1. $\Rightarrow$ mettre toutes les variables à la même échelle et éviter que des variables avec des unités différentes n'aient un impact disproportionné sur l'analyse.
- Calcul des composantes principales : L'ACP consiste à calculer les composantes principales qui sont des combinaisons linéaires des variables d'origine.
 - La première composante principale est la direction qui montre le maximum de variance dans les données,
 - la deuxième est la direction qui montre le maximum de variance restante,
 - et ainsi de suite. Les composantes principales sont calculées de manière à être non corrélées entre elles.

Les 4 étapes de l'ACP (2/2)

- Sélection des composantes principales : Pour déterminer le nombre de composantes principales à conserver, on peut appliquer la règle du seuil.
 - La règle du seuil consiste à choisir le nombre de composantes principales qui montrent ensemble un pourcentage suffisant de la variance totale (par exemple, 80 %).
- Interprétation des résultats : les composantes principales sont des variables synthétiques qui peuvent être utilisées pour expliquer les relations entre les variables d'origine. Par exemple, si une composante principale a une forte corrélation avec la taille et le poids des individus, cela peut indiquer que cette composante est liée à la notion de "taille corporelle" des individus.

Les 5 étapes de la préparation

Discrétisation des données

- Trois types d'attributs

- Nominal ou catégorique : valeurs d'un ensemble
- Ordinal : valeurs d'un ensemble ordonné
- Continu : réels

- Discrétisation

- diviser l'intervalle de valeurs possibles en sous intervalles
- certains algorithmes acceptent seulement des attributs catégoriques
- réduit le volume des données
- préparation pour de futures analyses
- Exemple : segmenter des données numériques en intervalles relativement uniformes



**Merci pour
votre attention**

des questions ?

Partie 3 :


Apprentissage non
supervisée de données :



Règles d'association

Motivation

- Une règle d'association = règle de **décision**
- Une règle d'association est un **pattern** qui prédit qu'un évènement va se réaliser avec une certaine probabilité
- Les règles d'association sont souvent des conditions logiques de la forme **If ... Then ...**
- Origine « Market Basket Analysis »
- E-commerce, marketing, ...



Motivation

- Rechercher les associations consiste à rechercher les règles de type :
 - « Si pour un individu, la variable $A = X_a$, la variable $B = X_b$, etc, alors, dans 80% des cas, la variable $Z = X_z$, cette configuration s'effectue pour 30 % des individus »
- Repérer des règles liant les données avec un bon niveau de probabilité = découverte de relations fines entre attributs
- Mettre en évidence les produits / des articles achetés ensemble
- Transcrire la connaissance sous forme de règles d'association :
si $[P(\text{tid}, X) := \text{prémisse}] \rightarrow [P(\text{tid}, Y) := \text{conséquence}]$

Terminologie

N° transaction (Caddie)	Contenu du caddie			
1	pastis	martini	chips	saucisson
2	martini	chips		
3	pain	beurre	pastis	
4	saucisson			
5	pain	lait	beurre	
6	chips	pain		
7	confiture			

Données de transaction (1/3)

Analyse des tickets de caisse

N° transaction (Caddie)	Contenu du caddie			
1	pastis	martini	chips	saucisson
2	martini	chips		
3	pain	beurre	pastis	
4	saucisson			
5	pain	lait	beurre	
6	chips	pain		
7	confiture			

- Une observation = Un caddie
 - Ne tenir compte que de la présence des produits = articles (pas de leur quantité)
 - Dans un caddie, le nombre de produits est variable
 - La liste des articles est immense et variable !
- Objectifs :
- (1) Mettre en évidence les articles achetés ensemble
 - (2) Transcrire la connaissance sous forme de règle d'association

Si antécédent Alors conséquent



listes de produits

- ◆ ex. : Si pastis et martini Alors saucisson et chips

Données de transaction (2/3)

- Autre représentation des données de transactions :

Tableau de transactions → Tableau binaire 0/1

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates
2	Moutarde	Œufs		
3	Pain	Beurre	Poulet	
4	Pates			
5	Pain	Lait	Beurre	
6	Œufs	Pain		
7	Confiture			



	P1	P2	P3	P4	P5	P6	P7	P8
1	1	1	1	1	0	0	0	0
2	0	1	1	0	0	0	0	0
3	1	0	0	0	1	1	0	0
4	0	0	0	1	0	0	0	0
5	0	0	0	0	1	1	1	0
6	0	0	1	0	1	0	0	0
7	0	0	0	0	0	0	0	1

désignation

P1 = Poulet

P2 = Moutarde

P3 = Œufs

P4 = Pates

P5 = Pain

P6 = Beurre

P7 = Lait

P8 = Confiture

Données de transaction (3/3)

Codage disjonctif complet

Observation	Taille	Corpulence
1	Petit	Mince
2	Grand	Enveloppé
3	Grand	Mince



Observation	Taille = Petit	Taille = Grand	Corpulence = Mince	Corpulence = Enveloppé
1	1	0	1	0
2	0	1	0	1
3	0	1	1	0

Il s'agit de détecter les cooccurrences des modalités (attribut = valeur)
(attention : on ne peut pas être « petit » et « grand » en même temps)



Dès que l'on peut se ramener à des données 0/1 :

Il est possible de construire des règles d'association

Passage en forme disjonctive complète

- **Catégoriel, qualitatif, discret** : type marché, entreprises, taux, appartenance, ...

	Marché
c ₁	Part.
c ₂	Autre
c ₃	Part.
c ₄	Part.
c ₅	Entr.



	P	E	A
c ₁	1		
c ₂			1
c ₃	1		
c ₄	1		
c ₅		1	

- **Continu, quantitatif** : virement, âge, température, consommation, pourcentage, ...

	Dom
c ₁	1100
c ₂	0
c ₃	2200
c ₄	800
c ₅	3800



	d0	d1	d2	d3	d4
c ₁			1		
c ₂	1				
c ₃				1	
c ₄		1			
c ₅					1

Critères d'évaluation des règles d'association

SUPPORT

- ✓ indicateur de « fiabilité »
- ✓ probabilité absolue :
 $P(p1 \text{ et } p2)$
- ✓ $\text{freq}(p1 \text{ et } p2) / N = \%$ de transactions vérifiant la règle

Règle d'association :
 $p1 \rightarrow p2$

$\text{sup}(R_1) = 2$: en termes absolus
ou $\text{sup}(R_1) = 2 / 6 = 33\%$: en termes relatifs

$\text{Conf}(R_1) = \text{sup}(R_1) / \text{sup}(\text{antécédant } R_1)$
 $= \text{sup}(p1 \rightarrow p2) / \text{sup}(p1) = 2 / 4 = 50\%$

CONFIANCE

- ✓ Indicateur de « précision »
- ✓ probabilité conditionnelle :
 $P(p2|p1)$
- ✓ $\text{freq}(p1 \text{ et } p2) / \text{freq}(p1) = \%$ de transactions vérifiant l'implication

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1



« Bonne » règle = règle avec un support et une confiance élevée

Analyse des tickets

{ "crème" } → { "pain" }



ID	PRODUITS
1	pain, crème, eau
2	crème
3	pain, crème, vin
4	eau
5	crème, eau

Support = Prob. (crème et pain) :

$$\text{Sup} = \frac{\text{nom}(\text{tran. contenant crème et pain})}{\text{nom_total}(\text{tran.})} = \frac{2}{5} = 0.4$$

Confiance = Prob(crème et pain / crème) :

$$\text{Conf} = \frac{\text{nom}(\text{tran. contenant crème et pain})}{\text{nom}(\text{tran. contenant crème})} = \frac{2}{4} = 0.5 = \frac{\text{sup}(\text{crème et pain})}{\text{sup}(\text{crème})}$$

Extraction des règles d'association

- A noter :

- item = produit
- itemset = ensemble de produits (ex. {p1,p3})
- sup(itemset) = nombre de transactions d'apparition simultanée des produits (ex. sup{p1,p3} = 4)
- card(itemset) = nombre de produits dans l'ensemble (ex. card{p1,p3} = 2)
- itemset fréquent = itemset dont le support est $\geq$ à support min

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1



Lift d'une règle (1\2)

- Une règle peut avoir d'excellents supports et confiance sans être pour autant « intéressante »



Il faut un critère - **une mesure d'intérêt** - qui caractérise une forme de causalité c.-à-d. l'idée « la connaissance de l'antécédent amène de l'information (supplémentaire) sur la connaissance du conséquent »

Remarque :

Le LIFT peut se lire comme un rapport de vraisemblance

$$\text{lift}(A \rightarrow C) = \frac{P(AC)}{P(A) \times P(C)}$$

Lift d'une règle (2\2)

- LIFT = Indicateur de pertinence d'une règle
- L'amélioration apportée par une règle, par rapport à une réponse au hasard est appelée « lift »
 - Le lift est une bonne mesure de performance de la règle d'association.
 - Le lift est la confiance de la règle divisée par la valeur espérée de la confiance.

$$\text{Pour } R : A \rightarrow C, \text{ lift} = \left(\frac{n_{ac}}{n_a} \right) / \left(\frac{n_c}{n} \right)$$

- Interprétation du lift :
 - Un lift supérieur à 1 : Indique une corrélation positive
 - Un lift de 1 indique une corrélation nulle
 - Un lift inférieur à 1 : Indique une corrélation négative

Exercise



Rule	Support	Confidence	Lift
$A \Rightarrow D$			
$C \Rightarrow A$			
$A \Rightarrow C$			
$B \& C \Rightarrow D$			



Solution de l'exercice



Rule	Support	Confidence	Lift
$A \Rightarrow D$	$2/5$	$2/3$	$10/9$
$C \Rightarrow A$	$2/5$	$2/4$	$5/6$
$A \Rightarrow C$	$2/5$	$2/3$	$5/6$
$B \& C \Rightarrow D$	$1/5$	$1/3$	$5/9$

Extraction des règles d'association

Démarche globale

- **Paramètres** : Fixer un degré d'exigence sur les règles à extraire
 - Support min. (ex. 2 transactions)
 - Confiance min. (ex. 75%)
→ L'idée est surtout de contrôler (limiter) le nombre de règles produites

- **Démarche** : Construction en deux temps :
 - recherche des itemsets fréquents (support $\geq$ support min.)
 - à partir des itemsets fréquents, produire les règles (conf. $\geq$ conf. min.)


Alg. A priori

Tout sous-ensemble d'un ensemble d'articles fréquents doit aussi être un ensemble fréquent

Recherche des itemsets fréquents

Extraction des itemsets fréquents

Il s'agit de parcourir un treillis et de calculer les supports associés à chaque combinaison



Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1

$$C_4^1 = 4$$

itemsets
de card = 1

$$C_4^2 = 6$$

itemsets
de card = 2

$$C_4^3 = 4$$

$$C_4^4 = 1$$

$$\Sigma = 15 = 2^4 - 1$$

Sup min = 3 $\rightarrow$ F = { {p1}, {p2}, {p3}, {p1,p3}, {p2,p3} }

- Le nombre de configuration est très vite très élevé
- Chaque configuration nécessiterait un scan de la base de données
- $\rightarrow$ Il faut s'appuyer sur le paramètre « support.min »
- $\rightarrow$ Et les propriétés des itemsets
- Pour réduire le nombre de configuration à évaluer réellement

Exemple :

Calcul de L1



On va prendre la valeur du Support minimal = 3

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1



1-Itemsets	Support	absolu
{p1}	4	
{p2}	3	
{p3}	5	
{p4}	1	

$L1 = \{ \{p1\}, \{p2\}, \{p3\} \}$

$C2 = \{ \{p1,p2\}, \{p1,p3\}, \{p2,p3\} \}$



Ensembles candidats

Exemple :

Calcul de L2



On va prendre le Support minimal = 3

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1



2-Itemsets	Support	absolu
{p1,p2}	2	
{p1,p3}	4	
{p2,p3}	3	

$$L2 = \{ \{p1,p3\}, \{p2,p3\} \}$$

$$C3 = \{ \{p1,p2,p3\} \}$$



Exemple :

Calcul de L3



On va prendre le Support minimal = 3

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1



3-Itemsets	Support	absolu
{p1,p2, p3}	2	

$$L_3 = \emptyset$$

$$C_4 = \emptyset$$

$$F = \{ \{p1\}, \{p2\}, \{p3\}, \{p1,p3\}, \{p2,p3\} \}$$

Exemple :

Déduction des règles d'association



On va prendre le pourcentage de la confiance minimale = **65%**

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1

{p1,p3}

$p1 \rightarrow p3$: confiance = $4/4 = 100\%$

$p3 \rightarrow p1$: confiance = $4/5 = 80\%$



{p2,p3}

$p2 \rightarrow p3$: confiance = $3/3 = 100\%$

$p3 \rightarrow p2$: confiance = $3/5 = 60\%$



Algorithme à priori des items fréquents

```
L1 = { frequent 1-ensemble } ;  
for (k = 2 ; Lk-1 ≠ ∅ ; k++) do  
    {  
        Ck = apriori-gen(Lk-1); // Generate new candidates  
        foreach transactions t ∈ DB do  
            { // Counting  
                Ct = { subset(Ck, t) }; // get subsets of t candidates  
                foreach c ∈ Ct do c.count++;  
            }  
        Lk = { c ∈ Ck | c.count ≥ minsup } ; // Filter candidates  
    }  
F = {Lk} ;
```



**Merci pour
votre attention**

des questions ?