




Data Mining

Hela Mahersia
helamahersia@yahoo.fr

Master M Pro DS - Université de Carthage
Faculté des Sciences de Bizerte
Fouille de données


Partie 4 :



**Apprentissage non
supervisée de
données : Clustering**


Plan

- Motivation
- Utilité du clustering
- K-Means




Motivation


- Combien de classes?



Two Clusters



Four Clusters



Six Clusters



- Deux individus se ressemblent le plus **SI** les points qui les représentent dans le nuage sont les plus proches
- Nécessité d'une métrique de similarité
 - Distance Euclidienne
 - Distance de Mahalanobis
 - Distance de Manhattan

Utilité du clustering



Banque / Assurance

- Catégoriser la clientèle : chercher un profil qui représente les membres de chaque classe
- Regrouper les clients selon des critères et caractéristiques communs : cibler « les mailing »



Médecine

- Déterminer des segments de patients susceptibles d'être soumis à des protocoles thérapeutiques déterminés, chaque segment regroupant tous les patients réagissant identiquement
- Retrouver les différents comportements similaires



Biologie – Zoologie – Ethologie – Sciences humaines

- Expliquer les relations entre espèces, races, genres, familles,
- Retrouver de nouvelles répartitions




- Profiling
- Analyse sémantique, sentimentale,
- Analyse et mesure de la tonalité d'un contenu textuel
- Catégorisation des concepts ou des entités nommés
- Construction d'agrégateur synthétique à partir des flux d'actualités


Le regroupement

- Clustering = classification non supervisée (pas de labels prédéfinies)
- Clustering = regroupement : vise à construire une collection d'individus :
 - Similaires au sein d'un même groupe
 - Non similaires dans des groupes différents
- Une bonne méthode de regroupement permet de garantir :
 - Une grande similarité intra-groupe
 - Une faible similarité inter-groupe

La qualité d'un regroupement dépend donc de la mesure de similarité utilisée





Principales méthodes de clustering



Algorithmes de partitionnement

- Construire une partition à k clusters d'une base D de n individus
- les classes qu'il construit n'entretiennent jamais de relations hiérarchiques: une classe n'est jamais incluse dans une autre classe
- Les k clusters doivent optimiser le critère choisi
 - Chaque cluster doit au moins contenir un individu
 - Chaque individu doit appartenir à un seul cluster
- Principales méthodes :
 - K-means : K centres mobiles
 - K-means flou



K-means : algorithme

Algorithme K-Means

Entrée : k le nombre de groupes cherchés

DEBUT

Choisir aléatoirement les centres des groupes

REPETER

- i. Affecter chaque cas au groupe dont il est le plus proche au son centre
- ii. Recalculer le centre de chaque groupe


JUSQU'À (stabilisation des **centres**)

OU (nombre d'itérations = **t**)

OU (stabilisation de **l'inertie totale** de la population)


FIN

K-means : simulation (1/7)




Choisir **3**
Centres de
classes
(au hasard)

K-means : simulation (2/7)




Affecter chaque point à la classe dont le centre est le plus proche

K-means : simulation (3/7)




Déplacer chaque
centre de classe vers
la moyenne de chaque
classe

K-means : simulation (4/7)




Réaffecter les points
qui sont plus proches
du centre d'une autre
classe

K-means : simulation (5/7)




les trois points
qui changent de
classe

K-means : simulation (6/7)



Re-calculer les
moyennes des classes

K-means : simulation (7/7)




Déplacer les
centres des classes
vers les moyennes


K-means : Exemple

- Soient les 4 médicaments suivants, caractérisé chacun par deux caractéristiques weight index et pH
- On souhaite grouper ces médicaments en 2 groupements

Médicament	Weight index	pH
A	1	1
B	2	1
C	4	3
D	5	4



K-means : Exemple



$$c_1 = A, c_2 = B$$

$$D^0 = \begin{bmatrix} 0 & 1 & 3.61 & 5 \\ 1 & 0 & 2.83 & 4.24 \end{bmatrix}$$

$c_1 = (1,1)$ group - 1
 $c_2 = (2,1)$ group - 2


	A	B	C	D	
X	1	2	4	5	
Y	1	1	3	4	

Euclidean distance

$$d(D, c_1) = \sqrt{(5-1)^2 + (4-1)^2} = 5$$

$$d(D, c_2) = \sqrt{(5-2)^2 + (4-1)^2} = 4.24$$


K-means : Exemple



$$c_1 = (1, 1)$$

$$c_2 = \left(\frac{2 + 4 + 5}{3}, \frac{1 + 3 + 4}{3} \right) \\ = \left(\frac{11}{3}, \frac{8}{3} \right)$$


K-means : Exemple



$$D^1 = \begin{bmatrix} 0 & 1 & 3.61 & 5 \\ 3.14 & 2.36 & 0.47 & 1.89 \end{bmatrix} \quad \begin{array}{l} \mathbf{c}_1 = (1, 1) \text{ group-1} \\ \mathbf{c}_2 = (\frac{11}{3}, \frac{8}{3}) \text{ group-2} \end{array}$$

	A	B	C	D	
$\begin{bmatrix} 1 & 2 & 4 & 5 \\ 1 & 1 & 3 & 4 \end{bmatrix}$					X
					Y

K-means : Exemple



$$c_1 = \left(\frac{1+2}{2}, \frac{1+1}{2} \right) = \left(1\frac{1}{2}, 1 \right)$$

$$c_2 = \left(\frac{4+5}{2}, \frac{3+4}{2} \right) = \left(4\frac{1}{2}, 3\frac{1}{2} \right)$$

$D^2 = \begin{bmatrix} 0.5 & 0.5 & 3.20 & 4.61 \\ 4.30 & 3.54 & 0.71 & 0.71 \end{bmatrix}$				$c_1 = (1\frac{1}{2}, 1)$	group-1
				$c_2 = (4\frac{1}{2}, 3\frac{1}{2})$	group-2
	A	B	C	D	
	1	2	4	5	X
	1	1	3	4	Y

K-means : exercice


- Refaire le clustering avec la distance de Manhattan

- K=2

- C1 = A and C2 = C

1-distance	$\sum_{i=1}^n x_i - y_i $
------------	----------------------------

Medicine	Weight	pH-Index
A	1	1
B	2	1
C	4	3
D	5	4




Points faibles du K-means



- Le choix du nombre de groupes est subjectif dans le cas où le nombre de classes est inconnu au sein de l'échantillon.
- L'algorithme du K-Means ne trouve pas nécessairement la configuration la plus optimale correspondant à la fonction objective minimale.
- Les résultats de l'algorithme du K-Means sont sensibles à l'initialisation aléatoires des centres.


Le groupement hiérarchique

- Connue aussi sous le nom Classification Ascendante Hiérarchique (ou CAH)
- Objectifs : production d'une structure (arbre) permettant :
 - La mise en évidence de liens hiérarchiques entre individus ou groupe d'individu
 - La détection d'un nombre de classe **naturel** au sein de la population




Distance entre deux ensembles de points

Saut minimal ou minimum (single linkage)



$$D(C_1, C_2) = \min (\{d(x, y)\}, x \in C_1, y \in C_2)$$


Saut maximal (complete linkage)



$$D(C_1, C_2) = \max (\{d(x, y)\}, x \in C_1, y \in C_2)$$

Distance moyenne

$$D(C_1, C_2) = \frac{1}{n_{C_1} n_{C_2}} \sum_{x \in C_1} \sum_{y \in C_2} d(x, y)$$



n_{C_1} : Le cardinal de C_1

n_{C_2} : Le cardinal de C_2

Algorithme de la CAH

Entrée : tableau de données (X)

Sortie : Indicateur de partition des individus

calcul du tableau des distances entre individus
Chaque individu constitue un groupe (classe)

REPETER

Détecter les 2 groupes les plus proches

Les agréger pour n'en former qu'un seul

JUSQU'À tous les individus forment un seul groupe

Identifier le nombre adéquat de groupes


Procéder au partitionnement

Définir une mesure de
distance entre individus


Définir une stratégie
d'agrégation c.-à-d. une mesure
de dissimilarité entre groupes
(entre un individu et un groupe)

De quel outil peut-on disposer
pour identifier la « bonne »
partition ? Dendrogramme.

CAH : Exemple





(source :
https://youtu.be/SE_4dLh5vXY)



	A	B	C	D	E	F	G
B	0.50						
C	0.25	0.56					
D	5.00	4.72	4.80				
E	5.78	5.55	5.57	1.00			
F	4.32	4.23	4.07	2.01	2.06		
G	4.92	4.84	4.68	2.06	1.81	0.61	
H	5.00	5.02	4.75	3.16	2.90	1.28	1.12



CAH : Exemple



	A	B	C	D	E	F	G
B	0.50						
C	0.25	0.56					
D	5.00	4.72	4.80				
E	5.78	5.55	5.57	1.00			
F	4.32	4.23	4.07	2.01	2.06		
G	4.92	4.84	4.68	2.06	1.81	0.61	
H	5.00	5.02	4.75	3.16	2.90	1.28	1.12

1^{er} regroupement

CAH : Exemple




2^e regroupement

	AC	B	D	E	F	G
B	0.50					
D	4.80	4.72				
E	5.57	5.55	1.00			
F	4.07	4.23	2.01	2.06		
G	4.68	4.84	2.06	1.81	0.61	
H	4.75	5.02	3.16	2.90	1.28	1.12

	A	B	C	D	E	F	G
B	0.50						
C	0.25	0.56					
D	5.00	4.72	4.80				
E	5.78	5.55	5.57	1.00			
F	4.32	4.23	4.07	2.01	2.06		
G	4.92	4.84	4.68	2.06	1.81	0.61	
H	5.00	5.02	4.75	3.16	2.90	1.28	1.12


1^{er} regroupement

CAH : Exemple



CAH : Exemple

En définissant un niveau de coupure, on construit une partition



Points faibles de la CAH



- Le choix du critère de distance entre les groupes influe énormément sur les groupements formés.
- On ne peut pas décider sur la coupure optimale de l'arbre
- Devient complexe avec temps de calcul énorme avec de grandes données

Solution : on peut coupler la CAH au k-means :
C'est ce qu'on appelle la méthode mixte.




Exercice

- Effectuer la classification hiérarchique des individus avec la distance euclidienne et le critère de saut maximal.
- Individus :
 $w_1(2,2)$, $w_2(7.5,4)$, $w_3(3,3)$, $w_4(0.5,5)$ et $w_5(6,4)$



Correction de l'exercice






**Merci pour
votre attention**

des questions ?

Partie 5 :





**Classification
supervisée de
données : SVM**



Plan

- Motivation
- Séparateurs à vaste marge :
 - Cas linéairement séparable
 - Cas non-séparable linéairement
- SVM non linéaire
- Exemple

Problèmes de classification




Linéaire





Non-linéaire

Motivation : machine à vecteurs de support

- Comment séparer ces nuages de points?
 - Problème à deux classes linéairement séparables
 - Solution : infinité de séparateurs linéaires mais lequel minimisera l'erreur d'apprentissage?
 - L'idée est de rechercher une règle de décision basée sur une **séparation par hyperplan de marge optimale**



Exemple de mauvais choix




- Pour minimiser la sensibilité au bruit, la droite de décision doit être aussi éloignée que possible des données de chaque classe

Séparation linéaire et marge

- On donne un ensemble d'apprentissage : $\{(x_i, y_i), i = 1, \dots, n\}$, $x_i \in \mathbb{R}^d$, $y_i \in \{-1, 1\}$
- Dans un problème de classification à deux classes, le but est de chercher une fonction $f: X \rightarrow \mathbb{R}$ qui permet de prédire si un nouvel exemple appartient à la classe -1 ou à la classe $+1$.
- Le principe est de séparer l'espace de descripteurs X en deux parties : $X = \{x \in X | f(x) > 0\} \cup \{x \in X | f(x) < 0\}$.
 - Si $f(x) > 0$ alors x est affecté à la classe $+1$,
 - si $f(x) < 0$ alors x est affecté à la classe -1 ,
 - si $f(x) = 0$ alors x se trouve sur la « surface de séparation » entre les deux classes et le classifieur ne peut pas l'affecter à l'une des classes.


Séparation linéaire et marge

- **Marge** : Distance entre la plus petite distance signée entre la surface de décision et les données de l'ensemble d'apprentissage



- Les SVM linéaires cherchent le séparateur (l'hyperplan de séparation) qui **maximise** la marge → On appelle cela « séparateur à vaste marge ».

Séparation linéaire et marge



Fonction de décision : $f(x) = w^T x + b = 0$

- $f(x) = 0$: hyperplan (surface) de séparation
- $f(x) > 0$: classe 1 ($y_i = 1$)
- $f(x) < 0$: classe 2 ($y_i = -1$)

Paramètres :

- w est la normale à l'hyperplan,
- b est le décalage par rapport à l'origine

- Les « vecteurs de support » se trouvent à une distance égale à la marge d'un côté ou de l'autre de l'hyperplan de séparation
- Une fois le séparateur $f(x)$ trouvé, la classification d'un nouvel exemple se fait par une simple décision à seuil zéro

SVM linéaire (cas séparable)

- On suppose d'abord que les données d'apprentissage sont linéairement séparables : qu'il existe un hyperplan qui sépare les données sans erreur.
- Dans ce cas, on cherche l'hyperplan de marge maximale :

$$f(x) = \langle w, x \rangle + b = w^\top x + b$$

- Si x_s est un vecteur de support et $H = \{x | w^\top x + b = 0\}$ alors la marge est donnée par :

$$\text{Marge} = 2d(x, H) = 2 \frac{|w^\top x_s + b|}{||w||}$$

- On impose alors la condition de normalisation $|w^\top x_s + b| = 1$ pour les vecteurs de support x_s , ce qui conduit à :



$$\text{Marge} = \frac{2}{||w||}$$

Optimisation de la marge

- $w \cdot x_i + b = 1$ si x_i est un vecteur de support de la classe +1 et $w \cdot x_i + b = -1$ si x_i est un vecteur de support de la classe -1.
- Dans ces cas :
 - Si $y_i = 1$ alors $w \cdot x_i + b \geq 1$ et donc $y_i(w \cdot x_i + b) \geq 1$,
 - Si $y_i = -1$ alors $w \cdot x_i + b \leq -1$ et donc $y_i(w \cdot x_i + b) \geq 1$,
- On arrive donc au problème d'optimisation suivant :

$$\begin{cases} \min_{w,b} \frac{1}{2} ||w||^2 \\ \text{tel que } y_i(w \cdot x_i + b) \geq 1, i = 1, \dots, n \end{cases}$$

Optimisation quadratique

- Pour trouver une solution, on utilise les multiplicateurs α_i de Lagrange. Le lagrangien est donné par :

$$L(w, b, \alpha) = \frac{1}{2} ||w||^2 - \sum_{i=1}^n \alpha_i [y_i (w^T x_i + b) - 1]$$

- Les conditions nécessaires d'optimum :

$$\frac{\partial L}{\partial b} L(w, b, \alpha) = 0 \implies \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial w} L(w, b, \alpha) = 0 \implies w = \sum_{i=1}^n \alpha_i y_i x_i$$

Optimisation de la marge

- Par substitution on obtient le problème dual :

$$\left\{ \begin{array}{l} \max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \\ t. q. \\ \alpha_i \geq 0, i = 1, \dots, n \text{ (admissibilité duale)} \\ \sum_{i=1}^n \alpha_i y_i = 0 \text{ (stationarité)} \end{array} \right.$$

- Les vecteurs de support sont ceux pour lesquels $\alpha_i > 0$
- A partir des α_i on obtient w
- b est obtenu à partir de la relation $|x_s^T w + b| = 1$ valable pour tous les vecteurs de support x_s
- Ajouter des échantillons à l'ensemble d'apprentissage qui ne sont pas des vecteurs supports n'a aucune influence sur la solution finale

Séparation linéaire et marge


- La fonction de décision permettant de classer une nouvelle observation x est :

$$f(x) = \sum_{i=1}^n \alpha_i y_i x_i^T x + b$$

- L'hyperplan solution ne dépend que du produit scalaire entre le vecteur d'entrée et les vecteurs de support.
→ Cette particularité permet l'utilisation de fonctions noyau pour aborder des problèmes non linéaires

SVM à noyau

Exemple avec noyau gaussien



$$y(\mathbf{x}) = \sum_{n=1}^N a_n t_n k(\mathbf{x}_n, \mathbf{x}) + b$$

Exemple

- Le tableau suivant contient des données sur des individus d'une population décrits selon deux attributs : attribut 1 et attribut 2.
- On souhaite utiliser la méthode SVM pour classer ces données en deux classes : C1 et C2.

N°	Attribut 1	Attribut 2	Classe
1	0	3	C1
2	3	3	C1
3	1	4	C1
4	2	5	C1
5	1	6	C2
6	2	7	C2
7	3	7	C2
8	3	8	C2
9	2	9	C2
10	4	9	C2
11	8	9	C2

- Représentez sur le plan de la figure 1 les données du tableau précédent, en symbolisant la classe C1 par une croix (+) et la classe C2 par un cercle (o).
- Représentez l'hyperplan séparateur optimal en montrant clairement les supports de vecteur que vous utilisez.



**Merci pour
votre attention**

des questions ?

Partie 6 :

The logo for AdaBoost is displayed in a stylized, hand-drawn font. The word 'Ada' is rendered in orange with a dark outline, and 'Boost' is rendered in teal with a dark outline. The letters are blocky and have a slightly irregular, sketchy appearance.

**Combinaison de
modèles**

Plan

- Motivation
- Combinaison de plusieurs modèles
- Bagging –Boosting
- Algorithme Adaboost

Motivation

- Types d'apprentissage :
 - Apprentissage supervisé : il y des étiquettes à prédire
 - Apprentissage non supervisé : étiquettes ne sont pas fournis
 - Apprentissage semi-supervisé
 - Apprentissage par renforcement !!
- Pourquoi utiliser un seul modèle?
 - Un système combinant plusieurs modèles différents ne serait-il pas meilleurs?
 - En pratique la réponse est toujours (ou presque) oui
- Le résultat de combinaison de plusieurs modèles est appelé **ensemble** ou **comité de modèles** ou **modèle d'agrégation**

Exemple introductif

En regroupant nos modèles tous ensemble, on obtient une meilleure performance que lorsqu'on utilise nos modèles chacun de leur côté

	Modèle 1	Modèle 2	Modèle 3
			
1	✓	✓	✓
2	✗	✓	✓
3	✓	✓	✗
4	✓	✗	✓
5	✓	✓	✗
6	✓	✓	✓
7	✗	✗	✓
8	✗	✓	✓
9	✓	✗	✓
10	✓	✓	✗
	70%	70%	70%



	Modèle 1	Modèle 2	Modèle 3		
					
1	✓	✓	✓	→	✓
2	✗	✓	✓	→	✓
3	✓	✓	✗	→	✓
4	✓	✗	✓	→	✓
5	✓	✓	✗	→	✓
6	✓	✓	✓	→	✓
7	✗	✗	✓	→	✗
8	✗	✓	✓	→	✓
9	✓	✗	✓	→	✓
10	✓	✓	✗	→	✓
	70%	70%	70%		90%

Principe

- La façon la plus simple d'obtenir M modèles est d'utiliser M algorithmes d'apprentissage différents

- pour $m = 1, \dots, M$

- entraîner un modèle $y_m(\mathbf{x})$ à l'aide du m^{e} algorithme d'apprentissage

- retourner le modèle ensemble (comité)

- pour la régression :

$$y_{\text{COM}}(\mathbf{x}) = \frac{1}{M} \sum_{m=1}^M y_m(\mathbf{x})$$

- pour la classification : $y_{\text{COM}}(\mathbf{x})$ retourne la classe ayant le plus de votes

Principe

- Les M algorithmes pourraient aussi être le même algorithme, mais avec M choix d'hyper-paramètres différents

- pour $m = 1, \dots, M$

- entraîner un modèle $y_m(\mathbf{x})$ à l'aide du m^{e} algorithme d'apprentissage

- retourner le modèle ensemble (comité)

- pour la régression :

$$y_{\text{COM}}(\mathbf{x}) = \frac{1}{M} \sum_{m=1}^M y_m(\mathbf{x})$$

- pour la classification : $y_{\text{COM}}(\mathbf{x})$ retourne la classe ayant le plus de votes

Bagging (1/3)

- Bagging (Breiman, 1996) :


- On tire au hasard dans la base d'apprentissage B échantillons, appelés échantillons "bootstrap"
- Pour chaque échantillon i on calcule le modèle $G_i(x)$
 - ◆ Régression : agrégation par la moyenne des $G_i(x)$
 - ◆ Classification : agrégation par vote $G(x) = \text{Vote majoritaire}(G_i(x))$

- Exemple : Forêts aléatoires

- Amélioration du bagging pour les arbres de décision
- Objectif : rendre les arbres utilisés plus indépendants (moins corrélés)
- Bons résultats surtout en grande dimension
- Très simple à mettre en œuvre
- Peu de paramètres


Bagging (2/3)

Créer plusieurs copies d'un même modèle, en entrainant chaque copie sur une partie **aléatoire** du dataset.




Bagging (3/3)

Avec Bootstrapping



Sans Bootstrapping



Boosting

- Le principe du boosting est de combiner les sorties de plusieurs classifieurs faibles G_i (weak classifier) pour obtenir un résultat plus fort (strong classifier)
- Classifieur faible : un comportement de base meilleur que l'aléatoire
 - $\approx$ taux d'erreurs sous 0.5 pour une classification binaire
 - ne se trompe pas plus d'une fois sur deux en moyenne, si la répartition des classes est équilibrée
- Les exemples mal classés auront **un poids plus important**
 - on dit qu'ils sont boostés vis-à-vis de l'apprenant faible au prochain tour, afin qu'il pallie le manque.
- **Chaque classifieur faible est pondéré par la qualité de sa classification** : mieux il classe, plus il sera important.

Boosting






Illustration du boosting



Exemple de Boosting : Adaboost


1. Initialize the observation weights $w_i = 1/N$, $i = 1, 2, \dots, N$.
2. For $m = 1$ to M :
 - (a) Fit a classifier $G_m(x)$ to the training data using weights w_i .
 - (b) Compute
$$\text{err}_m = \frac{\sum_{i=1}^N w_i I(y_i \neq G_m(x_i))}{\sum_{i=1}^N w_i}.$$
 - (c) Compute $\alpha_m = \log((1 - \text{err}_m)/\text{err}_m)$.
 - (d) Set $w_i \leftarrow w_i \cdot \exp[\alpha_m \cdot I(y_i \neq G_m(x_i))]$, $i = 1, 2, \dots, N$.
3. Output $G(x) = \text{sign} \left[\sum_{m=1}^M \alpha_m G_m(x) \right]$.

Exemple de Boosting : Adaboost




Bagging vs Boosting (1/2)

single




1 iteration

bagging




boosting



- › **Bagging** : particulièrement approprié lorsque chaque modèle individuel a **beaucoup de capacité**
- › **Boosting** : particulièrement approprié lorsque chaque modèle individuel n'a **pas beaucoup de capacité**

Bagging vs Boosting (2/2)





**Merci pour
votre attention**

des questions ?