

Examen TP (DataViz)

Suivie des encadrements des stages de la spécialité MPDS2

Préambule

- Tout type de documents est autorisé (internet, cours, tutoriels, ...) ;)
- Durée d'examen : **02h heures** y compris la période de dépôt de vos travaux sur la plateforme (11h – 13h).
- L'examen aura lieu dans la salle info 3 avec la possibilité de le réaliser en ligne et à distance.
- L'examen **peut être réalisé en ligne depuis chez vous** (si vous êtes totalement sûr de la disponibilité d'une connexion internet stable. Vous assumez toute la responsabilité concernant ce point)
- Le sujet de l'examen ainsi le matériel nécessaire sera accessible avant 10 mn de l'examen (c-à-d à 10h50mn)
- Vous êtes sensés déposer, en ligne sur la plateforme UVT, vos travaux au plus tard à **13h00**.
- Vous avez le choix entre 02 outils pour réaliser cet examen :
 - o Un logiciel « SpreadSheet » : Google Sheet ou Excel
 - o Un langage de Scripting plus toutes les bibliothèques nécessaires (Python, Matplotlib, Pandas, Numpy, Seaborn, Scipy, ...)
- Le dépôt de votre travail comporte **un seul fichier** selon l'outil utilisé et il doit indiquer votre nom comme suit :
 - o Logiciel "SpreadSheet" → Exemple : **Ibrahim_bah.xlsx**
 - Dans ce cas, vous devez répondre directement sur une feuille « Sheet » du classeur qui contient les données. Autrement dit, générer les graphes demandés et les inclure directement sur une feuille de votre classeur de travail.
 - o Python → Exemple : **Ibrahim_bah.py**
 - Dans ce cas, vous devez retourner un code python exécutable sans bugs qui génère les graphes demandés
- **Aucun travail n'est accepté en dehors ceux déposés sur la plateforme et durant la période allouée.**


Remarques

- On propose de manipuler des **données réelles extraites sous leurs formes brutes**. Autrement dit, il y aura un travail de préparation des données afin de pouvoir les valoriser via des graphes.
- Tout le travail doit se faire d'une façon propre et rigoureuse.
- La taille de la base n'est pas aussi volumineuse ce qui pourra vous encourager à faire des manipulations manuelles (comptage, copier-coller, ...) **chose qui n'est pas acceptable**. En effet, tous vos traitements de données doivent se faire dans les règles de l'art.
- Dans le cas du choix d'un logiciel « SpreadSheet », vous aurez probablement besoin d'utiliser
 - o Les fonctions
 - o Les tables croisées (pivot table)
 - o Les fonctions de filtrage
 - o Les fonctions de tris

Travail demandé

En vue de suivre le déroulement des encadrements des stages de fin des études de la spécialité « Data Science », une plateforme de gestion de stage est mise à la disposition du responsable du mastère « Mr. Anis ». La figure Fig.1, représente l'interface de gestion des stages. Toutefois, la plateforme ne dispose pas des outils de visualisation de données. En tant que jeunes « Data Scientist », on vous demande d'aider « Mr. Anis » à développer quelques graphiques qui récapitulent d'une façon visuelle rapide la suivie des encadrements. Votre mission sera donc de développer 05 graphiques qui permettent à « Mr. Anis » de mieux gérer les stages.

Fig. 1



Mr. Anis télécharge le fichier qui récapitule l'état d'encadrement sous format « .csv » et sous le nom « 2022_MPDS_STAGE ». Un extrait du fichier est donné dans la figure Fig.2. Le fichier en question est mis à votre disposition pour en extraire les informations pertinentes que vous devez les valoriser sous forme de graphiques utiles.


Fig. 2

N° DOSS	STATUS	CIN	NOM	ENCADRANT	SUJET	ACTION
R5S7E5RE	VALIDER			NON VALIDER	7495111	BEN AHME
O6U91JQK	VALIDER			NON VALIDER	7982123	ABBASSI
QOCR6LXM	VALIDER			NON VALIDER	7997999	SWESSI R
3TA5MHSS	VALIDER			NON VALIDER	9882000	BEN HASS
ZWZXPSAK	VALIDER			NON VALIDER	9911222	MENSI CH
BJEGZTYV	VALIDER			NON VALIDER	11386777	LAMOURI
B3WEQBSB	VALIDER			NON VALIDER	11399564	ARIDHI
DSJYCUCA	NON VALIDER			NON VALIDER	11411987	FETNI MOHAMED
9J3WS1AA	NON VALIDER			NON VALIDER	11412369	KILBI OMAR;BE
QRF609QC	VALIDER			NON VALIDER	13633561	TLILI M
Z2S0JVER	NON VALIDER			NON VALIDER	14267845	NOURI WAFAB
V8LCXOMX	NON VALIDER			NON VALIDER	MR170697	AMAR HADDAD M
SGIYG3N	VALIDER			NON VALIDER	MR200456	SOUAIDA
6ARPBKYH	VALIDER			NON VALIDER	MR200123	HAMAMIN
0DOSZGVK	VALIDER			NON VALIDER	MR200813	SIDI BR
6TADSYDF	NON VALIDER			NON VALIDER	MR200972	EBNOU MOHAMED
C65ONXNL	VALIDER			NON VALIDER	MR200573	SIDI M'
46P6BTYM	NON VALIDER			NON VALIDER	MR200963	DHLEIMA MOHAM

Si vous avez choisi d'utiliser un outil de « SpreadSheet »

Remarque : Une fois vous avez importé les données sous forme de table, répondez aux questions juste en dessous de la table. Utilisez une cellule pour répondre à chaque question.


- 1) Importer les données et mettez les sous forme d'une table.
- 2) Les bonnes pratiques d'un « data analyst » recommande de copier les données originales afin de les retrouver en cas de mauvaise manipulation. Copier alors les données dans une autre feuille.
- 3) Est-ce qu'il y des attributs (colonnes) inutiles et qui n'ont pas probablement d'intérêt pour la suivie des encadrements. Identifier les en justifiant votre réponse.
- 4) Eliminer les attributs inutiles.
- 5) Chaque étudiant doit déposer sur la plateforme sa proposition de stage en spécifiant l'intitulé et la description. Par la suite, le responsable du mastère valide ou non le stage en fonction de sa description. S'il est validé, l'étudiant pourra poursuivre le stage. Dans le cas contraire, l'étudiant doit chercher un autre sujet qui répond aux exigences du mastère « Data Science ». La colonne « STATUS » contient l'état de chaque projet de stage.
 - a. Examiner la colonne. Y a-t-il de bruit qui doit être nettoyé. Identifier le en justifiant votre réponse.
 - b. Nettoyer alors la colonne pour qu'elle soit exploitable.
 - c. Afin d'aider « Mr. Anis » de repérer rapidement l'état des projets validés et non validés, vous proposez de créer un graphe adéquat : « pie » (secteur). Créez alors le graphe. On vous donne un exemple de ce que pourrait être.



- 6) La classe « MPDS2 » contient des étudiants étrangers et locaux. La colonne « CIN » indique si l'étudiant est local ou étranger. Les étudiants locaux sont repérés par leurs numéro de la carte nationale d'identité (exemple : 14267022) tandis que les étudiants étrangers sont repérés par un code à 02 lettres (nationalité) et 06 chiffres (identifiant) (exemple : MR200972). Afin d'aider Mr. Anis à identifier rapidement et visuellement les proportions des étudiants étrangers, vous pensez créer un graphe adéquat : « Donut » (anneau). Créez alors le graphe. On vous donne un exemple de ce que pourrait être.


Remarque : Afin de préserver la vie privée des étudiants et respecter les lois relatives à la protection des données personnelles, les numéros CIN et les codes sont modifiés.

Etudiants Etrangers Vs Etudiants Locaux




- 7) Mr. Anis veut bien analyser les proportions des sujets validés pour les étudiants locaux et étrangers. Il vous demande de créer un seul graphe qui montre rapidement cette répartition. Vous pensez qu'un graphe hiérarchique de type « compartimentage » (Treemap) pourra être adéquat aux exigences de Mr. Anis. Créez alors le graphe. On vous donne un exemple de ce que pourrait être.

- Un graphique de type compartimentage (Treemap) fournit une vue hiérarchique des données.
- Les branches de l'arborescence sont représentées par des rectangles et les sous-branches par des rectangles plus petits.
- Il permet de visualiser d'un coup d'œil, les éléments les plus volumineux par rapport à l'ensemble des données
- Les graphiques de compartimentage affichent les catégories par couleur et proximité




- 8) Afin d'étudier la répartition des projets par rapport aux enseignants, Mr. Anis veut bien d'un graphe qui présente cette répartition (Nombre de projets par enseignant) et ceci afin d'essayer d'équilibrer la charge d'encadrement et solliciter les enseignants les moins chargés. Entre autre ce graphe permet aussi de présenter le nombre des étudiants sans encadrement. Vous pensez qu'un graphe de type « barre » (bar chart) est le mieux adéquat. Créez alors le graphe. On vous donne un exemple de ce que pourrait être.



- 9) Afin de d'analyser plus en détails, Mr. Anis veut bien d'un graphe qui montre pour chaque enseignant :
- Le nombre total de projets encadrés
 - Le nombre de projets avec sujets validés
 - Le nombre de projets avec sujets non validés

Via ce graphe, on pourra identifier les problèmes relatifs aux sujets des stages fins des études. Vous pensez qu'un graphe de type « barres empilées » (Stacked bar) est le mieux adéquat. Créez alors le graphe. On vous donne un exemple de ce que pourrait être.



Si vous avez choisi d'utiliser un outil de « Scripting » (Python & ses bibliothèques)

- Cas d'un notebook (.ipynb)
 - Utiliser des cellules code pour taper votre code
 - Utiliser des cellules « Markdown » pour répondre aux questions
 - Compresser (zipper) votre notebook (winrar, ...) avant de le déposer sur la plateforme.
Vérifier bien que le fichier zippé peut être dé-zippé sans problème.
- Cas d'un code python (.py)
 - Utiliser les signes de commentaire pour répondre aux questions