



Nom & Prénom : CIN : Identifiant secret :

Une grande importance sera donnée à la clarté de la rédaction

Barème : Ex n°1 (5 pts), Ex n°2 (7.5 pts), Ex n°3 (7.5 pts)

EXERCICE 1 : (5 pts)

- 1) En big data. Quelle est la différence entre les termes "base de données" et "magasin de donnée"

.....

.....

.....

.....

.....

.....

.....

.....

- 2) Quelles sont les différences entre les services Azure suivants : Azure SQL Database, Azure Cosmos DB, Data Lake Storage ?

.....

.....

.....

.....

.....

.....

.....

.....

- 3) Décrire et détailler l'architecture d'entreposage de données à grand échelle (identifier 04 éléments les plus rependus).

.....

.....

.....

.....

.....

.....

.....

.....

4) Pipeline d'ingestion des données

- a) Expliquer comment les « pipelines » orchestrent le processus ETL.
- b) Quelles solutions Azure peut-on utiliser pour cette fin.
- c) Donner un exemple concret d'un « pipeline » en énumérant les technologies Azure participantes

5) Traitement des lots et des flux

- a) Expliquer la différence entre le traitement de lot et le traitement de flux
- b) Est-il possible de combiner les deux dans une architecture d'analyse de données de à grande échelle. Donner et détailler une méthode pour le faire.

EXERCICE 2 : (7.5 pts)

Vous venez d'être embauché en tant qu'analyste de données dans l'hôpital régional de Bizerte. Le stockage et la gestion de données se font via la plateforme logiciel Hadoop. On met à votre disposition les deux bases de données suivantes (vue la taille des fichiers, on ne représente ici que de simples extraits) :

Info_medical.csv

```
1,Female,80,0,1,never,25.19,6.6,140,0,
2,Female,54,0,0,No Info,27.32,6.6,80,0
3,Male,28,0,0,never,27.32,5.7,158,0
4,Female,36,0,0,current,23.45,5.0,155,0
5,Male,76,1,1,current,20.14,4.8,155,0
6,Female,20.1,0,0,never,27.32,6.6,85,0
7,Female,44.0,0,0,never,19.31,6.5,200,1
8,Female,4.0,0,0,No Info,13.99,4.0,140,0
9,Male,30.0,0,0,never,33.76,6.1,126,0
10,Male,67.1,0,1,not current,27.32,6.5,200,1
11,Male,40.0,0,0,current,27.85,5.8,80,0
12,Male,45.0,1,0,never,26.47,4.0,158,0
.....
```

Info_personnel.csv

```
1,Asma ben brahim, 160, Tunis,
2,Najoua ben ghdira, 155, Bizerte,
3,Karim shabou, 171, Kairouan,
4,Jihen amamou, 177, Nabeul,
5,Jihed arbi, 179, Tozeur,
.....
```

- Info_medical.csv : est un fichier « .csv » contenant les données médicales relatifs aux patients de l'hôpital. C'est une collection de données médicales et démographiques sur les patients, ainsi que leur état diabétique (positif ou négatif). Pour des raisons d'anonymité et protection de la vie personnelle, les patients sont identifiés par des indexes. Le fichier Info_personnel.csv n'est accessible que par l'équipe analyste. Les différents attributs de la base de données (respectivement de gauche à droite) sont présentés dans le tableau ci-dessous.

Attribut	Description
ID	Index du patient
Genre	Mâle / femelle
Age	
hypertension	hypertension : pression artérielle dans les artères.
heart_disease	Maladies cardiaques
smoking_history	Le tabagisme est considéré comme un facteur de risque de diabète.
bmi	BMI (Body Mass Index) = (indice de masse corporelle) est une mesure de la graisse corporelle basée sur le poids et la taille. $BMI = \frac{\text{poids en kg}}{(\text{Taille en mètre})^2}$
HbA1c_level	Le taux d'HbA1c (hémoglobine A1c) est une mesure de la glycémie moyenne d'une personne au cours des 2 à 3 derniers mois.
blood_glucose_level	La glycémie désigne la quantité de glucose dans le sang à un moment donné. L'hyperglycémie est un indicateur clé du diabète.
diabetes	C'est la cible. Indique si le patient est diabétique ou non

- Afin de protéger la vie privée des patients, les données personnelles sont enregistrées dans un fichier séparé nommé « Info_personnel.csv ». Les attributs relatifs au dit fichier sont respectivement de droite à gauche : ID, nom, taille(cm), ville.

Vous êtes chargés de mener une analyse sur les données récoltées et ceci en utilisant Pig. Pour cela, on vous demande de

- 1) Ecrivez un code qui permet de lire correctement les deux fichiers en spécifiant un schéma de lecture détaillé pour chaque fichier.

.....

.....

.....

.....

.....

.....

- 2) Calculer et afficher la moyenne d'âge des patients

.....

.....

.....

.....

- 3) Donner le code qui permet de calculer et d'afficher le pourcentage des patients mâle et femelle (en pourcent).

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

- 4) Donner le code qui permet de calculer l'âge moyen et l'écart type des âges pour toute la population, pour les femmes et pour les hommes.

.....

.....

.....

.....

.....

.....

Nom :
Prénom :
CIN :
Epreuve :

5) Donner le code qui

- Détermine le nombre totale des patients diabétiques.
- Détermine le nombre de femmes diabétiques
- Détermine le nombre d'hommes diabétiques

6) Donner le code qui permet de calculer le nombre des patients diabétiques fumeurs.

7) Donner le code qui permet d'afficher les 05 patients mâles avec les tensions artériels les plus élevées.
On affiche juste l'index du patient et non pas son nom.

Ne rien écrire ici

8) Même question que 7) mais cette fois ci on désire afficher les noms des patients.

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

9) Donner le code qui permet de calculer le poids des patients. Ajouter le résultat comme une colonne supplémentaire dans la table Info_personnel.csv

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

10) Donner le code qui tri les villes par nombre de patients décroissant.

.....

.....

.....

.....

.....

.....

.....

EXERCICE 3 : (7.5 pts)

Reprendre les mêmes énoncés et questions de l'exercice précédent. Vous pensez utiliser maintenant HiveQL au lieu de PigLatin.

Votre solution ici

Votre solution ici