


Examen semestriel

Modules "Fouille et extraction de données" & "Datamining"

Corrigé

Exercice 1 (8 points) :

Soit le schéma suivant représentant une classification par SVM de deux classes de données (représentées par + et o).



1/ Donnez l'équation de la droite D1.

Réponse :

$$Y = -X + 8$$

(1 pt)

2/ Donnez l'équation de la droite D2, parallèle à D1 et passant par le point (5, 5).

Réponse :

$$Y = -X + 10$$

(1 pt)

3/ Donnez l'expression qui permet de calculer la marge entre D1 et D2. Calculez la valeur de cette marge.

Réponse :

$$1^{\text{ère}} \text{ droite : } Y = aX + b1, \quad 2^{\text{ème}} \text{ droite : } Y = aX + b2$$

$$\text{Marge} = |b1 - b2| / \sqrt{a^2 + 1}$$

(1 pt)

$$\text{Marge} = \sqrt{2} \cong 1.41$$

(0.5 pt)

4/ Donnez l'équation du séparateur S1 qui passe au milieu de D1 et D2.

Réponse :

$$Y = -X+9$$

(1 pt)

5/ On considère un deuxième séparateur S2 d'équation $X=4.5$ (droite verticale). Lequel des séparateurs S1 et S2 est le meilleur ? Justifiez.

Réponse :

S1 est meilleur que S2.

(1 pt)

Justification :

Si on choisit S1, la marge entre les deux classes est 1.41 (calculée à la question 3)

Si on choisit S2, la marge est environ 1 (peut être lue directement sur la figure).

Finalement, on choisit S1 car il procure une plus grande marge entre les deux classes.

(1 pt)

6/ En se basant sur le séparateur choisi à la question 5, dans quelle classe sera affecté le point (5, 3) ?. Justifiez.

Réponse :

En se basant sur le séparateur S1, le point (5,3) sera affecté à la classe +.

(1 pt)

Justification : Le point (5,3) se trouve en dessous du séparateur S1. L'ordonnée (3) du point est inférieure à la valeur obtenue en remplaçant l'abscisse (5) dans l'équation du séparateur S1 : $3 < -(5)+9$

(0.5 pt)

Exercice 2 (12 points) : On veut construire un arbre de décision pour modéliser le comportement des utilisateurs de la messagerie électronique : on veut savoir dans quels cas les utilisateurs lisent les emails qu'ils trouvent dans leurs boîtes électroniques. Chaque message est décrit par 4 attributs :

- « Auteur » : dont les valeurs sont « Connu » (le message a un auteur bien identifié) ou « Inconnu »,
- « Date » : dont les valeurs sont « Nouveau » (le message a été envoyé récemment) ou « Ancien »,
- « Taille » : dont les valeurs sont « Long » ou « Court »,
- « Lieu » : pour décrire si l'accès au mail se fait sur le lieu de « Travail » ou à la « Maison ».

La classe obtenue peut-être « Oui » (l'utilisateur accepte de lire le message) ou « Non ».

Pour construire l'arbre de décision souhaité, on dispose de l'ensemble d'apprentissage suivant :

N°	Auteur	Date	Taille	Lieu	Classe
01	Connu	Ancien	Court	Maison	Non
02	Connu	Nouveau	Long	Maison	Oui
03	Inconnu	Ancien	Court	Maison	Non
04	Connu	Ancien	Long	Travail	Oui
05	Inconnu	Ancien	Court	Travail	Non
06	Connu	Nouveau	Court	Travail	Oui
07	Inconnu	Nouveau	Court	Travail	Non
08	Connu	Nouveau	Court	Maison	Oui
09	Connu	Ancien	Long	Maison	Non
10	Connu	Ancien	Court	Travail	Oui
11	Inconnu	Ancien	Long	Maison	Non

1/ Construire un arbre de décision en utilisant l'ensemble d'apprentissage et l'algorithme ID3. Détaillez toutes les étapes.

Réponse :

Calcul de l'entropie au niveau du nœud racine : Soit S l'ensemble des données de départ.



$$\text{Entropie}(S) = -\left(\frac{5}{11} * \log_2\left(\frac{5}{11}\right) + \frac{6}{11} * \log_2\left(\frac{6}{11}\right)\right) = 0.99$$

(0.5 pt)

Calcul du gain d'entropie :

$$\text{Gain}(S, \text{« Auteur »}) = \text{Entropie}(S) - \left(\frac{7}{11} * \text{Entropie}(S_{\text{Connu}}) + \frac{4}{11} * \text{Entropie}(S_{\text{Inconnu}})\right)$$

$$\text{Gain}(S, \text{« Auteur »}) = 0.44 \quad (0.5 \text{ pt})$$

$$\text{Gain}(S, \text{« Date »}) = \text{Entropie}(S) - \left(\frac{7}{11} * \text{Entropie}(S_{\text{Ancien}}) + \frac{4}{11} * \text{Entropie}(S_{\text{Nouveau}})\right)$$

$$\text{Gain}(S, \text{« Date »}) = 0.15 \quad (0.5 \text{ pt})$$

$$\text{Gain}(S, \text{« Taille »}) = \text{Entropie}(S) - \left(\frac{7}{11} * \text{Entropie}(S_{\text{Court}}) + \frac{4}{11} * \text{Entropie}(S_{\text{Long}})\right)$$


$$\text{Gain}(S, \text{« Taille »}) = 0 \quad (0.5 \text{ pt})$$

$$\text{Gain}(S, \text{« Lieu »}) = \text{Entropie}(S) - \left(\frac{6}{11} * \text{Entropie}(S_{\text{Maison}}) + \frac{5}{11} * \text{Entropie}(S_{\text{Travail}})\right)$$

$$\text{Gain}(S, \text{« Lieu »}) = 0.05 \quad (0.5 \text{ pt})$$

On voit que le gain d'entropie qu'engendre l'attribut « Auteur » est le plus élevé. Donc, c'est cet attribut qui sera choisi comme test au niveau de la racine de l'arbre.

Voici l'arbre partiel obtenu :



(0.5 pt)

Calcul de l'entropie au niveau du nœud 11 : Soit S11 l'ensemble des données correspondant au nœud 11.

$$\text{Entropie}(S11) = -\left(\frac{5}{7} * \text{Log}_2\left(\frac{5}{7}\right) + \frac{2}{7} * \text{Log}_2\left(\frac{2}{7}\right)\right) = 0.86$$

(0.5 pt)

Calcul du gain d'entropie :

$$\text{Gain}(S11, \text{« Date »}) = \text{Entropie}(S11) - \left(\frac{4}{7} * \text{Entropie}(S11_{\text{Ancien}}) + \frac{3}{7} * \text{Entropie}(S11_{\text{Nouveau}})\right)$$

$$\text{Gain}(S11, \text{« Date »}) = 0.29$$

(0.5 pt)

$$\text{Gain}(S11, \text{« Taille »}) = \text{Entropie}(S11) - \left(\frac{4}{7} * \text{Entropie}(S11_{\text{Court}}) + \frac{3}{7} * \text{Entropie}(S11_{\text{Long}})\right)$$

$$\text{Gain}(S11, \text{« Taille »}) = 0$$

(0.5 pt)


$$\text{Gain}(S11, \text{« Lieu »}) = \text{Entropie}(S11) - \left(\frac{4}{7} * \text{Entropie}(S11_{\text{Maison}}) + \frac{3}{7} * \text{Entropie}(S11_{\text{Travail}})\right)$$

$$\text{Gain}(S11, \text{« Lieu »}) = 0.29$$

(0.5 pt)

On voit que le gain d'entropie est le même pour les attributs « Date » et « Lieu ». Donc, on peut choisir l'un comme l'autre comme test au niveau du nœud 11.

Voici l'arbre partiel obtenu, si on choisit l'attribut « Date » :



(0.5 pt)

Calcul de l'entropie au niveau du nœud 21 : Soit S21 l'ensemble des données correspondant au nœud 21.

Entropie(S21) = 1

(0.5 pt)

Calcul du gain d'entropie :

$\text{Gain}(S21, \text{« Taille »}) = \text{Entropie}(S21) - \left(\frac{2}{4} * \text{Entropie}(S21_Court) + \frac{2}{4} * \text{Entropie}(S21_Long)\right)$

$\text{Gain}(S21, \text{« Taille »}) = 0$ (0.5 pt)

$\text{Gain}(S21, \text{« Lieu »}) = \text{Entropie}(S21) - \left(\frac{2}{4} * \text{Entropie}(S21_Maison) + \frac{2}{4} * \text{Entropie}(S21_Travail)\right)$

$\text{Gain}(S21, \text{« Lieu »}) = 1$ (0.5 pt)


Le gain d'entropie est le plus élevé pour l'attribut « Lieu ». Cet attribut sera choisi comme test au niveau du nœud 21.

2/ Dessinez l'arbre de décision obtenu.

Réponse :


**Il y'a deux arbres possibles (en fonction du choix de l'attribut de test fait au nœud 11).
Le candidat pouvait donner l'un des deux.**

1ère variante :



(1 pt)

2ème variante :



(1 pt)

3/ Comment évaluer la performance de l'arbre obtenu ?. Faites cette évaluation.

Réponse :

Pour évaluer la performance du modèle (arbre de décision) produit, on le teste sur chacun des éléments de l'ensemble d'apprentissage que l'on utilise comme ensemble de test. On vérifie si la classe calculée par le modèle correspond bien à la classe déclarée dans l'ensemble.

(1 pt)

Evaluation :

N°	Classe réelle	Classe calculée	Observation
01	Non	Non	Correct
02	Oui	Oui	Correct
03	Non	Non	Correct
04	Oui	Oui	Correct
05	Non	Non	Correct
06	Oui	Oui	Correct
07	Non	Non	Correct
08	Oui	Oui	Correct
09	Non	Non	Correct
10	Oui	Oui	Correct
11	Non	Non	Correct

La précision du modèle est donc de 100%

(1 pts)

4/ Donnez tous les cas possibles qui n'appartiennent pas à l'ensemble d'apprentissage. Utilisez l'arbre obtenu pour prédire la classe de chacun de ces cas.

Réponse :

N°	Auteur	Date	Taille	Lieu	Classe calculée
12	Connu	Nouveau	Long	Travail	Oui
13	Inconnu	Nouveau	Long	Maison	Non
14	Inconnu	Ancien	Long	Travail	Non
15	Inconnu	Nouveau	Long	Travail	Non
16	Inconnu	Nouveau	Court	Maison	Non

(2 pts)