

Business intelligence

Chp3: Entrepôt de données (Data Warehouse)

DR. OLFA DRIDI


olfa.dridi@gmail.com

- ▶ Introduction
- ▶ Architecture de l'ID
- ▶ Présentation des différents composants
 - ▶ OLTP
 - ▶ ETL
 - ▶ Data Warehouse et Data mart
 - ▶ OLAP
- ▶ Modélisation dimensionnelle

Introduction: Données de l'entreprise

3

- ▶ Les données de l'entreprise sont stockées dans des systèmes transactionnels qui enregistrent les données quotidiennes.
- ▶ Différentes sources de données :
 - ▶ Fichiers Excel....
 - ▶ ERPs
 - ▶ Systèmes de CRMs
 - ▶ Capteurs
- ▶ Et aujourd'hui :
 - ▶ Données du Web
 - ▶ Twitter ...



Introduction: Difficultés

4


- ▶ Sources diverses et disparates ;
- ▶ Sources sur différentes plateformes et OS ;
- ▶ Applications legacy utilisant des BDs et autres technologies obsolètes ;
- ▶ Historique de changement non-préservé dans les sources ;
- ▶ Qualité de données douteuse et changeante dans le temps ;
- ▶ Structure des systèmes sources changeante dans le temps ;
- ▶ Incohérence entre les différentes sources ;
- ▶ Données dans un format difficilement interprétable ou ambigu.

► Stockage de données : Data Warehouse

- Base de données unique - vocabulaire unique
- Contenu adapté aux besoins des décideurs
 - Structure multidimensionnelle spéciale
 - Niveau de détail bien étudié
 - Données historiques

► Interrogation des données:

- Outil interactif, convivial
- Outil offrant des fonctions d'analyse
 - Tri des données
 - Calcul et comparaison
 - Analyse des tendances, relations et excé
 - Simulation




- ▶ « Un entrepôt de données est une collection de données orientées sujet, intégrées, non volatiles et historiées, organisées pour le support d'un processus d'aide à la décision »
- ▶ « Un entrepôt de données ne s'achète pas, il se construit... »

(B. Inmon) - 1994

L'architecture classique de l'ID

7



Fonction d'un SID

8

- ▶ Fonction de collecte de données
 - ▶ Fonction d'intégration
 - ▶ Fonction de diffusion (ou distribution)
 - ▶ Fonction présentation
-

Architecture d'un entrepôt de données

9

Sources de données

ERP / CRM

Legacy

POS

OLT / Web

Externes

Processus ETL

Sélection

Extraction

Transformation

Intégration

Chargement

Entrepôt de données

Méta-données

Accès

Datamart

Datacube

API / Intergiciels


Applications (visualisations)

Rapports de routine

Forage de données / textes

OLAP, tableaux de bord

Autres



Éléments importants d'un SID

10

- ▶ Préparation des données
- ▶ Processus ETL :
 1. Extract
 2. Transform
 3. Load
- ▶ Présentation des données
 - ▶ Tableaux de bords
 - ▶ Cube OLAP
- ▶ Modélisation des données
 - ▶ Schéma en étoile ou en flocons
 - ▶ Dénormalisation des tables

- ▶ Première étape dans l'acheminement des données
- ▶ Zone de stockage
- ▶ Ensemble de processus : ETL
 - ▶ Extraction (Extract)
 - ▶ Transformation (Transform)
 - ▶ Chargement (Load)
- ▶ Entre les applications opérationnels source et les outils de présentation des données et des résultats
- ▶ Zone interdite à tout utilisateur

OLTP (On Line Transaction Processing)

12

- ▶ OLTP est le modèle utilisé par les SGBD. Son mode d'exploitation est transactionnel.
- ▶ L'objectif est de pouvoir insérer, modifier et interroger rapidement les données et en sécurité de la base de données. Ainsi, OLTP est caractérisé par un grand nombre de transactions de type INSERT, UPDATE, DELETE.
- ▶ L'accent est mis sur le traitement des requêtes très rapides, le maintien de l'intégrité des données dans des environnements multi-accès et une efficacité mesurée par le nombre de transactions par seconde.
- ▶ Dans les bases de données OLTP, il existe des données détaillées et à jour, et le schéma utilisé pour stocker les bases de données transactionnelles est le modèle entité. Chaque transaction travaille sur de faibles quantités d'informations, et en général sur les versions les plus récentes des données.

- ▶ La fonction collecte (parfois appelée **datapumping**) recouvre l'ensemble des tâches consistant à détecter, sélectionner, extraire et filtrer les données brutes issues des environnements pertinents compte tenu du périmètre couvert par le SID.
- ▶ Plusieurs **types de sources** de données:
 - ▶ fichiers plats, fichiers Excel, base de données (DB2, Oracle, SQL Server, etc.), services web, données massives
- ▶ Plusieurs **natures** d'informations:
 - ▶ Données quantitatives, texte, image, flux, ...
 - ▶ Flux de données
 - ▶ Données bruitées, données fausses

- ▶ La fonction d'intégration consiste à concentrer les données collectées dans un espace unifié, dont le socle informatique essentiel est l'entrepôt de données (**Data warehouse**).
- ▶ Cela inclut :
 - ▶ Le nettoyage et filtrage des données
 - ▶ La validation des données
 - ▶ La synchronisation
 - ▶ La certification

- ▶ L'intégration de données appelé ETL (**Extraction Transfer Loading**) regroupe les processus par lesquels les données provenant de différentes parties du système d'information sont déplacées, combinées et consolidées. Ces processus consistent habituellement à extraire des données de différentes sources (bases de données, fichiers, applications, Services Web, emails, etc.), à leur appliquer des transformations (jointures, lookups, déduplication, calculs, etc.), et à envoyer les données résultantes vers les systèmes cibles.
- ▶ Il existe plusieurs système d'intégration de données :
 - ▶ La médiation au service de l'intégration de données d'entreprise (EII).
 - ▶ L'intégration de données via les applications (EAI).
 - ▶ L'intégration de données via les services Web (ESB, SOA).
 - ▶ L'intégration de données en nuage (Data Cloud)

- ▶ La médiation au service de l'intégration de données d'entreprise (EI):
 - ▶ Enterprise Information Integration (EI) est une approche d'architecture (voire d'urbanisme) permettant d'obtenir une vue unifiée des données informatiques de l'entreprise.
- ▶ L'intégration de données via les applications (EAI):
 - ▶ L'intégration d'applications d'entreprise est une architecture intergicielle permettant à des applications hétérogènes de gérer leurs échanges. On la place dans la catégorie des technologies informatiques d'intégration métier (Business Integration) et d'urbanisation. Sa particularité est d'échanger les données en pseudo temps réel.
- ▶ L'ETL (Extract - Transform - Load)

- ▶ La fonction de collecte s'appuie habituellement sur des outils **d'ELT** (**Extract, Transform, Load**)
- ▶ Processus :
 - ▶ **Extract** : Extraire les données de sources hétérogènes
 - ▶ **Transform** : Transformation des données pour les stocker dans un data warehouse
 - ▶ **Load** : Chargement des données dans le data warehouse
- ▶ Les logiciels d'ETL sont des intergiciels = des logiciels dont le but est de faire passer des données entre plusieurs logiciels.

- ▶ Extract : Lecture des données
 - ▶ Hétérogénéité des sources
 - ▶ Accès aux différentes applications
 - ▶ Bases de données réparties sur différents sites et différents SGBD
- ▶ Transform : Interprétation des données
 - ▶ Connaissance des schémas de toutes les bases
 - ▶ Ouverture à de nombreux SGBD
 - ▶ Filtrage parfois nécessaire
- ▶ Load : Placement dans la zone de transformation
 - ▶ Réservation d'un espace mémoire temporel dédié

- ▶ Rafraichissement régulier des données (tous les mois, toutes les semaines, . . .)
- ▶ N'extraire que les données nouvelles dans les bases de
- ▶ données sources
- ▶ Marquage des données par la date de dernière modification
- ▶ Utilisation d'un journal des transactions
- ▶ Extensibilité de l'outil d'extraction
- ▶ Intégrité du système à garantir (en cas de problème, panne, . . .)


- ▶ Nettoyage
 - ▶ Correction orthographique
 - ▶ Résolution de conflits de domaine
 - ▶ Traitement du problème des éléments manquants
 - ▶ Conversion à des formats standard
- ▶ Combinaison à partir de multiples sources
- ▶ Dédoublage (si nécessaire) et création de clés primaires spécifiques
- ▶ Aide à la découverte de données incohérentes
- ▶ Tris, traitements séquentiels, synchronisation des clés, .
..

- ▶ Non basée sur l'algèbre relationnelle, peut travailler sur des fichiers à plats
- ▶ Modélisation en troisième forme normale ou modélisation dimensionnelle
- ▶ Conformité aux règles de références classiques à garantir
- ▶ Modélisation dimensionnelle à privilégier (simplification, rapidité, économie de temps)

Transformation


22

Intégration des données



- Existence de plusieurs sources
 - Non conformité des représentations

- Découpages géographiques différents



- Codage des couleurs



- Identification des produits différents


- Difficulté de comparaison des sources de données
- Mise en conformité nécessaire

Chargement des données (Loading)

24


- ▶ Transfert des données vers les magasins de données
- ▶ Création des tables dimensionnelles et de faits
- ▶ Indexation des données pour optimiser les requêtes futures
- ▶ Avertissement des utilisateurs de la mise à jour du magasin de données
- ▶ Précision sur les changements éventuels dans les dimensions et dans les faits

- ▶ Plusieurs logiciels sont disponibles sur le marché. Ils permettent d'effectuer de l'ETL sous forme de programmes "graphiques". Ils sont intégrés dans des suites de BI.
 - ▶ Anatella2
 - ▶ DataStudio (Data)
 - ▶ Feature Manipulation Engine (FME)
 - ▶ Hurence avec un ETL natif Hadoop
 - ▶ IBM InfoSphere DataStage
 - ▶ Informatica PowerCenter
 - ▶ MapReport
 - ▶ Microsoft SQL Server Integration Services (SSIS) OpenText Genio
- ▶ Oracle Data Integrator (Sunopsis)
- ▶ Oxio Data Intelligence solution ETL
- ▶ SAP Data Services
- ▶ SAS Data Integration Studio
- ▶ Stambia
- ▶ STATISTICA ETL (StatSoft)
- ▶ SynchroDB
- ▶ Talend



- ▶ Données de production :
 - ▶ SGBD et supports physiques hétérogènes
 - ▶ Qualité inégale des données
 - ▶ Représentations hétérogènes

- Objectif d'obtention de données :
 - centralisées
 - fiables
 - interprétables



► TRANSFORMATION

- Filtrer
- Trier
- Homogénéiser
- Nettoyer
- ...
- Chargement (Loading)

Définition d'un entrepôt de données

28

- ▶ A data warehouse is a subject-oriented, integrated, nonvolatile, and time-variant collection of data in support of management's decisions. The data warehouse contains granular corporate data.

(Inmon, 2002, p31)

Définition d'un entrepôt de données

29

Définition de Inmon (1992) :

« une **collection** de **données thématiques, intégrées, non volatiles** et **historiées, organisées** pour le support d'un processus d'aide à la décision»

► Données :

- **thématiques** : données pertinentes pour un **sujet** ou **thème** et nécessaire aux **besoins d'analyse**
- **intégrées** : données résultant de **l'intégration de données** provenant de **différentes sources** pouvant être **hétérogènes**
- **historiées** : données représentent **l'activité d'une entreprise durant une certaine période** (plusieurs années)
- **non-volatiles** : données **essentiellement utilisées en interrogation** (consultation) et ne peuvent pas être modifiées

Définition d'un entrepôt de données

30

- ▶ Un entrepôt de données (ED) est une base de données construite par copie et réorganisation de multiples sources (dont principalement le système transactionnel de l'entreprise), afin de servir de source de données à des applications décisionnelles :
 - ▶ il agrège de nombreuses données de l'entreprise (intégration) ;
 - ▶ il mémorise les données dans le temps (historisation) ;
 - ▶ il les organise pour faciliter les requêtes de prise de décision (optimisation).

(Goglin, 2001, p27)

- ▶ **Orientés sujet:**
 - ▶ Les données sont organisées par sujet (ex: clients, produits, ventes, etc.).
- ▶ **Intégrés:**
 - ▶ Les données, qui proviennent de diverses sources hétérogènes, sont consolidées et intégrées dans l'entrepôt.
- ▶ **Historiques (données datées) :**
 - ▶ Les données ont très souvent une composante temporelle (ex: date et heure d'une transaction).
- ▶ **Non-volatiles:**
 - ▶ Une fois insérées dans l'entrepôt, les données ne sont jamais modifiées ou effacées; elle sont conservées pour des analyses futures.


- ▶ L'objectif du data warehouse est de permettre des requêtes sur de grands ensembles des données, la plupart du temps sous forme d'agrégats (**GROUP BY**) afin d'en obtenir une vision synthétique (propre à la prise de décision).
- ▶ Le data warehouse dédié au décisionnel est séparé du système transactionnel dédié à la gestion quotidienne.
- ▶ Un est uniquement destiné à l'exécution de **questions** statistiques sur des données statiques (ou faiblement dynamiques).

Objectif d'un DW

33


► Objectif

- Retrouver une information historique et transversale à l'entreprise



► Comment

- Fédérer/Regrouper l'ensemble des données de l'entreprise



- ▶ Les deux problématiques fondamentales des DW sont **l'optimisation** et la **simplification** : comment rester performant et lisible avec de très gros volumes de données et des requêtes portant sur de nombreuses tables (impliquant beaucoup de jointures) ?
- ▶ On utilise massivement :
 - ▶ Les vues concrètes : Un data warehouse procède par copie depuis le ou les systèmes transactionnels.
 - ▶ La dénormalisation : Un data warehouse est hautement redondant.

- ▶ La fonction de diffusion met les données à la disposition des utilisateurs, selon des schémas correspondant aux profils ou aux métiers de chacun, sachant que l'accès direct à l'entrepôt de données ne correspond généralement pas aux besoins spécifiques d'un décideur ou d'un analyste.
- ▶ La diffusion est souvent multi-dimensionnelle ⇒ Hypercube ⇒ OLAP

- ▶ Partie du SID vue par les utilisateurs
- ▶ Données présentées, stockées et consultées sous forme de schémas dimensionnels
- ▶ Modélisation dimensionnelle
- ▶ Pour la présentation, on utilise
 - ▶ Des tableaux (une mesure d'une dimension représentés par rapport à deux autres dimensions)
 - ▶ Des cubes (ajout d'une dimension)
 - ▶ Des hypercubes (nombre de dimension supérieure à 3 – on parle alors de cube OLAP)

OLAP (On Line Analytical Processing)


37

- ▶ OLAP est caractérisé par un volume relativement petit de transactions, mais sur un volume très important de données. Les requêtes sont très complexes et impliquent de nombreuses agrégations.
- ▶ Pour les systèmes OLAP, la donnée temps de réponse n'est pas très importante. Ce système travaille en lecture seulement. Les programmes consultent d'importantes quantités de données pour procéder à des analyses.
- ▶ Les objectifs principaux sont : regrouper, organiser les informations provenant des sources diverses, les intégrer et les stocker pour donner à l'utilisateur une vue orientée métier, retrouver et analyser l'information facilement et rapidement. Cela nécessite de consulter des versions historisées de la base et peut se permettre d'ignorer temporairement les dernières mises à jour. Ces bases sont souvent d'un ordre de grandeur nettement supérieur à celles des bases OLTP, du fait de la conservation de l'historique.

OLAP (On Line Analytical Processing)

38

- ▶ OLAP est une approche d'analyse multi-dimensionnelle des données. Elle est basée sur le concept d'hypercube
- ▶ Une Hypercube (ou cube OLAP) est un tableau multi-dimensionnel de données - une feuille excel mais avec plus de dimensions....



- ▶ **Rotate** : sélection du couple de dimensions à cibler, Slicing : extraction d'une tranche d'information,
- ▶ **Scoping** : extraction d'un bloc de données (opération plus générale que le slicing),
- ▶ **Drill-up** : synthèse des informations en fonction d'une dimension (exemple de drill-up sur l'axe temps : passer de la présentation de l'information jour par jour sur une année, à une valeur synthétique pour l'année),
- ▶ **Drill-down** : c'est l'équivalent d'un « zoom », opération inverse du drill-up,
- ▶ **Drill-through** : lorsqu'on ne dispose que de données agrégées (indicateurs totalisés), le drill-through permet d'accéder au détail élémentaire des informations (voir notamment les outils H-OLAP).

- ▶ Visualisation
- ▶ Reporting

BI moderne : D'autres fonctions :


- ▶ Predictive Analysis : Machine Learning / Data Mining / ...
- ▶ Real-time business intelligence (RTBI)
- ▶ Social BI
- ▶

- ▶ Applications surement la plus utilisée de l'informatique décisionnelle, les tableaux de bords permettent de :
 - ▶ Sélectionner des données relatives à telle période, telle maladie, tel type de patient, . . .
 - ▶ Trier, regrouper ou répartir ces données selon certains critères
- ▶ Réaliser divers calculs (totaux, moyennes, écarts, comparatif d'une période à l'autre, . . .)
- ▶ Présenter les résultats d'une manière synthétique ou détaillée, le plus souvent graphique selon leurs besoins ou les attentes des utilisateurs

DW vs Data mart

43

- Un data warehouse et un data mart se distinguent par le spectre qu'il recouvre :
 - Le data warehouse recouvre l'ensemble des données et problématiques d'analyse visées par l'entreprise.
 - Le data mart recouvre une partie des données et problématiques liées à un métier ou un sujet d'analyse en particulier
-
- Un data mart est fréquemment un sous-ensemble du data warehouse de l'entreprise, obtenu par extraction et agrégation des données de celui-ci.



OLTP vs OLAP

44

OLTP	OLAP
• Informatique opérationnelle • Opérations journalières • Orienté applications • Usage répétitif • Requête simple, courte • Sur peu de données • Beaucoup d'utilisateurs	• Informatique décisionnelle • Support décisionnel • Orienté sujet • Usage occasionnel • Requête complexe • Sur des millions de données • Très peu d'utilisateurs

	Bases de Production (OLTP)	Entrepôt de Données (DW)
Données	▪atomiques ▪orienté application ▪à jour ▪dynamiques	▪résumés ▪orienté sujet ▪historiques ▪statiques
Utilisateurs	▪employés de bureau ▪nombreux ▪concurrents ▪mises à jour ▪requêtes prédéfinies ▪réponses immédiates ▪accès à peu de données	▪analystes ▪peu ▪non concurrents ▪interrogations ▪requêtes " one-use" ▪réponses moins rapides ▪accès à beaucoup d'information

Découverte des données

46

- ▶ Opération triviale mais absolument nécessaire
 - ▶ Outils de structuration des données
 - ▶ Évaluation de la qualité des données sources
 - ▶ Utilisation de méthodes statistiques et de fouille de données
 - ▶ Vigilance et précision
-



Architecture d'un entrepôt de données

47


Sources de données



Processus ETL




Accès



Applications (visualisations)



- ▶ Informations de l'environnement qui ne proviennent pas des données elles-mêmes
- ▶ Utiles dans toutes les étapes
- ▶ Quelques exemples
 - ▶ Schémas des bases de données source
 - ▶ Définitions des faits
 - ▶ Définitions des agrégats
 - ▶ Planning des opérations ETL
 - ▶ Organisation de l'entrepôt de données
 - ▶ Paramétrage de sécurité
 - ▶ ...



- Un DataMart (littéralement en anglais magasin de données) est un sous-ensemble d'un Data Warehouse destiné à fournir des données aux utilisateurs, et souvent spécialisé vers un groupe ou un type d'affaire.
-

Caractéristique	Base de données de production	Data warehouses	Datamarts
Opération	gestion courante, production	référentiel, analyse ponctuelle	analyse récurrente, outil de pilotage, support à la décision
Modèle de données	entité/relation	3NF, étoile, flocon de neige	étoile, flocon de neige
Normalisation	fréquente	maximum	rare (redondance d'information)
Données	actuelles, brutes, détaillées	historisées, détaillées	historisées, agrégées
Mise à jour	immédiate, temps réel	souvent différée, périodique	souvent différée, périodique
Niveau de consolidation	faible	faible	élevé
Perception	verticale	transverse	horizontale
Opérations	lectures, insertions, mises à jour, suppressions	lectures, insertions, mises à jour	lectures, insertions, mises à jour, suppressions
Taille	en gigaoctets	en téraoctets	en gigaoctets

Modélisation dimensionnelle

- ▶ Modélisation dimensionnelle (introduit par Kimball en 1996)
- ▶ Deux nouveaux concepts
 - ▶ Faits : mesures définies à partir des données
 - ▶ Dimensions : axes d'intérêts
- ▶ Étapes de la modélisation
 1. Choix du processus à modéliser
 2. Définition de la granularité du processus
 3. Choix des dimensions
 4. Identification des faits
- ▶ Différents schémas possible

1. Analyse des données
 - a. Étude des sources de données (quantification, analyses générales)
 - b. Qualification des données (qualité et intérêt)
 - c. Intégration logique des données (simulation d'un schéma relationnel virtuel)
 - d. Normalisation du schéma virtuel en 3NF pour en avoir une vue cohérente
2. Analyse des besoins clients
 - a. Exprimer les besoins sous la forme de requêtes décisionnelles
 - b. Réaliser les vues hiérarchiques pour chaque requête
3. Sélectionner les requêtes qui seront effectivement réalisables en fonction des données disponibles
4. Conception du data warehouse et des data marts
 - a. Séparer les requêtes en fonction de la granularité de la table des faits (grain fin des ventes, grain plus grossier du ticket de caisse, etc.)
 - b. Créer un data warehouse intégrant toutes les requêtes de grain fin
 - c. Extraire un data mart par niveau de grain supérieur et/ou pour des thématiques particulières nécessitant par exemple une pré-agrégation

1. Choix du processus à modéliser
 - ▶ Activité de l'organisation
 - ▶ Écoute des utilisateurs
 - ▶ Pas attacher à un service ou à une fonction
2. Définition de la granularité du processus
 - ▶ Niveau de détails des mesures d'une ligne de la table de faits
 - ▶ Étape critique et obligatoire
3. Choix des dimensions
 - ▶ Caractéristiques de la table des faits
4. Identification des faits
 - ▶ Mesures à mettre dans la table de faits
 - ▶ Au niveau de granularité de l'étape 2

- ▶ Les dimensions sont le noyau des BD multidimensionnelles
- ▶ Les dimensions sont utilisées pour:
 - ▶ La sélection des données
 - ▶ Groupement des données à un niveau de détail
- ▶ Chaque dimension est composée des « Valeurs de la dimensions »
- ▶ Les dimensions fournissent le contexte des faits (qui, quoi, quand, où, pourquoi et comment)

- ▶ Une dimension peut être définie comme :
 - ▶ Un thème, ou un axe (attributs), selon lequel les données seront analysées
 - ▶ Ex : Temps, Découpage administratif, Produits
- ▶ Une dimension contient des membres organisés en hiérarchie :
 - ▶ Chacun des membres appartient à un niveau hiérarchique (ou niveau de granularité) particulier
 - ▶ Ex : pour la dimension Temps: année – semestre – mois – jour

- ▶ Les dimensions sont composées d'un niveau de hiérarchie
 - ▶ Typiquement 3-5 niveaux de détails
 - ▶ Produit: Produit -> Type ->Catégorie
 - ▶ Magasin: Magasin -> Zone -> Ville -> Pays
 - ▶ Temps: jour -> Mois -> Trimestre -> Année
 - ▶ Les valeurs de dimensions sont organisées selon une structure arborescente (hiérarchie)
- ▶ Chaque dimension a un niveau bas et un niveau haut
- ▶ Hiérarchie
 - ▶ Décomposition d'une dimension en arborescence de niveaux
- ▶ Un niveau peut avoir des attributs
 - ▶ Simple et non hiérarchique, exemple : Jour – jour ouvrable
- ▶ Un attribut
 - ▶ Caractéristique d'un niveau d'une hiérarchie (ex : prix d'un article)
- ▶ □ Agrégat

- ▶ Une mesure est un élément de donnée sur lequel portent les analyses, en fonction des différentes dimensions
 - ▶ Ex. coût des travaux, nombre d'accidents, ventes, dépenses
-

- ▶ Un fait représente la valeur d'une mesure, mesurée ou calculée, selon un membre de chacune des dimensions (ex. ce qui est recueilli par les systèmes transactionnels).
 - ▶ Ex. « le coût des travaux en 1995 pour la région 02 est 250 000 \$ » est un fait qui exprime la valeur de la mesure « coût des travaux » pour le membre « 1995 » du niveau « année » de la dimension « temps » et le membre « 02 » du niveau « région » de la dimension « découpage administratif ».
- Tables des faits : comme son nom l'indique, contient les faits

- ▶ Un fait représente un sujet qu'on souhaite analyser
 - ▶ Ce qui est important pour les affaires de l'entreprise et devrait être analysé
 - ▶ Un fait est identifié via les valeurs de ses dimensions
 - ▶ Un fait ne peut pas être une cellule vide
 - ▶ Généralement, un fait devrait être
 - ▶ Attaché à exactement une valeur de chaque dimension
-

La table de faits

62

- ▶ Les mesures sont stockées dans les tables de faits
 - ▶ Table de fait contient les valeurs des mesures et les clés vers les tables de dimensions
-

► **Mesure**


- Dépendent d'un événement d'affaires (le sujet);
- Ont souvent des valeurs continues (ou un grand nombre de valeurs discrètes possibles);
- Servent dans le calcul d'indicateurs de performance;
- Ex: montant total et quantité d'une commande.

► **Attribut**

- Indépendants des événements d'affaires;
- Ont souvent des valeurs discrètes;
- Servent à filtrer ou étiqueter les faits;
- Ex: jour et heure d'une transaction, âge d'un client, etc.

Exemple

64





MODÉLISATION CONCEPTUELLE D'UN DATA WAREHOUSE

► Schéma en étoile



► Schéma en flocons de neige




► Schéma en constellation de faits



- ▶ Une (ou plusieurs) table(s) de faits comprenant une ou plusieurs mesures.
- ▶ Plusieurs tables de dimension dénormalisées: descripteurs des dimensions.
- ▶ Les tables de dimension n'ont pas de lien entre elles
- ▶ Avantages :
 - ▶ Facilité de navigation
 - ▶ Performances : nombre de jointures limité ; gestion des données creuses.
 - ▶ Gestion des agrégats
- ▶ Inconvénients :
 - ▶ Toutes les dimensions ne concernent pas les mesures
 - ▶ Redondances dans les dimensions
 - ▶ Alimentation complexe.


Le modèle en étoile

68



Le modèle en étoile : Exemple

69



Le modèle en étoile : Exemple

70

Product

<u>Product _Code</u>	Description	Color	Size
100	Sweater	Blue	40
110	Shoes	Brown	10 1/2
125	Gloves	Tan	M
...			

Period

<u>Period _Code</u>	Year	Quarter	Month
001	1999	1	4
002	1999	1	5
003	1999	1	6
...			

Sales


<u>Product _Code</u>	<u>Period _Code</u>	<u>Store _Code</u>	Units _Sold	Dollars _Sold	Dollars _Cost
110	002	S1	30	1500	1200
125	003	S2	50	1000	600
100	001	S1	40	1600	1000
110	002	S3	40	2000	1200
100	003	S2	30	1200	750
...					

Store

<u>Store _Code</u>	<u>Store _Name</u>	City	Telephone	Manager
S1	Jan's	San Antonio	683-192-1400	Burgess
S2	Bill's	Portland	943-601-2135	Thomas
S3	Ed's	Boulder	417-196-8037	Perry
...				


Le modèle en étoile : Exemple

71



Le modèle en étoile : Exemple

72



Service	Traumatisme	Mois	Nb de patients	Durée de séjour
Urgence	Fracture pied	Avril	557	1809
Urgence	Fracture pied	Mai	619	2157
Urgence	Fracture bras	Avril	428	570
Urgence	Fracture bras	Mai	320	446
Traumatologie	Fracture pied	Avril	119	390
.	.	.	.	.
.	.	.	.	.
.	.	.	.	.

Le modèle en flocons


73

- ▶ Le schéma en flocon est dérivé du schéma en étoile où les tables de dimensions sont normalisées (la table des faits reste inchangée).
- ▶ Avec ce schéma, chacune des dimensions est décomposée selon sa (ou ses) hiérarchie(s).
- ▶ Exemple : Commune, Département, Région, Pays, Continent

Client	Continent	Pays	Region	Département	Commune
PEPONE	E UROPE	FRANCE	RHÔNEALPES	RHÔNE	LYON1
TESTUT	E UROPE	FRANCE	RHÔNEALPES	RHÔNE	LYON2
S OININ	E UROPE	FRANCE	RHÔNEALPES	RHÔNE	LYON3
VEPONT	E UROPE	FRANCE	ILE DE FRANCE	PARIS	PARIS1
MARTIN	E UROPE	FRANCE	ILE DE FRANCE	PARIS	PARIS2
ELVERT	E UROPE	FRANCE	ILE DE FRANCE	YVELINES	VERSAILLES


Le modèle en flocons

74



Le modèle en flocons

75



- ▶ Modèle en étoile + normalisation des dimensions
- ▶ Lorsque les tables sont trop volumineuses
- ▶ Avantages :
 - ▶ Réduction du volume,
- ▶ Inconvénients :
 - ▶ Navigation difficile,
 - ▶ Nombreuses jointures.


Le modèle en constellation

77

- ▶ La modélisation en constellation consiste à fusionner plusieurs modèles en étoile qui utilisent des dimensions communes.
- ▶ Un modèle en constellation comprend donc plusieurs tables de faits et des tables de dimensions communes ou non à ces tables de faits.

Modèle en constellation

78




- ▶ Voici une liste de points importants à prendre en compte pour que le projet du SID soit un succès :
 - ▶ Se concentrer sur les exigences et les objectifs
 - ▶ Obtenir le soutien des responsables du côté utilisateur
 - ▶ Choisir un mode de développement itératif plutôt que global
 - ▶ Prévoir au mieux les coûts de chaque étape (en temps, en homme/jour, en dépenses)
 - ▶ Préférer la commodité d'utilisation et la performance des requêtes plutôt que la facilité de développement
- ▶ Rechercher au maximum des solutions simples
- ▶ Respecter une architecture commune et cohérente
- ▶ Ne pas se limiter à une granularité trop importante
- ▶ Préparer et prendre en compte l'évolution future du système opérationnel et de l'environnement en général
- ▶ S'assurer de l'acceptation du système par les utilisateurs

- ▶ Avancées constantes de la technologie
- ▶ Sécurité et confidentialité
 - ▶ Qui est propriétaire de vos informations personnelles ?
 - ▶ Qui est utilisateur de vos informations personnelles ?
- ▶ Sauvegarde et sûreté du système
 - ▶ Prévenir les destructions physiques
 - ▶ Prévenir le piratage
- ▶ Tendances culturelles et politiques
 - ▶ Management par les chiffres
 - ▶ Utilisation croissante d'indicateurs sophistiqués
 - ▶ Sous-traitance risquée

Exemple de modèle dimensionnel en étoile

81

- L'ETL (Extraction Transformation Loading) est le processus de copie des données depuis les tables des systèmes transactionnels vers les tables du modèle en étoile du data warehouse.



▶ ETL

- ▶ Outil d'ETL de **Talend**

▶ Reporting

- ▶ Outil de reporting **Birt**

▶ Exploration

- ▶ Outil d'exploration de données **JPivot**


▶ Analyse

- ▶ Outil d'analyse statistique **Weka**


Exercice

83

Vue transactionnelle intégrée



Transformation



Datawarehouse

