

Réduction du volume de données : ACP

Plan

I. Introduction

II. Définitions

III. Objectifs

IV. Cas d'utilisation

V. Fonctionnement

VI. Avantages et Limites

VII. Étude de cas et Quiz


VIII. Conclusion

Introduction

Problématique

L'augmentation des dimensions complique l'interprétation et l'analyse des données, entraînant la malédiction de la dimensionnalité.

Défis des données de haute dimension




I. Introduction

Objectif de la réduction de dimensionnalité

Simplifier les données tout en préservant les informations pertinentes, facilitant ainsi la visualisation et le traitement par des algorithmes d'apprentissage automatique.

Objectif de la réduction de dimensionnalité




Méthodes principales

- **Analyse en Composantes Principales (ACP)** : est une technique statistique qui permet de simplifier des jeux de données complexes.
- **Analyse Factorielle des Correspondances (AFC)** : Adaptée aux tableaux de contingence croisant des variables qualitatives.
- **Analyse des Correspondances Multiples (ACM)** : Extension de l'AFC pour décrire des tableaux avec plusieurs variables qualitatives.

I. Introduction


Processus de Réduction de Dimensionnalité





Définitions

II. Définitions



- Constituent le cœur de l'ACP.
- **Vecteurs propres** : déterminent les directions principales (axes) où les données varient le plus.
- **Valeurs propres** : quantifient l'importance de ces directions en mesurant la variance expliquée.
- La décomposition en vecteurs et valeurs propres est essentielle pour transformer les données initiales dans un nouvel espace de dimension réduite.

- Nouvelles variables créées après la transformation.
- Chaque composante principale est une combinaison linéaire des variables d'origine.
- Les composantes principales sont ordonnées selon la quantité de variance qu'elles expliquent.
- L'objectif de l'ACP est de maximiser la variance capturée par chaque composante.

- Représente comment les variables d'origine varient ensemble.
- Identifie les directions où la variance est la plus grande.
- Permet à l'ACP de concentrer l'information dans un plus petit nombre de dimensions.



Objectifs

III. Objectifs

Objectifs de l'ACP



IV

Cas d'utilisation

Dans quel domaine appliquer l'ACP
(Analyse en Composantes
Principales) pour la réduction de
données ?

Traitement d'image
Réduire la taille des images
sans perdre en qualité.



Analyse financière
Identifier les facteurs clés
influençant les prix des
actions.



Segmentation client
Regrouper les clients en
segments en réduisant les
dimensions des variables.

V

Fonctionnement

- Comment trouver les composantes ?
- Analyse en composantes principales, quelles sont les étapes ?

- Comment trouver les composantes ?

- A partir des variables initiales, l'ACP consiste à calculer des nouvelles variables, appelées composantes et qui sont des combinaisons linéaires des variables initiales.
- Ces composantes sont non corrélées et de variance ordonnée, un nombre réduit de ces composantes résume les variables initiales en minimisant la perte d'information due à cette réduction.
- $C_1 = a_{11}X_1 + a_{21}X_2 + \dots + a_{p1}X_p$ on définit la première composante C1 comme une combinaison linéaire des variables centrées réduites $X_1, X_2, \dots, X_p$:
- Telle que la variance de C1 soit maximale. La deuxième composante C2 est aussi une combinaison linéaire des mêmes variables : $C_2 = a_{12}X_1 + a_{22}X_2 + \dots + a_{p2}X_p$
- Telle que C2 est non corrélée avec C1 corrélation $(C_1, C_2) = 0$, et C2 possède la variance maximale parmi toutes les combinaisons linéaires qui ne sont pas corrélées avec C1 etc.

- Comment trouver les composantes ?
 - On démontre que les variances correspondant aux composantes sont les valeurs propres positifs de la matrice de corrélation et les vecteurs propres correspondants fournissent les coefficients à être attribuées aux variables $X_1, X_2, \dots, X_p$ pour constituer ces combinaisons linéaires appelées composantes.
 - Les composantes sont toujours de moyennes nulles et de variances égales aux valeurs propres ordonnés : $\lambda_1 > \lambda_2 > \dots \lambda_p > 0$.


- Comment trouver les composantes ?

Les composantes ainsi calculées possèdent un certain nombre de propriétés :

1. $V(C_i) = \lambda_i$: c'est la variance de la nième composante principale, C_i est la n-ième valeur propre de la matrice de corrélation R . C'est pour cette raison que l'on peut dire des composantes C_i qu'elles sont à variance ordonnée : $\lambda_1 > \lambda_2 > \dots \lambda_p > 0$
2. $\text{Corrélation}(C_i, C_j) = 0, i \neq j$, c'est-à-dire les composantes sont non corrélées, les vecteurs propres sont orthogonaux.
3. la valeur propre exprimée en pourcentage λ_i/p indique le pourcentage de la variance totale expliquée par la composante C_i .

- Analyse en composantes principales, quelles sont les étapes ?


Étapes de l'analyse en composantes principales



- Choix des composantes

Une autre solution consiste à représenter la contribution à la variance en fonction du nombre de dimensions. Lorsque la contribution à la variance cesse de croître rapidement. Vous pouvez considérer cela comme la dimension intrinsèque du jeu de données.

- Méthode d'Elbow




- Interprétations des axes factoriels

On se base sur les corrélations entre les composantes principales et les variables initiales, ces corrélations peuvent être représentées par un graphique appelé cercle de corrélation:


- On cherche les variables initiales qui sont fortement corrélées avec les axes, ce qui permet de donner une interprétation aux axes.
- Il faut regarder le niveau de corrélation de la variable avec l'axe ainsi que le sens de la corrélation (positive ou négative).

- Cercle de corrélation



VI


Avantages et Limites



Peser les avantages et les inconvénients de l'ACP.

VI. Avantages

Améliorer l'analyse des données avec l'ACP



VI. Avantages

Réalisation d'une Analyse de Données Améliorée

Réduction de la Dimension

Réduire les variables tout en maintenant la variance

Meilleure Visualisation des Données

Améliorer la représentation graphique des données

Élimination de la Redondance

Supprimer les corrélations de données pour l'efficacité

Amélioration des Modèles Prédictifs

Améliorer la performance des modèles et éviter le surapprentissage



Comprendre les limitations de l'ACP

Approche linéaire

Seules les relations linéaires sont efficaces

Sensibilité aux échelles des données

Les résultats dépendent des unités des données



Difficulté d'interprétation

Les nouvelles variables sont difficiles à interpréter

Perte d'information

Certaines données sont inévitablement perdues

VII

Étude de cas



VIII

Quiz

Question 1 : Qu'est-ce qu'une composante principale ?

- A. Une variable initiale du jeu de données.
- B. Une nouvelle variable non corrélée obtenue après transformation des variables initiales.
- C. Une combinaison aléatoire de variables sans explication de variance.
- D. Un vecteur propre utilisé pour la transformation des données.

Réponse : B. Une composante principale est une nouvelle variable non corrélée, obtenue après transformation des variables initiales, expliquant une part de la variance des données.

Question 2 : Dans quels domaines utiliserait-on l'ACP ?

- A. En biologie pour analyser les écosystèmes.
- B. En traitement d'image pour la compression, en marketing pour la segmentation client, ou en finance pour l'analyse des facteurs influençant les actions.
- C. En logistique pour optimiser les routes de livraison.
- D. En médecine pour diagnostiquer les maladies.

Réponse : B. L'ACP est utilisée en traitement d'image pour la compression, en marketing pour la segmentation client, et en finance pour analyser les facteurs influençant les actions.

Question 3 : Pourquoi est-il nécessaire de normaliser les données avant l'ACP ?

- A. Pour que toutes les variables soient sur la même échelle et éviter qu'une variable à grande échelle domine les autres dans le calcul de la variance.
- B. Pour rendre les données plus faciles à lire.
- C. Pour éliminer les valeurs négatives dans le jeu de données.
- D. Parce que la normalisation augmente la précision des calculs.

Réponse : A. La normalisation est nécessaire pour que toutes les variables soient sur la même échelle, afin d'éviter qu'une variable à grande échelle domine les autres dans le calcul de la variance.

Question 4 : Quels sont les avantages de l'ACP pour l'analyse de données ?

- A. Elle réduit le nombre de variables tout en capturant l'essentiel de l'information.
- B. Elle améliore la visualisation des données complexes.
- C. Elle améliore les performances des modèles prédictifs.
- D. Toutes les réponses ci-dessus.

Réponse : E. L'ACP permet la réduction de dimension, l'amélioration de la visualisation, l'élimination de la redondance, et une meilleure performance des modèles prédictifs.

IX

Conclusion



Résumé de l'ACP

L'ACP est une **méthode puissante** pour la **réduction** de dimension qui **transforme** des variables **corrélées** en un ensemble de nouvelles variables **non corrélées**.



Avantages et limites

Bien qu'elle simplifie l'analyse des données, l'ACP peut entraîner une **perte d'information** et poser des **difficultés d'interprétation**.



Ouverture

D'autres méthodes comme le **t-SNE** ou l'Analyse Discriminante Linéaire (**LDA**) peuvent être envisagées lorsque des **relations non linéaires** ou d'autres contraintes sont présentes dans les données.

**Merci de votre
Attention**