

Big Data Mining

Préparé par: Mme. Olfa DRIDI



Objectifs du cours

- Fouille de données massives :
 - Faire comprendre les approches de passage à l'échelle
 - Présenter les méthodes de résolution de certains problèmes fréquents
 - Familiariser avec des logiciels permettant l'exécution distribuée
 - Faire appliquer ces méthodes sur des données réelles
 - Systèmes de recherche d'information
 - Systèmes de recommandation
- ⇒ Capacité à mettre œuvre, sur des données massives, des techniques de fouille de données et de visualisation

Contenu du cours

1. Introduction
 1. Data mining
 2. Big data
2. Approches du passage à l'échelle
 1. Réduction de la complexité
3. Fouille de textes:
 1. Filtrage
 2. Représentation
4. Fouille du Web: Fouille de graphes et réseaux sociaux
5. Systèmes de recherche d'information
 1. Définition
 2. Principe de fonctionnement
 3. Évaluation
6. Systèmes de recommandation
 1. Définition
 2. Principe

Séances de TP

- **TP n°1** (1 séance):
 - Manipulation de données avec Pandas
- **TP n°2** (1 séance) :
 - Introduction à Scikit-Learn
- **TP n°3** (2 séances):
 - Mini-projet:
 - Exploitation de pandas et scikit-learn
 - Cross-validation et GridSearch
- **TP n°4**: (1 séance)
 - Mini-projet: Text mining
 - Analyser un texte
 - Manipuler la bibliothèque nltk
- **TP n°5**: (1 séance)
 - Suite mini-projet: Utilisation de Word2Vec (développement d'un système de RI).

Références bibliographiques

➤ Fouille de données massives

- J. Leskovec, A. Rajaraman, J. Ullman. Mining of Massive Datasets. Cambridge University Press.
<http://www.mmds.org>
- Karau, H., A. Konwinski, P. Wendell et M. Zaharia. Learning Spark - Lightning-Fast Big Data Analysis, O'Reilly, 2015.
- Ryza, S., U. Laserson, S. Owen and J. Wills. Advanced Analytics with Spark - Patterns for Learning from Data at Scale, O'Reilly, 2015.

➤ Visualisation des données

- B. Fry. Visualizing data. O'Reilly, 2008.
- R. Spence. Information Visualization, design for interaction. Prentice Hall, 2007.

➤ sans oublier, entre autres

- C. O'Neil, Weapons of Math Destruction. Crown, 2016.



Introduction

Mise à niveau

Data mining : Définition

- Fouille de données : Ensemble d'approches statistiques permettant d'extraire de l'information de grands jeux de données dans une perspectives d'aide à la décision.
- Data mining : “Process of nontrivial extraction of implicit, previously unknown and potentially useful information (such as knowledge rules, constraints, regularities) from data in databases” (G. Piatetski-Shapiro)

Data mining : à quoi ça sert?

- publicité ciblée sur internet
- identification des prospects les plus susceptibles de devenir clients
- reconnaissance faciale dans une image
- calcul de la rentabilité des clients
- évaluer le risque d'un client (credit scoring)
- détection de fraudes bancaires
- analyse automatique de contenus textuels (text mining)
- reconnaissance de la parole
- prévision de consommation d'électricité
- prévision de trafic routier
- tester l'efficacité d'un traitement médical
- ...

Data mining: les étapes à suivre

1. Nettoyage des données (erreurs, données manquantes, outliers)
2. Transformation éventuelle des données (normalisation, linéarisation...)
3. Explicitation de l'objectif de l'analyse en terme statistique (régression, classification, clustering...)
4. Choix de la méthode à utiliser
5. Mise en œuvre informatique
6. Test (validation de la qualité des résultats)
7. Exploitation

Data mining: panorama des méthodes



Data mining: panorama des méthodes



Clustering_(non supervisée) vs classification_(supervisée)

Clustering

- Z_i inconnue (aucune signification a priori)
- objectif : à partir de l'observation de $\mathbf{X}_1, \dots, \mathbf{X}_n$, prédire $Z_1, \dots, Z_n$
- les classes sont ensuite interprétées dans le but de leur donner une signification concrète

Classification

- Z_i connue (signification connue a priori)
- objectif : à partir de l'observation de $(\mathbf{X}_1, Z_1), \dots, (\mathbf{X}_n, Z_n)$ construire une règle de classement r :


$$r : \mathbf{X} \longrightarrow r(X) = Z$$

- utiliser cette règle de classement pour classer de nouveaux individus de classes inconnues

Les datas


- Savez-vous qu'un moteur à réaction peut générer plus de 10 téraoctets de données pour seulement 30 minutes de vol ? Et combien de vols y a-t-il par jour ? Cela représente plusieurs pétaoctets d'informations chaque jour.
- La Bourse de New York génère environ un téraoctet de nouvelles données de transactions par jour.
- Les téléchargements de photos et de vidéos, les messages et les commentaires sur Facebook créent plus de 500 téraoctets de nouvelles données chaque jour.
- C'est le **Big Data**.

Types de données traitées




source <http://www.kdnuggets.com> 2017

Volume of data




Volume of data



Types of big data

- Les **données structurées** ont un format fixe et sont souvent numériques. Dans la plupart des cas, elles sont traitées par des machines plutôt que par des humains. Ce type de données est constitué d'informations déjà gérées par l'organisation dans des bases de données et des feuilles de calcul stockées dans des bases de données SQL, des data lakes et des data warehouses.
- Les **données non structurées** sont des informations qui ne sont pas organisées et qui n'ont pas de format prédéterminé, car il peut s'agir de quasiment n'importe quoi. Par exemple, elles comprennent les données recueillies à partir des réseaux sociaux et elles peuvent être placées dans des fichiers texte conservés dans des clusters de type Hadoop ou des systèmes NoSQL.
- Les **données semi-structurées** peuvent contenir les deux types de données, comme c'est le cas des journaux de serveur Web ou des données provenant de capteurs que vous avez mis en place. Il s'agit des données qui, bien qu'elles n'aient pas été classées dans un dépôt (base de données) particulier, contiennent des informations essentielles ou des balises séparant les différents éléments au sein des données.


Types of big data



Unstructured Data

Semi-Structured Data


Structured Data



Big data characteristics




Quels sont les grands V du Big Data ?




- **Volume:** le Big Data se compose de **volumes importants** de données. La quantité de données que vous recevez est donc importante. Il peut s'agir de données dont la valeur est inconnue, telles que les données sur le nombre de clics sur une page Web ou une application mobile. Il peut s'agir de quelques dizaines de téraoctets de données pour certaines organisations ou de plusieurs centaines de pétaoctets pour d'autres. Ou peut-être que vous connaissez précisément la source et la valeur des données que vous recevez, mais que les volumes que vous allez recevoir chaque jour sont très importants.
- **Vitesse:** La vitesse est le grand V qui représente la **rapidité de la réception et du traitement** des données. Si les données sont envoyées directement dans la mémoire plutôt qu'écrites sur un disque, la vitesse sera plus élevée et, par conséquent, vous irez beaucoup plus vite et fournirez des données en temps quasi réel. Mais cela nécessitera également des moyens d'évaluer les données en temps réel. La vitesse est aussi le grand V le plus important pour des domaines comme le machine learning et l'intelligence artificielle.

Quels sont les grands V du Big Data ?



- **Variété:** La variété fait référence aux **types de données** disponibles. Lorsque vous travaillez avec autant de données, vous devez savoir que beaucoup d'entre elles sont non structurées et semi-structurées (texte, audio, vidéo, etc.), ce qui exige un traitement supplémentaire des métadonnées pour qu'elles soient compréhensibles pour tout le monde.
- **Véracité:** La véracité fait référence à l'**exactitude des données** dans les ensembles de données. Vous pouvez recueillir beaucoup de données à partir de réseaux sociaux ou de sites Web, mais comment pouvez-vous être sûr qu'elles sont exactes et correctes ? Les données de mauvaise qualité qui ne sont pas vérifiées peuvent causer des problèmes. Les données incertaines peuvent entraîner des analyses inexactes et vous pousser à prendre de mauvaises décisions. Par conséquent, vous devez toujours vérifier vos données et vous assurer que vous disposez de suffisamment de données exactes pour obtenir des résultats valides et significatifs.

Quels sont les grands V du Big Data ?



- **Valeur:** Comme nous l'avons déjà mentionné, certaines des données collectées n'ont pas de valeur et ne peuvent pas être utilisées pour prendre des décisions business. Il est important de connaître la **valeur des données** dont vous disposez. Vous devrez également mettre en place des moyens de nettoyer vos données et de vous assurer qu'elles sont pertinentes pour votre objectif actuel.
- **Variabilité:** Lorsque vous avez beaucoup de données, vous pouvez les utiliser à des **fins multiples** et les formater de différentes façons. Il n'est pas facile de recueillir autant de données, de les analyser et de les gérer correctement. Il est donc normal de les utiliser à plusieurs reprises. La variabilité est la possibilité d'utiliser les données à des fins multiples.

