

Big Data Mining

Préparé par: Mme. Olfa DRIDI



Plan

01 Introduction

Data mining & big data

02 Passage à l'échelle

Réduction de la complexité

03 Text Mining

Fouille de textes

04 Web Mining

Fouille du Web

05 Systèmes de recherche d'information

Définition, principes et évaluation

06 Systèmes de recommandation

Définition et principe

Passage à l'échelle

- La scalabilité est la capacité d'un système à s'adapter à une croissance non bornée de la taille des données (nous parlons de données, et de traitements sur les données, car c'est le sujet du cours).
- Cette croissance, si nous ne lui envisageons pas de limite, finit *toujours* par dépasser les capacités d'une seule machine.

Passage à l'échelle

- Vise notamment la capacité à traiter de très gros volumes de données
- Faible densité d'information $\Rightarrow$ il n'est pas toujours souhaitable d'exclure a priori certaines composantes des données
 - Travailler sur un échantillon trop petit : les « régularités » recherchées ne se manifestent pas suffisamment pour être détectables...
 - Travailler sur un nombre de variables trop faible : les « régularités » sont incomplètes, les capacités prédictives sont insuffisantes...
- Peut concerner d'autres aspects : hétérogénéité, nombre de variables, etc.
- Le terme anglais “Scalability” désigne la capacité d'un algorithme à traiter avec la même efficacité des volumes de données de taille arbitraire. Généralement, le temps d'exécution de tels algorithmes évolue linéairement en fonction de la taille des données en entrée.

Solutions

- **Passage à l'échelle (scalability)**
 - Capacité à faire face à une forte hausse du volume de données
- **Approche : réduction du volume**
 - Échantillonnage
 - Réduction du nombre de caractéristiques des données
 - Limites en cas de faible densité en information
 - Difficulté à détecter des régularités
- **Approche : réduction des calculs**
 - Méthode de calcul locale / voisinage
 - Méthodes approchées et approximation
 - Structure de données, Hachage, Table d'index, ...
- **Approche basée sur les infrastructures**
 - Répartir les traitements et les données (Map-Reduce)

Le passage à l'échelle : approches complémentaires

- Réduction de la complexité (N: volume des données)
 - Sans changer l'ordre de complexité : réduction de dimension, calculs sur échantillon
 - Réduction de l'ordre de complexité : $O(N) \rightarrow O(\log(N))$ ou $O(\text{cst.})$, $O(N^2) \rightarrow O(N \log(N))$
 - Méthodes exactes ou approximatives!
- Parallélisation des calculs
 - Architectures parallèles dédiées
 - Rapport coût / performance très élevé (architectures et technologies dédiées)
 - Goulot d'étranglement entre stockage de masse et unités centrales
 - Distribution des calculs sur un grand nombre d'ordinateurs standard (coût bas), avec
 - Minimisation des échanges avec le stockage de masse, tout en assurant la fiabilité aux pannes
 - Minimisation des échanges de données entre ordinateurs

Problématique

- Comment faciliter l'implémentation d'une grande diversité d'algorithmes sur une plateforme distribuée ?
 - Mécanisme d'exécution composé d'opérations simples et génériques
- Comment réduire la fragilité aux pannes, inévitables pour des calculs longs réalisés sur des plateformes comportant de grands nombres d'ordinateurs ?
 - Mécanisme de **réplication** pour le stockage fiable des données.
 - **Partitionnement** des calculs en « grains » traçables qui peuvent être (ré)affectés à d'autres ordinateurs.



Réduction du volume de données

Méthodes de réduction de la complexité

A- Réduction du volume de données (sans changer l'ordre de complexité)

1. Calculs sur échantillon : N données $\rightarrow$ échantillon de $n \ll N$ données
 2. Réduction de dimension : réduire fortement le nombre de variables tout en conservant au mieux l'« information utile »
- Les résultats sont en général des approximations de ceux obtenus sur les données complètes
 - Difficultés si les données sont à faible densité d'information :
 - Échantillon trop petit : les « régularités » recherchées ne se manifestent pas suffisamment pour être détectables.
 - Réduction trop forte de dimension : les « régularités » sont incomplètes, les capacités prédictives sont insuffisantes.

Méthodes de réduction de la complexité (2)

B- Réduction de l'ordre de complexité (sans diminuer le volume de données)

- Principe : les modèles sont souvent locaux, la décision est locale → les calculs impliquant des données éloignées peuvent être évités
- Plusieurs types de problèmes de modélisation et de décision
- Solutions basées sur l'utilisation d'index multidimensionnels ou métriques
- Méthodes exactes ou approximatives
- Difficultés
 - Malédiction de la dimension (curse of dimensionality) : méthodes inefficaces si les variables sont nombreuses
 - Mise en œuvre efficace sur une plate-forme distribuée
- Possible de combiner plusieurs méthodes, par ex. réduction de l'ordre de complexité après réduction de dimension (diminuer l'impact de la malédiction de la dimension)

Malédiction/ fléau de dimensionnalité

- La malédiction de la dimensionnalité fait référence à tous les problèmes surgissant lors de la manipulation de données dans un espace de grande dimension, ce qui n'est pas le cas dans des espaces de dimensions inférieures.
- A mesure que le nombre de variables prédictives augmente, le nombre d'échantillons augmente proportionnellement afin de collecter le maximum de pattern caché dans l'échantillon et d'avoir une prédiction précise. Cette relation de proportionnalité risque de rendre le modèle complexe, entraînant un surapprentissage (**overfitting**) qui dégrade la performance du modèle.

Calculs sur un échantillon

Méthodes d'échantillonnage

- Méthodes non aléatoires : par quotas, au jugé, volontaires, etc. ; qualité discutable des résultats ; plutôt pour exploration à faible coût
- Méthodes aléatoires :
 1. Échantillonnage simple : tirages sans remise, indépendants, chaque donnée a la même probabilité d'être sélectionnée
 2. Échantillonnage stratifié : l'ensemble de données est constitué de sous-ensembles (strates, par ex. département, tranche d'âge, tranche de revenus...) d'une certaine homogénéité interne par rapport à l'étude ; échantillonnage simple appliqué dans chaque strate
 - Exemple : pour une étude des pratiques des clients du commerce en ligne, partitionnement en tranches de revenus (1 tranche = 1 strate) et échantillonnage simple avec une même p_s appliqué dans chaque tranche ; avec un échantillonnage simple sans strates, plus la population d'une tranche de revenus est faible, plus son taux de présence dans l'échantillon s'éloignerait de p_s
 - Par rapport à l'échantillonnage simple, l'échantillonnage stratifié augmente la précision pour une même valeur de n (ou conserve la précision avec n plus faible)

Méthodes d'échantillonnage (2)

- Méthodes aléatoires (suite) :
 - 3. Échantillonnage en grappes : l'ensemble de données est constitué de sous-ensembles (grappes) présentant une hétérogénéité interne par rapport à l'étude ; on choisit au hasard des « grappes » et on examine tous les individus de chaque grappe sélectionnée
 - Exemple : pour l'étude des pratiques sportives des élèves d'une zone urbaine, choix aléatoire d'un certain nombre de collèges et sondage auprès de tous leurs élèves de troisième (1 collège = 1 grappe)
 - Méthode adéquate si l'hétérogénéité intra-grappe est plus forte que l'hétérogénéité inter-grappes
- L'échantillon doit être de taille assez grande pour que les régularités supposées (qui seront recherchées) y trouvent un support suffisant

Réduction de dimension

- Pourquoi réduire les dimensions dans des problèmes d'apprentissage automatique ?
- La réduction de dimensionnalité est l'ensemble de techniques réduisant le nombre de variables prédictives dans les données d'apprentissage. Ceci peut être effectué après le nettoyage et la normalisation et avant l'entraînement afin de détecter les colonnes capturant l'essence de la donnée.
- L'avantage principal de la réduction de dimensionnalité est d'éviter le surapprentissage. En effet, cette technique réduit le nombre de données trompeuses, les fonctionnalités redondantes et le bruit, ce qui améliore la performance du modèle.
- Un autre avantage est la simplification des hypothèses soulevées par le modèle, facilitant ainsi les traitements et améliorant le temps de calcul.
- D'un point de vue stockage, la réduction de dimensionnalité permet de gagner en espace vu qu'une grosse partie de la donnée est filtrée avant l'entraînement.

Réduction de dimension

Réduction du nombre de variables : Objectifs

- N données dans $\mathbb{R}^m \rightarrow$ N données dans $\mathbb{R}^k$, $k \ll m$
 1. Réduire le volume de données à traiter, tout en conservant au mieux l'information « utile » ← définir ce qu'est information utile
 2. Améliorer le rapport signal / bruit en supprimant des variables non pertinentes ← définir ce qu'est une variable non pertinente
 3. Améliorer la « lisibilité » des données
 - Mettre en évidence des relations entre variables ou groupes de variables
 - Permettre la visualisation ← définir ce qu'il faut mettre en évidence
 4. Répondre à la « malédiction de la dimension » (curse of dimensionality)

Objectifs différents, critères différents → méthodes différentes

Réduction de dimension

Réduction du nombre de variables : Approches

1. Sélection de variables (***Feature selection***)

- Sélection d'un sous-ensemble de k variables parmi les m variables initiales
- Les variables sélectionnées gardent leur signification initiale
- Solution potentiellement sous-optimale car cas particulier de la construction de nouvelles variables

2. Réduction de dimension (***Factorisation matricielle***)

- Modélisation à partir d'un nombre plus faible de variables obtenues par construction de nouvelles variables à partir des variables initiales
- Plus de flexibilité par rapport à la sélection
- Les nouvelles variables sont rarement interprétables

Réduction de dimension

Sélection de variables

- C'est l'approche la plus connue parmi celles de réduction de dimensionnalité, où on utilise des méthodes statistiques ou de notation pour sélectionner les colonnes pertinentes à conserver. Ce filtrage peut aussi être effectué manuellement, en utilisant le contexte. Par exemple, considérons un modèle qui prédit le poids des personnes. Une colonne décrivant la couleur des vêtements n'aide pas à prédire le poids, tandis qu'une colonne décrivant les hauteurs peut être pertinente pour la prédiction.
- On distingue deux classes principales de techniques utilisées en *feature selection*: les méthodes d'encapsulation (*wrapper methods*) et les méthodes de filtrage (*filter methods*).

Réduction de dimension

Sélection de variables

- Les méthodes d'encapsulation enveloppent un modèle d'apprentissage automatique en ajustant et évaluant le modèle avec différents sous-ensembles de variables prédictives. Le sous-ensemble ayant la meilleure performance est ensuite sélectionné. Parmi les méthodes utilisées, on peut citer *RFE (Recursive Feature Elimination)*.
- Les méthodes de filtrage utilisent des méthodes de notation, telles que la corrélation entre la variable prédictive et la variable cible, pour sélectionner le sous-ensemble de variables prédictives ayant la plus forte corrélation. Il existe plusieurs méthodes de filtrage, comme par exemple ***F'ANOVA*** dans le cas des variables continues, ***Chi-Square*** pour les variables catégorielles, et la corrélation de Pearson.

Réduction de dimension

Sélection de variables

■ Approches :

- Méthodes de filtrage : basées sur des critères (par ex. minimisation de la redondance entre variables, maximisation de l'information mutuelle avec la classe à prédire...) qui ne tiennent pas compte du modèle prédictif ultérieur
- *Wrappers* : basées sur des mesures des performances du modèle prédictif qui emploie les variables sélectionnées
- Méthodes intégrées (*embedded*) : l'opération de sélection est indissociable de la méthode d'apprentissage statistique

■ Choisir k variables parmi $m \Rightarrow$ espace de recherche de l'ordre de $C_m^k \rightarrow$ solutions approximatives préférées :

1. Tri des m variables initiales par rapport à un critère de « pertinence » exprimable par variable individuelle, puis sélection des k premières (par ex. *ChiSqSelector* dans Spark : sélection sur la base du test du χ^2)
2. Construction incrémentale de l'ensemble de k variables : à chaque itération on ajoute la variable qui forme le meilleur ensemble avec celles déjà sélectionnées aux itérations précédentes

Réduction de dimension

Factorisation matricielle

- Ce sont des techniques d'algèbre linéaire utilisées pour réduire la dimension. Plus précisément, les méthodes de factorisation matricielles réduisent une matrice de données en ses parties constituantes, comme la composition en valeurs propres ou la décomposition en valeurs singulières.
- Afin de tirer les meilleurs résultats, il est conseillé de normaliser les données avant l'application de ces méthodes de calcul.
- Les méthodes principales de réduction de dimensionnalité en algèbre linéaire sont:
 - PCA (principal component analysis) : l'analyse en composante principale consiste à identifier les principales directions avec des variantes importantes,
 - LDA (linear discriminant analysis) : l'analyse discriminante linéaire identifie les directions décorréélées les unes des autres,
 - SVD (singular value decomposition) : la SVD passe par une décomposition d'une matrice en valeurs singulières.

Réduction de dimension

Factorisation matricielle

- PCA (*Principal Component Analysis*): qui consiste à transformer des variables corrélées en nouvelles variables décorrélées en projetant les données dans le sens de la variance croissante. Les variables avec la variance maximale sont les composants principaux.
- LDA (*Linear Discriminant Analysis*): il s'agit d'expliquer et de prédire l'appartenance d'une observation à une classe prédéfinie à partir des caractéristiques des variables prédictives. Cette méthode projette les données de manière à maximiser la séparabilité des classes et donc à minimiser la variance. Ce qui fait que les exemples de la même classe sont rassemblés par la projection tandis que les exemples de différentes classes sont éloignés.


Réduction de dimension

Factorisation matricielle

- La figure ci-dessous souligne la différence entre les deux méthodes : PCA peut être décrit comme un algorithme « non supervisé », car il ignore les étiquettes de classe et cherche les directions (les composantes principales λ_1 , λ_2) qui maximisent la variance dans un ensemble de données. Contrairement à PCA, LDA est « supervisé » et calcule les directions (« discriminants linéaires ») qui représenteront les axes maximisant la séparation entre les classes (la classe bleue et la classe verte projeté sur l'axe horizontal).


PCA:

component axes that maximize the variance



LDA:


maximizing the component axes for class-separation



Réduction de dimension

Transformation des variables

- La dépendance entre les nouvelles variables et les variables initiales peut être
 - Linéaire : trouver un sous-espace linéaire de dimension k dans l'espace initial $\mathbb{R}^m$
 - Non linéaire : trouver un sous-espace non linéaire de dimension faible (voir la figure)



sous-espace linéaire



sous-espace non linéaire

- Nous rappellerons ici trois méthodes factorielles linéaires
 - Analyse en composantes principales (ACP) : exploratoire, variables numériques
 - Analyse factorielle discriminante (AFD) : pour la discrimination, variables numériques
 - Analyse factorielle des correspondances binaires (AFCB) ou multiples (ACM) : exploratoire, variables nominales

Réduction de dimension

ACP : données, objectifs


- Données : N observations caractérisées par m variables quantitatives (matrice de données brutes R)
- Objectif général : résumer les variables initiales par un petit nombre k de variables synthétiques (les composantes principales) obtenues comme des combinaisons linéaires des variables initiales
- Utilisations (dans un contexte de données massives)
 - Condenser les données en conservant au mieux leur organisation globale
 - Visualiser en faible dimension l'organisation prépondérante des données
 - Interpréter les corrélations ou anti-corrélations entre multiples variables
 - Interpréter les projections des prototypes de classes d'observations par rapport aux variables
 - Préparer des analyses ultérieures en éliminant les sous-espaces dans lesquels la variance des données est très faible (assimilés à des sous-espaces de bruit, sans information utile)

Réduction de dimension

ACP générale

Sur les valeurs directement recueillies

- Interviennent dans l'analyse à la fois la position du nuage d'observations par rapport à l'origine des axes et la forme du nuage
- Utilisation : analyse tenant compte du zéro naturel de certaines variables




Réduction de dimension

ACP centrée

Sur les variables centrées (moyennes nulles)

- Analyse de la forme du nuage d'observations (par rapport à son centre de gravité)
- Utilisation : variables directement comparables




Réduction de dimension

ACP normée

Sur les variables centrées et réduites (moyennes nulles et écarts-types unitaires)

- Analyse de la forme du nuage après normalisation
- Utilisation : variables non directement comparables, ayant des unités de mesure différentes et/ou des intervalles de variation très différents



Réduction de dimension

ACP: solution

- Lignes de $\mathbf{R}$ décrivent les observations dans l'espace des variables initiales, colonnes de $\mathbf{R}$ décrivent les variables dans l'espace des observations $\Rightarrow$ deux analyses possibles : du nuage des observations ou du nuage des variables
- Analyse du nuage des observations : le sous-espace de dimension k recherché est généré par les k vecteurs propres $\mathbf{u}_\alpha$ associés aux k plus grandes valeurs propres λ_α de la matrice $\mathbf{X}^T\mathbf{X}$: $\mathbf{X}^T\mathbf{X}\mathbf{u}_\alpha = \lambda_\alpha\mathbf{u}_\alpha$, $\alpha \in \{1, \dots, k\}$
- La matrice $\mathbf{X}$ est :
 - ACP générale : la matrice des données brutes $\mathbf{X} = \mathbf{R}$
 - ACP centrée : la matrice des données centrées (de chaque variable on retire la moyenne empirique) $\Rightarrow \mathbf{X}^T\mathbf{X}$ est la matrice des *covariances empiriques*
 - ACP normée : la matrice des données normées (on divise chaque variable centrée par son écart-type) $\Rightarrow \mathbf{X}^T\mathbf{X}$ est la matrice des *corrélations empiriques*
- Rappel : si $\mathbf{u}_\alpha$ satisfait $\mathbf{X}^T\mathbf{X}\mathbf{u}_\alpha = \lambda_\alpha\mathbf{u}_\alpha$ alors pour tout $\beta \in \mathbb{R}$, $\beta\mathbf{u}_\alpha$ satisfait la même relation

Réduction de dimension

ACP: solution


- La matrice $\mathbf{X}^T\mathbf{X}$ est symétrique et (semi-)définie positive, donc toutes ses valeurs propres sont réelles, positives (certaines nulles si matrice semi-définie) et les vecteurs propres associés à des valeurs propres différentes sont orthogonaux
- Analyse du nuage des variables : la matrice à diagonaliser est $\mathbf{X}\mathbf{X}^T$, ses valeurs propres non nulles sont les mêmes que celles de $\mathbf{X}^T\mathbf{X}$ et il y a des relations de transition entre les deux analyses
- Comme en général $N \gg m$ (nombre d'observations $\gg$ nombre de variables initiales), on préfère traiter la matrice $\mathbf{X}^T\mathbf{X}$ de dimension $m \times m$ plutôt que $\mathbf{X}\mathbf{X}^T$ de dimension $N \times N$

Réduction de dimension

ACP: nuage des observations

Données mises à disposition par le Laboratoire de Traitement d'Image et de Reconnaissance de Formes (LTIRF) de l'Institut National Polytechnique de Grenoble (INPG) dans le cadre du projet ESPRIT III ELENA (No. 6891) et du groupe de travail ESPRIT ATHOS (No. 6620)

- Visualisation : projection (d'un échantillon) des observations sur les premiers plans factoriels
- $N=5500$, $m=40$




Réduction de dimension

ACP: nuage des nuages

Données issues de Allison T., Cicchetti D., Sleep in mammals : ecological and constitutional correlates, Science, vol. 194, pp. 732-734.

- Visualisation : projection des variables sur le premier plan factoriel
- Dans l'exemple considéré ($N = 62$, $m = 10$) :
 - Groupes : « sommeil », « danger », « corps, cerveau, vie, gestation » (CCVG)
 - Forte opposition entre le groupe « sommeil » et le groupe « danger »
 - Opposition plus faible entre le groupe « danger » et le groupe CCVG




Réduction de dimension

ACP: choix du nombre de composantes

Suivant l'objectif de l'analyse :

- Analyse descriptive avec visualisation : à partir de quel ordre les différences entre les pourcentages d'inertie expliquée ne sont plus significatives ?
- Réduction du volume de données : qualité d'approximation mesurée par le taux d'inertie expliquée
- Prétraitement avant méthodes décisionnelles : simple critère de conditionnement de la matrice des covariances empiriques (ou corrélations si analyse normée), ou nombre d'axes comme paramètre de la méthode décisionnelle



Réduction de dimension

ACP: observations et variables supplémentaires

De nouveaux individus et/ou variables peuvent être projetés sur les axes factoriels afin de contribuer à l'interprétation

■ Observations supplémentaires :

- Observations atypiques, éliminées de l'analyse en raison de leurs contributions absolues excessives
- Centre de gravité d'un groupe d'observations, par ex. celles qui possèdent une modalité d'une variable nominale

■ Variables supplémentaires :

- Quantitatives : projection directe sur les axes de l'analyse du nuage des variables
- Nominales : pour chaque modalité, calcul du centres de gravité des observations qui la possèdent et projection sur les axes de l'analyse du nuage des observations

Réduction de dimension


AFD : données, objectifs

- Données : **N** observations caractérisées par m variables quantitatives (matrice de données **X**) et une variable nominale « classe » $Y \in \{1, \dots, q\}$
- Objectifs :
 - Étape descriptive : identifier des « facteurs discriminants » (combinaisons linéaires de variables explicatives) qui permettent de différencier au mieux les classes
 - Étape décisionnelle : sur la base des valeurs prises par les variables explicatives, décider à quelle classe affecter une nouvelle observation
- Utilisations :
 - Descriptive : condenser la représentation des données en conservant au mieux la séparation entre les classes
 - Décisionnelle : classer de nouvelles observations à partir du sous-espace linéaire qui optimise la séparation

Réduction de dimension


AFD versus ACP

- L'ACP maximise la variance des projections sur le sous-espace
- L'AFD maximise la différenciation entre les classes dans le sous-espace




Réduction de dimension

AFD versus ACP : illustration



ACP




AFD

Réduction de dimension

AFD : solution

■ Covariances :

1. Intra-classes : **D**, calculée sur les observations de départ, en centrant chaque classe sur son centre de gravité
2. Inter-classes : **E**, calculée en considérant que les observations sont les centres de gravité des classes
3. Totale : **S**, calculée sur les observations de départ ; relation de Huygens **S = E + D**



Réduction de dimension

AFD : solution (2)

- Le sous-espace de dimension k recherché est généré par les k vecteurs propres u_α associés aux k plus grandes valeurs propres λ_α de l'équation de valeurs et vecteurs propres généralisée $Eu_\alpha = \lambda_\alpha Su_\alpha$, $\alpha \in \{1, \dots, k\}$
- Il est possible de résoudre plutôt $Eu_\alpha = \lambda_\alpha Du_\alpha$ si le rang de D n'est pas inférieur à celui de $\mathbf{S}$
Si $\mathbf{S}$ est inversible, il est préférable de résoudre $S^{-1}Eu_\alpha = \lambda_\alpha u_\alpha$
- Approche fréquente si $\mathbf{S}$ est singulière : réduire la dimension avec une ACP pour rendre dans l'espace réduit $\mathbf{S}'$ de rang complet, ensuite résoudre $S'^{-1}E'u_\alpha = \lambda_\alpha u_\alpha$ dans l'espace réduit
- Si l'ACP est appliquée pour réduire la dimension au-delà de la nécessité de rendre $\mathbf{S}'$ de rang complet, risque d'élimination de variables discriminantes ! Préférer une approche de régularisation, par ex. remplacer $\mathbf{S}$ par $\mathbf{S} + r\mathbf{I}_m$ pour r assez grand

Réduction de dimension

AFD : choix du nombre d'axes

1. Tests statistiques (hypothèses : classes issues de lois normales) :
 - a. Test de Rao : test d'égalité à 0 de la i -ème valeur propre
 - b. Test du Lambda de Wilks : apport significatif des axes au-delà du i -ème ?
 - c. Test incrémental : apport significatif du $i + 1$ -ème axe ?
2. Méthode de l'échantillon-test (si utilisation décisionnelle directe ou couplage avec un modèle décisionnel) :
 - Extraire (par tirages aléatoires) un échantillon-test
 - Répéter pour différentes valeurs du nombre d'axes : appliquer l'AFD sur les données restantes, développer le modèle décisionnel sur ces mêmes données, évaluer le modèle décisionnel sur l'échantillon-test
 - Choisir les paramètres (dont nombre d'axes d'AFD) qui donnent le meilleur résultat
 - La capacité de généralisation du modèle retenu sera estimée à partir de données non utilisées pour l'AFD ou pour le choix des paramètres

Réduction de dimension

Analyse des correspondances : données

- Données : N observations caractérisées par m variables nominales (ou à modalités), représentées par un tableau disjonctif complet (TDC) ; chaque observation possède exactement une modalité pour chaque variable

	var. 1	var. k	var. q	
	1	j	p	marge
1				q
.				.
.				.
.				.
i		x_{ij}		q
.				.
.				.
.				.
.				.
n				q
marge	n_1	n_j	n_p	$n \ q$

Réduction de dimension

Analyse des correspondances : objectifs, utilisations

- Objectif général : mettre en évidence les relations dominantes entre modalités des variables nominales initiales
- Utilisations
 - Traitement d'enquêtes basées sur des questions fermées à choix multiples
 - Résumer un grand nombre de variables nominales par un faible nombre de variables quantitatives
 - Lorsque le nombre d'observations est faible, peut mettre en évidence des relations entre observations et variables
 - Possibilité d'inclure des variables quantitatives dans l'analyse, après leur transformation en variables nominales

Réduction de dimension

ACM : exemple

Données issues de l'enquête « Les étudiants et la ville » réalisée en 2001 sous la direction de S. Denèfle à l'Université de Tours

- Questions (variables nominales) choisies :
 - Habitez-vous : seul(e), en colocation, en couple, avec les parents
 - Quel type d'habitation occupez-vous : cité U, studio, appartement, chambre chez l'habitant, autre
 - Si vous vivez en dehors du foyer familial, depuis combien de temps : moins d'1 an, de 1 à 3 ans, plus de 3 ans, non applicable
 - A quelle distance de la fac vivez-vous : moins d'1 km, de 1 à 5 km, plus de 5 km Quelle est la surface habitable de votre logement : moins de 10m², de 10m² à 20m², de 20m² à 30m², plus de 30m²
- Observation : sur les 5 variables, 3 sont issues de variables quantitatives discrétisées !
- Nombre élevé de modalités ⇒ le TDC (ou le tableau de Burt = concaténation des tableaux de contingences par paires de variables) peu lisible ⇒ synthèse par ACM nécessaire

Réduction de dimension

ACM : solution

- Analyse des observations (lignes du TDC) et analyse des modalités (colonnes TDC)
 - Si le nombre d'observations (N) est grand alors on s'intéresse surtout à l'analyse des modalités
- Pondération de chaque modalité (colonne du TDC) par sa fréquence relative → les modalités rares ont un impact faible sur l'analyse
- Distance utilisée :
 - Emploi de la distance du χ^2 : l'influence de chaque composante est pondérée par l'inverse de son poids
 - Équivalence distributionnelle de la distance du χ^2 : si deux colonnes proportionnelles sont cumulées en une seule (fusion de deux modalités), les résultats de l'analyse ne changent pas
- Comme pour l'ACP, on cherche un espace de dimension k ($\ll$ nombre colonnes du TDC) qui résume le mieux la dispersion du nuage analysé

Réduction de dimension


ACM : interprétation

- Sur la base de similarités (ou oppositions) entre projections de modalités :
 - De variables différentes : mêmes populations d'observations
 - D'une même variable (donc mutuellement exclusives) : populations similaires par rapport aux autres variables
- Observations importantes :
 - Le centre de gravité des modalités d'une même variable se confond avec le centre de gravité du nuage de toutes les modalités
 - Plus une modalité est rare, plus elle est éloignée du centre de gravité

Réduction de dimension

ACM : inclusion de variables quantitatives

- Intérêt :
 - Trouver des relations entre modalités de variables qualitatives et intervalles de valeurs de variables quantitatives
 - Mettre en évidence des relations non linéaires entre intervalles de variables quantitatives
- Découper en intervalles le domaine de variation de la variable quantitative (sur la base de connaissances a priori, à partir de l'histogramme, etc.) ; chaque intervalle sera une modalité de la nouvelle variable qualitative.





Réduction de l'ordre de complexité

Réduction de l'ordre de complexité : méthodes


- Le **principe général** de la réduction de l'ordre de complexité grâce à la similarité est de regrouper les données par similarité et d'éviter les opérations impliquant des données issues de groupes éloignés. Des structures de données particulières (index multidimensionnels ou métriques) permettent de mettre en œuvre ces regroupements et de sélectionner efficacement, pour chaque donnée (déjà présente dans la base ou nouvelle) vue comme « requête », les données suffisamment proches pour intervenir dans les calculs.

Réduction de l'ordre de complexité

A. Réduction du volume de données (sans changer l'ordre de complexité)

B. Réduction de l'ordre de complexité (sans diminuer le volume de données)

- Principe : les modèles sont souvent locaux, la décision est locale → les calculs impliquant des données éloignées peuvent être évités




- Solutions basées sur l'utilisation d'index multidimensionnels ou métriques
- Méthodes exactes ou approximatives

Réduction de l'ordre de complexité : typologie des besoins


- Recherche par similarité (par ex. pour recommandation par similarité)
- Décision : k plus proches voisins, machine à noyaux
- Estimation de densité (description, décision)
- Classification automatique, quantification
- Jointure par similarité (par ex. identification proximités fortes)
- Apprentissage supervisé, apprentissage semi-supervisé

Recherche par similarité


- Recherche par intervalle (*range query*) : $Range_r(\mathbf{q}) = \{\mathbf{x} \in \mathcal{D} \mid \forall i, |x_i - q_i| \leq r_i\}$
- Recherche dans un rayon (*sphere query*) : $Sphere_\epsilon(\mathbf{q}) = \{\mathbf{x} \in \mathcal{D} \mid d(\mathbf{x}, \mathbf{q}) \leq \epsilon\}$
- Recherche des k plus proches voisins (*kppv*, *kNN*) :
 $kNN(\mathbf{q}) = \{\mathbf{x} \in \mathcal{D} \mid |kNN(\mathbf{q})| = k \wedge \forall \mathbf{y} \in \mathcal{D} - kNN(\mathbf{q}), d(\mathbf{y}, \mathbf{q}) > d(\mathbf{x}, \mathbf{q})\}$



range query



sphere query




kNN query

N données $\Rightarrow$ complexité $O(N)$?

Décision : k plus proches voisins

- 1 Trouver les k ppv de x
- 2 Vote majoritaire des k ppv (avec ou sans rejet d'ambiguïté)




k plus proches voisins

N données $\Rightarrow$ complexité $O(N)$?

Estimation de densité

- 1 Noyaux de Parzen : noyaux K identiques centrés sur les N observations initiales, la densité en $\mathbf{x}$ est $f(\mathbf{x}) \propto \sum_{i=1}^N K(\mathbf{x}, \mathbf{x}_i)$
- 2 Modèle paramétrique (par ex. mélange additif de lois normales) : la densité est une somme pondérée de lois, on note par N le nombre de lois dans le mélange



N noyaux $\Rightarrow$ complexité $O(N)$?


Noyau local ($K(\mathbf{x}, \mathbf{x}_i) \approx 0$ pour $d(\mathbf{x}, \mathbf{x}_i) > \epsilon$) ou loi à décroissance rapide $\Rightarrow$ seuls comptent les voisins *dans un rayon*

Classification vectorielle

automatique,

quantification

- *k-means* : groupes représentés par leurs centres de gravité, nombre de centres fixé (mais on considère que pour N données il faudrait utiliser $O(N^{1/3})$ centres)




- *k-medoids* : extension aux espaces métriques en général, chaque groupe est représenté par son élément le plus central (*medoid*)
- Classification ascendante hiérarchique : arbre de regroupements, pouvant donner de multiples partitionnements

N données $\Rightarrow$ complexité $O(N)$ (ou $O(N^{4/3})$), resp. $O(N^2)$ et $O(N^2 \log N)$?

Jointure par similarité

- Jointure avec seuil de distance θ , ensembles $\mathcal{D}_1$, $\mathcal{D}_2$, avec N_1 et respectivement N_2 éléments : $K_\theta = \{(\mathbf{x}, \mathbf{y}) | \mathbf{x} \in \mathcal{D}_1, \mathbf{y} \in \mathcal{D}_2, d(\mathbf{x}, \mathbf{y}) \leq \theta\}$
- Auto-jointure : $\mathcal{D}_1 \equiv \mathcal{D}_2$



jointure par similarité

$\Rightarrow$ complexité $O(N_1 \times N_2)$?



auto-jointure par similarité

$\Rightarrow$ complexité $O(N^2)$?

Réduction de l'ordre de complexité : objectifs

- Recherche par l'exemple, décision, estimation de densité : requête de même nature que les données
 - Objectif : $O(N) \rightarrow O(\log N)$ ou $O(1)$
- Apprentissage semi-supervisé, apprentissage actif, recherche par détecteur : requête = frontière de décision
 - Objectif : $O(N) \rightarrow O(\log N)$ ou $O(1)$
- Jointure par similarité, apprentissage supervisé à noyaux, *N-body problems*, certaines méthodes de classification automatique
 - Objectif : $O(N^2) \rightarrow O(N \log N)$ ou $O(N)$
- Remarque générale : complexité $\geq$ taille résultat !

Conclusion

- La réduction de dimensionnalité en Machine Learning est une étape importante du nettoyage de données. Cette technique consiste à diminuer le nombre de variables prédictives à l'entrée du modèle afin d'éviter le fléau de la dimensionnalité et le surapprentissage. Différentes méthodes ont été proposées dont notamment **feature selection**, **feature engineering**, et les méthodes d'algèbre linéaire (**PCA, LDA**).
- Des combinaisons de méthodes de réduction de complexité peuvent également être intéressantes.
- Par exemple, appliquer une réduction de dimension avant la réduction de l'ordre de complexité permet de diminuer l'impact de la malédiction de la dimension sur la structure d'index employée.