

Big Data Mining

Préparé par: Mme. Olfa DRIDI



Plan

01 Introduction

Data mining & big data

02 Passage à l'échelle

Réduction de la complexité

03 Text Mining

Fouille de textes

04 Web Mining et analyse des sentiments

De la fouille de données à la fouille du Web

05 Systèmes de recherche d'information

Définition, principes et évaluation

Introduction

- C'est quoi le Web?
- La quantité d'informations disponibles sur le Web aujourd'hui est immense. Il est très difficile pour un utilisateur de trouver ce qu'il souhaite sans outil.
- Le Web Mining tente de répondre à cette problématique en ayant pour objectif de diminuer le temps de recherche et d'améliorer les résultats qui en découlent sur le Web.
- Il regroupe diverses communautés comme le domaine des bases de données, de la récupération d'informations, du traitement du langage naturel, etc.

Introduction

- La complexité du contenu du Web est attribuée aux caractéristiques suivantes:
 - La taille énorme: Le volume du Web croît de manière exponentielle, et reste difficile à évaluer.
 - En plus des données textuelles, qui constituent la forme la plus usuelle pour véhiculer l'information, nous trouvons aussi un nombre important d'images, de fichiers audio et vidéo, ainsi que des programmes (applications) dans le Web. Dans la majorité des cas, ces types variés de données coexistent dans le même document (ou page), ce qui accroît la complexité de leur prise en charge au même temps avec une technique de fouille donnée.
 - La distribution: Le Web est intrinsèquement distribué. Les données se trouvent donc éparpillées géographiquement sur des ordinateurs et des plateformes, qui sont interconnectées par des topologies souvent non prédéfinies.
 - La non structuration: L'absence d'une structure unifiée est le premier argument pour ceux qui croient que la fouille de données ne peut réussir pour le Web. En effet, le Web n'a pas de schémas ou de modèles de données uniformes ou rigides, ceci est dû, comme nous l'avons mentionné, au manque de style de rédaction et de contrôle de son contenu.

Introduction

- La dynamicité: Les données du Web sont dynamiques et changeantes dans le temps. Cette variation rapide concerne aussi bien l'aspect structure que les contenus, ainsi des données et des liens différents et nouveaux sont perpétuellement ajoutés, mise à jour, ou supprimés s'ils s'avèrent obsolètes.
- L'hyper-liaison: A l'opposé des collections traditionnelles de documents généralement plats, le Web est un important hypertexte. Les utilisateurs y accèdent et surfent en utilisant son graphe de liens reliant les pages et les sites entre eux, ces liens véhiculent des informations auxiliaires très utiles qui modélisent des relations topologiques ou sémantiques entre les données

Définition du Web Mining

- **Le Web Mining (Fouille du Web)** est l'application des techniques d'exploration de données de très grande échelle en vue de découvrir des constantes, schémas ou modèles, dans les ressources d'internet ou les données le concernant.
- Le Web Mining est l'application de techniques et modèles permettant de rechercher, récolter, nettoyer, analyser, classer et recommander des informations/données issues du Web. Ces techniques sont notamment utilisées dans les moteurs de recherche, qui jouent un rôle central dans la société de l'information connectée, ainsi que les réseaux sociaux.


Objectifs du Web Mining

Le Web Mining poursuit deux principaux objectifs:

1. L'amélioration et la valorisation des sites Web : L'analyse et la compréhension du comportement des internautes sur les sites Web permet de valoriser le contenu des sites en améliorant l'organisation et les performances des sites.
2. La personnalisation: Les techniques de Data Mining appliquées aux données collectées sur le Web permettent d'extraire des informations intéressantes relatives à l'utilisation du site par les internautes. L'analyse de ces informations permet de personnaliser le contenu proposé aux internautes en tenant compte de leurs préférences et de leur profil.

Processus de Web Mining

- Le processus du Web Mining se déroule en trois étapes :
 1. Collecte des données sur l'utilisateur,
 2. Utilisation de ces données à des fins de personnalisation,
 3. Présentation à l'utilisateur d'un contenu ciblé.



Données du Web et leurs sources

- Les données utilisées dans le Web Mining en quatre types :
 - Données relatives au contenu : données contenues dans les pages Web (textes, graphiques),
 - Données relatives à la structure : données décrivant l'organisation du contenu (structure de la page, structure inter-page),
 - Données relatives à l'usage: données fournissant des informations sur l'usage telles que les adresses IP, la date et le temps des requêtes,
 - Données relatives au profil de l'utilisateur : données fournissant des informations démographiques sur les utilisateurs du site Web.

Applications du Web Mining

- L'analyse du contenu des pages Web (Web Content Mining) : C'est le processus d'extraction des connaissances à partir du contenu réel des pages Web. Les informations provenant du Web sont stockées dans des bases de données. Ces dernières sont ensuite analysées en utilisant les langages d'interrogations des bases de données et les techniques de fouille de données.
- L'analyse des liens entre les pages Web (Web Structure Mining) : Il s'agit d'une analyse de la structure du Web, de l'architecture et des liens qui existent entre les différents sites. L'analyse des chemins parcourus permet par exemple de déterminer combien de pages consultent les internautes en moyenne et ainsi d'adapter l'arborescence du site pour que les pages les plus recherchées soient dans les premières pages du site. De même, la recherche des associations entre les pages consultées permet d'améliorer l'ergonomie du site par création de nouveaux liens

Applications du Web Mining

- L'analyse de l'usage des pages Web (Web Usage Mining) : Cette dernière branche du Web Mining consiste à analyser le comportement de l'utilisateur à travers l'analyse de son interaction avec le site Web. Cette analyse est notamment centrée sur l'ensemble des clics effectués par l'utilisateur lors d'une visite au site (on parle alors d'analyse du clickstream).
- L'intérêt est d'enrichir les sources de données utilisateur (bases de données clients, bases marketing, etc.) à partir des connaissances extraites des données brutes du clickstream et ce afin d'affiner les profils utilisateur et les modèles comportementaux.

Opinion mining and Sentiment analysis

Fouille d'opinions et analyse des sentiments

Plan

1. Fouille d'opinions – Cadre général
2. Analyse des sentiments
3. Analyse des sentiments sur Twitter
4. Plus loin avec la fouille d'opinions

Contexte de la fouille d'opinions

- Savoir ce que pensent les « gens » (électeurs, clients, concurrents, etc.) est fondamental pour la prise de décision.
- Les enquêtes d'opinions constituent une manière de les récolter.
- Avec le Web 2.0, ces informations sont disponibles à profusion, sous forme d'avis sur les sites de vente en ligne (accompagnée d'une note d'ailleurs), de discussions dans les médias et réseaux sociaux (blogs, wikis, twitter, facebook, etc.).
- Ces écrits sont de nature différente de ceux des professionnels (pour lesquels la trame et les critères sont explicites), ils intègrent une dimension émotionnelle et sont peu codifiés (non cadrés par un questionnaire)

Intérêt de la fouille d'opinions

- La fouille d'opinions, en particulier à partir de données des réseaux sociaux, est un excellent substitut nettement moins coûteux des enquêtes d'opinions.
 - Evaluation des produits, d'une politique, d'une personnalité
 - En appui des systèmes de recommandations (ex. ne pas proposer des produits qui ont des mauvaises notes)
 - Analyse de la popularité, des tendances
 - Positionnements par rapport à un sujet délicat (ex. mariage pour tous)
- Mais les réseaux sociaux permettent d'aller plus loin....
 - Susciter des réactions (ex. loi travail)
 - Identifier des leaders d'opinions et/ou des spammeurs d'opinions
 - Détecter des communautés (ex. Affaire Brown à Ferguson)

Exemple introductif (Liu et Zhang, page 416)

(1) I bought an iPhone a few days ago. (2) It was such a nice phone. (3) The touch screen was really cool. (4) The voice quality was clear too. (5) However, my mother was mad with me as I did not tell her before I bought it. (6) She also thought the phone was too expensive, and wanted me to return it to the shop . . .

(1) relate un fait **objectif**. (2), (3) et (4) expriment une **opinion subjective** plutôt **positive** ; (5) et (6) une opinion **négative**.

L'**entité** iPhone en général est le sujet de (2) ; (3), (4) et (6) sont relatifs respectivement aux **aspects** « touch screen », « voice quality » et « price » de l'iPhone ; « me » est le sujet de (5).

« I » (je) est le **titulaire** des opinions (2), (3) et (4) ; pour (5) et (6), il s'agit de « mother ».

Concepts de la fouille d'opinions

Entité est la cible de l'opinion (objet, produit, évènement, personne...)

Holder (titulaire) de l'opinion c.-à-d. celui qui l'exprime. Important à distinguer lorsqu'ils sont plusieurs et que des phénomènes de communautés peuvent apparaître (coopérant ou s'opposant)

(1) *I bought an iPhone a few days ago.* (2) *It was such a nice phone.* (3) *The touch screen was really cool.* (4) *The voice quality was clear too.* (5) *However, my mother was mad with me as I did not tell her before I bought it.* (6) *She also thought the (price of the) phone was too expensive, and wanted me to return it to the shop . . .*

Aspect de l'entité ciblée par l'opinion. Parfois, l'opinion peut porter sur l'entité en général (ex. *nice phone*).

Orientation de l'opinion, qui peut être de **polarité** positive ou négative. Une opinion peut être *régulière* (une appréciation) ou *comparative* (en comparaison avec une autre entité). Seul le premier cas nous intéresse ici.

Définition d'une opinion

- Une opinion est un quintuplet $(e_i, a_{ij}, o_{ijkl}, h_k, t_l)$, où e_i est l'entité, a_{ij} est un des aspects de e_i , h_k est le titulaire, o_{ijkl} est son orientation (polarité), et t_l est la date (time) où elle a été exprimée. Parce que bien sûr, une opinion peut être fluctuante dans le temps.
- Tous les éléments ne sont pas strictement nécessaire. Par ex., on peut omettre le titulaire si l'on souhaite faire des statistiques sur un grand nombre de documents ; ignorer la date si on travaille à fenêtre temporelle fixée ; etc.
- Dans certains cas, il peut être intéressant d'ajouter une granularité supplémentaire pour approfondir les analyses (ex. sexe, âge ou CSP des titulaires, etc.)

Définition d'une opinion

Une opinion est un quintuplet $(e_i, a_{ij}, o_{ijkl}, h_k, t_l)$, où e_i est l'entité, a_{ij} est un des aspects de e_i , h_k est le titulaire, o_{ijkl} est son orientation (polarité), et t_l est la date (time) où elle a été exprimée. Parce que bien sûr, une opinion peut être fluctuante dans le temps.

Tous les éléments ne sont pas strictement nécessaire. Par ex., on peut omettre le titulaire si l'on souhaite faire des statistiques sur un grand nombre de documents ; ignorer la date si on travaille à fenêtre temporelle fixée ; etc.

Dans certains cas, il peut être intéressant d'ajouter une granularité supplémentaire pour approfondir les analyses (ex. sexe, âge ou CSP des titulaires, etc.)

Etapes usuelles pour identifier le quintuplet $(e_i, a_{ij}, o_{ijkl}, h_k, t_l)$ dans un corpus D

1. Extraction des entités et regroupement. Identification des entités, regroupement des éventuels synonymes.
2. Extraction des aspects. Association avec les entités, regroupement des éventuels synonymes.
3. Identification du titulaire, datation. Un titulaire exprime une opinion à une date donnée, qui peut être déterminante dans l'analyse.
4. Détermination de l'orientation de l'opinion. Elle peut être positive, neutre, ou négative. Parfois, il est nécessaire de faire la distinction au préalable entre une expression objective (fait) et subjective (opinion).
5. Enumération de l'ensemble des tuples $(e_i, a_{ij}, o_{ijkl}, h_k, t_l)$ dans le corpus suite aux étapes ci-dessus.

Analyse des sentiments

- L'analyse des sentiments s'intéresse à l'orientation d'une opinion par rapport à une entité ou à un aspect d'une entité. On parle de *polarité*, elle peut être positive, neutre, ou négative.
- Nous positionnons l'analyse au niveau du document (*document level sentiment*). L'individu statistique est le document. On aurait pu descendre d'un cran et décomposer au niveau des phrases (*sentence level sentiment*), un document pouvant être constitué de plusieurs phrases (ex. J'aime les histoires. Mais l'emballage n'est pas terrible.)
- Nous considérons que le titulaire de chaque document est unique. Mais il peut y avoir des titulaires différents d'un document à l'autre, plusieurs documents peuvent avoir le même titulaire.
- Le niveau de sentiment « neutre » peut être une position intermédiaire entre « positif » et « négatif ». Il peut être également significatif d'un énoncé objectif (fait), auquel cas il convient de discerner ce qui relève de l'opinion (subjective) ou non dans un premier temps (voir plus loin...)

Analyse de sentiments - Approches

- Apprentissage statistique. Les documents sont étiquetés manuellement par un expert (ex. -1, 0 , +1). Nous rentrons dans le cadre bien connu de la catégorisation de textes, nous utilisons les différentes techniques de machine learning. La démarche est rigoureuse, mais l'étiquetage expert est un véritable goulot d'étranglement, il peut être aussi bruité (l'expert n'est pas infallible...).
- Utilisation d'un thésaurus de sentiments. Des polarités sont associés à des termes ou à des phrases complètes. La polarité d'un document peut être alors calculée à partir de la somme des polarités des termes (ou des phrases) qui la compose. En pratique, ce n'est pas toujours facile. Il y a la synonymie à gérer, un même terme peut avoir des polarités différentes selon les domaines (ex. « épais » dans la mode et dans le catch n'a pas vraiment la même tonalité...), il faut traiter convenablement la négation (ex. il n'est pas rapide), l'ironie, les sarcasmes, etc.

Twitter, un espace privilégié pour l'analyse des sentiments

- Twitter est un outil de microblogage qui permet à tout un chacun de communiquer via un message limité à 140 caractères. Les utilisateurs (@) peuvent interagir entre eux, il est possible de définir des sujets avec (#). Il est incontournable aujourd'hui dans la stratégie de communication des décideurs (ex. Le Monde – Stratégie Trump)
- Les documents sont brefs et de longueur équivalentes. Un document est souvent focalisé sur un aspect d'une entité, et est associé une et une seule orientation.
- On y exprime souvent des avis. Nous avons bien des opinions subjectives souvent.
- Les auteurs (titulaires) sont clairement identifiables avec @. Les éventuels interlocuteurs aussi. On peut voir les communautés émerger (ex. Paris plage)
- Les sujets (entités) sont clairement identifiables avec #.
- Mises à jour fréquentes, dynamisme et réactivité des acteurs. On peut détecter
- des tendances par rapport aux auteurs / communautés, par rapport aux sujets.
- Les messages se prêtent à une multitude d'analyses (ex. Tweet Sentiment
- Visualization)... mais, attention, ils ne permettent pas de tout faire (ex. présidentielles)

Prétraitement des données

- **Objectif du Prétraitement :**

Rendre les Données Cohérentes : Le prétraitement des données est une étape cruciale visant à rendre le texte plus maniable et cohérent. Cela inclut la correction des fautes de frappe, la gestion des abréviations et la normalisation de la casse.

- **Gestion des Éléments Non-Textuels :**

Suppression des Balises HTML et des Caractères Spéciaux : Dans le cas de données provenant de sources web comme Twitter, il est essentiel de supprimer les balises HTML et de traiter les caractères spéciaux pour éviter des interférences avec l'analyse.

- **Tokenisation :**

Découpage en Mots : La tokenisation divise le texte en unités discrètes (mots).

- **Suppression des Stop Words :**

Les mots courants sans réelle valeur sémantique (comme "et", "le", "de") sont souvent supprimés pour focaliser l'analyse sur les termes significatifs

Extraction des caractéristiques

- **Importance de l'Extraction de Caractéristiques :**

Transformation du Texte en Données Exploitable : Les modèles d'analyse des sentiments nécessitent une représentation numérique du texte. L'extraction de caractéristiques convertit le texte en vecteurs ou matrices numériques.

- **Utilisation d'Embeddings de Mots :**

Word Embeddings : Les embeddings de mots attribuent à chaque mot un vecteur numérique dense basé sur son contexte d'utilisation. Ces représentations préservent la similarité sémantique entre les mots, améliorant la capacité du modèle à comprendre les nuances.

- **Autres Techniques d'Extraction de Caractéristiques :**

- TF-IDF (Term Frequency-Inverse Document Frequency) : Mesure de l'importance relative d'un mot dans un document par rapport à une collection plus large de documents.
- N-grams : Considération de séquences de mots pour capturer des relations plus complexes.

- **Choix Stratégiques :**

Sélection en Fonction du Contexte : Le choix de la méthode d'extraction de caractéristiques dépend du contexte, de la taille des données et des objectifs spécifiques de l'analyse des sentiments.

Défis et solutions

Défis

➤ **Ambiguïté Contextuelle :**

Les mots peuvent avoir différentes significations en fonction du contexte, introduisant une ambiguïté dans l'interprétation des sentiments.

➤ **Gestion de la Négation et du Sarcasme :**

La négation et le sarcasme peuvent inverser le sens des mots, posant des défis pour les modèles d'analyse des sentiments.

➤ **Manque de Données Étiquetées :**

La nécessité de grandes quantités de données annotées pour entraîner des modèles de deep learning peut être un obstacle.

Solutions

✓ Utilisation de modèles de deep learning comme BERT qui capturent la sémantique contextuelle pour une compréhension plus précise.

✓ Intégration de modèles qui tiennent compte du contexte global, comme les LSTM, pour mieux interpréter les nuances.

✓ Transfert d'apprentissage en utilisant des modèles pré-entraînés, réduisant la dépendance aux ensembles de données spécifiques.

Bibliothèques

spaCy est une bibliothèque Python moderne et rapide pour le traitement du langage naturel, se concentrant sur la performance et la simplicité d'utilisation.

- **Fonctionnalités Principales :**

- Analyse syntaxique, reconnaissance des entités nommées, lemmatisation, etc.
- Modèles pré-entraînés pour plusieurs langues.

- **Analyse Sentimentale :**

- Bien que spaCy ne propose pas d'outil intégré spécifique à l'analyse sentimentale, il excelle dans la préparation des données et l'extraction d'informations nécessaires à cette tâche.

- **Impact dans l'Analyse Sentimentale :**

- Performance rapide et efficace, adaptée aux applications en temps réel.
- Utilisé pour l'extraction d'entités et d'informations contextuelles, qui sont des éléments clés dans l'analyse des sentiments.

Bibliothèques

NLTK est une bibliothèque de traitement du langage naturel (NLP) en Python, offrant des outils robustes pour une variété de tâches linguistiques.

- **Fonctionnalités Principales :**

- Tokenisation, lemmatisation, analyse des parties du discours, et plus encore.
- Accès à des ressources lexicales telles que WordNet.

- **Analyse Sentimentale :**

- Comprend le module `nltk.sentiment` avec des outils pour l'analyse des sentiments.
- Possibilité d'utiliser des lexiques et des modèles pré-entraînés.

- **Impact dans l'Analyse Sentimentale :**

- Favorise la flexibilité avec des modules dédiés à différentes tâches.
- Utilisé dans l'analyse sentimentale pour la préparation des données et l'implémentation d'algorithmes.

Analyse des graphes sur les réseaux sociaux




Introduction

- Les médias sociaux représentent une mine de connaissances cachées à travers un ensemble de données de plus en plus volumineuses, hétérogènes, et distribuées.
- L'application des outils du datamining sur de telles données ou bien «Social Media Mining» vise la représentation, l'analyse et l'extraction de modèles significatifs, à partir des données des médias sociaux.
- Un média social est un groupe d'applications Internet (services en ligne) conçues sur les fondations du Web 2.0 (simplicité, sociabilité, intelligence collective,..), et qui permettent à chaque utilisateur de générer (créer) un certain contenu et de le partager avec les autres utilisateurs.

Définitions


- L'analyse de graphes sur les réseaux sociaux: l'étude des connexions et des interactions entre les individus au sein des plateformes de médias sociaux.
- Offre des informations précieuses pour comprendre les dynamiques sociales, l'influence, la diffusion de l'information et bien d'autres aspects de la vie numérique.



modèles graphiques

Définitions

- Les réseaux sociaux en ligne sont devenus un élément essentiel de la vie moderne, rassemblant des milliards d'utilisateurs à travers le monde. Comprendre comment les individus se connectent, partagent des informations, forment des communautés et influencent les autres revêt une importance pour divers secteurs, allant du marketing et de la publicité à la recherche en sciences sociales.
- Source de données pour extraire des informations exploitables.



Objectifs

- ✓ La détection de structures de communautés, l'identification des influenceurs.
- ✓ L'analyse de la diffusion de l'information.
- ✓ La prédiction de tendances.
- ✓ La compréhension des comportements des utilisateurs.
- ✓ Vise à donner un sens aux relations en ligne et à aider les chercheurs, les entreprises et les décideurs à prendre des décisions informées en se basant sur ces données.

Représentation

- Représentation en graphe: Dans cette représentation, un nœud représente un acteur et un lien représente une relation du réseau. Il s'agit de la représentation la plus courante des reseaux.
- Les données issues des médias sociaux peuvent être modélisées par un graphe $G(V, E)$, : V ensemble de sommets et E : ensemble de liens.
- On distingue plusieurs types de graphes : graphe orienté/ non orienté/ pondéré/ biparti, etc.
- Par exemple, le réseau Facebook peut être modélisé par un graphe non orienté $G(V, E)$ avec V : Ensemble d'individus, E liens d'amitié.
- Par contre, le média social Twitter peut être représenté par un graphe orienté $G(V, E)$ avec V : Ensemble d'individus et E : liens de «Follower».

Étapes

- Collecte de données

APIs de médias sociaux :sont des outils pour collecter des données à partir des plateformes de médias sociaux. Ils offrent un moyen structuré et sécurisé pour accéder aux informations publiques mises.

- Modélisation du graphe

Représentation du réseau :La manière dont vous représentez un réseau social sous forme de graphe est cruciale pour l'analyse. Il existe différentes approches, chacune avec ses avantages. Voici quelques éléments à considérer.

Étapes

■ Analyse des communautés

Modularité (Modularity) : La modularité est une mesure couramment utilisée pour évaluer la qualité de la division d'un réseau en communautés. Les algorithmes de détection de communautés cherchent à maximiser la modularité, qui est une mesure de la séparation des communautés par rapport aux connexions internes.

Détection de densité : Cette approche repose sur la détection des régions denses du réseau, où les nœuds sont fortement interconnectés. Les algorithmes de détection de densité, tels que DBSCAN (Density-Based Spatial Clustering of Applications with Noise), identifient des groupes de nœuds qui sont plus densément connectés que le reste du réseau.

Identification des rôles des utilisateurs : L'attribution des rôles consiste à identifier la position et l'influence de chaque utilisateur au sein de sa communauté. Par exemple, vous pouvez identifier les utilisateurs clés (influenceurs), les ponts entre les communautés, les membres centraux, etc.

Étapes

- détection de communautés

La détection des communautés dans des données issues des médias sociaux permet de comprendre la structure du réseau. Une communauté peut correspondre, à un groupe d'amis dans facebook, ou un groupe de chercheurs travaillant sur des mêmes thèmes dans LinkedIn, .. etc. Les résultats trouvés peuvent induire à une connaissance «utile» comme par exemple : cibler un groupe spécifique d'utilisateurs par des recommandations, détecter des communautés « dangereuses », ... etc.

Détection de communautés

- Objectif : identifier automatiquement des groupes pertinents
- Applications
 - Identifier automatiquement des groupes pertinents.
 - Comprendre la structure des réseaux.
 - Détecter des communautés spécifiques (Pages web, influenceurs politiques, groupes d'amis, ...)
 - Visualisation.
 - Amélioration de moteurs de recherche, systèmes P2P, ...
- Challenges
 - Nombre de communautés inconnu.
 - Communautés de taille variable.
 - Passage à l'échelle : milliards de sommets.

Conclusion

- Les médias sociaux représentent une mine de connaissances cachées à travers un ensemble de données de plus en plus volumineuses, hétérogènes, et distribuées. L'application des outils du datamining sur de telles données ou bien «Social Media Mining» vise la représentation, l'analyse et l'extraction de modèles significatifs, à partir des données des médias sociaux.
- L'analyse de graphe des réseaux sociaux se focalise sur les relations en ligne, tandis que le web mining explore le contenu et la structure du web. En les combinant, nous obtenons une vision complète du paysage numérique, allant au-delà des interactions pour englober les tendances émergentes et les comportements en ligne.
- Cette approche intégrée offre des informations approfondies pour des décisions éclairées dans des domaines tels que le marketing.



THANK YOU

Insert the Sub Title of Your Presentation

