

Big Data Mining

Préparé par: Mme. Olfa DRIDI



Plan

01 Introduction

Data mining & big data

02 Passage à l'échelle

Réduction de la complexité

03 Text Mining

Fouille de textes

04 Web Mining

Fouille du Web

05 Systèmes de recherche d'information

Définition, principes et évaluation

06 Systèmes de recommandation

Définition et principe

Fouille de données textuelles


- Objectifs et applications
- Approche générale
- Principales opérations
- Représentations vectorielles
- Environnements logiciels

Du data mining au text mining

Étendre la démarche data mining au traitement des données textuelles

Data mining

- Le data mining est un processus d'extraction de structures (connaissances) inconnues, valides et potentiellement exploitables dans les bases (entrepôts) de données (Fayyad, 1996), à travers la mise en œuvre des techniques statistiques et de machine learning.



La statistique exploratoire, l'économétrie, n'ont pas attendu le data mining pour s'intéresser à la modélisation sur des données issues d'enquêtes, de recueils divers,..., au sein des organisations ou en dehors (données de notre environnement socio-économique).

Contexte

- Les données textuelles contiennent des informations potentiellement très utiles pour la fouille.
- Les données textuelles constituent également une source d'information qui permettrait d'extraire de la connaissance (détecter des régularités [*patterns*], recherche des similarités, identifier les relations de causalité, etc.).
- Ces données sont présentes sous des formes très diverses, allant de textes élaborés, avec une bonne conformité grammaticale, à de simples « mots-étiquettes » (*tags*, souvent parties de mots ou mots issus d'un lexique de groupe), en passant par des phrases incomplètes en langage SMS, présentant un lexique particulier, de nombreuses fautes d'orthographe et une syntaxe très simplifiée. Ces données sont destinées à être lues et comprises par des humains, parfois appartenant à des groupes restreints.

Texte = document non structuré

Document structuré vs. Document non structuré en data mining

- Les données usuellement exploités en data mining se présentent sous forme de tableaux attributs-valeurs.

Ligne = individu statistique,

Colonne = attribut (descripteur).

Les algorithmes sont taillées pour les traiter.

- Les données en text mining se présentent sous forme de textes bruts. Les algorithmes de data mining ne savent pas les appréhender nativement.

→ Une piste de travail possible consiste à transformer la collection de textes en tableau de valeurs, en espérant ne pas trop perdre d'informations. En ligne, nous aurions les documents, mais que mettre en colonne (*features, termes*) ? Et quelles valeurs mettre à l'intérieur du tableau (*weight, pondération*) ?

Texte = document non structuré

Des textes de différentes natures :

- Pages Web, blogs, forums, emails
- Documents techniques, rapports produits dans les entreprises
- Livres, Bibliothèques numériques, articles scientifiques
- Enquête de consommateurs,
- Lettres de plaintes de consommateurs
- Dossiers patients (examens médicaux, lettres de médecin, compte-rendus, etc.)
- Rapports d'interaction entre médicaments
- Rapports d'incidents, constats d'accident
- Articles de journaux

Fouille de données textuelles : Définition

- Le text mining est un processus d'extraction de structures (connaissances) inconnues, valides et potentiellement exploitables dans les documents textuels, à travers la mise en œuvre de techniques statistiques ou de machine learning.
- Fouille de données textuelles = processus d'extraction non triviale d'informations utiles inconnues a priori à partir de grands volumes de textes
- Mais d'autres applications spécifique aux textes sont possibles : résumé automatique, extraction d'information, etc.
- **Spécificité** : les données sont sous une forme qui n'est pas directement exploitable par les méthodes classiques de fouille de données

Fouille de données textuelles : Objectifs

- **Identification de thèmes** : regroupement de (parties de) textes en thèmes inconnus a priori. Cela implique en général l'utilisation de méthodes de classification automatique sur des données textuelles dont la représentation a été adaptée, par exemple par le passage à des représentations vectorielles (que nous examinerons plus loin).
- **Affectation de (parties de) textes** à des catégories (classes) prédéfinies. Cela passe en général par l'application de modèles décisionnels, obtenus par apprentissage supervisé, à des représentations vectorielles de textes (ou d'ensembles de *tags*). La détection d'entités nommées, à représenter séparément, peut être utile.
- **Recherche de « variables » explicatives** utilisables ensuite conjointement avec d'autres variables (quantitatives, nominales)
- **Extraction d'informations** : mise en correspondance des textes avec des « schémas » plus directement exploitables par des méthodes classiques de fouille de données.

Nécessité du text mining


- L'analyse textuelle est un problème ancien
 - L'exemple le plus simple (et ancien) est le traitement des questions ouvertes dans les enquêtes.
- Text mining une nécessité de plus en plus patente avec la profusion des documents au format numérique.
 - Profusion des documents, augmentation des capacités de stockage, apparition de nombreux corpus spécialisés (ex. MEDLINE).
- Text mining incontournable avec l'explosion du web
 - Le web 2.0 a démultiplié dans des proportions gigantesques la disponibilité de documents rédigés, stockés numériquement (ex. newsgroups, réseaux sociaux [twitter], forums, etc.).
 - Les opportunités d'extraction de connaissances utiles sont innombrables.

Application du text mining



Catégorisation de textes

Cadre de l'apprentissage supervisé : exploiter une collection de documents préalablement étiquetés




Remarques

- On parle de « document classification » en anglais
- Le processus permet également d'associer les documents à des termes prédéfinis, on parle alors d'indexation automatique (ex. Reuters)
- Le cadre le plus fréquent est binaire avec une classe d'intérêt (« + ») contre les autres (« - » qui peuvent être constitués de documents très hétérogènes)
- Une application phare est le filtrage automatique de documents (ex. e-mail, pages web, etc.) ; mais il y en a d'autres (analyse des sentiments, opinion mining, etc.)

Clustering de textes

Cadre de l'apprentissage non-supervisé : partitionner en groupes homogènes les documents



Les documents d'un même groupe sont le plus similaires possible.
Les documents de groupes différents sont le plus dissimilaires possible.




On bénéficie des avantages liés à la structuration : une organisation des documents pour faciliter la consultation et la recherche ; disposer d'un résumé du corpus (une forme de réduction de la dimensionnalité) ; etc.



L'enjeu, toujours en clustering, est de comprendre la nature des groupes, en les associant à des thèmes par exemple.

Recherche d'information



L'objectif de la recherche d'information (*information retrieval* en anglais) est de mettre en place les stratégies permettant d'identifier, dans un corpus, les documents pertinents relatifs à un document requête. Il s'agit d'une **recherche par le contenu**, le texte est concerné, mais elle peut s'étendre à l'image, la vidéo, le son...



L'indexation joue un rôle fondamental dans la recherche, la **mesure de similarité** entre documents...



Les applications sont très nombreuses. Ex. détection de plagiat, recherche de dossiers médicaux, etc.



Il existe des bibliothèques logicielles performantes (Ex. Lucene, Elasticsearch).

Extraction d'information

L'extraction d'information consiste à rechercher des champs prédéfinis dans un texte plus ou moins rédigé en langage naturel. On s'appuie plus sur l'analyse lexicale et morphosyntaxique pour identifier les zones d'intérêts.

Annonce 1

Description :
FIAT COUPE 2L 20V 155 CV
1999
136000 km
Contrôle technique ok
Prix: 2990 €
Equipement :
Cuir. Climatisation. Vitres électriques. Rétroviseurs électriques. Direction assistée. Fermeture centralisée. ABS. Airbag. Jantes aluminium

Ex. extraire automatiquement les informations additionnelles sur les annonces automobiles.

Annonce	2L	5 cylindres	Turbo	Bolidée	1ère main	Réparations à prévoir
1	oui	oui	non	non	?	non
2	oui	non	oui	oui	?	oui
3	...	...	...	...	...	...

Annonce 2

Fiat coupe T 16 (moteur lancia delta dorigine) an 95 tuning leger rabaisse av et ar blistein b8 ressort court ct ok en cours le vehicule roule tres peu (suite perte emploi) il es entretenu marche tres fort environ 200 ch il peut parcourir tous les trajet. je ne suis pas presse alors les marchand de tapis pas la peine de venir la peinture a ete refait par lancien proprietaire ainsi que lebrayage mais elle as des imperfections demande de renseignement par tel uniquement

Objectif : Récupérer automatiquement les informations qui ne sont pas standardisées sur leboncoin.fr (ex. pour les voitures : année modèle, kilométrage, carburant, boîte)

Autres exemples d'applications

1. Gestion de la relation client :

- Détermination de catégories de clients à partir de leurs échanges avec le service client, redirection des courriels mal adressés
- Identification de l'objet des retours négatifs fréquents, détermination des causes majeures de l'attrition de clientèle
- Détermination de l'image d'une famille de produits
- Détermination des attentes majeures dans l'évolution des produits

2. Identification de tendances à partir de messages postés sur des médias sociaux:

- Produits ou familles de produits recherchés, caractéristiques recherchées pour des produits d'une certaine famille.
- Quantification de l'impact affectif de caractéristiques de produits, d'événements liés à des marques.

Fouille de données textuelles : exemples d'applications

3. Identification de supports adaptés pour la publicité en ligne :
 - Classification thématique de blogs ou (sous-)forums
 - Identification de caractéristiques recherchées pour des produits d'une certaine famille
4. Identification de risques sécuritaires par la surveillance d'échanges sur des réseaux sociaux :
 - Classification thématique avec suivi de l'évolution thématique et de l'activité
 - Quantification de l'impact affectif d'événements
5. Identification de concepts et liens entre concepts (par ex. pour aider la recherche scientifique) :
 - Analyse de littérature scientifique trans-communautés pour trouver des liens entre faits intra-communautés
 - Analyse de compte-rendus d'examens médicaux

Problème majeur : le « **fossé sémantique** » ; a un impact variable suivant l'objectif

Approche générale

La fouille de données textuelles passe par plusieurs étapes:

1. La **collecte des données textuelles**: identification des sources, récupération des contenus à partir des sources, extraction des textes (par ex. une page HTML peut contenir d'autres composants : scripts Javascript, menus...)
2. Le **pré-traitement des données textuelles**: uniformisation du codage, élimination éventuelle de certains caractères spéciaux (sauts de lignes, symboles, etc. suivant l'objectif), « traduction » de langage SMS...
3. L'**extraction d'entités primaires**: mots, éventuellement locutions nominales (« chemin de fer »), verbales (« arrondir les angles »)...
4. L'**étiquetage grammatical** ou étiquetage morpho-syntaxique (*part-of-speech tagging* ou *POS tagging*).
5. L'**extraction d'entités nommées**: noms de personnes, de lieux (« Mont Blanc »), d'organisations, dates...

Approche générale

6. Analyse syntaxique (générale ou spécifique) : identification de la négation (→ distinction entre affirmation et négation), « quantification » des adverbes (ex. « très abouti / plus ou moins abouti / peu abouti »)
7. Extraction d'informations : suppression des « mots ignorés » (stop words) ; mise en relation avec des schémas d'interprétation
8. Lemmatisation ou racinisation : remplacer chaque mot (par ex. « pensons ») par sa forme canonique (« penser ») ou par sa racine (« pense ») ; peuvent engendrer des confusions (par ex. « organ » pour « organe » comme pour « organisation »)
9. Représentation vectorielle des textes : pondération $tf*idf$, décomposition en valeurs singulières (analyse sémantique latente, LSA), analyse sémantique explicite (ESA)...
10. Développement de modèles sur la base du contenu textuel seul ou en ajoutant des variables quantitatives et nominales
11. Utilisation des modèles développés et évaluation des résultats.

Principales opérations



Collecte et pré-traitement des données textuelles

1. **Identification des sources** : possible de regrouper des données issues de plusieurs sources
 - **Textes bien formés** : suite de phrases structurées mais conformité grammaticale variable
 - **Mots-clés, tags** : simples listes de mots, en général courtes, parfois bruitées
 - **Transcription de SMS** : fautes de frappe ou de sélection, émoticônes, langage codé, expressions ad-hoc
 - **Transcription à partir de séquences audio** : difficile, nombreuses erreurs ; meilleurs résultats si connexion entre transcription et modèles de langage, ou word-spotting, ou directement extraction d'informations suivant schémas
2. **Récupération des contenus à partir des sources** : outils variés suivant les sources
3. **Extraction des données textuelles** : outils configurables pour la suppression d'autres contenus (par ex. scripts, menus...)
4. **Pré-traitements** : uniformisation du codage, élimination de certains caractères spéciaux (sauts de lignes, symboles, suivant l'objectif), traduction de langage SMS

Extraction d'entités primaires

- Entités primaires : mots simples ou composés (« chauve-souris »), ponctuation, éventuellement locutions nominales (« chemin de fer »), verbales (« arrondir les angles »)...
- Outil de segmentation (tokenizer) : utilise des règles (dépendantes de la langue) et un lexique
- Lexique : ensemble des lemmes (~mots) d'une langue et/ou d'un domaine particulier
 - Informations additionnelles : morphologiques (formes possibles, à partir de racine et suffixes, préfixes), parfois syntaxiques
 - Peut souvent être enrichi par des lemmes et des locutions spécifiques au domaine
- L'extraction de certaines locutions peut exiger des traitements plus complexes que la recherche dans un lexique

Extraction d'entités primaires

- Les lemmes extraits ne sont pas toujours directement associables à des concepts.
 - Synonymie : un concept associé à plusieurs lemmes différents (par ex. voiture et automobile)
 - Homonymie : un lemme associé à plusieurs concepts différents (par ex. avocat)
- Les relations entre concepts (sorte_de, partie_de...) sont définies dans des ontologies, qui incluent aussi des informations sur l'expression des concepts par des lemmes (dans une langue particulière).
- L'identification des concepts associés aux lemmes passe par une étape parfois difficile de désambiguïsation.

Étiquetage grammatical *(part-of-speech tagging ou POS tagging)*

- Caractérisation grammaticale de chaque composante du texte par une catégorie lexicale (ex. nom commun, nom propre, verbe, adverbe...), le genre, nombre, mode, temps, etc. ; souvent par analyse superficielle
- Ex. : **TreeTagger** peut **apprendre** des règles à partir d'exemples (<http://www.cis.uni-muenchen.de/~schmid/tools/TreeTagger/>)

La	DET :ART	le
fouille	NOM	fouille
de	PRP	de
données	NOM	donnée
peut	VER :pres	pouvoir
être	VER :infi	être
définie	VER :pper	définir
comme	ADV	comme
le	DET :ART	le
"	PUN :cit	"
Processus	NOM	processus
d'	PRP	de
...		

Extraction d'entités nommées, résolution référentielle

- Entité nommée = élément du langage qui fait référence à une entité unique, appartenant éventuellement à un domaine spécifique
 - Exemples : noms de personnes (« Barack Obama Jr. »), de lieux (« Mont Blanc »), d'organisations (« Mouvement international de la Croix-Rouge et du Croissant-Rouge », « ICRC »), dates...
 - Approches : règles explicitement définies, apprentissage à partir d'un corpus annoté, approches hybrides
- Difficultés :
 - polysémie (« Washington » → la ville ou l'état ou la personne ?),
 - métonymie (nommer un objet par le nom d'un autre exp. : « l'Elysée » → la présidence de la République Française ou le palais ?) ⇒ le contexte doit être pris en compte
 - Exemple d'outil qui exploite DBpedia : <http://www.nuxeo.com/blog/mining-wikipedia-with-hadoop-and-pig-for-natural-language-processing/>
 - **Résultats** : extraction correcte d'env. 90% des entités nommées (si des ressources adaptées sont disponibles)

Analyse syntaxique

- **Complète** : mettre en évidence la structure hiérarchique des phrases d'un texte (⇒ ensemble d'arbres syntaxiques)
 - Difficultés : mots hors lexique, structures non répertoriées par la grammaire, diverses formes d'ambiguïté
 - ⇒ analyse « robuste » : proposer une analyse pour chaque élément et peu d'analyses alternatives
 - ⇒ souvent analyse « de surface » qui ne met pas en évidence la structure complète et ne cherche pas à enlever toute ambiguïté ; extraction de **chunks** (groupes nominaux, groupes verbaux) et de relations simples entre eux
- **Partielle** : traiter des fragments spécifiques, qui présentent des constructions simples et avec peu de variabilité
 - Identification de la négation (→ distinction entre affirmation et négation)
 - Analyse limitée au voisinage de certains lemmes répertoriés (ex. entités nommées)
 - Traitement de certains adverbes (ex. « très utile / plus ou moins utile / peu utile »)

Extraction d'informations

- Objectif : extraire d'un texte des éléments ciblés par rapport à l'application ;
exemples :
 - Faits : « Tôt le 25 avril 1974, au Portugal, des capitaines en rupture avec le système de Salazar se révoltent et prennent le pouvoir. »
Avis : « J'ai été terriblement déçu par ce roman. Je trouvais l'écriture fade et le style pseudo-éthérique très agaçant. »
- Approche générale : mise en relation avec des schémas d'interprétation (ou patrons sémantiques)
 - {Fait : événement politique}{Où : Portugal}{Quand : 25/04/1974}{Qui : forces armées}{Nature : prise de pouvoir}}
- Approche :
 - Définition du lexique et des entités nommées spécifiques, des schémas d'interprétation, des règles d'inférence spécifiques
 - Étiquetage grammatical, extraction d'entités nommées, résolution référentielle, analyse syntaxique locale, règles d'inférence issues d'une ontologie ou définies spécifiquement, règles pragmatiques (ex. mise en forme)...

Lemmatisation ou racinisation


- Objectif : représentation unique pour les formes fléchies d'un même lemme
- Racinisation :
 - Remplacer un mot (par ex. « pensons ») par sa racine (« pense »)
 - En général basée sur des règles et un lexique
 - Peut engendrer des confusions, par ex. « mange » pour « mangeable » comme pour « immangeable », « organ » pour « organe » comme pour « organisation »)
- Lemmatisation :
 - Remplacer un mot (par ex. « pensons ») par sa forme canonique (« penser »)
Basée sur l'analyse lexicale, utilise l'étiquetage grammatical
- Racinisation suffisante pour l'anglais, lemmatisation mieux adaptée au français

Représentation vectorielle des textes

- Objectif : pouvoir manipuler des données textuelles avec les nombreux outils disponibles pour les espaces vectoriels
- Au préalable, possible suppression des « mots ignorés » (stop words) : prépositions, conjonctions, articles, verbes auxiliaires...
 - L'ensemble des mots à ignorer peut dépendre de l'objectif de l'analyse !
 - Doit être appliquée seulement après l'extraction de locutions (ex. « chemin de fer »)
- Principe : affecter une dimension de l'espace à chaque lemme trouvé dans la base de documents → chaque texte (document, requête) est représenté par un vecteur de (très) grande dimension, (très) creux :

Représentation vectorielle des textes

- Comparaison des vecteurs avec la distance cosinus : la norme du vecteur étant proportionnelle à la longueur du texte, mieux vaut mesurer l'angle entre vecteurs que la distance euclidienne
- Evolutions de la représentation vectorielle de base : pondération TF-IDF, sélection de mots (test du χ^2), analyse sémantique latente (LSA), analyse sémantique explicite (ESA), Word2Vec [9, 10]...



Construction de la matrice Documents Termes

Transformation d'une collection de textes en un tableau de données
Sans nécessiter de connaissances particulières sur le domaine étudié


REPRÉSENTATION « BAG-OF-WORDS »



Petit rappel sur les principales notions




- Document = individu statistique



- Corpus = « Base » d'apprentissage = collection de documents

Enjeu : traduire la collection de documents en un tableau de données « attributs-valeurs » propice au traitements à l'aide des algorithmes de data mining, *en minimisant au possible la perte d'information.*



N°	V1	V2	V3	...
1				
2		?		
3				
4				
5				

1. Que mettre en colonnes (V1, V2,...) ?
2. Quelles valeurs mettre dans le tableau ?

La représentation bag-of-words [BOW] (Sac de mots)

Plusieurs étapes :

1. Repérer les mots (*tokens*) présents dans les documents
2. Qui vont constituer le dictionnaire
3. Les mots deviennent des descripteurs (features, *termes*)
4. On associe alors l'absence ou la présence des mots à chaque document

L'identification du délimiteur de mots est important. Ce sera souvent l'espace, les ponctuations,... Certains caractères sont moins évidents (ex. « - » dans « écart-type »)

Potentiellement, le nombre de mots est très important. Il peut y avoir des redondances dans le dictionnaire, il faudra pouvoir les traiter (parfois évidentes : voiture vs. voitures ; parfois moins : voiture vs. automobile...).

Ca peut être aussi le nombre d'apparition des mots, ou autre type de valeurs. On parle de *pondération*.

La représentation bag-of-word – Un exemple

4 documents (Coelho & Richert, 2015 ; page 55, légèrement modifiée) :

1. Imaging databases can get huge.
2. Most imaging databases save images permanently.
3. Imaging databases store images baby.
4. Imaging databases store images. Imaging databases store images.

Documents

Termes

Document	imaging	databases	can	get	huge	most	save	images	permanently	store	baby
1	1	1	1	1	1	0	0	0	0	0	0
2	1	1	0	0	0	1	1	1	1	0	0
3	1	1	0	0	0	0	0	1	0	1	1
4	3	3	0	0	0	0	0	3	0	3	0

- La ponctuation « . » a été retirée.
- « » a joué le rôle de délimiteur.
- 4 documents 4 lignes dans le tableau
- Le dictionnaire est composé des termes présents dans le corpus : {imaging, databases, can, get, huge, most, save, images, permanently, store}.
- La taille du dictionnaire n'est pas connue à l'avance.
- Le nombre de valeurs non nulles dans la ligne dépend de la longueur du document.

Complément du « bag-of-words »

- D'autres informations peuvent compléter la représentation bag-of- words dans la construction de la matrice des données.
- Utilisation d'une base de données lexicale: Répertorier, classifier et mettre en relation le contenu sémantique et lexical d'une langue (ex. WORDNET pour la langue anglaise) (Wikipédia).

Synset


Les synset (synonym set) correspondent à des groupes de mots interchangeables. Ex. en anglais : car, automobile, machine, motorcar, etc. Dans la représentation bag-of-word, ils permettent de réduire considérablement la dimensionnalité.

Ontologies (Arbres de concepts)

- car, auto, automobile, machine, motorcar motor vehicle, automotive vehicle
 - vehicle
 - conveyance, transport
 - instrumentality, instrumentation
 - artifact, artefact
 - object, physical object
 - entity, something

Part of speech (POS)

- Le schéma BOW fait partie du NLP, mais on peut aller encore plus loin en exploitant les connaissances que nous pouvons avoir sur le langage naturel. Ex. Part of speech (POS) se propose de distinguer les mots d'une phrase selon leurs catégories lexicales (ex. nom, verbe, adjectif, préposition, etc.).



- On peut utiliser des bibliothèques prédéfinies. Mais on peut aussi tagger les mots par apprentissage [part-of-speech tagging]. En effet, il peut être spécifique à un domaine. Ex. « porte » peut venir du verbe « porter », comme désigner une « porte ». Dans la menuiserie, on a plus de chances d'être dans le second cas.
- Ex. La bibliothèque NLTK (Python) peut construire le système de classement à partir d'un **corpus** où les termes ont été annotés.

Parsing


- La décomposition de la phrase peut enrichir la compréhension du rôle des mots. En effet, elle (la phrase) obéit à une certaine organisation.



- On comprend sans ambiguïté que « porte » est un nom dans ce contexte.
- On comprend aussi que Clémence correspond à un nom propre. A la différence de son rôle dans « Je demande la clémence pour les cancre ».

Word sense disambiguation

- L'objectif est d'associer le sens adéquat à un mot en fonction du contexte dans lequel nous nous situons.



Robert est poli.

Le meuble est poli.

- Dans une représentation en BOW, le terme « poli » peut avoir des sens différents, on ne peut pas l'utiliser tel quel.
- Une approche possible consiste à appliquer un algorithme supervisé de data mining sur un corpus où le sens des termes a été annoté manuellement par un expert.

La matrice documents-termes (MDT) possède des spécificités

- Les valeurs du tableau sont toujours positives ou nulles. On se concentre sur les occurrences positives des termes (ex. avec les règles d'association).
- Les descripteurs (colonnes) sont exprimés dans les mêmes unités. Il n'y a pas de normalisation ou de standardisation des variables à effectuer.
- Certains termes sont présents dans peu de documents. Ou certains documents sont composés de peu de termes. De très nombreuses valeurs sont nulles.
- Mais les descripteurs sont issus des termes présents dans le corpus, une colonne composée exclusivement de la valeur 0 ne peut pas exister (sauf pondération TF-IDF)
- Il n'y a jamais de données manquantes (N/A). Un terme est forcément soit absent, soit présent dans un document.

Réduction de la dimensionnalité

- **Problème:** La dimensionnalité est souvent très élevée. Le nombre de colonnes peut excéder le nombre de lignes. Problème pour les algorithmes de data mining souvent (ex. calcul de la matrice variance covariance). La réduction de la dimensionnalité est un enjeu crucial.
- **Pistes des solutions:**
 - Quelles pistes pour réduire la dimensionnalité (réduire la taille du dictionnaire) ?
 - Nettoyage du corpus (ex. retrait des chiffres, correction orthographique, harmonisation de la casse, ...)
 - Certains mots ne sont pas intrinsèquement porteurs de sens (ex. most) → stopwords
 - Certains mots sont issus de la même forme canonique (lemmatisation) ou partagent la même racine (stemming) (ex. imaging vs. images)
 - Certains mots sont synonymes ou recouvrent le même concept (ex. store vs. save)
 - Certains mots apparaissent très souvent, d'autres très rarement (filtrage sur les fréquences)

Réduction de la dimensionnalité

- Dans l'idéal, on connaît les prétraitements à réaliser, on connaît **la liste des mots pertinents**. Tout devient facile.
- Sauf situations très particulières, ce type de stratégie est impraticable sur des grands corpus.
- Le nombre de 0 dans la table a été réduit de manière drastique.

Pondération binaire

- Comptabiliser la présence de chaque terme dans le document, sans se préoccuper du nombre d'occurrences (de la répétition).
- Avantages
 - Simplicité
 - Forme de « lissage » de l'information en donnant la même importance à tous les termes
 - Adaptée à certaines techniques (ex. règles d'association) et mesures de distance (ex. Jaccard)
 - Ex. de règle d'association : Si databases & store Alors image (support : 0.75 ; confiance : 1.0)
- Inconvénients
 - Une partie de l'information n'est pas captée (perte d'information), dont pourrait tirer profit certaines catégories de techniques statistiques
 - Pourquoi donner la même importance à tous les termes ?

Fréquence des termes (TF : Term frequency)

- Pour un document, comptabiliser le nombre d'occurrence des termes. Indicateur de l'importance du terme dans le document.

1. image databases can get huge
2. most image databases store image permanently
3. image databases store image baby
4. image databases store image image databases
store image image databases store image



Document	databases	huge	image	permanently	store
1	1	1	1	0	0
2	1	0	2	1	1
3	1	0	2	0	1
4	3	0	6	0	3

- **Avantages**

- On capte plus d'information, la répétition d'un terme dans le document est prise en compte
- Des techniques savent prendre en compte ce type d'information (calcul matriciel)

- **Inconvénients**

- Les écarts entre documents sont exagérés (ex. si on utilise une distance euclidienne)
- On ne tient pas compte de la prévalence des termes dans l'ensemble des documents (cf. IDF)

Inverse document frequency (IDF)

- Un terme présent dans presque tout le corpus (D) influe peu quand il apparaît dans un document. A l'inverse, un terme rare apparaissant dans un document doit retenir notre attention. L'IDF mesure l'importance d'un terme dans un corpus.

$$idf(t, D) = \log_{10} \frac{N}{n_t}$$

N : nombre de documents dans le corpus

n_t : nombre de documents où le terme apparaît

Document	databases	huge	image	permanently	store
1	1	1	1	0	0
2	1	0	2	1	1
3	1	0	2	0	1
4	3	0	6	0	3
n_t	4	1	4	1	3
idf(t,D)	0.000	0.602	0.000	0.602	0.125

« *databases* » et « *image* » sont des termes « évidents » qui ne peuvent pas servir à la différenciations des documents.

Le filtrage sur les fréquences permet d'éviter l'influence exagérée des termes très rares.

Pondération TF-IDF

- Relativiser l'importance d'un terme dans un document (TF) par son importance dans le corpus (IDF).

$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \times \text{idf}(t, D)$$

Dans sa forme la plus utilisée
(mais des variantes sont possibles)

$$\text{tfidf}(t, d, D) = f_{t,d} \times \log_{10} \frac{N}{n_t}$$

Le TF-IDF d'un terme dans un document est élevé quand :

Le terme apparaît beaucoup dans le document.

Il se fait rare par ailleurs.



Document	databases	huge	image	permanently	store
1	0.00	0.60	0.00	0.00	0.00
2	0.00	0.00	0.00	0.60	0.12
3	0.00	0.00	0.00	0.00	0.12
4	0.00	0.00	0.00	0.00	0.37

MESURER LES SIMILARITÉS



Mesures de similarité / dissimilarité en text mining

- Les mesures de similarité sont sous-jacents à de nombreuses méthodes de data mining (visualisation, classification supervisée et non supervisée). Elles caractérisent les ressemblances entre les objets.

Dans le cas particulier du text mining, nous devons mesurer des similarités entre documents

1. image databases can get huge
2. most image databases store image permanently
3. image databases store image baby
4. image databases store image image databases store image image databases store image

Dans quelle mesure les documents 1 et 2 se ressemblent ?

Documents qui ont été traduits en vecteurs de pondération (feature vector)

Document	databases	huge	image	permanently	store
1	1	1	1	0	0
2	1	0	2	1	1
3	1	0	2	0	1
4	3	0	6	0	3

Sachant que les calculs doivent être effectués à partir des valeurs fournies par la matrice documents-termes.


Catégorisation de texte - Problématique

- L'objectif de la catégorisation de textes est de pouvoir associer automatiquement des documents à des classes (catégories, étiquettes, index) prédéfinies. Nous nous plaçons dans le cadre de l'apprentissage supervisé.

Catégorisation de textes – Représentation « bag of words »

- La solution la plus simple consiste à s'appuyer sur la représentation en sac de mots pour obtenir une présentation tabulaire des données, propice à l'utilisation des algorithmes usuels de data mining.

Catégorisation de textes - Processus



Représentation de documents en sac de mots (bag of words) – critique

- La représentation en sac de mots ne tient pas compte des positions relatives de mots dans les documents.

(0) condition du bien etre
(1) etre important
(2) solution bien etre
(3) important bien etre



	bien	condition	du	etre	important	solution
(0)	1	1	1	1	0	0
(1)	0	0	0	1	1	0
(2)	1	0	0	1	0	1
(3)	1	0	0	1	1	0



La contextualisation de « bien » par « être » (ou l'inverse d'ailleurs) est importante, ils sont souvent « voisins ». La représentation en sac de mots passe à côté (les algos de machine learning ne verront que la co-occurrence, c'est déjà pas mal - ex. topic modeling)

L'ALGORITHME WORD2VEC

- « word2vec » est une technique de « word embedding » basée sur un algorithme de deep learning.
- L'objectif est de représenter les termes d'un corpus à l'aide d'un vecteur de taille K (paramètre à définir, parfois des centaines, tout dépend de la quantité des documents), où ceux qui apparaissent dans des contextes similaires (taille du voisinage V , paramètre à définir) sont proches .
- De la description des termes, nous pouvons dériver une description des documents, toujours dans un espace de dimension K . Possibilité d'appliquer des méthodes de machine learning par la suite (ex. catégorisation de documents).
- $K \ll$ taille du dictionnaire : nous sommes bien dans la réduction de la dimensionnalité (par rapport à la représentation « bag-of-words » par exemple.).
- Il existe des modèles pré-entraînés sur des documents (qui font référence, ex. Wikipedia ; en très grande quantité) que l'on peut directement appliquer sur nos données (ex. Google Word2Vec ; Wikipedia2Vec)



Questions ??