

Big Data Mining

Préparé par: Mme. Olfa DRIDI



Plan

01 Introduction

Data mining & big data

02 Passage à l'échelle

Réduction de la complexité

03 Text Mining

Fouille de textes

04 Web Mining & analyse de sentiments

De la fouille de données à la fouille du Web

05 Fouille de graphes & réseaux sociaux

06 Systèmes de recherche d'information

07 Systèmes de recommandation

Qu'est ce que la recherche d'information

- La *Recherche d'Information* (RI, *Information Retrieval*, *IR* en anglais) consiste à trouver des *documents* peu ou faiblement structurés, dans une grande *collection*, en fonction d'un *besoin d'information*. Le domaine d'application le plus connu est celui de la recherche “plein texte”. Étant donné une collection de documents constitués essentiellement de texte, comment trouver les plus pertinents en fonction d'un besoin exprimé par quelques mots-clés?
- La RI développe des *modèles* pour interpréter les documents d'une part, le besoin d'information d'autre part, en vue de faire correspondre les deux, mais aussi des *techniques* pour calculer des réponses rapidement même en présence de collections très volumineuses.
- Des systèmes de recherche d'information (SRI) (exemple de SRI: “moteurs de recherches”) fournissent des solutions sophistiquées prêtes à l'emploi.

Définition de la RI

Une définition


La **Recherche d'Information** (*Information Retrieval*, IR) consiste à trouver des **documents** peu ou faiblement structurés, dans une grande **collection**, en fonction d'un **besoin d'information**.

- Recherche sur le Web. Utilisée quotidiennement par des milliards d'utilisateurs.
- Recherche dans votre boîte mail.
- Recherche sur votre ordinateur (*Spotlight*).
- Recherche dans une base documentaire, publique ou privée.

Définition de la RI

- En RI, les données, ou « documents », sont souvent hétérogènes, de provenances diverses, présentent des irrégularités et des variations dues à l'absence de contrainte et de validation au moment de leur création.
- De plus, un système de RI est souvent utilisé par des utilisateurs non-experts.
- À la difficulté d'interpréter le contenu des documents et de le décrire s'ajoute celle de comprendre le « besoin », exprimé souvent de manière très partielle.

Étapes de la RI



Terme et vocabulaire

- Nous utilisons progressivement la notion de *terme* (*token* en anglais) qui est un peu différente de celle de « mot ».
- Un terme est soit un mot, soit une séquence de mots (une *phrase*) placée entre apostrophes.
- Le *vocabulaire*, parfois appelé *dictionnaire*, est l'ensemble des termes sur lesquels on peut poser une requête.

Acteurs de la RI

Collection :

un ensemble de documents



Utilisateur :

un besoin
d'information
et/ou une tâche
à accomplir



Système de RI : l'outil qui doit
retrouver les documents
pertinents pour le besoin de
l'utilisateur



Diversité des besoins d'information

➤ Recherche d'un **élément connu**

L'utilisateur sait exactement quels éléments il recherche.

- Il sait reconnaître les éléments désirés s'il les voit.

Exemple: recherche d'une citation bibliographique précise.

Bases de données (SQL, XQuery, etc.)

➤ Recherche d'une **information générale**

- L'utilisateur recherche une information sur un sujet en général. Il existe de nombreuses façons de décrire le sujet.
- Cette information peut ne satisfaire l'utilisateur.
- Il est possible que l'information pertinente ne soit pas reconnue
- Que de façon partielle.

Diversité des besoins d'information

➤ Recherche d'une **information précise**

L'utilisateur recherche une information spécifique mais ignore sous quelle forme elle se présente.

- Réponse partielle impossible

– *Exemple: À quelle date le président Kennedy a-t-il été assassiné?*

➤ **Extraction d'information** et **systèmes de question-réponse**

➤ **Exploration**

Le but n'est pas de répondre à une question en particulier, mais de parcourir l'ensemble des données pour découvrir quels types d'informations concernant un sujet ou un domaine sont présents.

➤ **Navigation**

Diversité des sources d'information

- Emplacement des informations
 - Ressources locales ou distantes
 - Problèmes: disponibilité, identification, répartition sur plusieurs sources, variabilité des formats (encodage des caractères et description du contenu)
- Nature des fichiers de ressources
 - **Bases de données**: formats bien décrits, langages d'interrogation non ambigus (ex : SQL pour les bases de données relationnelles)
 - **Fichiers annotés** : formats plus ou moins bien décrits, annotations de présentation et/ou de description sémantique du contenu, langages d'interrogation (ex : XSLT/XPath pour les fichiers XML)
 - **Fichiers textes** : formats très peu ou pas décrits, langue(s) connue(s) ou non, plus ou moins de régularité entre les documents d'une même classe, pas d'interprétation générique possible (problème du Traitement Automatique des Langues)

Diversité des problèmes

✓ Difficultés d'**accès**, **couverture**, **temps de traitement** –

- Les bases documentaires sont très grandes, réparties sur de nombreux supports dans des endroits différents



✓ Difficultés de définition de la **pertinence**

- Comment un document remplit-il le besoin informationnel d'une personne donnée ?
- Quelle est sa pertinence? Comment la mesure-t-on?



✓ Difficulté d'**exploitation**

- Les documents pertinents ne sont pas nécessairement dans la langue de la requête.
- L'information recherchée n'est pas nécessairement clairement identifiable dans un document.



Evolutions de la RI

Précédemment :

- Bases documentaires structurées et de petite taille
- Accès par des métadonnées et rarement par le texte intégral
- Utilisation de langages documentaires (constraints) par les spécialistes




Aujourd'hui

- Documents multimédias sous forme électronique
- Nombreux formats de représentation (texte brut, HTML, XML, PDF, RTF, formats propriétaires...)
- De plus en plus de données non structurées
- Une masse d'information gigantesque (Web...)
- Une composante sociale

Un exemple de besoin



Un moteur de recherche bien connu



Google

avocat

Tous Images Actualités Maps Vidéos Plus Paramètres Outils

Environ 52 200 000 résultats (0,74 secondes)

Avocat (fruit) — Wikipédia
[https://fr.wikipedia.org/wiki/Avocat_\(fruit\)](https://fr.wikipedia.org/wiki/Avocat_(fruit)) ▼
Cet article ne cite pas suffisamment ses sources (janvier 2017). Si vous disposez d'ouvrages ou d'articles de référence ou si vous connaissez des sites web de ...
[Description](#) · [Variétés](#) · [Marché mondial](#) · [Utilisation dans l...](#)

Avocat (métier) — Wikipédia
[https://fr.wikipedia.org/wiki/Avocat_\(métier\)](https://fr.wikipedia.org/wiki/Avocat_(métier)) ▼
Représentation d'un **avocat** français au début du XX^e siècle. Appellation. **Avocat**. Secteur d'activité. Justice - Droit. Compétences requises. Bac+6, Master.
Professions voisines: [Juriste d'entreprise](#) - [Not...](#) **Niveau de formation:** Universitaire (Master en ...
Secteur d'activité: [Justice](#) - [Droit](#) **Compétences requises:** [Bac+6](#), [Master](#)

Annuaire | Ordre des avocats de Paris
www.avocatparis.org/annuaire ▼
Accueil Annuaire. Annuaire. Voir l'annuaire international. La grande bibliothèque du droit · Barreau de Paris Solidarité · [Avocats Actions Conjointes](#) · [L'...](#)

E-barreau | Ordre des avocats de Paris
www.avocatparis.org/e-barreau ▼
1 déc. 2016 - A ce titre, il permet l'échange d'actes de procédure civile et pénale, dans le strict respect des dispositions légales. Les **avocats** peuvent alors, ...

Annuaire des avocats de France | Conseil national des barreaux
<https://www.cnb.avocat.fr/fr/annuaire-des-avocats-de-france> ▼
Vous êtes **avocat** et constatez une anomalie sur votre fiche ? Les données présentées sur cet annuaire proviennent directement des informations enregistrées ...

Virgile Amaudric du Chaffaut - Cabinet d'Avocat à Paris
[Annonce](#) www.vadc-avocat.com/Avocat ▼
Avocat en Droit du Travail, Droit Pénal, Droit des Affaires et Droit Civil.
information, transparence · défense, stratégie · écoute, disponibilité · conseil, anticipation
[Droit du Travail](#) · [Droit Civil et Familial](#) · [Droit Pénal](#) · [Droit des Affaires](#)
📍 37 Quai des Grands Augustins, Paris

Le Bouard Avocats - Cabinet d'Avocats à Versailles
[Annonce](#) www.lebouard-avocats.fr/ ▼
Avocats spécialisés en droit commercial, des affaires et droit du travail
Fondé En 1977 · Pro. Expérimentés · Service Performant · Gestion Électronique

Évaluation d'un moteur de recherche



Google avocat

Tous Images Actualités Maps Vidéos Plus Paramètres Outils

Environ 52 200 000 résultats (0,74 secondes)

Avocat (fruit) — Wikipédia
[https://fr.wikipedia.org/wiki/Avocat_\(fruit\)](https://fr.wikipedia.org/wiki/Avocat_(fruit)) ▼
Cet article ne cite pas suffisamment ses sources (janvier 2017). Si vous disposez d'ouvrages ou d'articles de référence ou si vous connaissez des sites web de ...
Description · Variétés · Marché mondial · Utilisation dans l ...

Avocat (métier) — Wikipédia
[https://fr.wikipedia.org/wiki/Avocat_\(métier\)](https://fr.wikipedia.org/wiki/Avocat_(métier)) ▼
Représentation d'un avocat français au début du XX^e siècle. Appellation. Avocat. Secteur d'activité. Justice - Droit. Compétences requises. Bac+6, Master.
Professions voisines: Juriste d'entreprise - Not... Niveau de formation: Universitaire (Master en ...
Secteur d'activité: Justice - Droit Compétences requises: Bac+6, Master

Annuaire | Ordre des avocats de Paris
www.avocatparis.org/annuaire ▼
Accueil Annuaire. Annuaire. Voir l'annuaire international. La grande bibliothèque du droit · Barreau de Paris Solidarité · Avocats Actions Conjointes · L' ...

E-barreau | Ordre des avocats de Paris
www.avocatparis.org/e-barreau ▼
1 déc. 2016 - A ce titre, il permet l'échange d'actes de procédure civile et pénale, dans le strict respect des dispositions légales. Les avocats peuvent alors, ...

Annuaire des avocats de France | Conseil national des barreaux
<https://www.cnb.avocat.fr/fr/annuaire-des-avocats-de-france> ▼
Vous êtes avocat et constatez une anomalie sur votre fiche ? Les données présentées sur cet annuaire proviennent directement des informations enregistrées ...

Virgile Amaudric du Chaffaut - Cabinet d'Avocat à Paris
www.vadc-avocat.com/Avocat ▼
Avocat en Droit du Travail, Droit Pénal, Droit des Affaires et Droit Civil.
Information, transparence · défense, stratégie · écoute, disponibilité · conseil, anticipation
Droit du Travail · Droit Civil et Familial · Droit Pénal · Droit des Affaires
📍 37 Quai des Grands Augustins, Paris

Le Bouard Avocats - Cabinet d'Avocats à Versailles
www.lebouard-avocats.fr/ ▼
Avocats spécialisés en droit commercial, des affaires et droit du travail
Fondé En 1977 · Pro. Expérimentés · Service Performant · Gestion Électronique

Avocat fonction publique - Demandez un devis
www.bruno-roze-avocat.com/ ▼
Intervention en conseil et contentieux pour les trois fonctions publiques

Fonctionnalités avancées



WIKIPÉDIA
L'encyclopédie libre

[Accueil](#)
[Portails thématiques](#)
[Article au hasard](#)
[Contact](#)

[Contribuer](#)

[Débuter sur Wikipédia](#)
[Aide](#)
[Communauté](#)
[Modifications récentes](#)
[Faire un don](#)

[Outils](#)

[Importer un fichier](#)
[Pages spéciales](#)
[Version imprimable](#)

[Langues](#) 

Page spéciale

Rechercher

[Aide pour la recherche](#)

 avocat



Rechercher

Avocat

Avocat (métier)

Avocat en France

Avocat (fruit)

Avocatier

Avocat aux conseils

Avocats sans frontières France

Avocats et Associés

Avocat général (France)

Avocat général pour l'Angleterre et le pays de Galles

[Cookies](#) [Version mobile](#)

ECommerce : recherche à facettes

Le Marché

Produits frais

Fruits & Légumes

Boucherie

Surgelés

Epicerie

Boissons

Cave

Hygiène & Beauté

Entretien

Animaux

Bébé

Petit électro

Maison & Déco

[Retour](#)

RÉSULTAT DE MA RECHERCHE

15 résultat(s) pour "avocat"

Trier par : - cher au + cher ▼

Affichage :   

J'AFFINE MA RECHERCHE :

Boutique

Hygiène & Beauté (5)

Le Marché (5)

Casher (2)

Epicerie (2)

Produits frais (1)

Prix

Moins de 5€ (10)

5 - 10€ (4)

10 - 20€ (1)

Marque

Garnier - Ultra Doux (4)

Cora (2)

Reyes Gutierrez (2)



360°

1,99€
6,63€/Kg

Cora

Salsa saveur avocat doux
300g

- 1 +

Acheter

Epicerie > [...] > Tex-Mex



Début de saison



2,00€
2,00€/pièce

♥♥♥♥♥

Avocat Hass
Reyes Gutierrez
À laisser mûrir
1 pièce à laisser mûrir

- 1 +

Acheter

Le Marché > [...] > Avocat



Début de saison



2,49€
2,49€/pièce

Avocat Hass
Reyes Gutierrez
Prêt à déguster
1 pièce prêt à déguster

- 1 +

Acheter

Le Marché > [...] > Avocat



360°

2,80€
11,20€/L

Green Juices

Jus Avocat Pomme Poire Co...
250ml
DLC : dim. 26 nov. 17

- 1 +

Acheter

Produits frais > [...] > Bien être, Smoot

18

Évaluation d'un moteur de recherche

Deux notions importantes

- **Faux positifs** : ce sont les documents **non pertinents** inclus dans le résultat; ils ont été sélectionnés à tort.
 - **Faux négatifs** : ce sont les documents **pertinents** qui **ne sont pas** inclus dans le résultat.
-
- La recherche plein texte est susceptible de récupérer beaucoup de faux positifs.
 - La récupération de documents non pertinents est souvent provoquée par l'ambiguïté inhérente au langage naturel ;
 - En général, chercher à réduire les faux positifs entraîne l'augmentation des faux négatifs, et réciproquement.

La précision

- La *précision* mesure la proportion des vrais positifs dans le résultat r . Si on note respectivement $t_p(r)$ et $f_p(r)$ le nombre de vrais et de faux positifs dans r (de taille $|r|$), alors

$$\text{précision} = \frac{t_p(r)}{t_p(r) + f_p(r)} = \frac{t_p(r)}{|r|}$$

Une précision de 1 correspond à l'absence totale de faux positifs. Une précision nulle indique un résultat ne contenant aucun document pertinent.


Le rappel

- Le rappel mesure la proportion des documents pertinents qui sont inclus dans le résultat. Si on note $f_n(r)$ le nombre de documents faussement négatifs, alors le rappel est:

$$\frac{t_p(r)}{t_p(r) + f_n(r)}$$

Un rappel de 1 signifie que tous les documents pertinents apparaissent dans le résultat. Un rappel de 0 signifie qu'il n'y a aucun document pertinent dans le résultat.

Illustration des faux-positifs et négatifs



How many selected items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$


How many relevant items are selected?

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$


Performances

- On peut améliorer les performances des moteurs de recherche à l'aide de plusieurs techniques :
 - des requêtes plus structurées
 - requêtes booléennes,
 - expressions rationnelles,
 - proximité,
 - recherche d'expression
 - des résultats classés
 - modèle vectoriel
 - PageRank
 - analyse sémantique latente

Moteurs de recherche

- Moteurs libres
 - Apache Solr (Lucene)
 - ElasticSearch (Lucene)
 - Sphinx
 - Xapian
- Moteurs commerciaux
 - Google Search Appliance
 - Exalead, Qwant
 - Amazon CloudSearch
 - Microsoft Azure Search, Bing

Accès au contenu sémantique



Accès au contenu sémantique

Le texte des pages Web est en langage naturel

- En HTML, le **marquage** (ou **balisage**) existe,
- mais concerne :
 - La **mise en forme** (fonte, taille, couleur)
 - Les **hyperliens**
- Le **contenu sémantique** est accessible aux hommes, mais pas (facilement) aux machines...

Comment rendre le Web "compréhensible" pour libérer l'utilisateur du travail de recherche, d'intégration et d'exploitation des données ?

W3C (World Wide Web Consortium)

- Le W3C, un organisme de **standardisation** à but non lucratif
- Fondé en 1994
- Le but du W3C : promouvoir l'**évolutivité** du Web et l'**interopérabilité** des technologies (HTML, XHTML, CSS, XML, RDF, PNG, SVG, SOAP...).
- Ses **recommandations**:
 - **Ajouter de la sémantique** pour rendre les ressources plus accessibles à des processus automatiques.
 - Attacher aux ressources des **étiquettes** qui les définissent : adjoindre aux données des **métadonnées**.
 - Définir formellement les termes utilisés.
 - Définir des **ontologies** (ensemble de termes et de relations sur un domaine).
 - Développer un **langage** standard pour représenter les ontologies.

Vers une représentation des connaissances...

La Joconde *de Léonard de Vinci*


[Entrer sur le site de La Joconde](#) de leonard de vinci

Bienvenue sur mon site qui a pour but de parler de [la Joconde](#) du célèbre peintre [Léonard de Vinci](#).
J'essaierai de faire un portrait de l'artiste peintre de Vinci et bien entendu de celui de [Mona Lisa](#). Tout le monde sait que [La Joconde est devenue un tableau](#) que l'on pourrait considérer de Mythique, une peinture à l'huile réalisée vers le début du XVIème siècle (peut être en 1503 ou quelques années après).
[Ce tableau est exposé aux musée du Louvre à Paris](#) dirigé par Vincent Pomarède, autrefois sous la responsabilité du conservateur Cécile Scammanez, Il est situé en profondeur à cause de la lumière et de certains photographes qui ne peuvent s'empêcher d'utiliser le Flash, à savoir que la lumière détruit à long terme l'oeuvre...

Cliquez sur le tableau de la Joconde pour entrer dans le site :



Vers une représentation des connaissances...



Web sémantique

Le Web sémantique fournit un modèle qui permet aux données d'être partagées et réutilisées entre plusieurs applications, entreprises et groupes d'utilisateurs



Il permet de donner du sens aux informations.



Il autorise une intégration d'information et des raisonnements.



Un gros travail de représentation des connaissances ou de construction d'un schéma global est nécessaire.



Il manipule des données structurées et non plus du texte.

An abstract geometric pattern consisting of numerous white dots connected by thin white lines, forming a complex, interconnected network that resembles a molecular structure or a data visualization. The pattern is set against a solid blue background.

Questions ??