
Projet

Détection de messages haineux sur Twitter

Objectif du projet :

Développer un modèle de machine learning pour identifier les messages haineux sur Twitter. Le projet mettra l'accent sur le prétraitement des données textuelles et la classification de ces données.

Présentation du projet:

Les discours de haine expriment un comportement antisocial. Dans ce cas, les réseaux sociaux constituent une arène majeure pour la diffusion de discours de haine en ligne. L'analyse manuelle des contenus publiés et leur modération sont impossibles en raison de l'énorme quantité de données circulant sur Internet. Une solution efficace à ce problème serait la détection automatique des commentaires haineux. Les approches proposées pour la détection automatique des discours de haine sont basées sur des représentations du texte sous forme numérique et sur l'utilisation de modèles statistiques.

Travail demandé :

1. Collecte de Données : Utiliser une API Twitter (comme Tweepy) pour collecter des tweets en temps réel, ou utiliser le jeu de données du fichier `DataProject.csv`.
2. Prétraitement des Données : Prévoir une étape de nettoyage des données pour retirer les informations non pertinentes (liens, hashtags, émojis, etc.). Utiliser des techniques de NLP pour le traitement des textes : tokenisation, élimination des mots inutiles, stemming ou lemmatisation, et vectorisation des textes avec TF-IDF, Word2Vec ou BERT.
3. Effectuer une analyse exploratoire des données pour identifier les principaux mots et phrases associées aux messages haineux.
4. Modélisation : Essayer plusieurs modèles de machine learning et deep learning, tels que les modèles de régression logistique, les forêts aléatoires et les SVM.
5. Déterminer les hyper-paramètres à l'aide d'un k-fold stratifié et d'une validation croisée pour obtenir le meilleur modèle.
6. Comparer les performances de ces modèles à l'aide de métriques comme la précision, le rappel, la F1-score, et l'AUC pour déterminer lequel est le plus efficace.
7. Évaluation et Visualisation des Résultats : Créer des visualisations claires pour montrer la proportion de messages haineux détectés, ainsi que des exemples de faux positifs et faux négatifs.

Compte rendu :

Chaque étudiant doit rendre un notebook bien commenté décrivant les différentes étapes réalisées. Le fichier porte le nom et le prénom de l'étudiant.