

## Travaux pratiques n°1

## #Prétraitement de données

**Matière :** Machine Learning 2

**Enseignant :** Taoufik Ben Abdallah

**Discipline :** 2<sup>ème</sup> année Mastère pro Data Science

**Année Universitaire :** 2024-2025 / S1

L'objectif de ce TP est d'explorer et d'étudier les données, ainsi que d'appliquer des techniques de prétraitement sur le jeu de données décrit dans le fichier *titanic.csv*. Ce jeu de données est constitué de 891 observations décrivant 9 attributs (**Sex**, **Age**, **SibSp**, **Parch**, **Ticket**, **Fare**, **Cabin**, **Embarked** et **Survived**).

Le **Tableau 1** montre un extrait du jeu de données *titanic.csv*

| Sex    | Age  | SibSp | Parch | Ticket              | Fare    | Cabin | Embarked | Survived |
|--------|------|-------|-------|---------------------|---------|-------|----------|----------|
| male   | 22.0 | 1     | 0     | A/5 21171           | 7.25    | NaN   | S        | no       |
| female | 38.0 | 1     | 0     | PC 17599            | 71.2833 | C85   | C        | yes      |
| female | 26.0 | 0     | 0     | STON/O2.<br>3101282 | 7.925   | NaN   | S        | yes      |
| female | 35.0 | 1     | 0     | 113803              | 53.1    | C123  | S        | yes      |
| male   | 35.0 | 0     | 0     | 373450              | 8.05    | NaN   | S        | no       |
| male   | NaN  | 0     | 0     | 330877              | 8.4583  | NaN   | Q        | no       |

Tableau 1 : Extrait de jeu de données *titanic.csv*

### Travail à Faire :

- 1/ Charger le jeu de données *titanic.csv* dans une variable nommée **df\_titanic**. Afficher le nombre total d'observations ainsi que les 5 premières lignes de **df\_titanic**
- 2/ Afficher le type de chaque attribut de **df\_titanic** en indiquant le nombre d'observations *non-null* pour chaque attribut
- 3/ Afficher un résumé statistique de toutes les colonnes de **df\_titanic**
- 4/ Déterminer le nombre total de valeurs manquantes (**NaN**) ainsi que celui pour chaque attribut
- 5/ Créer deux listes, **l\_discret** et **l\_num**, qui contiennent respectivement les noms des colonnes avec des valeurs *catégorielles* et *numériques* dans **df\_titanic**
- 6/ Présenter la matrice de corrélation de Pearson entre les différents attributs numériques de **df\_titanic**
- 7/ Représenter les *boxplots* de l'attribut "**Fare**" de **df\_titanic**, en fonction des valeurs de l'attribut numérique qui présente la corrélation la plus élevée. Ensuite, remplir les valeurs manquantes de l'attribut "**Fare**" avec les valeurs appropriées
- 8/ Trier **df\_titanic** en ordre *décroissant* en fonction de l'attribut ayant une forte corrélation positive avec "**Age**". Ensuite, remplir les valeurs manquantes de l'attribut "**Age**" de **df\_titanic** avec les valeurs de la cellule précédente dans la même colonne
- 9/ Remplir les valeurs manquantes de l'attribut "**Cabin**" de **df\_titanic** avec l'élément le *plus fréquent*
- 10/ Supprimer les observations ayant des valeurs manquantes dans l'attribut "**Embarked**" de **df\_titanic**

- 11/ Créer une figure avec **4** axes où chaque ligne comporte 2 axes : chacun de ces axes affiche l'*histogramme de la distribution* d'un attribut catégoriel à partir de **df\_titanic**. Ensuite, supprimer l'attribut ou les attributs *discret(s)* **que vous jugez inutiles** à partir de **df\_titanic**
- 12/ Vérifier que **df\_titanic** ne comporte aucune valeur manquante et traiter les données aberrantes de tous les attributs *numériques* de **df\_titanic**
- 13/ Encoder les valeurs des attributs "**Sex**" (**female**, **male**) et "**Embarked**" (C, Q et S) de **df\_titanic** en valeurs numériques ordinales
- 14/ Afficher un histogramme illustrant la *distribution des âges* de **df\_titanic** selon 4 intervalles, avec une *courbe de densité gaussienne* intégrée dans la même figure. Ensuite, discrétiser les valeurs en utilisant un encodage ordinal, en choisissant la technique appropriée
- 15/ Sélectionner les descripteurs les plus importants à partir de **df\_titanic** en appliquant la technique de la variance, avec un seuil ne dépassant pas 0.1

Bon Travail ♣