

Université de Carthage
FSB - Dép. Info.

MPDS2



Artificial Intelligence

Natural Language Processing

Hela Mahersia
Hela.mahersia@fsb.rnu.tn



Textbooks



Objectifs du module

- ❑ Ce cours est conçu pour présenter aux étudiants, les concepts et les idées fondamentales du traitement du langage naturel (NLP) et pour les mettre au courant des recherches récentes dans le domaine.
- ❑ Il développe une compréhension approfondie des algorithmes disponibles pour le traitement de l'information textuelle.

Contacts

❑ Classroom :

- Natural Language Processing
- Code : [kjccecn](#)

❑ Emails :

- hela.mahersia@fsb.rnu.tn

Chapitre 1:

Introduction au Traitement Automatique des Langues (NLP)



Objectifs du chapitre


- ❑ Comprendre les fondements et l'importance du TAL.
- ❑ Explorer les domaines d'application du TAL dans l'informatique.
- ❑ Examiner les défis spécifiques liés au traitement des langues naturelles.
- ❑ Connaître les quatre niveaux de traitement d'un système TAL
- ❑ Connaître les approches existantes du TAL

Plan

- ❑ Définition du Traitement Automatique des Langues
- ❑ Historique du TAL
- ❑ Applications du TAL
- ❑ Niveaux de traitement d'un système TAL
- ❑ Défis du TAL
- ❑ Approches du TAL

Motivation


- ❑ La langue se compose de plusieurs niveaux de structure
- ❑ Les humains intègrent couramment tous ces éléments dans la production/compréhension du langage.
- ❑ Idéalement, un ordinateur (ou agent intelligent) peut le faire aussi !



Définition du TAL (1/2)

- ❑ Le traitement du langage naturel (Natural Language Processing) fait référence à la branche de l'intelligence artificielle qui vise à donner aux ordinateurs la capacité de comprendre le texte et les mots prononcés de la même manière que les êtres humains.


Le traitement automatique des langues (TAL) étudie la composante langagière de l'intelligence artificielle




Définition du TAL (2/3)

- Composante primordiale dans le **test de Turing**, proposé par Alan Turing en 1950

Un ordinateur réussit le test si l'humain qui a posé au préalable des questions écrites, est incapable de savoir si les réponses écrites proviennent de la machine ou de la personne.



Définition du TAL (3/3)




Ensemble de méthodes et algorithmes visant à reproduire, à l'aide de la machine, la capacité humaine à comprendre et à produire des énoncés linguistiques

~ Alain Turing, 1950


Historique du TAL (1/2)

Avant Deep Learning



Historique du TAL (2/2)

Après Deep Learning





Applications du TAL (1/8)

how do i make a sushi roll

how make a sushi roll

how make a **california** roll

how **to** make a sushi **hand** roll

how **to** make **homemade** sushi roll

how **to** make **simple** sushi roll

About 106,000,000 results (0.55 seconds)

Recipes



Homemade Sushi

Fifteen Spatulas

4.9 ★★★★★ (40)

15 min

Cream cheese, sushi rice, soy sauce, avocado, raw salmon



Easy Sushi Rolls

Gimme Some Oven

No reviews

1 hr

Smoked salmon, sushi rice, soy sauce, spicy mayo, toasted



California Sushi Rolls



Taste of Home

5.0 ★★★★★ (5)


1 hr

Cups sushi rice, black sesame seeds, soy sauce, avocado,

Applications du TAL (2/8)



Applications du TAL (3/8)



Applications du TAL (4/8)



out of sight,
out of mind

out of sight out of mind

Anglais ▼



Français ▼



hors de vue, hors
de l'esprit

Anglais ▼



out of sight, out of mind



Français ▼



Loin des yeux, loin du
cœur

25/5000



entaires

Applications du TAL (5/8)



2.6%

PlagScan Results of plagiarism analysis from 2018-08-23 13:34

Space-and-Exploration.docx

Date: 2018-08-23 13:34



View: * All sources 4



4 matches



Comments 1

* All sources 4

☆ Top three 3

🌐 Internet sources 3

👤 Own documents 1

- ☒ [0] **1.9%** 3 matches Highlight matches in source
 2 documents with identical matches
- ☒ [1] **1.2%** 2 matches Highlight matches in source
 "New_Horizons.pdf" dated 2018-06-15
- ☒ [2] **0.5%** 2 matches Highlight matches in source
<https://www.plagscan.com/diView?7395199>
- ☒ [3] **0.0%** 1 match Highlight matches in source
<http://adc.gsfc.nasa.gov/adc/education/spa>

Legend text highlighting

Aa exact match

Aa possibly altered text

Aa marked as quotation

Applications du TAL (6/8)

Space and Exploration

In recent years of human history, the idea of travelling into space has become a routine operation, no longer that of science fiction fantasies, with the missions being reserved mostly for surveillance, data collection, and research aboard the International Space Station into the effects of space on human growth. While deep exploration has invigorated young minds for generations, there has been little progress in the formulation of a coherent plan to colonize further into our galaxy. **However, certain destructive events may have us thinking differently on the idea of deep space exploration.** Humans are constantly in danger from extraterrestrial threats, such as explosions in 1871, 1908, and 1935, all contributed to surface-impact meteors, almost in a clockwork pattern of 30 years. The Jet Propulsion Laboratory, an extension of NASA, has provided clues as to how exactly these impacts can affect human life, and as such, their research will provide a foundation for the contingency plans discussed in this paper.

While impacts of severe damage and threat only occur in 1,000 year increments, we are also at the mercy of shifting climate patterns due to intervention into the natural system by humans. Our careless use of fossil fuels, combined with our need of life-sustaining resources has advanced the damages of climate change, and stripped our planet of valuable elements. Hurricane Katrina, a high-level natural disaster resulting in nearly 1200 dead and \$100 billion in damage, can effectively be linked to change in climate patterns. According to Andrea Thompson, writer for Climate Central, Hurricane Katrina would have been significantly less damaging in the climate conditions of 1900, a time that, while there was plenty of industrial movement, had not experienced the mass production and technological

Applications du TAL (7/8)



Applications du TAL (8/8)

Publié Le , 16/17 Octobre, 2019



Hala-Mulki/T-HSAB-A-Tunisian-Hate-Speech-...

The first Tunisian Hate Speech and Abusive Dataset



1

Contributor

0

Issues

1

Star

3

Forks



DataSet T-HSAB :

- Analyse des sentiments
- 6024 instances
- 3 classes : Normal / Hate / Abusive

Niveaux de traitement d'un système TAL (1/3)

□ Pour un système TAL, une véritable analyse linguistique nécessite la capacité de :

- reconnaître
- structurer
- comprendre
- contextualiser



- phonologie: les sons (phonèmes) + l'intonation
- morphologie: les mots et leur forme
- syntaxe: l'organisation des mots en phrase
- sémantique: le sens hors contexte
- pragmatique: le sens en contexte



Niveaux de traitement d'un système TAL (2/3)

Traitement morphologique

- Un mot a normalement un seul radical mais peut avoir plusieurs affixes
- Exemple : chanteurs

chant (chant) → radical

eur (celui qui fait)
s (pluriel)


→ affixes




- **préfixe** : se place avant le radical
- **suffixe** : se place près le radical
- **circonfixe** : peut se placer avant ou après le radical
- **infixe** : se place à l'intérieur de le radical

Niveaux de traitement d'un système TAL (3/3)

Traitement syntaxique



The dog did not love a man in the park



<https://corenlp.run>

NEGATIVE

1 the dog did not love a man in the park

Défis du TAL (1/4)


- ❑ Interpréter une phrase correctement est une tâche très complexe à automatiser
 - pour un être humain, c'est une tâche qui ne requière, la plus part du temps, aucun effort
 - mais parfois, certains cas peuvent être très difficile à interpréter

- ❑ Voici quelques sources de difficultés à surmonter par les méthodes de TAL :
 - Ambiguïté
 - Métaphores
 - Variations dans le temps

un système TAL doit être efficace pour prendre des décisions de **désambiguïsation** concernant le sens des mots, la catégorie des mots, la structure syntaxique et portée sémantique

Défis du TAL (2/4)


- Ambiguïté : une phrase peut être interprétée de plusieurs façons
 - au niveau du sens des mot : avocat (métier ou fruit?)
 - au niveau du Part of speech: chair (noun or verb?)
 - Au niveau de la structure syntaxique: le livre de la fille sur la photo dans le sac



Défis du TAL (3/4)

❑ Métaphores : certains mots sont parfois utilisés de façon métaphorique

❑ Exemple :



The supernova swallowed the planet



■ on s'attend à ce que le mot swallow ait comme sujet une entité vivante

❑ Cette utilisation de mots rend une approche à base de règles prédéfinies très difficile

Défis du TAL (4/4)

- ❑ Variation dans le temps : l'utilisation des mots peut varier dans le temps
- ❑ Exemple : **sort of**
 - Utilisation originale: what sort of animal did you see
 - Utilisation plus moderne: he sort of understood what was going on
- ❑ Apparition de nouveaux mots: internet, wifi...

Pour résoudre ces problèmes...

- ❑ L'approche statistique permet de résoudre naturellement ces difficultés :
 - Généralement plus robuste que les méthodes précédentes basées sur des règles.
 - Les probabilités permettent de gérer notre **incertitude** sur l'interprétation (ambiguïté)
- ❑ Les attributs statistiques (de probabilité) pertinents sont appris à partir des données → nécessite normalement de nombreuses données sur un phénomène particulier.
- ❑ L'exploitation de données permet d'adapter automatiquement nos modèles (métaphore, variations dans le temps)
- ❑ Comment on reconnaît ?
 - on va définir des modèles probabilistes du langage
 - on va estimer, de façon automatisée, les paramètres du modèle probabiliste à partir des données :
 - $P(\text{« house »} \rightarrow \text{« maison »})$ élevée
 - $P(\text{« avocat général »} \rightarrow \text{« the general avocado »})$ faible

Approches du TAL

- ❑ Approche classique : Rule-based approach
 - Regular expression
 - Context-free grammars

- ❑ L'approche à base de corpus : Probabilistic modeling & Machine Learning
 - Attributs automatiquement extraits de volumes importants de données textuelles caractéristiques de la classe d'application envisagée
 - Classification à l'aide des classifieurs de la machine learning

- ❑ Approche par apprentissage profond : Deep learning approach

**Merci pour votre
attention**

Des questions ?

