

Université de Carthage
FSB - Dép. Info.

MPDS2



Artificial Intelligence

Natural Language Processing

Hela Mahersia
Hela.mahersia@fsb.rnu.tn



Textbooks



Objectifs du module

- ❑ Ce cours est conçu pour présenter aux étudiants, les concepts et les idées fondamentales du traitement du langage naturel (NLP) et pour les mettre au courant des recherches récentes dans le domaine.
- ❑ Il développe une compréhension approfondie des algorithmes disponibles pour le traitement de l'information textuelle.

Contacts

❑ Classroom :

- Natural Language Processing
- Code : [kjccecn](#)

❑ Emails :

- hela.mahersia@fsb.rnu.tn

chapitre 2:

Prétraitement de textes et matrice d'édition




Objectifs du chapitre

- ❑ Apprendre les techniques de prétraitement du texte.
- ❑ Comprendre l'importance de la tokenisation dans le TAL.
- ❑ Mettre en œuvre des algorithmes de tokenisation.
- ❑ Savoir différencier entre les processus de stemming et de lemmatization.
- ❑ Comprendre la notion de distance d'édition
- ❑ Savoir calculer la distance d'édition entre deux chaînes

Plan

- ❑ Notion de corpus
- ❑ Étapes de prétraitement du texte
 - Suppression du bruit
 - Normalization
 - Réduction au miniscule
 - Stemming/Lemmatization
 - Segmentation
- ❑ Erreur de prétraitement
- ❑ Distance d'édition
- ❑ Exemple de matrice d'édition

Applications principales du TAL : Rappel



Notion de corpus

- En TAL, les données texte sont organisées selon une structure typique :



Corpora



Corpus



Document



Token

Corpus (pluriel: corpora) en Latin signifie “corps”
en TAL : “Corps du texte”.

- Corpus :

- Ensemble de données textuelles
- « Collection de données langagières qui sont sélectionnées et organisées selon des critères linguistiques explicites pour servir d'échantillons dans une langue ». [Habert et al. 1998]

Exemples de corpus



exemples de corpus

BNC : British National Corpus

- 100 millions de mots anglais
- 10 % d'oral, des textes de fiction depuis 1960, des textes informatifs depuis 1975

Cobuild - Bank of English

- 200 millions de mots, oral et écrit
- à partir de 1980, à l'Université de Birmingham et Collins

Santa Barbara


- oral de l'anglais américain
- 75 \$, CD-ROM

Shakespeare 2000

- les pièces de Shakespeare en version XML

The Europarl Corpus

- proceedings du Parlement européen de 1996 à 2012.
- Lancé en 2001,
- couvre 11 langues officielles de l'union européenne



Quelle est l'information utile en TAL?

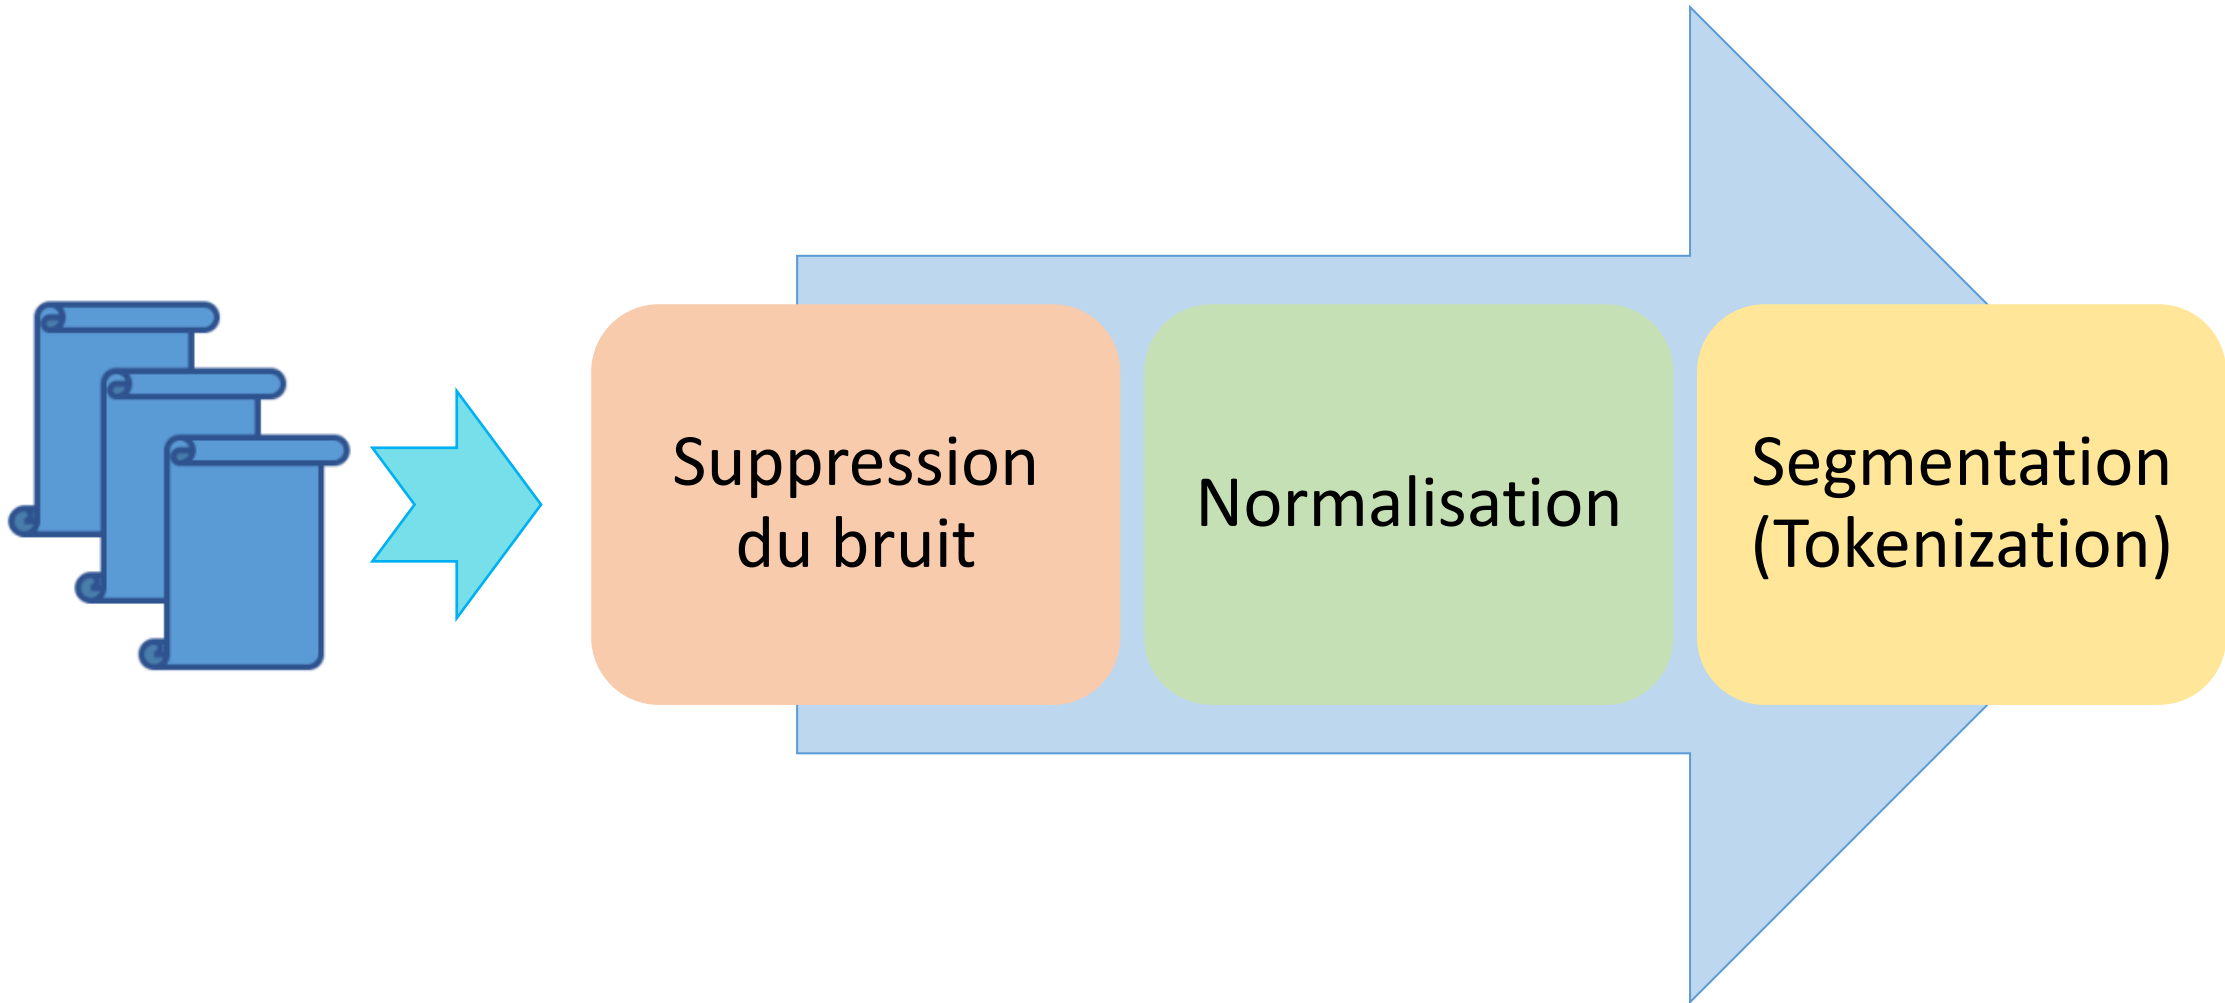
@Cl3 and @Hela are tuning a GREAT NLP model at <https://www.fsb.ucar.tn!!!>"

Beaucoup de bruit : informations inutiles !



Prétraitement : Cl3 Hela tune nlp model

Étapes de prétraitement du texte (1/9)



Étapes de prétraitement du texte (2/9)

Suppression du bruit


- ❑ La phase de suppression du bruit consiste à :
 - Supprimer les espaces multiples
 - Supprimer les Tags, HTML, ...
 - Convertir les caractères à accents
 - Supprimer les caractères spéciaux
 - Supprimer les “stop words”
- ❑ Quels sont les mots les plus fréquents dans un corpus?
 - Mots les plus fréquents dans le corpus anglais Europarl (24 mil. mots) :
 - Les mots fréquents forment des classes fermées = classes syntaxiques auxquelles on n’ajoute pas de mots → stop words
 - Généralement, les stop words ne contribuent pas au sens

Frequency	Type
1,698,599	the
849,256	of
793,731	to
640,257	and
508,560	in
407,638	that
400,467	is
394,778	a
263,040	I

Étapes de prétraitement du texte (3/9)

Normalisation

- ❑ Dans certaines applications, les variations morphologiques d'un même mot ne sont pas utiles
- ❑ Il est souhaitable donc de normaliser la forme prise par les mots afin d'éliminer ces variations inutiles :



Étapes de prétraitement du texte (4/9)

Normalisation

- ❑ Normalisation des majuscules
 - Us, us → us (si les deux sont pronoms)
 - us, US (pourrait être pronom ou pays)
- ❑ Nous pouvons utiliser des heuristiques :
 - Mettre au minuscule le début de la phrase
 - Mettre au minuscule les mots dans les titres
 - Laisser les mots à mi-phrase tels qu'ils sont
- ❑ Acronymes
 - Nous pouvons utiliser une phase de reconnaissance des entités nommées

Étapes de prétraitement du texte (5/9)

Normalisation

① Racinisation ou stemming

- ❑ Retirer les affixes d'un mot pour obtenir la forme la plus proche du radical/racine = stem
 - Généralement seuls les suffixes sont enlevés
 - Le token obtenu n'est pas forcément un mot

② Lemmatisation ou lemmatization

- ❑ Renvoie la forme de base ou du dictionnaire d'un mot = lemma
 - Contrairement à la racinisation, le token trouvé doit être un mot
 - C'est une tâche plus difficile que le stemming
 - La lemmatisation peut varier en fonction du contexte
 - found dans le sens trouver : found → find
 - found dans le sens fonder : found → found

Étapes de prétraitement du texte (6/9)

Normalisation

- ❑ Exemple de Stemmer : Le stemmer de Porter
 - correspond à une collection de règles, appliquées en différentes étapes et selon certaines priorités

Rule	Example
SSSES → SS	caresses → caress
IES → I	ponies → poni
SS → SS	caress → caress
S →	cats → cat

- ❑ Exemple de Lemmatizer : [WordNet Lemmatizer](#) : Utilise la base de données WordNet pour rechercher les lemmas

Mot	Stemming	Lemmatization
Information	Inform	Information
Computers	Comput	Computer
Leaves	Leav	Leaf

- ❑ Stemmer ou lemmatizer ? nous devons essayer les deux pour choisir la meilleure solution qui convient à notre tâche

Étapes de prétraitement du texte (7/9)

Segmentation

- Nous pouvons considérer le texte comme étant une séquence de :
Paragrapes, Phrases, Groupements nominaux et verbaux, Mots, Caractères
- Il semble naturel de penser à un texte comme une séquence de mots
- Comment trouver les limites des mots?
 - En anglais, nous pouvons diviser une phrase par des espaces ou une ponctuation
Input: Friends, Romans, Countrymen, lend me your ears;
Output: Friends Romans Countrymen lend me your ears
 - En allemand, il y a des mots composés écrits sans espaces :
 - «Rechtsschutzversicherungsgesellschaften» signifie sociétés d'assurance qui assurent la protection juridique !!
 - En japonais, il n'y a pas d'espaces du tout !!

Étapes de prétraitement du texte (8/9)

Segmentation

- Un premier prétraitement souvent utilisé consiste à couper chaque document en une liste d'occurrences : token
 - cette étape est appelée segmentation (tokenization)
 - chaque unité lexicale correspond normalement à un mot
- Même pour l'anglais ou le français, séparer les mots en fonction des espaces ne suffit pas :

This is Andrew's text, isn't it?

- On souhaite que Andrew soit séparé de 's, et que is soit séparé de not!
- On souhaite que chaque ponctuation soit traitée comme une unité lexicale («mot») séparée!

Étapes de prétraitement du texte (9/9)

Segmentation

- Parfois on veut qu'un token puisse être une collocation
 - Exemple : New York, rock 'n' roll
 - Parfois on peut vouloir convertir les clitiques dans leur forme originale
 - Exemple : j'aime : je et aime - he's : he et is
- Le choix des règles de segmentation varie d'une application à une autre

□ Exemple 1 de Segmentation : Tokenization par la ponctuation

- `nltk.tokenize.WordPunctTokenizer`

This is Andrew ' s text , isn ' t it ?

- Problème: « s », « isn », « t » ne sont pas très significatifs

□ Exemple 2 de Segmentation : Tokenization par ensemble de règles :

- `nltk.tokenize.TreebankWordTokenizer`

This is Andrew 's text , is n't it ?

Erreurs de prétraitement

❑ Faire attention aux prétraitements → mal classer un texte

- Suppression de la ponctuation
- Suppression des mots

Tweet: This is not good, because your attitude is not even close to being nice.

processed_tweet: [good, attitude, close, nice]

Tweet: My beloved grandmother :(

processed_tweet: [belov, grandmoth]

- Ordre des mots :

Tweet: I am happy because I did not go.



Tweet: I am not happy because I did go.



Correction d'erreurs typographiques

- ❑ Les textes avec lesquels on travaille peuvent parfois contenir des erreurs typographiques
 - particulièrement le cas avec du texte qui n'est pas écrit par un professionnel
 - la numérisation de livres peut aussi introduire des erreurs
- ❑ Pour pallier ces problèmes, une façon simple est, pour chaque mot, de :
 - vérifier si le mot se trouve dans un dictionnaire
 - si n'est pas présent, remplacer ce mot par le mot «le plus proche»
- ❑ La distance d'édition : outil permettant de trouver la ressemblance entre des mots

Distance d'édition

- ❑ La distance d'édition est une distance générale entre deux séquences de caractères
- ❑ Seulement 3 opérations d'édition sont autorisées : **mot M** → **mot P**
 - Insertion dans M d'un caractère de P : (i)
 - Substitution d'un caractère de M par un caractère différent de P (s)
 - Suppression d'un caractère de M (d)
- ❑ Exemple : **intension** → **exécution**
 - Si le coût de chaque opération vaut 1 : D=5
 - Si le coût de « Substitution » vaut 2 :
 - Distance d'édition = distance de Levenshtein
 - D=8

I	N	T	E	*	N	T	I	O	N
*	E	X	E	C	U	T	I	O	N
d	s	s			i	s			

Calcul de la distance d'édition (1/2)

- Calculer la matrice des distances dynamique :
 - On calcul $D(i,j)$ pour les petites valeurs de i et j (petites chaînes)
 - Calculer les grandes distances $D(i,j)$ en fonctions des distances calculées précédemment

Conditions initiales: $D(i,0) = i, \quad \forall i \quad 0 \leq i \leq m$
 $D(0,j) = j, \quad \forall j \quad 0 \leq j \leq n$

Relation de récurrence pour $i, j > 0$:

$$D(i,j) = \min \begin{cases} D(i-1,j) & +1 \\ D(i,j-1) & +1 \\ D(i-1,j-1) + \delta(i,j) \end{cases},$$

Où $\delta(i,j) = 0$ si $x_i = y_j$ et 1 sinon.

Calcul de la distance d'édition (2/2)

Distance de Levenshtein

- Initialization

$$D(i, 0) = i$$

$$D(0, j) = j$$

- Recurrence Relation:


For each $i = 1 \dots M$

For each $j = 1 \dots N$

$$D(i, j) = \min \begin{cases} D(i-1, j) + 1 \\ D(i, j-1) + 1 \\ D(i-1, j-1) + \begin{cases} 2; & \text{if } X(i) \neq Y(j) \\ 0; & \text{if } X(i) = Y(j) \end{cases} \end{cases}$$

- Termination:

$D(N, M)$ is distance




$$\delta = 2$$


Exemple de matrice d'édition : étape 1

Source	N	9									
	O	8									
	I	7									
	T	6									
	N	5									
	E	4									
	T	3									
	N	2									
	I	1									
	-	0	1	2	3	4	5	6	7	8	9
	-	E	X	E	C	U	T	I	O	N	
Target											

Exemple de matrice d'édition : étape 2

Source	N	9									
	O	8									
	I	7									
	T	6									
	N	5									
	E	4									
	T	3									
	N	2									
	I	1	2								
	-	0	1	2	3	4	5	6	7	8	9
	-	E	X	E	C	U	T	I	O	N	
Target											

$$D(i,j) = \min \begin{cases} D(i-1,j) + 1 \\ D(i,j-1) + 1 \\ D(i-1,j-1) + \begin{cases} 2; & \text{if } X(i) \neq Y(j) \\ 0; & \text{if } X(i) = Y(j) \end{cases} \end{cases}$$



Exemple de matrice d'édition : étape 3

Source	N	9	8	9	10	11	12	11	10	9	8
	O	8	7	8	9	10	11	10	9	8	9
	I	7	6	7	8	9	10	9	8	9	10
	T	6	5	6	7	8	9	8	9	10	11
	N	5	4	5	6	7	8	9	10	11	10
	E	4	3	4	5	6	7	8	9	10	9
	T	3	4	5	6	7	8	7	8	9	8
	N	2	3	4	5	6	7	8	7	8	7
	I	1	2	3	4	5	6	7	6	7	8
	-	0	1	2	3	4	5	6	7	8	9
Target											
	-	E	X	E	C	U	T	I	O	N	

pseudocode

function MIN-EDIT-DISTANCE(*target*, *source*) **returns** *min-distance*

$n \leftarrow \text{LENGTH}(\textit{target})$

$m \leftarrow \text{LENGTH}(\textit{source})$

Create a distance matrix $\textit{distance}[n+1, m+1]$

Initialize the zeroth row and column to be the distance from the empty string

$\textit{distance}[0,0] = 0$

for each column i **from** 1 **to** n **do**

$\textit{distance}[i,0] \leftarrow \textit{distance}[i-1,0] + \textit{ins-cost}(\textit{target}[i])$

for each row j **from** 1 **to** m **do**

$\textit{distance}[0,j] \leftarrow \textit{distance}[0,j-1] + \textit{del-cost}(\textit{source}[j])$

for each column i **from** 1 **to** n **do**


for each row j **from** 1 **to** m **do**

$\textit{distance}[i,j] \leftarrow \text{MIN}(\textit{distance}[i-1,j] + \textit{ins-cost}(\textit{target}[i]),$
 $\textit{distance}[i-1,j-1] + \textit{sub-cost}(\textit{source}[j], \textit{target}[i]),$
 $\textit{distance}[i,j-1] + \textit{del-cost}(\textit{source}[j]))$

return $\textit{distance}[n,m]$

Matrice d'édition avec Alignement (1/2)

- ❑ En plus de la distance d'édition, on s'intéresse parfois à la série d'opérations minimales associée
- ❑ Cette information est souvent représentée sous la forme d'un alignement entre les deux chaînes
- ❑ Au cours du remplissage de la matrice d'édition, on peut garder des pointeurs :
 - Vers la case « minimisante »
 - Une fois le calcul des distances terminé, on suit les pointeurs en reculant de la case $D(n,m)$ vers $D(0,0)$ → alignement optimal
- ❑ Une case peut contenir plusieurs pointeurs → plusieurs alignements optimaux possibles



Matrice d'édition avec Alignement (2/2)

- Base conditions:

$$D(i, 0) = i$$

$$D(0, j) = j$$

Termination:

$D(N, M)$ is distance

- Recurrence Relation:

For each $i = 1 \dots M$

For each $j = 1 \dots N$

$$D(i, j) = \min \begin{cases} D(i-1, j) + 1 & \text{deletion} \\ D(i, j-1) + 1 & \text{insertion} \\ D(i-1, j-1) + \begin{cases} 2; & \text{if } X(i) \neq Y(j) \\ 0; & \text{if } X(i) = Y(j) \end{cases} & \text{substitution} \end{cases}$$
$$\text{ptr}(i, j) = \begin{cases} \text{LEFT} & \text{insertion} \\ \text{DOWN} & \text{deletion} \\ \text{DIAG} & \text{substitution} \end{cases}$$

Exemple de matrice d'édition avec alignement

n	9	↓ 8	↙←↓ 9	↙←↓ 10	↙←↓ 11	↙←↓ 12	↓ 11	↓ 10	↓ 9	↙ 8	
o	8	↓ 7	↙←↓ 8	↙←↓ 9	↙←↓ 10	↙←↓ 11	↓ 10	↓ 9	↙ 8	← 9	
i	7	↓ 6	↙←↓ 7	↙←↓ 8	↙←↓ 9	↙←↓ 10	↓ 9	↙ 8	← 9	← 10	
t	6	↓ 5	↙←↓ 6	↙←↓ 7	↙←↓ 8	↙←↓ 9	↙ 8	← 9	← 10	←↓ 11	
n	5	↓ 4	↙←↓ 5	↙←↓ 6	↙←↓ 7	↙←↓ 8	↙←↓ 9	↙←↓ 10	↙←↓ 11	↙↓ 10	
e	4	↙ 3	← 4	↙← 5	← 6	← 7	←↓ 8	↙←↓ 9	↙←↓ 10	↓ 9	
t	3	↙←↓ 4	↙←↓ 5	↙←↓ 6	↙←↓ 7	↙←↓ 8	↙ 7	←↓ 8	↙←↓ 9	↓ 8	
n	2	↙←↓ 3	↙←↓ 4	↙←↓ 5	↙←↓ 6	↙←↓ 7	↙←↓ 8	↓ 7	↙←↓ 8	↙ 7	
i	1	↙←↓ 2	↙←↓ 3	↙←↓ 4	↙←↓ 5	↙←↓ 6	↙←↓ 7	↙ 6	← 7	← 8	
#	0	1	2	3	4	5	6	7	8	9	
	#	e	x	e	c	u	t	i	o	n	

**Merci pour votre
attention**

Des questions ?

