

Université de Carthage
FSB - Dép. Info.

MPDS2



Artificial Intelligence

Natural Language Processing

Hela Mahersia
Hela.mahersia@fsb.rnu.tn



Textbooks



Objectifs du module

- ❑ Ce cours est conçu pour présenter aux étudiants, les concepts et les idées fondamentales du traitement du langage naturel (NLP) et pour les mettre au courant des recherches récentes dans le domaine.
- ❑ Il développe une compréhension approfondie des algorithmes disponibles pour le traitement de l'information textuelle.

Contacts

❑ Classroom :

- Natural Language Processing
- Code : [kjccecn](#)

❑ Emails :

- hela.mahersia@fsb.rnu.tn

chapitre 3:

Modélisation du Langage



Objectifs du chapitre

- ❑ Introduire le concept de modélisation du langage.
- ❑ Explorer les modèles de langage statistiques.
- ❑ Comprendre les techniques de lissage pour les modèles de langage.
- ❑ Savoir calculer la perplexité pour évaluer le modèle de langage

Plan

- ❑ Notion de corpus
- ❑ Exemple de corpus
- ❑ Propriétés des données textuelles
- ❑ Modèle statistique du langage
- ❑ Obtention du modèle n-gram
- ❑ Techniques de lissage
- ❑ Évaluation du modèle de langage

Notion de corpus

- En TAL, les données texte sont organisées selon une structure typique :



Corpora



Corpus



Document



Token

Corpus (pluriel: corpora) en Latin signifie “corps”
en TAL : “Corps du texte”.

- **Corpus :**

- Ensemble de données textuelles
- « Collection de données langagières qui sont sélectionnées et organisées selon des critères linguistiques explicites pour servir d'échantillons dans une langue ». [Habert et al. 1998]

Propriétés des données textuelles (1/5)

- ❑ Mots les plus fréquents dans le corpus [anglais Europarl](#) (sur 24 millions de mots (tokens))

- ❑ Quels sont les mots les plus fréquents dans un corpus?

- Les mots fréquents forment des classes fermées = classes syntaxiques auxquelles on n'ajoute pas de mots

- déterminants (un, le, son, etc.)
- pronoms (je, tu, il, etc.)
- conjonctions (mais, ou et, donc, etc.)
- prépositions (pour, de, etc.)

any word	
Frequency	Type
1,698,599	the
849,256	of
793,731	to
640,257	and
508,560	in
407,638	that
400,467	is
394,778	a
263,040	I

nouns	
Frequency	Type
124,598	European
104,325	Mr
92,195	Commission
66,781	President
62,867	Parliament
57,804	Union
53,683	report
53,547	Council
45,842	States

Propriétés des données textuelles (2/5)

- Mais aussi, sur 93 638 de mots distincts, **36 231** n'apparaissent qu'une seule fois.

Exemples:

- cornflakes, mathematicians, fuzziness, UNCITRAL, H-0695, ...

- Fréquences des mots → **Un vrai problème en TAL :**

- Peu de mots fréquents
- Beaucoup de mots rares



- pour plusieurs mots , on n'a pas beaucoup d'observations
- Il est difficile de caractériser des mots qui n'existent presque pas dans le corpus

any word	
Frequency	Type
1,698,599	the
849,256	of
793,731	to
640,257	and
508,560	in
407,638	that
400,467	is
394,778	a
263,040	I

Propriétés des données textuelles (3/5)





Traçage de la fréquence des mots

- Classez les mots par fréquence.
- Attribuer des rangs aux mots classés



Propriétés des données textuelles (4/5)

Traçage de la fréquence des mots



Propriétés des données textuelles (5/5)

- Comment peut-on interpréter les courbes obtenues pour différentes langues?

Loi de Zipf : $f \times r \approx k$

- f = fréquence d'un mot
- r = rang d'un mot (si trié par fréquence)
- k = une constante

- La loi de Zipf est une observation empirique concernant la fréquence des mots dans un texte : la fréquence f du mot est inversement proportionnelle à son rang r (approximativement)

- Pourquoi l'allure d'une ligne en échelle logarithmique?

$$fr = k \Rightarrow f = \frac{k}{r} \Rightarrow \log f = \log k - \log r$$

Interprétations des propriétés du texte

- ❑ Quelle que soit la taille du corpus, il y aura beaucoup d'informations peu fréquentes (et même à fréquence nulle !) → Cela signifie que nous devons trouver des moyens intelligents d'estimer les fréquences des mots rarement ou jamais vu pendant l'entraînement.
- ❑ Toutefois, se baser uniquement sur la fréquence des mots comme attributs textuels peut ne pas fonctionner correctement.
- ❑ Pour avoir une caractérisation pertinente des données textuelles, en profitant en même temps de la notion de fréquences des mots, nous allons considérer la probabilité des phrases :
- ❑ “Probabilité d’une phrase” = estime la probabilité avec laquelle cette phrase se produit en langage naturel

Modèle statistique du langage

- Un modèle de langage est une distribution de probabilités sur des séquences de mots : $P(w_1, w_2, \dots, w_n)$ Où w_i sont les mots de la séquence
- But :
 - Associer une probabilité à toute suite de mots : souvent on commence par décomposer la probabilité jointe en un produit de probabilités conditionnelles
 - Connaissant la probabilité d'une phrase, on peut alors estimer **le mot suivant le plus probable**

□ Pour estimer $P(S = w_1 \dots w_n)$:

$$P(w_1, \dots, w_n) = \prod_{i=1}^n P(w_i | w_1, w_2, \dots, w_{i-1})$$

□ Rappel :

- probabilité conditionnelle $P(A, B) = P(A/B) \times P(B)$
- Avec plus de variable : $P(A, B, C, D) = P(A) \times P(B/A) \times P(C/A, B) \times P(D/A, B, C)$

Modèle statistique du langage

- ❑ En utilisant les probabilités conditionnelles, il est très difficile de connaître la véritable probabilité d'une séquence arbitraire de mots.



$$P(\text{"une suite de cinq mots"}) =$$

$$\begin{aligned} &P(\text{"une"}) \times \\ &P(\text{"suite"} \mid \text{"une"}) \times \\ &P(\text{"de"} \mid \text{"une suite"}) \times \\ &P(\text{"cinq"} \mid \text{"une suite de"}) \times \\ &P(\text{"mots"} \mid \text{"une suite de cinq"}) \end{aligned}$$

$$P(w_1 w_2 \dots w_n) = \prod_i P(w_i \mid w_1 w_2 \dots w_{i-1})$$

Ces probabilités sont :

- Difficile à estimer
- Difficile à stocker

- ❑ Toutefois, nous pouvons définir un modèle de langage qui nous donnera de bonnes approximations.
- ❑ Le modèle de langage le plus utilisé en TAL : le modèle N-gram.

Obtention du model N-gram



- Hypothèse de Markov : On fait l'hypothèse que chaque mot ne dépend que d'un nombre fixe de mots qui le précèdent

- Cas trigramme (3-gram)

- $n = 3$: un mot dépend uniquement des 2 mots qui le précèdent

$$P(w_i | w_1, w_2, \dots, w_{i-1}) \approx P(w_i | w_{i-2}, w_{i-1})$$

- Cas bigramme (2-gram)

- $n = 2$: un mot dépend uniquement du mot qui le précède

$$P(w_i | w_1, w_2, \dots, w_{i-1}) \approx P(w_i | w_{i-1})$$

- Cas unigramme (1-gram)

- $n = 1$: un mot ne dépend d'aucun mot qui le précède

$$P(w_i | w_1, w_2, \dots, w_{i-1}) \approx P(w_i)$$

Début/fin d'une séquence

- Considérons les deux séquences :

	w_1	w_2	w_3	w_4
(1)	he	saw	the	yellow
(2)	feeds	the	cats	daily

- Pour capturer le comportement au début/fin des séquences, nous pouvons augmenter les données en insérant des balises :

	w_{-1}	w_0	w_1	w_2	w_3	w_4	w_5
(1)	<s>	<s>	he	saw	the	yellow	</s>
(2)	<s>	<s>	feeds	the	cats	daily	</s>

- Ainsi, on peut appliquer aisément le modèle trigramme :

$$P(w) = \prod_{i=1}^{n+1} P(w_i | w_{i-2}, w_{i-1})$$

Cas de n-gram rares

- ❑ Une suite de mots qui n'a pas été rencontrée dans le corpus, peut tout de même exister dans la langue → la probabilité serait 0
 - ❑ Le corpus est seulement un échantillon de la langue, pas de sa totalité
 - ❑ Le corpus peut être spécifique à un domaine et donc il n'est pas nécessairement corrélé avec l'application ciblée
- ces cas engendrent des problèmes lors de la phase de test car une séquence ayant des termes n-grams qui n'existent pas dans le corpus d'apprentissage n'a aucune chance d'être reconnue
- Les techniques de lissage tentent de compenser cette carence : une sorte de généralisation qui permet d'attribuer une probabilité non nulle à un événement **non vu** dans le corpus d'apprentissage.

Techniques de lissage (smoothing)

- ❑ But : attribuer une faible probabilité aux mots ou n-grams non observés dans le corpus d'apprentissage
- ❑ Techniques existantes :
 - Lissage “intuitif”
 - Lissage par simple interpolation
 - Lissage par des technique développées :
 - Jelinek-Mercer
 - Good-Turing
 - Katz
 - Absolute Discounting
 - Interpolated Absolute Discount
 - Kneser-Ney
 - Kneser-Ney Modified

Techniques de lissage “intuitives”

- Lissage de Laplace : Ajouter 1 à tous les n-grams :

(Laplace or Add-one smoothing)

Pretend we saw each word one more time than we did

$$P(w_i \mid w_{i-2} w_{i-1}) = \frac{N(w_{i-2} w_{i-1} w_i) + 1}{N(w_{i-2} w_{i-1}) + V}$$

Nombre de mots
distincts



- Ajouter δ à tous les n-grams :

(Add- δ smoothing)

$$P(w_i \mid w_{i-2} w_{i-1}) = \frac{N(w_{i-2} w_{i-1} w_i) + \delta}{N(w_{i-2} w_{i-1}) + V\delta}$$

Nombre de mots
distincts

Technique de lissage par simple interpolation

- Interpolation linéaire entre Tri-gramme, Bi-gramme et Uni-gramme

$$P(z \mid xy) = \lambda \frac{N(xyz)}{N(xy)} + \mu \frac{N(yz)}{N(y)} + (1 - \lambda - \mu) \frac{N(z)}{N(.)}$$

- Les coefficients d'interpolation seront en général calculés en prenant des échantillons connus du corpus d'apprentissage

Techniques développées : Good-Turing (1/2)

- Notation : soit N_c = Nombre de n-grammes qu'on a vu c fois
(Fréquence de la fréquence c)
- Exemple : Sam I am I am sam I do not eat

I	3		
am	2		
do	1		
not	1		
eat	1		

Unigrammes



$N_1 = 3$
$N_2 = 2$
$N_3 = 1$

Techniques développées : Good-Turing (2/2)

Selon Good-Turing, la probabilité d'observer **n'importe quel** mot jamais vu dans le corpus d'entraînement sera

$$P_{GT}^*(\text{things with frequency zero in training}) = \frac{N_1}{N_0 N}$$

On peut généraliser cette règle à n'importe quel mot de fréquence c

▸ la fréquence ajustée c^* est alors

$$c^* = (c + 1) \frac{N_{c+1}}{N_c}$$

$$p_{GT}(x : c) = \frac{c^*}{N}$$

Evaluation du choix du modèle n-gram

□ Comment savoir si un modèle de langage est meilleur qu'un autre ?

■ On calcule la Perplexité

■ Soit un corpus de test $W = w_1, w_2, \dots, w_n$

$$PP(W) = \sqrt[n]{\prod_{i=1}^n \frac{1}{P(w_i | w_{1\dots i-1})}}$$

□ Le modèle de langage qui a la plus petite perplexité sur un même corpus de test est le meilleur

□ Exemple : Training 38 million words, test 1.5 million words, WSJ

N-gram Order	Unigram	Bigram	Trigram
Perplexity	962	170	109

Lower perplexity = better model

Exercice

- ❑ Soit le corpus d'apprentissage suivant :
« he is he is he is going abroad is going to study in the field »

- ❑ Calculer $P(\text{is going abroad to study})$ avec :
 - Le modèle bi-grams sans lissage ?
 - Le modèle bi-grams avec lissage de Laplace?
 - Le modèle bi-grams avec lissage de Good Turing?

**Merci pour votre
attention**

Des questions ?

