

Université de Carthage
FSB - Dép. Info.

MPDS2



Artificial Intelligence

Natural Language Processing

Hela Mahersia
Hela.mahersia@fsb.rnu.tn



Textbooks



Objectifs du module

- ❑ Ce cours est conçu pour présenter aux étudiants, les concepts et les idées fondamentales du traitement du langage naturel (NLP) et pour les mettre au courant des recherches récentes dans le domaine.
- ❑ Il développe une compréhension approfondie des algorithmes disponibles pour le traitement de l'information textuelle.

Contacts

❑ Classroom :

- Natural Language Processing
- Code : [kjccecn](#)

❑ Emails :

- hela.mahersia@fsb.rnu.tn

chapitre 4:

Vectorisation et indexation des attributs textuels



Objectifs du chapitre



- ❑ Introduire le concept de Sac de mots : Bag of words
- ❑ Explorer le modèle BOW.
- ❑ Savoir calculer le TF-IDF pour filtrer les n-grams ou indexer un document

Plan

- ❑ Modèle bag of words
- ❑ Modèle bag of words amélioré
- ❑ Filtrage par TF-IDF

Bag of words (BOW) (1/3)

- ❑ Le modèle bag-of-words permet d'extraire des attributs numériques à partir des données textuelles.
- ❑ BOW est une approche largement utilisée en :
 - Recherche d'informations
 - Classifications de documents
- ❑ Le processus comporte les étapes suivantes:



Bag of words (BOW) (2/3)

Vectorisation du texte :

- La façon la plus simple pour avoir une représentation numérique du texte est de compter les occurrences des tokens particuliers dans le texte

Exemple d'application : chercher des mots-marqueurs comme « excellent » ou « décevant » pour l'étude des sentiments dans les tweets




	good	movie	not	a	did	like
good movie	1	1	0	0	0	0
not a good movie	1	1	1	1	0	0
did not like	0	0	1	0	1	1

Bag of words (BOW) (3/3)

❑ Problèmes liés à la représentation BOW :

- nous perdons l'ordre de mot,
- les compteurs ne sont pas normalisés
- Problème de sparsity : beaucoup de zéros

I am happy because I am learning NLP



Plus V devient grand, plus le vecteur devient encore plus « sparse » : → Temps d'apprentissage et de test devient très grand

- ## ❑ Autre solution : prendre un morceau de texte et de compter la fréquence des mots dans ce texte.

Un modèle BOW plus adapté

- ❑ Solution encore meilleure : compter les n-grammes
 - 1-gramme pour les tokens
 - 2-grammes pour les paires de tokens
 - 3-grammes pour les triplets de tokens

good movie		good movie	movie	did not	a	...
not a good movie	→	1	1	0	0	...
did not like		1	1	0	1	...
		0	0	1	0	...

- ❑ Problèmes : Nombre énorme d'attributs !!

Suppression de qq n-grammes

- ❑ Solution: supprimer certains n-grammes en se basant sur leurs fréquences d'apparition dans les documents de notre corpus
- ❑ N-grammes de haute fréquence:
 - Articles, prépositions, etc. (exemple : et, a, le)
 - Ils sont appelés **stop-words**, ils n'aideront pas à discriminer les textes → les supprimer
- ❑ N-grammes de basse fréquence :
 - Typos, n-grammes rares
 - Nous n'en avons pas besoin non plus, sinon nous allons probablement avoir un sur-apprentissage
- ❑ N-grammes de Fréquence moyenne :
 - Ce sont de bons n-grammes

Filtrage des n-grams par tf-idf

- Il est utile d'examiner la fréquence n-gramme dans un corpus pour filtrer les mauvais n-grammes
- Idée : les n-grammes avec des fréquences plus petites peuvent être plus discriminants parce qu'ils concernent des termes spécifiques dans le corpus
- Utiliser TF-IDF pour ce filtrage :
 - Produit de deux termes : $\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$
 - Un poids élevé du TF-IDF est atteint par un terme à fréquence élevée (dans le document donné) et une faible fréquence de document dans l'ensemble corpus

Calcul du terme tf-idf

□ TF/IDF : Term Frequency/Inverse Document Frequency

- TF : plus un terme t est fréquent dans un document d plus il est important dans la description de ce document
- IDF : (Inverse Document Frequency) la fréquence du terme dans la collection

Exemple de tf :

$$tf = \begin{cases} freq(t,d) \\ 1 + \log(freq(t,d)) \\ \frac{freq(t,d)}{\max_{t' \in d} (t',d)} \\ \frac{freq(t,d)}{\sum_{t' \in d} freq(t',d)} \end{cases}$$

Exemple de idf :

$$idf(t) = \begin{cases} \log\left(\frac{N}{n_t}\right) \\ \log\left(\frac{N - n_t}{n_t}\right) \end{cases}$$

avec

N : le nombre de documents de la collection,

n_t : le nombre de documents contenant le terme t

Exercice 1

- ❑ Soit un corpus contenant 3 documents :

Corpus (tiré d'œuvres de [Friedrich Gottlieb Klopstock](#))

Document 1	Document 2	Document 3
Son nom est célébré par le bocage qui frémit, et par le ruisseau qui murmure, les vents l'emportent jusqu'à l'arc céleste, l'arc de grâce et de consolation que sa main tendit dans les nuages.	À peine distinguait-on deux butes à l'extrémité de la carrière : des chênes ombrageaient l'un, autour de l'autre des palmiers se dessinaient dans l'éclat du soir.	Ah ! le beau temps de mes travaux poétiques ! les beaux jours que j'ai passés près de toi ! Les premiers, inépuisables de joie, de paix et de liberté ; les derniers, empreints d'une mélancolie qui eut bien aussi ses charmes.

- ❑ L'exemple porte sur le document 1 et le terme analysé est « **qui** » La ponctuation et l'apostrophe sont ignorées.

Solution de l'exercice 1

✿ Calcul de TF :

$$tf_{1,1} = \frac{n_{1,1}}{\sum_k n_{k,1}} = \frac{2}{38}$$

✿ Calcul de IDF :

$$idf_1 = \log \frac{|D|}{|\{d_j : t_1 \in d_j\}|} = \log \frac{3}{2}$$

✿ Poids final

$$tfidf_{1,1} = \frac{2}{38} \cdot \log \frac{3}{2} \approx 0,0092$$

Pour les autres documents :

$$tfidf_{1,2} = 0 \cdot \log \frac{3}{2} = 0$$

$$tfidf_{1,3} = \frac{1}{40} \cdot \log \frac{3}{2} \approx 0,0044$$

Le premier document apparaît ainsi comme
« le plus pertinent »

Améliorer BOW

- ❑ Remplacer les compteurs par TF-IDF
- ❑ Normaliser le résultat par ligne

good movie		good movie	movie	did not	...
not a good movie		0.17	0.17	0	...
did not like		0.17	0.17	0	...
		0	0	0.47	...

**Merci pour votre
attention**

Des questions ?

