

TP2 : Préparation de données

Pour le traitement du langage naturel et le nettoyage de texte, il est nous allons utiliser les bibliothèques **NLTK** et **re** en Python.

NLTK (Natural Language Toolkit) est une bibliothèque Python dédiée au traitement du langage naturel. Elle fournit des outils et des ressources pour le traitement de texte, incluant la tokenisation, le stemming, la lemmatisation, et la gestion des mots vides. Les fonctionnalités spécifiques utilisées dans le TP sont :

1. **Tokenisation** : Divise une chaîne de texte en une liste de mots.

Syntaxe : `word_tokenize(text)`

2. **Gestion des mots vides (Stop Words)** : Crée un ensemble de mots vides pour la langue spécifiée (par exemple, anglais).

Syntaxe : `stopwords.words('language')`

3. **Stemming** : Réduit un mot à sa racine en utilisant l'algorithme de Porter Stemmer.

Syntaxe : `PorterStemmer().stem(word)`

4. **Lemmatisation** : Réduit un mot à sa forme de base en utilisant WordNet. Le paramètre `pos` spécifie la partie du discours.

Syntaxe : `WordNetLemmatizer().lemmatize(word, pos='pos_tag')`

re (Expressions Régulières) permet de travailler avec les expressions régulières pour effectuer des recherches, des substitutions, des divisions, et plus encore dans les chaînes de caractères. Les fonctionnalités spécifiques utilisées dans le TP sont :

1. **Recherche et Correspondance** : Trouve la première occurrence d'un motif dans une chaîne de texte.

Syntaxe : `re.search(pattern, text)`

2. **Substitution** : Remplace toutes les occurrences d'un motif dans une chaîne par une chaîne de remplacement.

Syntaxe : `re.sub(pattern, remplacement, text)`

3. **Division** : Divise une chaîne de texte en utilisant un motif comme délimiteur.

Syntaxe : `re.split(pattern, text)`

4. **Extraction** : Trouve toutes les occurrences d'un motif dans une chaîne et les retourne sous forme de liste.

Syntaxe : `re.findall(pattern, text)`

Travail demandé

- 1) Charger la base des données « spam » dans un DataFrame. Afficher ses dimensions et les 10 premières lignes.
- 2) Supprimer toutes les lignes avec une valeur manquante et vérifier les dimensions du DataFrame.
- 3) Supprimer les duplications des lignes en gardant la première occurrence.
- 4) Visualiser la répartition des classes sous forme de diagramme à barres. Les annotations doivent être ajoutées au-dessus de chaque barre pour indiquer le nombre d'apparitions de chaque classe.
- 5) Supprimer les espaces multiples dans le texte.
- 6) Supprimer des tags HTML.
- 7) Convertir les caractères accentués s'ils existent.
- 8) Supprimer les ponctuations et les caractères spéciaux.
- 9) Supprimer les mots vides (stop words).
- 10) Convertir toutes les lettres en minuscule.
- 11) Réduire chaque mot à sa racine.
- 12) Pour chaque mot restant, calculer le nombre d'occurrences de ce mot. Ensuite, afficher chaque mot accompagné de son nombre d'occurrences ainsi que de sa probabilité d'apparition (calculée comme le rapport entre le nombre d'occurrences du mot et le nombre total de mots).