

TP3 : Correction d'erreurs typographiques

La bibliothèque Levenshtein est une bibliothèque Python optimisée qui permet de calculer efficacement la distance d'édition et la distance de Levenshtein, une mesure de similarité entre deux chaînes de caractères. Les opérations possibles sont l'insertion, la suppression et la substitution de caractères.

Dans ce TP nous allons utiliser la fonction « distance » de la bibliothèque Levenshtein pour corriger les mots mal orthographiés en les remplaçant par les mots les plus proches du vocabulaire extrait, sur la base de cette distance.

Exemple :

```
distance_edition = Levenshtein.distance("intention", "execution", weights=(1,1,1))  
print(distance) # Résultat : 5
```

```
distance_Levenshtein = Levenshtein.distance("intention", "execution", weights=(1,1,2))  
print(distance) # Résultat : 8
```

- 1) Charger le fichier CSV et extraire uniquement la colonne "Message".
- 2) Extraire les mots uniques à partir de toutes les phrases du dataset en les tokenisant.
- 3) Créer une fonction correction (sentence, vocabulary) qui prend en entrée une phrase et un vocabulaire extrait :
 - Tokeniser la phrase.
 - Pour chaque mot erroné, la fonction doit utiliser la distance d'édition puis la distance de Levenshtein pour :
 - Calculer la distance entre le mot et tous les mots du vocabulaire et l'afficher
 - Remplacer le mot par celui ayant la plus petite distance.
- 4) Tester le programme en corrigeant des phrases contenant des erreurs d'orthographe.
Par exemple :
 - "where are you? how arrrrre you performed?"
 - "Call me ounce youu freee."
- 5) Reprendre le même traitement en implémentant le code de chaque distance utilisée.