

TP4 : Fréquences et modèle statistique du langage

- 1) Reprendre le code de prétraitement de la base de données « spam » (TP2).
- 2) Afficher les 10 mots les plus fréquents avec leurs fréquences d'apparition.
- 3) Dessiner la courbe de distribution des fréquences des 10 mots les plus fréquents.
- 4) Réaliser le même traitement en utilisant nltk.FreqDist.
- 5) Présenter la distribution des fréquences des 10 unigrammes les plus fréquents à l'aide d'un barplot.
- 6) Utiliser la fonction FreqDist de nltk pour:
 - Générer des paires de mots consécutifs (bigrammes) et présenter la distribution des fréquences des 10 bigrammes les plus fréquents à l'aide d'un barplot.
 - Générer des triplets de mots consécutifs (trigrammes) et présenter la distribution des fréquences des 10 trigrammes les plus fréquents à l'aide d'un barplot.