

TP5 : TF IDF

- 1) Charger la base de données spam.csv.
- 2) Effectuer un prétraitement de base dans la colonne Message :
 - Convertir les lettres en minuscules.
 - Supprimer les caractères non alphabétiques en gardant que les lettres et les espaces.
- 3) Créer une fonction TF qui calcule le TF (Term Frequency) d'un terme dans un document : Le TF est calculé comme le nombre de fois qu'un terme apparaît dans un document, divisé par le nombre total de termes dans ce document.
- 4) Créer une fonction IDF qui calcule L'IDF (Inverse Document Frequency) comme le logarithme du nombre total de documents divisé par le nombre de documents contenant le terme.
- 5) Créer une fonction TF-IDF en utilisant les deux fonctions précédentes.
- 6) Afficher le TF, IDF, et TF-IDF des 10 premiers mots.
- 7) Refaire le même traitement en utilisant les fonctions prédéfinies :
CountVectorizer et TfidfVectorizer de sklearn.feature_extraction.text
Comparer le resultats.